

Control Informacional

Proyecto de Investigación II — ProInt_II

Alejandro Cruz López

Universidad Autónoma Metropolitana
Unidad Iztapalapa

Asesores

Dr. Asael Fabián Martínez Martínez
Dr. Joaquín Delgado Fernández 26 de mayo de 2026

Índice

1. Mapa de trabajo	2
2. Sección A – Probabilidad y simplex	2
3. Sección B – Correcciones locales y cambio de medida	3
4. Sección C – Operadores globales multiplicativos y composición	4
5. Sección D – Divergencia KL, métrica de Fisher y dinámica inducida	5
6. Sección E – Semántica bayesiana	7
6.1. Modelos continuos como estados informacionales discretos	12
6.2. Trayectorias Bayesianas	21
7. Sección F — Semántica markoviana	33
8. Sección G – Control Óptimo Informacional y Defecto de Ordenamiento	46

1. Mapa de trabajo

Este archivo es un borrador de trabajo para avanzar por capas. La ruta lógica es:

- Sección A: espacio de probabilidad, particiones finitas y símplex.
- Sección B: correcciones locales y cambio de medida discreto.
- Sección C: operadores globales multiplicativos y composición.
- Sección D: divergencia KL, métrica de Fisher y dinámica inducida.
- Sección E0: semántica bayesiana como caso particular del operador global.

Las proposiciones que realmente sostienen la transición hacia la semántica bayesiana son:

Prop. 2.1, Prop. 3.1, Prop. 3.2, Prop. 3.3,
Prop. 4.1, Prop. 4.2, Prop. 5.1, Prop. 5.2, Teo. 5.1.

2. Sección A – Probabilidad y símplex

Este bloque fija el dominio probabilístico discreto. El punto de partida es un espacio de probabilidad en el sentido de Kolmogórov [Kolmogorov, 1933]. A partir de una partición medible finita se asocia a la medida un vector de probabilidades, que se interpreta como estado informacional discreto.

Definición 2.1 (Espacio de probabilidad). *Un espacio de probabilidad es una terna $(\Omega, \mathcal{F}, P)$ tal que:*

1. Ω es un conjunto no vacío;
2. $\mathcal{F}$ es una σ -álgebra de subconjuntos de Ω ;
3. $P : \mathcal{F} \rightarrow [0, 1]$ es una medida con $P(\Omega) = 1$.

Definición 2.2 (Partición medible finita). *Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad. Una partición medible finita de Ω es una familia finita*

$$\Pi = \{E_1, \dots, E_n\} \subset \mathcal{F}, \quad n \geq 1,$$

tal que:

1. $E_i \cap E_j = \emptyset$ si $i \neq j$;
2. $\bigcup_{i=1}^n E_i = \Omega$.

Diremos que Π es no degenerada si además

$$P(E_i) > 0, \quad i = 1, \dots, n.$$

Definición 2.3 (Símplex de probabilidad e interior). Para $n \geq 1$ se define el símplex de probabilidad por

$$\Delta_n := \left\{ x \in \mathbb{R}^n : x_i \geq 0, \sum_{i=1}^n x_i = 1 \right\}.$$

Su interior relativo viene dado por

$$\Delta_n^\circ := \{ x \in \Delta_n : x_i > 0 \text{ para todo } i \}.$$

Definición 2.4 (Estado informacional discreto). Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sea $\Pi = \{E_1, \dots, E_n\}$ una partición medible finita. El estado informacional discreto asociado a Π es el vector

$$X = (X_1, \dots, X_n) \in \mathbb{R}^n, \quad X_i := P(E_i), \quad i = 1, \dots, n.$$

Proposición 2.1. Sea X el estado informacional discreto asociado a una partición medible finita $\Pi = \{E_1, \dots, E_n\}$. Entonces:

1. $X \in \Delta_n$;
2. si Π es no degenerada, entonces $X \in \Delta_n^\circ$.

Definición 2.5 (Operador de cierre). Sea

$$\mathbb{R}_{>0}^n := \{ z = (z_1, \dots, z_n) \in \mathbb{R}^n : z_i > 0 \text{ para todo } i \}.$$

El operador de cierre es la aplicación

$$\mathcal{C} : \mathbb{R}_{>0}^n \rightarrow \Delta_n^\circ, \quad \mathcal{C}(z) := \frac{1}{\sum_{i=1}^n z_i} z.$$

Observación 2.1. El cierre conserva únicamente la información relativa entre coordenadas. Esta idea es la que conecta el símplex con el formalismo composicional de Aitchison [Aitchison, 1986].

3. Sección B – Correcciones locales y cambio de medida

Aquí se introduce el mecanismo elemental de actualización. Dado un estado $X \in \Delta_n$, se definen correcciones relativas admisibles que preservan la masa total y se asocia a cada una de ellas un operador local. El resultado puede interpretarse como un cambio de medida discreto sobre la partición subyacente.

Definición 3.1 (Conjunto de correcciones admisibles en X). Sea $X = (X_1, \dots, X_n) \in \Delta_n$. Se define el conjunto de correcciones admisibles en X por

$$C(X) := \left\{ Y = (Y_1, \dots, Y_n) \in \mathbb{R}^n \mid X_i(1 + Y_i) \geq 0 \text{ para todo } i, \sum_{i=1}^n X_i(1 + Y_i) = 1 \right\}.$$

Definición 3.2 (Operador informacional local). Sea $X \in \Delta_n$ y sea $Y \in C(X)$. El operador informacional local asociado a Y en X es el vector

$$T_Y^{\text{loc}}(X) = (T_Y^{\text{loc}}(X)_1, \dots, T_Y^{\text{loc}}(X)_n) \in \mathbb{R}^n,$$

definido por

$$T_Y^{\text{loc}}(X)_i := X_i(1 + Y_i), \quad i = 1, \dots, n.$$

Proposición 3.1 (Preservación local del simplex). Sea $X \in \Delta_n$ y sea $Y \in C(X)$. Entonces

$$T_Y^{\text{loc}}(X) \in \Delta_n.$$

Proposición 3.2 (Cambio de medida discreto inducido por una corrección local). Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sea $\Pi = \{E_1, \dots, E_n\} \subset \mathcal{F}$ una partición medible finita no degenerada. Defínase

$$X_i := P(E_i), \quad i = 1, \dots, n,$$

de modo que $X = (X_1, \dots, X_n) \in \Delta_n^\circ$.

Sea $Y \in C(X)$ y defínase

$$h(\omega) := 1 + Y_i \quad \text{si } \omega \in E_i.$$

Sea además

$$Q_Y(A) := \int_A h(\omega) dP(\omega), \quad A \in \mathcal{F}.$$

Entonces Q_Y es una medida de probabilidad sobre $(\Omega, \mathcal{F})$.

Proposición 3.3 (Compatibilidad entre T_Y^{loc} y el cambio de medida). Con la notación anterior, para cada $i = 1, \dots, n$ se cumple

$$Q_Y(E_i) = T_Y^{\text{loc}}(X)_i.$$

4. Sección C – Operadores globales multiplicativos y composición

Se pasa ahora al operador global, definido mediante correcciones multiplicativas positivas y renormalización. Esta es la versión que se usa después para la semántica bayesiana.

Definición 4.1 (Correcciones globales). Se define el conjunto de correcciones globales por

$$C_{\text{glob}} := \left\{ Y = (Y_1, \dots, Y_n) \in \mathbb{R}^n \mid 1 + Y_i > 0 \text{ para todo } i \right\}.$$

Para cada $Y \in C_{\text{glob}}$, el vector de factores multiplicativos asociado viene dado por

$$a(Y) := (1 + Y_1, \dots, 1 + Y_n) \in \mathbb{R}_{>0}^n.$$

Definición 4.2 (Operador informacional global). Sea $Y \in C_{\text{glob}}$. El operador informacional global asociado a Y es la aplicación

$$T_Y : \Delta_n^\circ \rightarrow \Delta_n^\circ, \quad T_Y(X) := \frac{X \circ a(Y)}{\sum_{j=1}^n X_j a_j(Y)},$$

donde $\circ$ denota el producto coordenada a coordenada. En forma explícita,

$$T_Y(X)_i = \frac{X_i(1 + Y_i)}{\sum_{j=1}^n X_j(1 + Y_j)}, \quad i = 1, \dots, n.$$

Proposición 4.1 (Preservación del interior del simplex). Sea $Y \in C_{\text{glob}}$. Entonces, para todo $X \in \Delta_n^\circ$,

$$T_Y(X) \in \Delta_n^\circ.$$

Proposición 4.2 (Ley de composición). Sean $Y_1, Y_2 \in C_{\text{glob}}$. Entonces existe un único $Y_{\text{tot}} \in C_{\text{glob}}$ tal que

$$T_{Y_2} \circ T_{Y_1} = T_{Y_{\text{tot}}},$$

y está determinado por

$$1 + Y_{\text{tot}} = (1 + Y_1) \circ (1 + Y_2).$$

Observación 4.1 (Coordenadas log-multiplicativas). Para $Y \in C_{\text{glob}}$ se definen las coordenadas

$$\theta_i := \log(1 + Y_i), \quad i = 1, \dots, n.$$

Entonces

$$T_\theta(X) = \frac{X \circ e^\theta}{\sum_{j=1}^n X_j e^{\theta_j}},$$

y la ley de composición se vuelve aditiva en θ .

5. Sección D – Divergencia KL, métrica de Fisher y dinámica inducida

En esta parte se introduce el funcional informacional

$$E_P(X) := D_{\text{KL}}(P \| X),$$

se calcula su gradiente respecto de la métrica de Fisher en el interior del simplex y se obtiene la dinámica continua asociada. Esta dinámica es la base para pasar de la corrección multiplicativa al flujo de descenso.

Definición 5.1 (Divergencia de Kullback–Leibler discreta). Sea $P \in \Delta_n^\circ$ fija. Para $X \in \Delta_n$ se define

$$D_{\text{KL}}(P \| X) = \begin{cases} \sum_{i=1}^n P_i \log\left(\frac{P_i}{X_i}\right), & \text{si } X_i > 0 \text{ para todo } i, \\ +\infty, & \text{si existe } i \text{ tal que } P_i > 0 \text{ y } X_i = 0. \end{cases}$$

Se define además el funcional

$$E_P : \Delta_n^\circ \rightarrow \mathbb{R}, \quad E_P(X) := D_{\text{KL}}(P \| X).$$

Definición 5.2 (Espacio tangente del simplex). Sea $X \in \Delta_n^\circ$. El espacio tangente en X viene dado por

$$T_X \Delta_n^\circ = \left\{ u \in \mathbb{R}^n \mid \sum_{i=1}^n u_i = 0 \right\}.$$

Definición 5.3 (Métrica de Fisher discreta). Para $X \in \Delta_n^\circ$, la métrica de Fisher en $T_X \Delta_n^\circ$ es

$$g_X(u, v) := \sum_{i=1}^n \frac{u_i v_i}{X_i}, \quad u, v \in T_X \Delta_n^\circ.$$

Definición 5.4 (Gradiente riemanniano respecto de la métrica de Fisher). Sea $E : \Delta_n^\circ \rightarrow \mathbb{R}$ una función suave. El gradiente riemanniano de E respecto de g es el campo $\text{grad}_g E$ caracterizado por

$$g_X(\text{grad}_g E(X), u) = dE(X)[u], \quad \forall u \in T_X \Delta_n^\circ.$$

Proposición 5.1 (Gradiente Fisher de la divergencia KL). Sea $P \in \Delta_n^\circ$ fija y sea

$$E_P(X) = D_{\text{KL}}(P \| X) = \sum_{i=1}^n P_i \log\left(\frac{P_i}{X_i}\right), \quad X \in \Delta_n^\circ.$$

Entonces

$$\text{grad}_g E_P(X) = X - P, \quad X \in \Delta_n^\circ.$$

Definición 5.5 (Flujo de gradiente Fisher–KL). El flujo de gradiente asociado a E_P es la ecuación diferencial

$$\dot{X}(t) = -\text{grad}_g E_P(X(t)), \quad X(t) \in \Delta_n^\circ.$$

Por la Proposición 5.1, esta ecuación toma la forma

$$\dot{X}(t) = P - X(t).$$

Proposición 5.2 (Solución explícita del flujo). Sea $X_0 \in \Delta_n^\circ$. La solución de

$$\dot{X}(t) = P - X(t), \quad X(0) = X_0,$$

viene dada por

$$X(t) = e^{-t} X_0 + (1 - e^{-t}) P, \quad t \geq 0.$$

En particular, $X(t) \in \Delta_n^\circ$ para todo $t \geq 0$ y $X(t) \rightarrow P$ cuando $t \rightarrow \infty$.

Proposición 5.3 (Monotonidad de E_P a lo largo del flujo). Sea $X(\cdot)$ una solución del flujo Fisher–KL. Entonces

$$\frac{d}{dt} E_P(X(t)) = -g_{X(t)}(\text{grad}_g E_P(X(t)), \text{grad}_g E_P(X(t))) \leq 0.$$

La igualdad sólo ocurre si $X(t) = P$.

Proposición 5.4 (Mínimo global de E_P). Para todo $X \in \Delta_n^\circ$ se cumple

$$E_P(X) \geq 0,$$

y además

$$E_P(X) = 0 \iff X = P.$$

En particular, P es el único minimizador global de E_P en Δ_n° .

Teorema 5.1 (Equivalencia estructural Sección C $\leftrightarrow$ Sección D). Sea $P \in \Delta_n^\circ$ fijo. Considérese el operador informacional global T_Y del Sección C, definido para $Y \in C_{\text{glob}}$ por

$$T_Y(X) = \frac{X \circ (1 + Y)}{\langle X, 1 + Y \rangle}.$$

Defínase, para cada $X \in \Delta_n^\circ$, el campo de corrección óptima

$$Y^*(X, P)_i := \frac{P_i}{X_i} - 1, \quad i = 1, \dots, n.$$

Entonces:

1. $T_{Y^*(X, P)}(X) = P$;
2. la iteración $X_{k+1} = T_{\alpha Y^*(X_k, P)}(X_k)$ se reduce a la interpolación convexa $X_{k+1} = (1 - \alpha)X_k + \alpha P$;
3. el límite infinitesimal de la regla global conduce a $\dot{X} = P - X$, que coincide con el flujo de gradiente Fisher–KL.

6. Sección E – Semántica bayesiana

La idea es fijar un espacio bayesiano, identificar la verosimilitud como una corrección global y demostrar que la actualización de Bayes aparece exactamente como un caso particular del operador T_Y . Esta lectura no se introduce de manera aislada: está alineada con la interpretación de Bayes spaces de Egozcue, Pawlowsky-Glahn, Tolosana-Delgado, Ortego y van den Boogaart (2013), donde la regla de Bayes se entiende como una perturbación entre densidades proporcionales, y también con la geometría afín del simplex de Pistone y Shoaib (2024), que permite leer las actualizaciones como operadores internos sobre el espacio de estados.

En paralelo, la parte diferencial del marco se apoya en la geometría de la información de Amari (2016), mientras que la interpretación variacional y del statistical bundle remite a Pistone (2018). Por eso, el objetivo de esta sección no es solo obtener una fórmula de actualización, sino situarla en una narración geométrica y probabilística coherente con la bibliografía ya revisada.

Definición 6.1 (Espacio Bayesiano). Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad. Sean $n, m \in \mathbb{N}$ y sean

$$\Pi_H = \{H_1, \dots, H_n\}, \quad \Pi_E = \{E_1, \dots, E_m\},$$

dos particiones medibles finitas de Ω . Supongamos que

$$P(H_i) > 0 \quad \text{para todo } i = 1, \dots, n, \quad P(E_j) > 0 \quad \text{para todo } j = 1, \dots, m.$$

Interpretamos los elementos de Π_H como hipótesis alternativas y los elementos de Π_E como observaciones posibles.

El estado informacional previo asociado a Π_H es el vector

$$X = (X_1, \dots, X_n) \in \Delta_n^\circ, \quad X_i := P(H_i), \quad i = 1, \dots, n,$$

de modo que $\sum_{i=1}^n X_i = 1$ y $X_i > 0$ para todo i .

Definición 6.2 (Probabilidad condicional en el espacio conjunto). Sea $(\Omega, \mathcal{F}, P)$ el espacio de probabilidad de la Definición 6.1, y sean $\Pi_H = \{H_1, \dots, H_n\}$ y $\Pi_E = \{E_1, \dots, E_m\}$ las particiones medibles finitas allí fijadas. Sean $i \in \{1, \dots, n\}$ y $j \in \{1, \dots, m\}$. Si $P(H_i) > 0$, se define la probabilidad condicional de la observación E_j dada la hipótesis H_i por

$$P(E_j \mid H_i) := \frac{P(H_i \cap E_j)}{P(H_i)}.$$

Se dirá que la observación E_j es compatible con la hipótesis H_i si $P(H_i \cap E_j) > 0$. Equivalentemente, puesto que $P(H_i) > 0$, esta compatibilidad se cumple si y sólo si $P(E_j \mid H_i) > 0$.

Definición 6.3 (Verosimilitud como corrección global). Sea $j \in \{1, \dots, m\}$ con $P(E_j) > 0$. Denótese por

$$\ell^{(j)} = (\ell_1^{(j)}, \dots, \ell_n^{(j)}) \in \mathbb{R}_{>0}^n$$

el vector de verosimilitud asociado a la observación E_j , donde

$$\ell_i^{(j)} := P(E_j \mid H_i), \quad i = 1, \dots, n.$$

Cuando $\ell_i^{(j)} > 0$ para todo i , el vector $\ell^{(j)}$ determina una corrección global $Y^{\ell^{(j)}} \in C_{\text{glob}}$ mediante

$$1 + Y_i^{\ell^{(j)}} := \ell_i^{(j)}, \quad i = 1, \dots, n.$$

En particular, la verosimilitud queda incorporada al formalismo global como un representante multiplicativo positivo.

Con esta identificación, la actualización posterior puede formularse ya como una transformación del propio estado en el simplex.

Proposición 6.1 (El operador bayesiano como caso particular de T_Y). Sean $(\Omega, \mathcal{F}, P)$ el espacio de probabilidad y $\Pi_H = \{H_1, \dots, H_n\}$, $\Pi_E = \{E_1, \dots, E_m\}$ las particiones de la Definición 6.1. Sea $j \in \{1, \dots, m\}$ tal que $P(E_j) > 0$, y supóngase que la verosimilitud asociada a E_j satisface

$$\ell^{(j)} = (\ell_1^{(j)}, \dots, \ell_n^{(j)}) \in \mathbb{R}_{>0}^n, \quad \ell_i^{(j)} := P(E_j \mid H_i), \quad i = 1, \dots, n.$$

Sea además $X \in \Delta_n^\circ$ el estado previo asociado a Π_H , dado por $X_i = P(H_i)$ para todo $i = 1, \dots, n$. Entonces, para cada $i = 1, \dots, n$, se tiene

$$T_{Y^{\ell^{(j)}}}(X)_i = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}} = P(H_i \mid E_j).$$

En particular, $T_{Y^{\ell^{(j)}}}(X)$ coincide con el estado posterior condicionado a la observación E_j .

Demostración. Como $\ell_i^{(j)} > 0$ para todo $i = 1, \dots, n$, el vector $Y^{\ell^{(j)}}$ pertenece a C_{glob} , y por tanto el operador global $T_{Y^{\ell^{(j)}}}$ está bien definido. Por la Definición 4.2, para cada $i = 1, \dots, n$,

$$T_{Y^{\ell^{(j)}}}(X)_i = \frac{X_i(1 + Y_i^{\ell^{(j)}})}{\sum_{k=1}^n X_k(1 + Y_k^{\ell^{(j)}})}.$$

Puesto que $1 + Y_i^{\ell^{(j)}} = \ell_i^{(j)}$, esta expresión se reduce a

$$T_{Y^{\ell^{(j)}}}(X)_i = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}}.$$

Ahora bien, por definición del estado previo y de la verosimilitud, $X_i = P(H_i)$ y $\ell_i^{(j)} = P(E_j | H_i)$, de modo que

$$X_i \ell_i^{(j)} = P(H_i) P(E_j | H_i) = P(H_i \cap E_j).$$

Además, como $\Pi_H = \{H_1, \dots, H_n\}$ es una partición de Ω , los conjuntos $H_1 \cap E_j, \dots, H_n \cap E_j$ son disjuntos y su unión es E_j . En consecuencia,

$$\sum_{k=1}^n X_k \ell_k^{(j)} = \sum_{k=1}^n P(H_k \cap E_j) = P(E_j).$$

Sustituyendo estas identidades en la expresión anterior, se obtiene

$$T_{Y^{\ell^{(j)}}}(X)_i = \frac{P(H_i \cap E_j)}{P(E_j)} = P(H_i | E_j), \quad i = 1, \dots, n.$$

□

La unicidad de esta representación fija la regla de actualización dentro de $\mathcal{G}$ y evita ambigüedades al pasar del prior al posterior.

Proposición 6.2 (Unicidad: $T_{Y^{\ell^{(j)}}}$ es el único operador coherente con P). Sean $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad,

$$\Pi_H = \{H_1, \dots, H_n\}, \quad \Pi_E = \{E_1, \dots, E_m\},$$

particiones medibles finitas de Ω , y

$$X = (X_1, \dots, X_n) \in \Delta_n^\circ, \quad X_i := P(H_i), \quad i = 1, \dots, n.$$

Sea $j \in \{1, \dots, m\}$ tal que

$$P(H_i \cap E_j) > 0, \quad i = 1, \dots, n,$$

y defínase

$$\ell_i^{(j)} := P(E_j | H_i), \quad i = 1, \dots, n.$$

Entonces, para un operador $T \in \mathcal{G}$, se tiene

$$T(X)_i = P(H_i | E_j), \quad i = 1, \dots, n,$$

si y sólo si

$$T = T_{Y^{\ell^{(j)}}}.$$

Demostración. Sea $T \in \mathcal{G}$. Entonces existe $Y \in C_{\text{glob}}$ tal que $T = T_Y$. Supóngase primero que

$$T(X)_i = P(H_i \mid E_j), \quad i = 1, \dots, n.$$

Por definición del operador global,

$$T_Y(X)_i = \frac{X_i(1 + Y_i)}{\sum_{k=1}^n X_k(1 + Y_k)}, \quad i = 1, \dots, n.$$

Por otra parte, como $X_i = P(H_i)$ y $\ell_i^{(j)} = P(E_j \mid H_i)$, se tiene

$$X_i \ell_i^{(j)} = P(H_i) P(E_j \mid H_i) = P(H_i \cap E_j),$$

y, puesto que Π_H es una partición de Ω ,

$$\sum_{k=1}^n X_k \ell_k^{(j)} = \sum_{k=1}^n P(H_k \cap E_j) = P(E_j).$$

De aquí se sigue que

$$P(H_i \mid E_j) = \frac{P(H_i \cap E_j)}{P(E_j)} = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}}, \quad i = 1, \dots, n.$$

Por consiguiente,

$$\frac{X_i(1 + Y_i)}{\sum_{k=1}^n X_k(1 + Y_k)} = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}}, \quad i = 1, \dots, n.$$

Como $X_i > 0$ para todo $i = 1, \dots, n$, se deduce que

$$\frac{1 + Y_i}{\ell_i^{(j)}} = \frac{\sum_{k=1}^n X_k(1 + Y_k)}{\sum_{k=1}^n X_k \ell_k^{(j)}} =: c, \quad i = 1, \dots, n.$$

La constante c es positiva e independiente de i , y por tanto

$$1 + Y_i = c \ell_i^{(j)}, \quad i = 1, \dots, n.$$

Sea ahora $Z \in \Delta_n^\circ$. Entonces, para cada $i = 1, \dots, n$,

$$T_Y(Z)_i = \frac{Z_i(1 + Y_i)}{\sum_{k=1}^n Z_k(1 + Y_k)} = \frac{Z_i c \ell_i^{(j)}}{\sum_{k=1}^n Z_k c \ell_k^{(j)}} = \frac{Z_i \ell_i^{(j)}}{\sum_{k=1}^n Z_k \ell_k^{(j)}} = T_{Y \ell^{(j)}}(Z)_i.$$

Se sigue que $T = T_{Y \ell^{(j)}}$.

Recíprocamente, si $T = T_{Y \ell^{(j)}}$, entonces para cada $i = 1, \dots, n$,

$$T(X)_i = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}} = \frac{P(H_i \cap E_j)}{P(E_j)} = P(H_i \mid E_j).$$

Esto concluye la demostración. □

Corolario 6.1 (Actualización bayesiana secuencial como composición en $\mathcal{G}$). Sean $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad,

$$\Pi_H = \{H_1, \dots, H_n\}, \quad \Pi_E = \{E_1, \dots, E_m\},$$

particiones medibles finitas de Ω , y

$$X_0 = (X_{0,1}, \dots, X_{0,n}) \in \Delta_n^\circ, \quad X_{0,i} := P(H_i), \quad i = 1, \dots, n.$$

Sean $j_1, \dots, j_r \in \{1, \dots, m\}$ y, para cada $s = 1, \dots, r$, supóngase que

$$P(H_i \cap E_{j_s}) > 0, \quad i = 1, \dots, n.$$

Para cada $s = 1, \dots, r$, defínase la verosimilitud asociada a la observación E_{j_s} por

$$\ell_i^{(j_s)} := P(E_{j_s} \mid H_i), \quad i = 1, \dots, n.$$

Entonces el estado posterior obtenido tras aplicar sucesivamente las r actualizaciones bayesianas viene dado por

$$X_r = T_{Y^{\ell(j_r)}} \circ \dots \circ T_{Y^{\ell(j_1)}}(X_0).$$

Si, además, las observaciones son condicionalmente independientes dadas las hipótesis, entonces la actualización secuencial coincide con la actualización en un solo paso asociada a la verosimilitud acumulada

$$\tilde{\ell}_i := \prod_{s=1}^r \ell_i^{(j_s)}, \quad i = 1, \dots, n,$$

es decir,

$$X_r = T_{Y^{\tilde{\ell}}}(X_0).$$

Demostración. Para cada $s = 1, \dots, r$, la hipótesis $P(H_i \cap E_{j_s}) > 0$ para todo $i = 1, \dots, n$ implica que

$$\ell_i^{(j_s)} = P(E_{j_s} \mid H_i) > 0, \quad i = 1, \dots, n.$$

Por consiguiente, cada vector $\ell^{(j_s)}$ determina una corrección global $Y^{\ell^{(j_s)}} \in C_{\text{glob}}$, y el operador

$$T_{Y^{\ell^{(j_s)}}} : \Delta_n^\circ \rightarrow \Delta_n^\circ$$

está bien definido.

Aplicando en cada paso la actualización bayesiana asociada a la observación correspondiente, se obtiene sucesivamente

$$X_1 = T_{Y^{\ell(j_1)}}(X_0), \quad X_2 = T_{Y^{\ell(j_2)}}(X_1), \quad \dots, \quad X_r = T_{Y^{\ell(j_r)}}(X_{r-1}).$$

Por sustitución iterada, resulta

$$X_r = T_{Y^{\ell(j_r)}} \circ \dots \circ T_{Y^{\ell(j_1)}}(X_0).$$

Supóngase ahora, además, que las observaciones son condicionalmente independientes dadas las hipótesis. Entonces, para cada $i = 1, \dots, n$, la verosimilitud conjunta es el producto de las verosimilitudes individuales:

$$\tilde{\ell}_i = \prod_{s=1}^r \ell_i^{(j_s)}.$$

Por la ley de composición de los operadores globales, la composición

$$T_{Y^{\ell(j_r)}} \circ \cdots \circ T_{Y^{\ell(j_1)}}$$

es nuevamente un operador global, cuyo factor multiplicativo es proporcional al producto coordinado de los factores individuales. Como dichos factores son precisamente

$$\ell^{(j_1)}, \dots, \ell^{(j_r)},$$

el operador compuesto coincide con $T_{Y^{\tilde{\ell}}}$. Por tanto,

$$X_r = T_{Y^{\tilde{\ell}}}(X_0).$$

Esto concluye la demostración. □

6.1. Modelos continuos como estados informacionales discretos

Observación 6.1 (Criterio medible para la discretización paramétrica). *La discretización paramétrica que se usa en este bloque descansa en dos planos ya fijados. En el plano interno, las Secciones A–D proporcionan el espacio de probabilidad, la partición medible finita, el símplex, el conjunto de correcciones globales y el operador multiplicativo normalizado; en particular, se usan los objetos introducidos en las Definiciones 2.1, 2.2, 2.3, 4.1 y 4.2. En el plano de teoría de la medida, la referencia de Tao, An Introduction to Measure Theory, justifica trabajar con conjuntos borelianos, funciones indicadoras, funciones medibles no negativas e integrales de Lebesgue sobre espacios de medida. Así, las masas de las celdas pueden escribirse como integrales de funciones indicadoras contra una densidad.*

Definición 6.4 (Partición paramétrica uniforme). *Sea $\Omega = (a, b) \subset \mathbb{R}$, con $a < b$, y sea $\mathcal{F} = \mathcal{B}(\Omega)$ la σ -álgebra de Borel relativa en Ω . Sea P_0 una medida de probabilidad sobre $(\Omega, \mathcal{F})$ absolutamente continua respecto de la medida de Lebesgue restringida a Ω . Sea*

$$f := \frac{dP_0}{d\lambda}$$

una densidad de P_0 respecto de λ , donde λ denota la medida de Lebesgue restringida a Ω . Se supone que

$$f : \Omega \rightarrow (0, \infty)$$

es $\mathcal{F}$ -medible y satisface

$$\int_{\Omega} f(\theta) d\theta = 1.$$

Dado $n \geq 1$, sea

$$h := \frac{b-a}{n}.$$

La partición paramétrica uniforme de orden n asociada a Ω es la familia

$$\Pi_n := \{E_1, \dots, E_n\},$$

donde

$$E_i := \begin{cases} [a + (i-1)h, a + ih) \cap \Omega, & i = 1, \dots, n-1, \\ [a + (n-1)h, b) \cap \Omega, & i = n. \end{cases}$$

El estado informacional previo asociado a $(\Omega, \mathcal{F}, P_0, \Pi_n)$ es el vector

$$X_0 = (X_{0,1}, \dots, X_{0,n}), \quad X_{0,i} := P_0(E_i) = \int_{E_i} f(\theta) d\theta, \quad i = 1, \dots, n.$$

Proposición 6.3 (Estado previo inducido por una partición paramétrica uniforme). Sea $\Omega = (a, b) \subset \mathbb{R}$, con $a < b$, y sea $\mathcal{F} = \mathcal{B}(\Omega)$. Sea P_0 una medida de probabilidad sobre $(\Omega, \mathcal{F})$ absolutamente continua respecto de la medida de Lebesgue restringida a Ω , con densidad $f : \Omega \rightarrow (0, \infty)$ medible y tal que

$$\int_{\Omega} f(\theta) d\theta = 1.$$

Sea $n \geq 1$, sea $h = (b - a)/n$ y sean

$$E_i := \begin{cases} [a + (i-1)h, a + ih) \cap \Omega, & i = 1, \dots, n-1, \\ [a + (n-1)h, b) \cap \Omega, & i = n. \end{cases}$$

Defínase

$$X_{0,i} := P_0(E_i) = \int_{E_i} f(\theta) d\theta, \quad i = 1, \dots, n.$$

Entonces $\Pi_n = \{E_1, \dots, E_n\}$ es una partición medible finita no degenerada de Ω y

$$X_0 = (X_{0,1}, \dots, X_{0,n}) \in \Delta_n^\circ.$$

Demostración. Para $i = 1, \dots, n$, cada E_i es intersección de un intervalo boreliano de $\mathbb{R}$ con Ω ; por tanto,

$$E_i \in \mathcal{F}.$$

Además,

$$E_i \cap E_j = \emptyset \quad (i \neq j), \quad \bigcup_{i=1}^n E_i = \Omega.$$

Luego Π_n es una partición medible finita de Ω .

Como cada E_i contiene un intervalo relativo no vacío de Ω y $f(\theta) > 0$ para todo $\theta \in \Omega$, se tiene

$$X_{0,i} = P_0(E_i) = \int_{E_i} f(\theta) d\theta > 0, \quad i = 1, \dots, n.$$

Por otra parte,

$$\sum_{i=1}^n X_{0,i} = \sum_{i=1}^n P_0(E_i) = P_0\left(\bigcup_{i=1}^n E_i\right) = P_0(\Omega) = 1.$$

Así,

$$X_{0,i} > 0 \quad (i = 1, \dots, n), \quad \sum_{i=1}^n X_{0,i} = 1,$$

y por consiguiente

$$X_0 \in \Delta_n^\circ.$$

□

Observación 6.2 (Promedio condicional de la verosimilitud). *La integral que aparece en la verosimilitud discreta es una integral de Lebesgue respecto de P_0 . La referencia de Tao permite tratar $\int_{E_i} \ell dP_0$ como integral de una función medible no negativa sobre un espacio de medida. La condición $0 < \int_{\Omega} \ell dP_0 < \infty$ evita cantidades extendidas en el normalizador; esta precaución es necesaria porque las operaciones algebraicas con $+\infty$ no admiten cancelación ordinaria. En la semántica bayesiana ya desarrollada en la Sección E, la verosimilitud actúa como factor multiplicativo; esta lectura concuerda con los espacios de Bayes de Egozcue, Pawlowsky-Glahn, Tolosana-Delgado, Ortego y van den Boogaart, donde la perturbación corresponde a multiplicación de densidades seguida de normalización.*

Definición 6.5 (Verosimilitud discreta inducida por una partición). *Sea $\Omega = (a, b) \subset \mathbb{R}$, sea $\mathcal{F} = \mathcal{B}(\Omega)$ y sea P_0 una medida de probabilidad sobre $(\Omega, \mathcal{F})$. Sea $\Pi_n = \{E_1, \dots, E_n\}$ una partición medible finita no degenerada de Ω . Sea e un dato observado y sea*

$$\ell : \Omega \rightarrow (0, \infty)$$

una función de verosimilitud medible, asociada al dato e , tal que

$$0 < \int_{\Omega} \ell(\theta) dP_0(\theta) < \infty.$$

La verosimilitud discreta del dato e bajo la celda E_i se define por

$$\ell_i := E_{P_0}[\ell \mid E_i] := \frac{\int_{E_i} \ell(\theta) dP_0(\theta)}{P_0(E_i)}, \quad i = 1, \dots, n.$$

Si, además, P_0 tiene densidad f respecto de la medida de Lebesgue restringida a Ω , entonces

$$\ell_i = \frac{\int_{E_i} \ell(\theta) f(\theta) d\theta}{\int_{E_i} f(\theta) d\theta}, \quad i = 1, \dots, n.$$

El vector asociado a la verosimilitud discreta se define por

$$1 + Y_i^\ell := \ell_i, \quad i = 1, \dots, n.$$

Proposición 6.4 (Admisibilidad de la corrección de verosimilitud). *Sea $(\Omega, \mathcal{F}, P_0)$ un espacio de probabilidad. Sea $\Pi_n = \{E_1, \dots, E_n\}$ una partición medible finita de Ω tal que*

$$P_0(E_i) > 0, \quad i = 1, \dots, n.$$

Sea $\ell : \Omega \rightarrow (0, \infty)$ una función medible tal que

$$0 < \int_{\Omega} \ell dP_0 < \infty.$$

Para cada $i = 1, \dots, n$, defínase

$$\ell_i := \frac{\int_{E_i} \ell dP_0}{P_0(E_i)}$$

y defínase $Y^\ell \in \mathbb{R}^n$ por

$$1 + Y_i^\ell := \ell_i, \quad i = 1, \dots, n.$$

Entonces

$$Y^\ell \in C_{\text{glob}}.$$

Demostración. Como $\ell(\omega) > 0$ para todo $\omega \in \Omega$ y $P_0(E_i) > 0$, se tiene

$$\int_{E_i} \ell dP_0 > 0.$$

Además,

$$0 < \int_{E_i} \ell dP_0 \leq \int_{\Omega} \ell dP_0 < \infty.$$

Por tanto,

$$0 < \frac{\int_{E_i} \ell dP_0}{P_0(E_i)} < \infty, \quad i = 1, \dots, n.$$

Es decir,

$$0 < \ell_i < \infty, \quad i = 1, \dots, n.$$

Como

$$1 + Y_i^\ell = \ell_i,$$

se obtiene

$$1 + Y_i^\ell > 0, \quad i = 1, \dots, n.$$

Así,

$$Y^\ell = (Y_1^\ell, \dots, Y_n^\ell) \in \mathbb{R}^n, \quad 1 + Y_i^\ell > 0 \quad (i = 1, \dots, n),$$

y por consiguiente

$$Y^\ell \in C_{\text{glob}}.$$

□

Observación 6.3 (Radon–Nikodym y construcción de la posterior). *En la teoría de la medida, una medida absolutamente continua puede representarse mediante una derivada de Radon–Nikodym respecto de una medida dominante. En este bloque no se invoca el teorema para obtener existencia abstracta: la posterior se construye directamente mediante la densidad ℓ/Z respecto de P_0 , donde $Z = \int_{\Omega} \ell dP_0$. La referencia de Tao proporciona el marco de espacios de medida e integración; la lectura bayesiana de los espacios de Bayes proporciona la interpretación multiplicativa de la actualización.*

Lema 6.1 (Cambio de medida exacto por celdas). *Sea $(\Omega, \mathcal{F}, P_0)$ un espacio de probabilidad. Sea $\Pi_n = \{E_1, \dots, E_n\}$ una partición medible finita de Ω tal que*

$$P_0(E_i) > 0, \quad i = 1, \dots, n.$$

Sea $\ell : \Omega \rightarrow (0, \infty)$ una función medible tal que

$$Z := \int_{\Omega} \ell dP_0$$

satisface

$$0 < Z < \infty.$$

Defínase, para $A \in \mathcal{F}$,

$$Q(A) := \int_A \frac{\ell}{Z} dP_0.$$

Defínase también

$$\ell_i := \frac{\int_{E_i} \ell dP_0}{P_0(E_i)}, \quad i = 1, \dots, n.$$

Entonces Q es una medida de probabilidad sobre $(\Omega, \mathcal{F})$, se cumple

$$\frac{dQ}{dP_0} = \frac{\ell}{Z},$$

y, para cada $i = 1, \dots, n$,

$$Q(E_i) = \frac{P_0(E_i)\ell_i}{\sum_{k=1}^n P_0(E_k)\ell_k}.$$

Demostración. Para $A \in \mathcal{F}$,

$$Q(A) = \int_A \frac{\ell}{Z} dP_0 \geq 0.$$

Además,

$$Q(\Omega) = \int_{\Omega} \frac{\ell}{Z} dP_0 = \frac{1}{Z} \int_{\Omega} \ell dP_0 = \frac{Z}{Z} = 1.$$

La aditividad numerable se hereda de la integral respecto de P_0 , pues la densidad ℓ/Z es medible y no negativa. Luego Q es una medida de probabilidad.

Por definición de Q ,

$$Q(A) = \int_A \frac{\ell}{Z} dP_0, \quad A \in \mathcal{F},$$

de modo que

$$\frac{dQ}{dP_0} = \frac{\ell}{Z}.$$

Para cada $i = 1, \dots, n$,

$$P_0(E_i)\ell_i = P_0(E_i) \frac{\int_{E_i} \ell dP_0}{P_0(E_i)} = \int_{E_i} \ell dP_0.$$

Por tanto,

$$\sum_{k=1}^n P_0(E_k)\ell_k = \sum_{k=1}^n \int_{E_k} \ell dP_0 = \int_{\bigcup_{k=1}^n E_k} \ell dP_0 = \int_{\Omega} \ell dP_0 = Z.$$

Así,

$$Q(E_i) = \int_{E_i} \frac{\ell}{Z} dP_0 = \frac{\int_{E_i} \ell dP_0}{Z} = \frac{P_0(E_i)\ell_i}{\sum_{k=1}^n P_0(E_k)\ell_k}.$$

□

Observación 6.4 (Identidad entre actualización bayesiana y operador global). La Sección C introduce el operador informacional global como multiplicación coordinada a coordinada seguida de normalización. La semántica bayesiana de la Sección E identifica la verosimilitud con los factores multiplicativos de esa corrección. En la bibliografía de espacios de Bayes, la fórmula de Bayes se lee precisamente como perturbación: se multiplican densidades positivas proporcionales y se normaliza. En consecuencia, la proposición siguiente formaliza que el operador T_Y no aproxima la posterior continua, sino que coincide con la masa que esa posterior asigna a cada celda de la partición.

Proposición 6.5 (Actualización bayesiana paramétrica en CI). Sea $\Omega = (a, b) \subset \mathbb{R}$, con $a < b$, y sea $\mathcal{F} = \mathcal{B}(\Omega)$. Sea P_0 una medida de probabilidad sobre $(\Omega, \mathcal{F})$ absolutamente continua respecto de la medida de Lebesgue restringida a Ω , con densidad $f : \Omega \rightarrow (0, \infty)$ medible y tal que

$$\int_{\Omega} f(\theta) d\theta = 1.$$

Sea $n \geq 1$, sea $h = (b - a)/n$ y sean

$$E_i := \begin{cases} [a + (i - 1)h, a + ih) \cap \Omega, & i = 1, \dots, n - 1, \\ [a + (n - 1)h, b) \cap \Omega, & i = n. \end{cases}$$

Defínase

$$X_{0,i} := P_0(E_i) = \int_{E_i} f(\theta) d\theta, \quad i = 1, \dots, n.$$

Sea $\ell : \Omega \rightarrow (0, \infty)$ una función medible tal que

$$Z := \int_{\Omega} \ell dP_0$$

satisface

$$0 < Z < \infty.$$

Defínase

$$\ell_i := \frac{\int_{E_i} \ell dP_0}{P_0(E_i)}, \quad 1 + Y_i^\ell := \ell_i, \quad i = 1, \dots, n.$$

Defínase, para $A \in \mathcal{F}$,

$$Q(A) := \int_A \frac{\ell}{Z} dP_0.$$

Finalmente, defínase

$$T_{Y^\ell}(X_0)_i := \frac{X_{0,i}(1 + Y_i^\ell)}{\sum_{k=1}^n X_{0,k}(1 + Y_k^\ell)}, \quad i = 1, \dots, n.$$

Entonces

$$T_{Y^\ell}(X_0)_i = Q(E_i), \quad i = 1, \dots, n.$$

En particular,

$$T_{Y^\ell}(X_0) \in \Delta_n^\circ.$$

Demostración. Para cada $i = 1, \dots, n$,

$$X_{0,i} = P_0(E_i), \quad 1 + Y_i^\ell = \ell_i.$$

Por tanto,

$$T_{Y^\ell}(X_0)_i = \frac{X_{0,i}(1 + Y_i^\ell)}{\sum_{k=1}^n X_{0,k}(1 + Y_k^\ell)} = \frac{P_0(E_i)\ell_i}{\sum_{k=1}^n P_0(E_k)\ell_k}.$$

Como

$$\ell_i = \frac{\int_{E_i} \ell dP_0}{P_0(E_i)},$$

se tiene

$$P_0(E_i)\ell_i = \int_{E_i} \ell dP_0.$$

Luego

$$\sum_{k=1}^n P_0(E_k)\ell_k = \sum_{k=1}^n \int_{E_k} \ell dP_0 = \int_{\Omega} \ell dP_0 = Z.$$

Sustituyendo,

$$T_{Y^\ell}(X_0)_i = \frac{\int_{E_i} \ell dP_0}{Z} = \int_{E_i} \frac{\ell}{Z} dP_0 = Q(E_i).$$

Además, como $f > 0$ en Ω y cada E_i tiene longitud positiva,

$$X_{0,i} > 0.$$

Como $\ell_i > 0$,

$$X_{0,i}(1 + Y_i^\ell) = X_{0,i}\ell_i > 0.$$

Así,

$$T_{Y^\ell}(X_0)_i > 0, \quad i = 1, \dots, n.$$

Finalmente,

$$\sum_{i=1}^n T_{Y^\ell}(X_0)_i = \sum_{i=1}^n Q(E_i) = Q(\Omega) = 1.$$

Por consiguiente,

$$T_{Y^\ell}(X_0) \in \Delta_n^\circ.$$

□

Observación 6.5 (Familias exponenciales y separación de niveles). *En los espacios de Bayes, las familias exponenciales aparecen como estructuras afines o cónicas de densidades positivas. Este hecho justifica separar dos niveles: el nivel continuo, donde la conjugación se expresa por suma de parámetros naturales, y el nivel discreto, donde el operador global recupera las masas de la posterior sobre una partición finita. La proposición siguiente no modifica el teorema bayesiano anterior; únicamente lo especializa al caso en que el producto entre densidad previa y verosimilitud conserva forma exponencial.*

Proposición 6.6 (Modelo conjugado exponencial como caso particular). Sea $\Omega = (a, b) \subset \mathbb{R}$, con $a < b$, y sea $\mathcal{F} = \mathcal{B}(\Omega)$. Sea $T : \Omega \rightarrow \mathbb{R}^m$ una función medible. Sean $\eta_0, \eta_\ell \in \mathbb{R}^m$ tales que

$$0 < I_0 := \int_{\Omega} \exp(\eta_0 \cdot T(\theta)) d\theta < \infty$$

y

$$0 < I_1 := \int_{\Omega} \exp((\eta_0 + \eta_\ell) \cdot T(\theta)) d\theta < \infty.$$

Defínase

$$f(\theta) := \frac{\exp(\eta_0 \cdot T(\theta))}{I_0}, \quad \theta \in \Omega,$$

y sea P_0 la medida de probabilidad sobre $(\Omega, \mathcal{F})$ dada por

$$dP_0(\theta) = f(\theta) d\theta.$$

Sea $c_\ell > 0$ y defínase la verosimilitud

$$\ell(\theta) := c_\ell \exp(\eta_\ell \cdot T(\theta)), \quad \theta \in \Omega.$$

Sea $n \geq 1$, sea $h = (b - a)/n$ y sean

$$E_i := \begin{cases} [a + (i - 1)h, a + ih) \cap \Omega, & i = 1, \dots, n - 1, \\ [a + (n - 1)h, b) \cap \Omega, & i = n. \end{cases}$$

Defínase

$$X_{0,i} := P_0(E_i), \quad \ell_i := \frac{\int_{E_i} \ell dP_0}{P_0(E_i)}, \quad 1 + Y_i^\ell := \ell_i.$$

Defínase Q por

$$Q(A) := \frac{\int_A \ell dP_0}{\int_{\Omega} \ell dP_0}, \quad A \in \mathcal{F}.$$

Entonces, para cada $i = 1, \dots, n$,

$$T_{Y^\ell}(X_0)_i = Q(E_i) = \frac{\int_{E_i} \exp((\eta_0 + \eta_\ell) \cdot T(\theta)) d\theta}{\int_{\Omega} \exp((\eta_0 + \eta_\ell) \cdot T(\theta)) d\theta}.$$

Además, Q es absolutamente continua respecto de la medida de Lebesgue restringida a Ω y su densidad es

$$q(\theta) = \frac{\exp((\eta_0 + \eta_\ell) \cdot T(\theta))}{\int_{\Omega} \exp((\eta_0 + \eta_\ell) \cdot T(u)) du}.$$

En particular, la posterior pertenece a la misma familia exponencial, con parámetro natural

$$\eta_{\text{post}} := \eta_0 + \eta_\ell.$$

Demostración. Primero,

$$\int_{\Omega} f(\theta) d\theta = \frac{1}{I_0} \int_{\Omega} \exp(\eta_0 \cdot T(\theta)) d\theta = 1.$$

Luego P_0 es probabilidad. Además,

$$\int_{\Omega} \ell dP_0 = \int_{\Omega} c_{\ell} \exp(\eta_{\ell} \cdot T(\theta)) \frac{\exp(\eta_0 \cdot T(\theta))}{I_0} d\theta.$$

Por tanto,

$$\int_{\Omega} \ell dP_0 = \frac{c_{\ell}}{I_0} \int_{\Omega} \exp((\eta_0 + \eta_{\ell}) \cdot T(\theta)) d\theta = \frac{c_{\ell} I_1}{I_0}.$$

Como $c_{\ell} > 0$, $0 < I_0 < \infty$ y $0 < I_1 < \infty$,

$$0 < \int_{\Omega} \ell dP_0 < \infty.$$

Para $A \in \mathcal{F}$,

$$Q(A) = \frac{\int_A \ell dP_0}{\int_{\Omega} \ell dP_0}.$$

El numerador satisface

$$\int_A \ell dP_0 = \frac{c_{\ell}}{I_0} \int_A \exp((\eta_0 + \eta_{\ell}) \cdot T(\theta)) d\theta.$$

El denominador satisface

$$\int_{\Omega} \ell dP_0 = \frac{c_{\ell}}{I_0} \int_{\Omega} \exp((\eta_0 + \eta_{\ell}) \cdot T(\theta)) d\theta.$$

Luego

$$Q(A) = \frac{\int_A \exp((\eta_0 + \eta_{\ell}) \cdot T(\theta)) d\theta}{\int_{\Omega} \exp((\eta_0 + \eta_{\ell}) \cdot T(\theta)) d\theta}.$$

Tomando $A = E_i$,

$$Q(E_i) = \frac{\int_{E_i} \exp((\eta_0 + \eta_{\ell}) \cdot T(\theta)) d\theta}{\int_{\Omega} \exp((\eta_0 + \eta_{\ell}) \cdot T(\theta)) d\theta}.$$

Por otra parte,

$$T_{Y^{\ell}}(X_0)_i = \frac{X_{0,i}(1 + Y_i^{\ell})}{\sum_{k=1}^n X_{0,k}(1 + Y_k^{\ell})} = \frac{P_0(E_i)\ell_i}{\sum_{k=1}^n P_0(E_k)\ell_k}.$$

Como

$$P_0(E_i)\ell_i = \int_{E_i} \ell dP_0, \quad \sum_{k=1}^n P_0(E_k)\ell_k = \int_{\Omega} \ell dP_0,$$

se obtiene

$$T_{Y^\ell}(X_0)_i = \frac{\int_{E_i} \ell dP_0}{\int_{\Omega} \ell dP_0} = Q(E_i).$$

Finalmente, la densidad de Q respecto de Lebesgue es

$$q(\theta) = \frac{\exp((\eta_0 + \eta_\ell) \cdot T(\theta))}{\int_{\Omega} \exp((\eta_0 + \eta_\ell) \cdot T(u)) du},$$

de modo que el parámetro natural posterior es

$$\eta_{\text{post}} = \eta_0 + \eta_\ell.$$

□

6.2. Trayectorias Bayesianas

El interés de esta sección es estudiar cómo un estado de creencia sobre un conjunto de hipótesis puede ser guiado deliberadamente hacia un estado destino, y no solamente actualizado de forma pasiva a medida que llega evidencia. La pregunta no es únicamente qué se concluye con la evidencia que se tiene, sino cuál evidencia disponible conviene adoptar cuando ya se tiene en mente un estado al que se quiere llegar.

La manera de hacerlo, en términos generales, es comparar en cada momento las observaciones que están disponibles, ver qué estado produciría cada una si se adoptara, y quedarse con la que más acerca al destino buscado. Repitiendo esta elección paso a paso se obtiene un recorrido que avanza progresivamente hacia ese destino, con un grado de avance medible en cada etapa.

La idea de elegir activamente qué observación adoptar, en vez de recibirla impuesta por un proceso externo, viene de Chernoff (1959): un decisor escoge entre experimentos disponibles para acumular evidencia sobre cuál hipótesis es la verdadera. Naghshvar y Javidi (2013) formalizan esa elección con un criterio explícito de divergencia, pero el destino sigue siendo la certeza sobre la hipótesis verdadera, y el efecto de cada observación es incierto hasta que se realiza. Csiszár (1975), en cambio, sí permite que el destino sea cualquier distribución y no solo una hipótesis verdadera, pero su construcción no tiene observación ni elección activa de por medio: es una proyección geométrica determinista entre distribuciones. Esta sección retoma la elección activa de los dos primeros, pero dirigida hacia un destino arbitrario como en el tercero — sin que ese destino represente la verdad, ni el resultado de elegir una observación sea incierto.

Definición 6.6 (Notación: operador bayesiano inducido por una verosimilitud). *Sea $\ell = (\ell_1, \dots, \ell_n) \in \mathbb{R}_{>0}^n$ un vector de verosimilitudes positivas. Por la Definición 6.3, ℓ determina una corrección global*

$$Y^\ell \in C_{\text{glob}}, \quad 1 + Y_i^\ell := \ell_i, \quad i = 1, \dots, n,$$

y, por la Definición 4.2, el operador informacional global asociado satisface

$$T_{Y^\ell}(X)_i = \frac{X_i \ell_i}{\sum_{k=1}^n X_k \ell_k}, \quad X \in \Delta_n^\circ, \quad i = 1, \dots, n.$$

Por la Proposición 6.1, cuando ℓ proviene de una verosimilitud genuina, $\ell_i = P(E \mid H_i)$, y X es el estado informacional previo asociado a Π_H , el operador $T_{Y^\ell}(X)$ coincide con el posterior bayesiano real $P(H_i \mid E)$. Por brevedad, en esta subsección se escribe $T_\ell := T_{Y^\ell}$.

Definición 6.7 (Objetivo bayesiano interior). Sea

$$\Pi_H = \{H_1, \dots, H_n\}$$

una partición finita de hipótesis, con $n \geq 2$, y sea

$$\Delta_n^\circ = \left\{ X \in \mathbb{R}^n \mid X_i > 0, \sum_{i=1}^n X_i = 1 \right\}.$$

Un objetivo bayesiano interior es un vector

$$\mathcal{P} = (\mathcal{P}_1, \dots, \mathcal{P}_n) \in \Delta_n^\circ$$

interpretado como una distribución objetivo sobre la partición de hipótesis Π_H .

Cada coordenada $\mathcal{P}_i$ representa la masa informacional que se desea asignar a la hipótesis H_i . En particular,

$$\mathcal{P}_i > 0 \quad \text{para todo } i = 1, \dots, n,$$

y

$$\sum_{i=1}^n \mathcal{P}_i = 1.$$

El vector $\mathcal{P}$ no representa una hipótesis individual. Si se quisiera seleccionar únicamente una hipótesis H_j , el vector asociado sería el vértice

$$e_j = (0, \dots, 0, 1, 0, \dots, 0),$$

con la entrada 1 en la posición j . Para $n \geq 2$, dicho vector satisface

$$e_j \notin \Delta_n^\circ,$$

pues posee coordenadas nulas. Por tanto, dentro de la semántica bayesiana interior, el objetivo admisible no es una hipótesis aislada, sino una distribución estrictamente positiva sobre las hipótesis de Π_H .

Corolario 6.2 (Realización bayesiana del paso discreto determinista). Sea

$$\Pi_H = \{H_1, \dots, H_n\}$$

una partición finita de hipótesis, con $n \geq 2$, y sea

$$\Delta_n^\circ = \left\{ X \in \mathbb{R}^n \mid X_i > 0, \sum_{i=1}^n X_i = 1 \right\}.$$

Sean

$$X = (X_1, \dots, X_n) \in \Delta_n^\circ$$

un estado informacional (Definición 6.1), y

$$\mathcal{P} = (\mathcal{P}_1, \dots, \mathcal{P}_n) \in \Delta_n^\circ$$

un objetivo bayesiano interior sobre la misma partición Π_H .

Para $\alpha \in [0, 1]$, defínase

$$\ell^{(\alpha)}(X, \mathcal{P}) = (\ell_1^{(\alpha)}(X, \mathcal{P}), \dots, \ell_n^{(\alpha)}(X, \mathcal{P}))$$

por

$$\ell_i^{(\alpha)}(X, \mathcal{P}) := 1 - \alpha + \alpha \frac{\mathcal{P}_i}{X_i}, \quad i = 1, \dots, n.$$

Entonces

$$\ell^{(\alpha)}(X, \mathcal{P}) \in \mathbb{R}_{>0}^n$$

y la actualización bayesiana inducida por $\ell^{(\alpha)}(X, \mathcal{P})$ satisface

$$T_{\ell^{(\alpha)}(X, \mathcal{P})}(X) = (1 - \alpha)X + \alpha\mathcal{P}.$$

Demostración. Como $X, \mathcal{P} \in \Delta_n^\circ$, se tiene

$$X_i > 0, \quad \mathcal{P}_i > 0, \quad i = 1, \dots, n.$$

Luego

$$\frac{\mathcal{P}_i}{X_i} > 0.$$

Si $\alpha \in [0, 1]$, entonces

$$1 - \alpha \geq 0 \quad \text{y} \quad \alpha \frac{\mathcal{P}_i}{X_i} \geq 0.$$

Además,

$$1 - \alpha + \alpha \frac{\mathcal{P}_i}{X_i} > 0$$

para todo $i = 1, \dots, n$. Por tanto,

$$\ell^{(\alpha)}(X, \mathcal{P}) \in \mathbb{R}_{>0}^n.$$

Defínase

$$Y^*(X, \mathcal{P})_i := \frac{\mathcal{P}_i}{X_i} - 1.$$

Entonces

$$\ell_i^{(\alpha)}(X, \mathcal{P}) = 1 + \alpha Y^*(X, \mathcal{P})_i.$$

Por la equivalencia estructural entre el corrector informacional y el paso discreto inducido, se tiene

$$T_{\ell^{(\alpha)}(X, \mathcal{P})}(X) = T_{\alpha Y^*(X, \mathcal{P})}(X) = (1 - \alpha)X + \alpha\mathcal{P}.$$

□

Observación 6.6 (Selección observacional guiada por el objetivo bayesiano). Sea

$$\Pi_H = \{H_1, \dots, H_n\}$$

una partición finita de hipótesis, y sea

$$\mathcal{P} \in \Delta_n^\circ$$

un objetivo bayesiano interior sobre dicha partición.

En una dinámica bayesiana controlada, el paso siguiente no debe entenderse como la elección libre de un parámetro de relajación. La actualización bayesiana estricta exige que el estado posterior se obtenga a partir de una verosimilitud asociada a información disponible o admisible.

Por ello, dado un estado

$$X_t \in \Delta_n^\circ,$$

el problema natural consiste en comparar observaciones candidatas. Cada observación admisible debe inducir, al menos en sentido algebraico-composicional, un vector de verosimilitudes positivas

$$\ell^{(E)} \in \mathbb{R}_{>0}^n,$$

y por tanto un posterior candidato

$$T_{\ell^{(E)}}(X_t).$$

Así, el criterio de Control Informacional no consiste primero en fijar un número α_t , sino en decidir qué observación conviene seleccionar para aproximar el posterior al objetivo $\mathcal{P}$. El parámetro de avance debe aparecer después, como una medida del efecto que una observación candidata produce sobre la divergencia entre el posterior obtenido y el objetivo bayesiano.

En consecuencia, la dinámica buscada no parte de una interpolación impuesta entre X_t y $\mathcal{P}$, sino de una selección observacional paso a paso:

$$E \longmapsto \ell^{(E)} \longmapsto T_{\ell^{(E)}}(X_t) \longmapsto \text{comparación con } \mathcal{P}.$$

Sólo después de esta comparación tiene sentido hablar de un coeficiente de avance asociado a la observación seleccionada.

Definición 6.8 (Familia observacional admisible y posterior candidato). Sea

$$\Pi_H = \{H_1, \dots, H_n\}$$

una partición finita de hipótesis, y sea

$$\Pi_E$$

una familia de observaciones posibles. Sea

$$X_t \in \Delta_n^\circ$$

un estado informacional en el tiempo t .

Una familia observacional admisible en el tiempo t es un conjunto finito no vacío

$$\mathcal{E}_t \subseteq \Pi_E$$

tal que a cada observación candidata

$$E \in \mathcal{E}_t$$

se le asocia un vector de verosimilitudes positivas

$$\ell_t^{(E)} = (\ell_{t,1}^{(E)}, \dots, \ell_{t,n}^{(E)}) \in \mathbb{R}_{>0}^n.$$

En sentido algebraico-composicional, la condición de admisibilidad queda dada por

$$\ell_t^{(E)} \in \mathbb{R}_{>0}^n.$$

En sentido observacional estricto, se exige además que exista una constante

$$c_E > 0$$

tal que

$$\ell_{t,i}^{(E)} = c_E P(E \mid H_i), \quad i = 1, \dots, n.$$

El posterior candidato inducido por E desde el estado X_t se define por

$$X_t^E := T_{\ell_t^{(E)}}(X_t).$$

Es decir,

$$X_{t,i}^E = \frac{X_{t,i} \ell_{t,i}^{(E)}}{\sum_{k=1}^n X_{t,k} \ell_{t,k}^{(E)}}, \quad i = 1, \dots, n.$$

En el sentido observacional estricto, esta construcción es congruente con la Proposición 6.1: si X_t coincide con el estado informacional previo real, $X_{t,i} = P(H_i)$, entonces $X_{t,i}^E = P(H_i \mid E)$, de modo que el posterior candidato no es solamente un punto del simplex, sino la probabilidad condicional genuina de H_i dada E .

Definición 6.9 (Coeficiente de avance KL). Sea

$$\Pi_H = \{H_1, \dots, H_n\}$$

una partición finita de hipótesis. Para

$$P, Q \in \Delta_n^\circ,$$

se define

$$D_{\text{KL}}(P \parallel Q) := \sum_{i=1}^n P_i \log \frac{P_i}{Q_i}.$$

Sea

$$X_t \in \Delta_n^\circ$$

un estado informacional, sea

$$\mathcal{P} \in \Delta_n^\circ$$

un objetivo bayesiano interior, y supóngase que

$$X_t \neq \mathcal{P}.$$

Sea además

$$\mathcal{E}_t$$

una familia observacional admisible en el tiempo t . Para cada

$$E \in \mathcal{E}_t,$$

sea

$$X_t^E := T_{\ell^{(E)}}(X_t)$$

el posterior candidato inducido por E .

Se define el coeficiente de avance KL de la observación candidata E , relativo al par $(X_t, \mathcal{P})$, por

$$\alpha_{\text{KL}}(E; X_t, \mathcal{P}) := 1 - \frac{D_{\text{KL}}(\mathcal{P} \| X_t^E)}{D_{\text{KL}}(\mathcal{P} \| X_t)}.$$

La interpretación del signo es la siguiente:

$$\alpha_{\text{KL}}(E; X_t, \mathcal{P}) > 0$$

si y sólo si

$$D_{\text{KL}}(\mathcal{P} \| X_t^E) < D_{\text{KL}}(\mathcal{P} \| X_t),$$

es decir, la observación E produce avance hacia $\mathcal{P}$ en divergencia KL.

Asimismo,

$$\alpha_{\text{KL}}(E; X_t, \mathcal{P}) = 0$$

si y sólo si

$$D_{\text{KL}}(\mathcal{P} \| X_t^E) = D_{\text{KL}}(\mathcal{P} \| X_t),$$

es decir, la observación E no produce avance KL.

Finalmente,

$$\alpha_{\text{KL}}(E; X_t, \mathcal{P}) < 0$$

si y sólo si

$$D_{\text{KL}}(\mathcal{P} \| X_t^E) > D_{\text{KL}}(\mathcal{P} \| X_t),$$

es decir, la observación E aleja el posterior candidato del objetivo $\mathcal{P}$ en divergencia KL.

Proposición 6.7 (Elección observacional óptima). Sea

$$\Pi_H = \{H_1, \dots, H_n\}$$

una partición finita de hipótesis. Sean

$$X_t \in \Delta_n^\circ, \quad \mathcal{P} \in \Delta_n^\circ, \quad X_t \neq \mathcal{P}.$$

Sea

$$\mathcal{E}_t$$

una familia observacional admisible finita no vacía en el tiempo t . Para cada

$$E \in \mathcal{E}_t,$$

sea

$$X_t^E := T_{\ell_t^{(E)}}(X_t)$$

el posterior candidato inducido por E .

Entonces una observación

$$E_t^* \in \mathcal{E}_t$$

maximiza el coeficiente de avance KL,

$$E_t^* \in \arg \max_{E \in \mathcal{E}_t} \alpha_{\text{KL}}(E; X_t, \mathcal{P}),$$

si y sólo si minimiza la divergencia KL posterior hacia el objetivo:

$$E_t^* \in \arg \min_{E \in \mathcal{E}_t} D_{\text{KL}}(\mathcal{P} \| X_t^E).$$

Demostración. Como

$$X_t \neq \mathcal{P},$$

y ambos vectores pertenecen a Δ_n° , se tiene

$$D_{\text{KL}}(\mathcal{P} \| X_t) > 0.$$

Por definición del coeficiente de avance KL, para cada

$$E \in \mathcal{E}_t$$

se cumple

$$\alpha_{\text{KL}}(E; X_t, \mathcal{P}) = 1 - \frac{D_{\text{KL}}(\mathcal{P} \| X_t^E)}{D_{\text{KL}}(\mathcal{P} \| X_t)}.$$

El término

$$D_{\text{KL}}(\mathcal{P} \| X_t)$$

no depende de E y es estrictamente positivo. Por tanto, para $E, F \in \mathcal{E}_t$,

$$\alpha_{\text{KL}}(E; X_t, \mathcal{P}) \geq \alpha_{\text{KL}}(F; X_t, \mathcal{P})$$

si y sólo si

$$1 - \frac{D_{\text{KL}}(\mathcal{P} \| X_t^E)}{D_{\text{KL}}(\mathcal{P} \| X_t)} \geq 1 - \frac{D_{\text{KL}}(\mathcal{P} \| X_t^F)}{D_{\text{KL}}(\mathcal{P} \| X_t)}.$$

Restando 1 en ambos lados,

$$-\frac{D_{\text{KL}}(\mathcal{P} \| X_t^E)}{D_{\text{KL}}(\mathcal{P} \| X_t)} \geq -\frac{D_{\text{KL}}(\mathcal{P} \| X_t^F)}{D_{\text{KL}}(\mathcal{P} \| X_t)}.$$

Multiplicando por el número positivo

$$D_{\text{KL}}(\mathcal{P} \| X_t)$$

y cambiando el signo, se obtiene

$$D_{\text{KL}}(\mathcal{P} \| X_t^E) \leq D_{\text{KL}}(\mathcal{P} \| X_t^F).$$

Así, ordenar las observaciones por mayor coeficiente de avance KL es equivalente a ordenarlas por menor divergencia KL posterior.

Como

$$\mathcal{E}_t$$

es finita y no vacía, existen maximizadores y minimizadores. Por la equivalencia anterior, ambos conjuntos coinciden. En consecuencia,

$$E_t^* \in \arg \max_{E \in \mathcal{E}_t} \alpha_{\text{KL}}(E; X_t, \mathcal{P})$$

si y sólo si

$$E_t^* \in \arg \min_{E \in \mathcal{E}_t} D_{\text{KL}}(\mathcal{P} \| X_t^E).$$

□

Definición 6.10 (Trayectoria bayesiana guiada por selección observacional). Sea

$$\Pi_H = \{H_1, \dots, H_n\}$$

una partición finita de hipótesis, y sea

$$\mathcal{P} \in \Delta_n^\circ$$

un objetivo bayesiano interior sobre Π_H . Sea

$$X_0 \in \Delta_n^\circ$$

un estado inicial.

Para cada tiempo

$$t \geq 0,$$

supóngase dada una familia observacional admisible finita no vacía

$$\mathcal{E}_t \subseteq \Pi_E.$$

La trayectoria bayesiana guiada por selección observacional se define recursivamente del siguiente modo.

Si

$$X_t = \mathcal{P},$$

se fija

$$X_{t+1} := \mathcal{P}.$$

Si

$$X_t \neq \mathcal{P},$$

para cada

$$E \in \mathcal{E}_t$$

se considera el posterior candidato

$$X_t^E = T_{\ell_t^{(E)}}(X_t),$$

y se elige una observación

$$E_t^* \in \mathcal{E}_t$$

tal que

$$E_t^* \in \arg \min_{E \in \mathcal{E}_t} D_{\text{KL}}(\mathcal{P} \| X_t^E).$$

Entonces se define

$$X_{t+1} := T_{\ell_t^{(E_t^*)}}(X_t).$$

Equivalente, mientras $X_t \neq \mathcal{P}$, la regla de evolución queda dada por

$$X_{t+1} = X_t^{E_t^*},$$

donde

$$E_t^* \in \arg \min_{E \in \mathcal{E}_t} D_{\text{KL}}(\mathcal{P} \| X_t^E).$$

Así, cada paso de la trayectoria se obtiene por una actualización bayesiana global, y la observación aplicada en el tiempo t es aquella que produce, entre los candidatos admisibles, el posterior más cercano al objetivo bayesiano $\mathcal{P}$ en divergencia KL.

Proposición 6.8 (Disipación y convergencia bajo progreso acumulado). Sea

$$\mathcal{P} \in \Delta_n^\circ$$

un objetivo bayesiano interior, y sea

$$(X_t)_{t \geq 0} \subset \Delta_n^\circ$$

una trayectoria bayesiana guiada por selección observacional.

Para cada $t \geq 0$ tal que

$$X_t \neq \mathcal{P},$$

denótese por

$$E_t^* \in \mathcal{E}_t$$

una observación óptima seleccionada según la regla

$$E_t^* \in \arg \min_{E \in \mathcal{E}_t} D_{\text{KL}}(\mathcal{P} \| X_t^E),$$

y escribase

$$X_{t+1} = T_{\ell_t^{(E_t^*)}}(X_t).$$

Supóngase que existe una sucesión

$$(\eta_t)_{t \geq 0} \subset [0, 1]$$

tal que, para todo $t \geq 0$ con $X_t \neq \mathcal{P}$,

$$\alpha_{\text{KL}}(E_t^*; X_t, \mathcal{P}) \geq \eta_t,$$

y además

$$\prod_{t=0}^{\infty} (1 - \eta_t) = 0.$$

Entonces

$$D_{\text{KL}}(\mathcal{P} \| X_t) \longrightarrow 0.$$

En consecuencia,

$$X_t \longrightarrow \mathcal{P}.$$

Demostración. Defínase

$$D_t := D_{\text{KL}}(\mathcal{P} \| X_t).$$

Si existe $t_0 \geq 0$ tal que

$$X_{t_0} = \mathcal{P},$$

entonces, por definición de la trayectoria,

$$X_t = \mathcal{P} \quad \text{para todo } t \geq t_0.$$

Por tanto,

$$D_t = 0 \quad \text{para todo } t \geq t_0,$$

y la conclusión queda probada.

Supóngase entonces que

$$X_t \neq \mathcal{P} \quad \text{para todo } t \geq 0.$$

Como $\mathcal{P}, X_t \in \Delta_n^\circ$, se tiene

$$D_t > 0 \quad \text{para todo } t \geq 0.$$

Por definición del coeficiente de avance KL,

$$\alpha_{\text{KL}}(E_t^*; X_t, \mathcal{P}) = 1 - \frac{D_{\text{KL}}(\mathcal{P} \| X_{t+1})}{D_{\text{KL}}(\mathcal{P} \| X_t)}.$$

Con la notación $D_t = D_{\text{KL}}(\mathcal{P} \| X_t)$, esto equivale a

$$\alpha_{\text{KL}}(E_t^*; X_t, \mathcal{P}) = 1 - \frac{D_{t+1}}{D_t}.$$

Luego

$$D_{t+1} = (1 - \alpha_{\text{KL}}(E_t^*; X_t, \mathcal{P})) D_t.$$

Por hipótesis,

$$\alpha_{\text{KL}}(E_t^*; X_t, \mathcal{P}) \geq \eta_t.$$

Como $\eta_t \in [0, 1]$, se obtiene

$$1 - \alpha_{\text{KL}}(E_t^*; X_t, \mathcal{P}) \leq 1 - \eta_t.$$

Por tanto,

$$D_{t+1} \leq (1 - \eta_t) D_t.$$

Iterando esta desigualdad desde 0 hasta $t - 1$, se obtiene

$$D_t \leq \left(\prod_{s=0}^{t-1} (1 - \eta_s) \right) D_0.$$

Como

$$\prod_{s=0}^{\infty} (1 - \eta_s) = 0,$$

se sigue que

$$\prod_{s=0}^{t-1} (1 - \eta_s) \longrightarrow 0.$$

En consecuencia,

$$D_t \longrightarrow 0.$$

Es decir,

$$D_{\text{KL}}(\mathcal{P} \| X_t) \longrightarrow 0.$$

Finalmente, por la desigualdad de Pinsker,

$$\|\mathcal{P} - X_t\|_1^2 \leq 2D_{\text{KL}}(\mathcal{P} \| X_t).$$

Como el lado derecho converge a 0, se obtiene

$$\|\mathcal{P} - X_t\|_1 \longrightarrow 0.$$

Por tanto,

$$X_t \longrightarrow \mathcal{P}.$$

□

Ejercicio 6.1 (Priorización secuencial de pruebas para la confirmación de un patógeno causante de un brote). **Contexto**

Un brote respiratorio puede deberse a tres patógenos candidatos, $\Pi_H = \{H_1, H_2, H_3\}$, correspondientes a los patógenos α , β y γ . El estado $X_t \in \Delta_3^\circ$ no representa la verdad biológica sobre la causa del brote, sino el estado de creencia institucional del equipo de vigilancia, actualizado con la evidencia de laboratorio disponible.

Estado previo

La vigilancia histórica fija el estado previo

$$X_0 = (0,50, 0,30, 0,20) \in \Delta_3^\circ.$$

Pruebas disponibles

El laboratorio puede aplicar una sola prueba por día, y el menú disponible cambia según el suministro de reactivos. El universo de pruebas es $\Pi_E = \{\text{I}, \text{II}, \text{III}\}$, cada una caracterizada por estudios de validación previos (sensibilidad frente al patógeno objetivo, reactividad cruzada frente a los otros dos):

$$\ell^{(\text{I})} = (0,8, 0,1, 0,1), \quad \ell^{(\text{II})} = (0,6, 0,3, 0,3), \quad \ell^{(\text{III})} = (0,5, 0,5, 0,1).$$

Disponibilidad diaria

El día 0: $\mathcal{E}_0 = \{I, II\}$. El día 1: se agota el reactivo de I y llega III, $\mathcal{E}_1 = \{II, III\}$.

Criterio de decisión

Sin protocolo estandarizado para ordenar las pruebas, el equipo fija un objetivo interno $\mathcal{P} = (0,96, 0,02, 0,02)$ y aplica cada día la prueba que más reduce

$$D_{KL}(\mathcal{P} \| X_t).$$

Cuando

$$D_{KL}(\mathcal{P} \| X_t) < \delta = 0,01,$$

se prioriza H_1 para remisión a confirmación de referencia.

Pregunta

¿Qué prueba se aplica cada día, cuál es la trayectoria (X_0, X_1, X_2) , y se alcanza el umbral al final del día 1?

Solución. Respuesta

$$E_0^* = I, X_1 = (8/9, 1/15, 2/45) \approx (0,8889, 0,0667, 0,0444), D_{KL}(\mathcal{P} \| X_1) \approx 0,0338.$$

$$E_1^* = II, X_2 = (16/17, 3/85, 2/85) \approx (0,9412, 0,0353, 0,0235), D_{KL}(\mathcal{P} \| X_2) \approx 0,0044 < \delta;$$

H_1 alcanza el umbral al final del día 1.

Verosimilitud ideal

Por el Corolario de realización bayesiana del paso discreto determinista, llegar a $\mathcal{P}$ en un solo paso desde X_0 exigiría la verosimilitud ideal $\ell^{(1)}(X_0, \mathcal{P})_i = \mathcal{P}_i / X_{0,i}$:

$$\ell^{(1)}(X_0, \mathcal{P}) = \left(\frac{0,96}{0,5}, \frac{0,02}{0,3}, \frac{0,02}{0,2} \right) = (1,92, 0,0667, 0,1).$$

Esto no coincide con $\ell^{(I)}$ ni con $\ell^{(II)}$: el salto directo no es admisible en $\mathcal{E}_0$, así que se procede por selección observacional.

Día 0

Con $\mathcal{E}_0 = \{I, II\}$:

$$X_0 \circ \ell^{(I)} = (0,40, 0,03, 0,02), \Sigma = 0,45 \Rightarrow X_0^I = \left(\frac{8}{9}, \frac{1}{15}, \frac{2}{45} \right) \approx (0,8889, 0,0667, 0,0444);$$

$$X_0 \circ \ell^{(II)} = (0,30, 0,09, 0,06), \Sigma = 0,45 \Rightarrow X_0^{II} = \left(\frac{2}{3}, \frac{1}{5}, \frac{2}{15} \right) \approx (0,6667, 0,2, 0,1333).$$

$$D_{KL}(\mathcal{P} \| X_0) = 0,96 \ln(1,92) + 0,02 \ln(0,0667) + 0,02 \ln(0,1) = 0,6262 - 0,0542 - 0,0461 = 0,5260.$$

$$D_{KL}(\mathcal{P} \| X_0^I) = 0,96 \ln(1,08) + 0,02 \ln(0,30) + 0,02 \ln(0,45) = 0,0739 - 0,0241 - 0,0160 = 0,0338.$$

$$D_{KL}(\mathcal{P} \| X_0^{II}) = 0,96 \ln(1,44) + 0,02 \ln(0,10) + 0,02 \ln(0,15) = 0,3501 - 0,0461 - 0,0379 = 0,2661.$$

$$\alpha_{KL}(I) = 1 - \frac{0,0338}{0,5260} = 0,9357, \quad \alpha_{KL}(II) = 1 - \frac{0,2661}{0,5260} = 0,4942.$$

$$E_0^* = I. X_1 := X_0^I = \left(\frac{8}{9}, \frac{1}{15}, \frac{2}{45} \right).$$

Día 1

Con $\mathcal{E}_1 = \{\text{II}, \text{III}\}$:

$$X_1 \circ \ell^{(\text{II})} = \left(\frac{8}{15}, \frac{1}{50}, \frac{1}{75} \right), \quad \Sigma = \frac{17}{30} \Rightarrow X_1^{\text{II}} = \left(\frac{16}{17}, \frac{3}{85}, \frac{2}{85} \right) \approx (0,9412, 0,0353, 0,0235);$$

$$X_1 \circ \ell^{(\text{III})} = \left(\frac{4}{9}, \frac{1}{30}, \frac{1}{225} \right), \quad \Sigma = \frac{217}{450} \Rightarrow X_1^{\text{III}} = \left(\frac{200}{217}, \frac{15}{217}, \frac{2}{217} \right) \approx (0,9217, 0,0691, 0,0092).$$

$$D_{\text{KL}}(\mathcal{P} \| X_1) = 0,0338 \text{ (ya calculada).}$$

$$D_{\text{KL}}(\mathcal{P} \| X_1^{\text{II}}) = 0,96 \ln(1,02) + 0,02 \ln(0,5667) + 0,02 \ln(0,85) = 0,0190 - 0,0114 - 0,0033 = 0,0044.$$

$$D_{\text{KL}}(\mathcal{P} \| X_1^{\text{III}}) = 0,96 \ln(1,0416) + 0,02 \ln(0,2893) + 0,02 \ln(2,17) = 0,0391 - 0,0248 + 0,0155 = 0,0298.$$

$$\alpha_{\text{KL}}(\text{II}) = 1 - \frac{0,0044}{0,0338} = 0,8699, \quad \alpha_{\text{KL}}(\text{III}) = 1 - \frac{0,0298}{0,0338} = 0,1187.$$

$E_1^* = \text{II}$ ($\ell_1^{(\text{III})} = \ell_2^{(\text{III})}$ no separa H_1 de H_2). $X_2 := X_1^{\text{II}} \approx (0,9412, 0,0353, 0,0235)$, $D_{\text{KL}}(\mathcal{P} \| X_2) \approx 0,0044 < \delta$.

Contraste: selección pasiva

Aplicando II el día 0 y III el día 1 sin comparar: $X_0^{\text{II}} = (2/3, 1/5, 2/15)$; luego $X_0^{\text{II}} \circ \ell^{(\text{III})} = (1/3, 1/10, 1/75)$, $\Sigma = 67/150$, da $X_2^{\text{pasiva}} = (50/67, 15/67, 2/67) \approx (0,7463, 0,2239, 0,0299)$, con $D_{\text{KL}}(\mathcal{P} \| X_2^{\text{pasiva}}) \approx 0,1855$: 42 veces más lejos del umbral. La prueba I solo estuvo disponible el día 0; no priorizarla cuesta la oportunidad.

Convergencia

El salto de un solo paso (Corolario, $\alpha = 1$) no era admisible; en su lugar, $\alpha_{\text{KL}}(E_0^*) = 0,9357 \geq 0,85$ y $\alpha_{\text{KL}}(E_1^*) = 0,8699 \geq 0,85$. Con $\eta_t = 0,85$, $\prod_t (1 - \eta_t) = \lim 0,15^t = 0$: el resultado de disipación y convergencia garantiza $X_t \rightarrow \mathcal{P}$ aunque el umbral no se alcance tan rápido en otra realización del proceso. $\square$

7. Sección F — Semántica markoviana

Las Secciones B–E establecieron el marco de CI y su semántica bayesiana. Esta sección identifica, dentro del mismo marco, el caso particular que corresponde al operador de Markov clásico. El resultado estructural central es que las cadenas de Markov entran en CI a través de la Sección B (correcciones locales dependientes del estado), mientras que la actualización bayesiana entra por la Sección C (correcciones globales independientes del estado). Esta asimetría algebraica es la que hace no trivial el problema de ordenamiento del Proyecto II.

Definición 7.1 (Base discreta). Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sea

$$\Pi = \{A_1, \dots, A_n\}$$

una partición medible finita de Ω tal que

$$P(A_i) > 0, \quad i = 1, \dots, n.$$

Identificamos cada celda A_i con el índice i , y escribimos

$$I := \{1, \dots, n\}.$$

Un estado discreto sobre Π es un vector fila

$$X = (X_1, \dots, X_n) \in \Delta_n,$$

donde X_i representa la masa asignada a la celda A_i .

Lema 7.1 (Distribución inducida por una partición finita). Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sea

$$\Pi = \{A_1, \dots, A_n\}$$

una partición medible finita de Ω tal que

$$P(A_i) > 0, \quad i = 1, \dots, n.$$

Defínase

$$X^P = (X_1^P, \dots, X_n^P), \quad X_i^P := P(A_i).$$

Entonces

$$X^P \in \Delta_n^\circ.$$

Demostración. Para cada $i = 1, \dots, n$, por hipótesis,

$$X_i^P = P(A_i) > 0.$$

Además, como Π es una partición de Ω , los conjuntos $A_1, \dots, A_n$ son disjuntos y satisfacen

$$\bigcup_{i=1}^n A_i = \Omega.$$

Por aditividad finita de P ,

$$\sum_{i=1}^n X_i^P = \sum_{i=1}^n P(A_i) = P\left(\bigcup_{i=1}^n A_i\right) = P(\Omega) = 1.$$

Por tanto,

$$X_i^P > 0 \quad (i = 1, \dots, n), \quad \sum_{i=1}^n X_i^P = 1,$$

y en consecuencia

$$X^P \in \Delta_n^\circ.$$

□

Definición 7.2 (Matrices estocásticas por filas). Sea $n \in \mathbb{N}$ y sea

$$I := \{1, \dots, n\}.$$

Se denota por $\mathcal{S}_n$ el conjunto de matrices estocásticas por filas de orden n :

$$\mathcal{S}_n := \left\{ K = (K_{ab})_{a,b=1}^n \in \mathbb{R}^{n \times n} : K_{ab} \geq 0 \ \forall a, b \in I, \quad \sum_{b=1}^n K_{ab} = 1 \ \forall a \in I \right\}.$$

Para $K \in \mathcal{S}_n$, el operador markoviano asociado es

$$M_K : \Delta_n \longrightarrow \mathbb{R}^n, \quad M_K(X) := XK,$$

donde X se considera vector fila y el producto es el producto matricial usual.

Observación 7.1 (Lectura markoviana). Si $K \in \mathcal{S}_n$, entonces para cada $a \in I$ la fila

$$(K_{a1}, \dots, K_{an})$$

es una distribución de probabilidad discreta sobre I . El número K_{ab} se interpreta como la fracción de masa que, en un paso markoviano, se transporta desde el estado a hacia el estado b .

Esta lectura sólo usa la base discreta $I = \{1, \dots, n\}$. En particular, si más adelante una partición de hipótesis se identifica con una base discreta, el mismo operador M_K podrá actuar sobre el simplex asociado a dicha partición.

Proposición 7.1 (El simplex es invariante bajo matrices estocásticas por filas). Sea $K \in \mathcal{S}_n$ y sea $X \in \Delta_n$. Entonces

$$M_K(X) = XK \in \Delta_n.$$

En particular,

$$M_K : \Delta_n \longrightarrow \Delta_n$$

está bien definido.

Demostración. Para cada $b = 1, \dots, n$,

$$(M_K(X))_b = (XK)_b = \sum_{a=1}^n X_a K_{ab}.$$

Como

$$X_a \geq 0 \quad \text{y} \quad K_{ab} \geq 0,$$

se tiene

$$(M_K(X))_b \geq 0.$$

Además,

$$\sum_{b=1}^n (M_K(X))_b = \sum_{b=1}^n \sum_{a=1}^n X_a K_{ab} = \sum_{a=1}^n X_a \sum_{b=1}^n K_{ab}.$$

Como $K \in \mathcal{S}_n$,

$$\sum_{b=1}^n K_{ab} = 1 \quad \text{para todo } a.$$

Luego

$$\sum_{b=1}^n (M_K(X))_b = \sum_{a=1}^n X_a = 1.$$

Por tanto,

$$M_K(X) \in \Delta_n.$$

□

Observación 7.2 (Interior del símplex y dominio de las correcciones locales). *La Proposición 7.1 garantiza*

$$M_K(\Delta_n) \subseteq \Delta_n,$$

pero no garantiza, en general,

$$M_K(\Delta_n^\circ) \subseteq \Delta_n^\circ.$$

Para preservar el interior basta imponer que ninguna columna de K sea nula, es decir, que para cada $b \in I$ exista al menos un $a \in I$ tal que

$$K_{ab} > 0.$$

Esta es precisamente la condición de compatibilidad con el interior del símplex. La condición más fuerte

$$K_{ab} > 0 \quad \forall a, b \in I$$

también preserva el interior, pero no es necesaria.

La corrección local asociada a un paso markoviano se escribirá mediante cocientes de la forma

$$\frac{(XK)_i}{X_i}.$$

Por ello, para definir dicha corrección local se requiere

$$X \in \Delta_n^\circ.$$

Si además se desea que el estado transformado permanezca en Δ_n° , se impondrá explícitamente la compatibilidad de K con el interior del símplex.

Proposición 7.2 (Representación local de un paso markoviano). *Sea $K \in \mathcal{S}_n$ y sea $X \in \Delta_n^\circ$. Defínase*

$$Y_i^K(X) := \frac{(M_K(X))_i}{X_i} - 1, \quad i = 1, \dots, n.$$

Entonces

$$Y^K(X) \in C(X)$$

y

$$T_{Y^K(X)}^{\text{loc}}(X) = M_K(X) = XK.$$

Demostración. Como $X \in \Delta_n^\circ$, se tiene

$$X_i > 0, \quad i = 1, \dots, n.$$

Por tanto, los cocientes

$$\frac{(M_K(X))_i}{X_i}$$

están bien definidos.

Para cada $i = 1, \dots, n$,

$$1 + Y_i^K(X) = \frac{(M_K(X))_i}{X_i}.$$

Multiplicando por X_i , se obtiene

$$X_i(1 + Y_i^K(X)) = (M_K(X))_i.$$

Por la Proposición 7.1,

$$M_K(X) \in \Delta_n.$$

En consecuencia,

$$X_i(1 + Y_i^K(X)) \geq 0 \quad \text{para todo } i,$$

y

$$\sum_{i=1}^n X_i(1 + Y_i^K(X)) = \sum_{i=1}^n (M_K(X))_i = 1.$$

Por definición de $C(X)$,

$$Y^K(X) \in C(X).$$

Además, por definición del operador local,

$$T_{Y^K(X)}^{\text{loc}}(X)_i = X_i(1 + Y_i^K(X)) = (M_K(X))_i.$$

Como esto vale para todo $i = 1, \dots, n$, se concluye que

$$T_{Y^K(X)}^{\text{loc}}(X) = M_K(X) = XK.$$

□

Proposición 7.3 (No globalidad de un operador markoviano no trivial). *Sea $K \in \mathcal{S}_n$. Supóngase que existe un vector*

$$a = (a_1, \dots, a_n) \in \mathbb{R}_{>0}^n$$

tal que

$$T_a(X) = M_K(X) \quad \text{para todo } X \in \Delta_n^\circ,$$

donde

$$T_a(X)_i = \frac{X_i a_i}{\sum_{k=1}^n X_k a_k}.$$

Entonces

$$K = I.$$

En consecuencia, si $K \neq I$, el operador markoviano M_K no puede representarse como un operador global con factor multiplicativo independiente de X .

Demostración. Sea $r \in I$. Tomemos una sucesión

$$(X^{(m)})_{m \geq 1} \subset \Delta_n^\circ$$

tal que

$$X^{(m)} \rightarrow e_r,$$

donde e_r denota el r -ésimo vector canónico.

Por hipótesis,

$$T_a(X^{(m)}) = M_K(X^{(m)}) = X^{(m)}K \quad \text{para todo } m.$$

Para cada $i = 1, \dots, n$,

$$T_a(X^{(m)})_i = \frac{X_i^{(m)}a_i}{\sum_{k=1}^n X_k^{(m)}a_k}.$$

Como $X^{(m)} \rightarrow e_r$, se tiene

$$\sum_{k=1}^n X_k^{(m)}a_k \rightarrow a_r > 0.$$

Además,

$$X_r^{(m)}a_r \rightarrow a_r, \quad X_i^{(m)}a_i \rightarrow 0 \quad (i \neq r).$$

Por tanto,

$$T_a(X^{(m)}) \rightarrow e_r.$$

Por otro lado, como $X \mapsto XK$ es lineal,

$$X^{(m)}K \rightarrow e_rK.$$

Al pasar al límite en

$$T_a(X^{(m)}) = X^{(m)}K,$$

se obtiene

$$e_r = e_rK.$$

Esto significa que la fila r -ésima de K coincide con e_r .

Como $r \in I$ fue arbitrario, todas las filas de K coinciden con las filas correspondientes de la matriz identidad. En consecuencia,

$$K = I.$$

Por tanto, si $K \neq I$, no existe un vector $a \in \mathbb{R}_{>0}^n$ tal que

$$T_a(X) = M_K(X) \quad \text{para todo } X \in \Delta_n^\circ.$$

□

Observación 7.3 (Local frente a global). *La corrección $Y^K(X)$ depende del estado base X . Por tanto, el paso markoviano entra en el formalismo como una corrección local. En cambio, la verosimilitud bayesiana actúa mediante un factor multiplicativo positivo que no depende del estado base; por ello entra como corrección global.*

En términos estructurales, el operador markoviano mezcla coordenadas mediante una matriz estocástica por filas:

$$X \mapsto XK.$$

El operador bayesiano reescala coordenadas por factores positivos y normaliza:

$$X_i \mapsto \frac{X_i \ell_i}{\sum_{k=1}^n X_k \ell_k}.$$

Esta diferencia algebraica es la que permite formular posteriormente el problema de conmutación entre el paso markoviano y la actualización bayesiana.

Definición 7.3 (Distribución estacionaria). Sea $K \in \mathcal{S}_n$. Una distribución $\pi \in \Delta_n^\circ$ se llama estacionaria para K si

$$\pi K = \pi.$$

Equivalente, en términos del operador markoviano M_K , esto significa que

$$M_K(\pi) = \pi.$$

Observación 7.4 (Estacionariedad y corrección local nula). Sea $K \in \mathcal{S}_n$ y sea $\pi \in \Delta_n^\circ$. Entonces π es estacionaria para K si y sólo si

$$Y^K(\pi) = 0.$$

En efecto, para cada $i = 1, \dots, n$,

$$Y_i^K(\pi) = \frac{(M_K(\pi))_i}{\pi_i} - 1 = \frac{(\pi K)_i}{\pi_i} - 1.$$

Como $\pi_i > 0$, se tiene

$$Y_i^K(\pi) = 0 \iff (\pi K)_i = \pi_i.$$

Por tanto,

$$Y^K(\pi) = 0 \iff \pi K = \pi.$$

Así, en el lenguaje local de CI, una distribución estacionaria es un estado cuya corrección markoviana local es nula.

Lema 7.2 (Estacionariedad positiva y compatibilidad con el interior). Sea $K \in \mathcal{S}_n$. Supóngase que existe una distribución estacionaria

$$\pi \in \Delta_n^\circ$$

para K , es decir,

$$\pi K = \pi.$$

Entonces K es compatible con el interior del símplex. En consecuencia,

$$M_K(\Delta_n^\circ) \subseteq \Delta_n^\circ.$$

Demostración. Sea $b \in I$. Como π es estacionaria para K , se tiene

$$\pi K = \pi.$$

Por tanto,

$$\pi_b = (\pi K)_b = \sum_{a=1}^n \pi_a K_{ab}.$$

Como $\pi \in \Delta_n^\circ$, se tiene

$$\pi_b > 0 \quad \text{y} \quad \pi_a > 0 \quad \text{para todo } a \in I.$$

Además, como $K \in \mathcal{S}_n$,

$$K_{ab} \geq 0 \quad \text{para todo } a, b \in I.$$

Si se tuviera

$$K_{ab} = 0 \quad \text{para todo } a \in I,$$

entonces

$$\sum_{a=1}^n \pi_a K_{ab} = 0,$$

lo cual contradice que

$$\pi_b = \sum_{a=1}^n \pi_a K_{ab} > 0.$$

Por tanto, existe al menos un $a \in I$ tal que

$$K_{ab} > 0.$$

Como $b \in I$ fue arbitrario, para cada $b \in I$ existe al menos un $a \in I$ tal que

$$K_{ab} > 0.$$

Así, K es compatible con el interior del símplex.

La inclusión

$$M_K(\Delta_n^\circ) \subseteq \Delta_n^\circ$$

se sigue de la compatibilidad de K con el interior del símplex. □

Proposición 7.4 (Disipación de la divergencia KL hacia la estacionaria). *Sea $K \in \mathcal{S}_n$ y sea $\pi \in \Delta_n^\circ$ una distribución estacionaria para K , es decir,*

$$\pi K = \pi.$$

Defínase

$$E_\pi(X) := D_{\text{KL}}(\pi \| X), \quad X \in \Delta_n^\circ.$$

Entonces, para todo $X \in \Delta_n^\circ$,

$$E_\pi(M_K(X)) = D_{\text{KL}}(\pi \| XK) \leq D_{\text{KL}}(\pi \| X) = E_\pi(X).$$

En particular, un paso markoviano no incrementa la divergencia KL hacia la distribución estacionaria.

Demostración. Sea $X \in \Delta_n^\circ$. Como $\pi \in \Delta_n^\circ$ es estacionaria para K , por el Lema 7.2 se tiene

$$M_K(X) = XK \in \Delta_n^\circ.$$

Por tanto,

$$D_{\text{KL}}(\pi \| XK)$$

está bien definida.

Como $\pi K = \pi$, para cada $j = 1, \dots, n$,

$$\pi_j = (\pi K)_j = \sum_{i=1}^n \pi_i K_{ij}.$$

Además,

$$(XK)_j = \sum_{i=1}^n X_i K_{ij}.$$

Entonces

$$D_{\text{KL}}(\pi \| XK) = \sum_{j=1}^n \pi_j \log \frac{\pi_j}{(XK)_j}.$$

Fijemos $j \in I$. Como $\pi_j > 0$, definimos

$$w_{ij} := \frac{\pi_i K_{ij}}{\pi_j}, \quad i = 1, \dots, n.$$

Entonces

$$w_{ij} \geq 0,$$

y, usando $\pi_j = \sum_i \pi_i K_{ij}$,

$$\sum_{i=1}^n w_{ij} = \frac{1}{\pi_j} \sum_{i=1}^n \pi_i K_{ij} = 1.$$

Además,

$$(XK)_j = \sum_{i=1}^n X_i K_{ij} = \sum_{i=1}^n \pi_i K_{ij} \frac{X_i}{\pi_i} = \pi_j \sum_{i=1}^n w_{ij} \frac{X_i}{\pi_i}.$$

Por tanto,

$$\frac{\pi_j}{(XK)_j} = \left(\sum_{i=1}^n w_{ij} \frac{X_i}{\pi_i} \right)^{-1}.$$

Luego

$$\log \frac{\pi_j}{(XK)_j} = -\log \left(\sum_{i=1}^n w_{ij} \frac{X_i}{\pi_i} \right).$$

Como la función $u \mapsto -\log u$ es convexa en $(0, \infty)$, por la desigualdad de Jensen se obtiene

$$-\log \left(\sum_{i=1}^n w_{ij} \frac{X_i}{\pi_i} \right) \leq \sum_{i=1}^n w_{ij} \left(-\log \frac{X_i}{\pi_i} \right).$$

Es decir,

$$\log \frac{\pi_j}{(XK)_j} \leq \sum_{i=1}^n w_{ij} \log \frac{\pi_i}{X_i}.$$

Multiplicando por π_j ,

$$\pi_j \log \frac{\pi_j}{(XK)_j} \leq \sum_{i=1}^n \pi_i K_{ij} \log \frac{\pi_i}{X_i}.$$

Sumando en j , se obtiene

$$D_{\text{KL}}(\pi \| XK) = \sum_{j=1}^n \pi_j \log \frac{\pi_j}{(XK)_j} \leq \sum_{j=1}^n \sum_{i=1}^n \pi_i K_{ij} \log \frac{\pi_i}{X_i}.$$

Como las sumas son finitas,

$$\sum_{j=1}^n \sum_{i=1}^n \pi_i K_{ij} \log \frac{\pi_i}{X_i} = \sum_{i=1}^n \pi_i \log \frac{\pi_i}{X_i} \sum_{j=1}^n K_{ij}.$$

Como $K \in \mathcal{S}_n$,

$$\sum_{j=1}^n K_{ij} = 1 \quad \text{para todo } i.$$

Por tanto,

$$D_{\text{KL}}(\pi \| XK) \leq \sum_{i=1}^n \pi_i \log \frac{\pi_i}{X_i} = D_{\text{KL}}(\pi \| X).$$

En consecuencia,

$$E_\pi(M_K(X)) \leq E_\pi(X).$$

□

Proposición 7.5 (Trayectoria markoviana como trayectoria local de CI). *Sea $K \in \mathcal{S}_n$ y sea $X_0 \in \Delta_n$. Defínase la trayectoria discreta*

$$X_{t+1} := M_K(X_t) = X_t K, \quad t \geq 0.$$

Entonces

$$X_t \in \Delta_n \quad \text{para todo } t \geq 0,$$

y

$$X_t = X_0 K^t \quad \text{para todo } t \geq 0.$$

Además, si $X_t \in \Delta_n^\circ$, entonces el paso $X_t \mapsto X_{t+1}$ admite la representación local

$$X_{t+1} = T_{Y^K(X_t)}^{\log}(X_t).$$

En particular, si $X_0 \in \Delta_n^\circ$ y K es compatible con el interior del simplex, entonces

$$X_t \in \Delta_n^\circ \quad \text{para todo } t \geq 0,$$

y cada paso de la trayectoria es una corrección local de CI.

Demostración. Primero probamos que $X_t \in \Delta_n$ para todo $t \geq 0$. Para $t = 0$, esto se cumple por hipótesis, pues

$$X_0 \in \Delta_n.$$

Supóngase ahora que

$$X_t \in \Delta_n.$$

Como $K \in \mathcal{S}_n$, por la Proposición 7.1 se tiene

$$M_K(X_t) = X_t K \in \Delta_n.$$

Por definición de la trayectoria,

$$X_{t+1} = X_t K,$$

luego

$$X_{t+1} \in \Delta_n.$$

Por inducción,

$$X_t \in \Delta_n \quad \text{para todo } t \geq 0.$$

Probamos ahora la forma cerrada. Para $t = 0$,

$$X_0 = X_0 K^0.$$

Supóngase que

$$X_t = X_0 K^t.$$

Entonces

$$X_{t+1} = X_t K = (X_0 K^t) K = X_0 K^{t+1}.$$

Por inducción,

$$X_t = X_0 K^t \quad \text{para todo } t \geq 0.$$

Si $X_t \in \Delta_n^\circ$, entonces, por la Proposición 7.2,

$$M_K(X_t) = T_{Y^K(X_t)}^{\text{loc}}(X_t).$$

Como

$$X_{t+1} = M_K(X_t),$$

se obtiene

$$X_{t+1} = T_{Y^K(X_t)}^{\text{loc}}(X_t).$$

Finalmente, supóngase que $X_0 \in \Delta_n^\circ$ y que K es compatible con el interior del símplex. En ese caso,

$$M_K(\Delta_n^\circ) \subseteq \Delta_n^\circ.$$

Como $X_0 \in \Delta_n^\circ$, se sigue por inducción que

$$X_t \in \Delta_n^\circ \quad \text{para todo } t \geq 0.$$

Por lo demostrado en el párrafo anterior, cada paso de la trayectoria admite la representación local

$$X_{t+1} = T_{Y^K(X_t)}^{\text{loc}}(X_t).$$

□

Observación 7.5 (Primitividad y convergencia a equilibrio). *La disipación de la divergencia KL hacia una distribución estacionaria no implica, por sí sola, la convergencia de la trayectoria markoviana hacia dicha distribución. Para obtener convergencia se requiere una hipótesis dinámica adicional sobre la matriz de transición.*

Una condición suficiente estándar es la primitividad: se dirá que $K \in \mathcal{S}_n$ es primitiva si existe $m \geq 1$ tal que

$$(K^m)_{ij} > 0 \quad \text{para todo } i, j \in I.$$

Bajo esta hipótesis, el teorema de Perron–Frobenius para matrices estocásticas finitas garantiza la existencia de una única distribución estacionaria

$$\pi \in \Delta_n^\circ$$

y la convergencia

$$K^t \longrightarrow \mathbf{1}\pi, \quad t \rightarrow \infty,$$

donde $\mathbf{1}\pi$ denota la matriz cuyas filas son todas iguales a π .

En consecuencia, si $X_0 \in \Delta_n$, entonces

$$X_0 K^t \longrightarrow X_0(\mathbf{1}\pi) = \pi.$$

La proposición siguiente incorpora esta convergencia al lenguaje de trayectorias informacionales.

Proposición 7.6 (Convergencia hacia la estacionaria bajo primitividad). Sea $K \in \mathcal{S}_n$ una matriz primitiva, es decir, supóngase que existe $m \geq 1$ tal que

$$(K^m)_{ij} > 0 \quad \text{para todo } i, j \in I.$$

Entonces existe una única distribución estacionaria

$$\pi \in \Delta_n^\circ$$

para K .

Sea $X_0 \in \Delta_n^\circ$ y defínase la trayectoria markoviana

$$X_{t+1} := M_K(X_t) = X_t K, \quad t \geq 0.$$

Entonces

$$X_t \longrightarrow \pi \quad \text{cuando } t \rightarrow \infty.$$

Además, si

$$E_\pi(X) := D_{\text{KL}}(\pi \| X),$$

entonces

$$E_\pi(X_{t+1}) \leq E_\pi(X_t) \quad \text{para todo } t \geq 0,$$

y

$$\lim_{t \rightarrow \infty} E_\pi(X_t) = 0.$$

Demostración. Como K es primitiva, por la Observación 7.5 existe una única distribución estacionaria

$$\pi \in \Delta_n^\circ$$

y se tiene

$$K^t \longrightarrow \mathbf{1}\pi.$$

Por la Proposición 7.5, la trayectoria satisface

$$X_t = X_0 K^t \quad \text{para todo } t \geq 0.$$

Por tanto,

$$X_t = X_0 K^t \longrightarrow X_0(\mathbf{1}\pi).$$

Como $X_0 \in \Delta_n$, se tiene

$$\sum_{i=1}^n X_{0,i} = 1.$$

Luego

$$X_0(\mathbf{1}\pi) = \left(\sum_{i=1}^n X_{0,i} \right) \pi = \pi.$$

Así,

$$X_t \longrightarrow \pi.$$

Ahora, como $\pi \in \Delta_n^\circ$ es estacionaria para K , por la Proposición 7.4 se tiene, para todo $t \geq 0$,

$$D_{\text{KL}}(\pi \| X_{t+1}) = D_{\text{KL}}(\pi \| X_t K) \leq D_{\text{KL}}(\pi \| X_t).$$

Es decir,

$$E_\pi(X_{t+1}) \leq E_\pi(X_t).$$

Finalmente, como $X_t \rightarrow \pi$ y $X_t \in \Delta_n^\circ$ para todo $t \geq 0$, por continuidad de la divergencia KL en el interior del simplex se obtiene

$$\lim_{t \rightarrow \infty} E_\pi(X_t) = \lim_{t \rightarrow \infty} D_{\text{KL}}(\pi \| X_t) = D_{\text{KL}}(\pi \| \pi) = 0.$$

□

8. Sección G – Control Óptimo Informacional y Defecto de Ordenamiento

Comparación de órdenes Bayes–Markov

El propósito de esta sección es comparar dos formas naturales de componer una corrección markoviana y una corrección bayesiana sobre un mismo estado informacional. En un orden se aplica primero la dinámica markoviana y después la actualización bayesiana; en el otro, se actualiza primero por Bayes y después se propaga por Markov. Aunque ambas operaciones están definidas sobre el mismo símplex, en general no producen el mismo estado terminal.

La diferencia entre estos dos órdenes será medida en términos de sus funciones de acción–valor. El objetivo formal de la sección es obtener una cota de la forma

$$\left| Q_{\tau}^{M \rightarrow B}(X; K, L) - Q_{\tau}^{B \rightarrow M}(X; K, L) \right| = C_{\tau} (\|\Gamma_{K,L}(X)\|_1 + \|\mathcal{D}_{K,L}(X)\|_1),$$

donde $\Gamma_{K,L}(X)$ mide el desacoplamiento de primer paso entre la propagación markoviana y la corrección bayesiana, mientras que $\mathcal{D}_{K,L}(X)$ mide el defecto producido por cambiar el orden de composición.

Para que esta comparación sea estable, no basta con definir las dos composiciones de manera puntual. Es necesario trabajar en clases de operadores y ventanas de estados donde las constantes de regularidad sean uniformes. La positividad de los kernels markovianos evita pérdidas abruptas de soporte; las ventanas interiores del símplex evitan singularidades del funcional logarítmico; y las cotas sobre las verosimilitudes permiten controlar de forma uniforme las correcciones bayesianas. La siguiente definición fija precisamente ese marco admisible.

Definición 8.1 (Clases admisibles y ventanas de control). *Sea $n \geq 2$ y sea $I := \{1, \dots, n\}$. Denotamos por*

$$\mathcal{S}_n := \left\{ K = (K_{ab})_{a,b=1}^n \in \mathbb{R}^{n \times n} : K_{ab} \geq 0 \ \forall a, b \in I, \quad \sum_{b=1}^n K_{ab} = 1 \ \forall a \in I \right\}$$

el conjunto de matrices estocásticas por filas.

Para $0 < \varepsilon \leq 1/n$, definimos

$$\mathcal{K}_{\varepsilon} := \{ K \in \mathcal{S}_n : K_{ab} \geq \varepsilon \ \forall a, b \in I \}.$$

Los elementos de $\mathcal{K}_{\varepsilon}$ serán llamados kernels markovianos admisibles.

Para $R > 0$, definimos la ventana logarítmica

$$\mathcal{U}_R := \{ u \in \mathbb{R}^n : \|u\|_{\infty} \leq R \}.$$

A partir de ella, definimos la clase de verosimilitudes admisibles

$$\mathcal{L}_R := \{ L \in \mathbb{R}_{>0}^n : \log L \in \mathcal{U}_R \},$$

donde

$$\log L := (\log L_1, \dots, \log L_n).$$

Equivalentemente,

$$e^{-R} \leq L_i \leq e^R, \quad i = 1, \dots, n.$$

Observación 8.1 (Recordatorio probabilístico del operador bayesiano). *En la Sección E se mostró que, cuando L proviene de un vector de verosimilitudes asociado a una observación E_j , la aplicación*

$$X_i \mapsto \frac{X_i L_i}{\sum_{k=1}^n X_k L_k}$$

coincide con la actualización posterior $P(H_i \mid E_j)$. En esta sección sólo usaremos esta misma fórmula como una transformación del simplex, restringida a verosimilitudes uniformemente controladas.

Definición 8.2 (Corrección bayesiana admisible global). *Sea $R > 0$ y sea $L \in \mathcal{L}_R$. La corrección bayesiana admisible asociada a L es la aplicación global*

$$B_L : \Delta_n^\circ \longrightarrow \Delta_n^\circ$$

definida, para cada $X \in \Delta_n^\circ$, por

$$B_L(X)_a := \frac{X_a L_a}{\langle X, L \rangle}, \quad a = 1, \dots, n,$$

donde

$$\langle X, L \rangle := \sum_{r=1}^n X_r L_r.$$

La llamaremos global porque la normalización depende simultáneamente de todas las coordenadas de X .

Definición 8.3 (Corrección markoviana admisible local). *Sea $0 < \varepsilon \leq 1/n$ y sea $K \in \mathcal{K}_\varepsilon$. Para cada $X \in \Delta_n^\circ$, la corrección markoviana asociada a K está dada por*

$$M_K(X) := XK.$$

En coordenadas,

$$M_K(X)_b = \sum_{a=1}^n X_a K_{ab}, \quad b = 1, \dots, n.$$

Su representación local alrededor de X se obtiene mediante el campo

$$Y_b^K(X) := \frac{(XK)_b}{X_b} - 1, \quad b = 1, \dots, n.$$

Con la notación de campos locales introducida previamente en el documento, este campo pertenece a $C(X)$ y satisface

$$T_{Y^K(X)}^{\text{loc}}(X) = XK.$$

Por tanto, M_K se puede leer como una corrección local alrededor del estado desde el cual se aplica.

Observación 8.2 (Base común e interpretación global–local del orden $B \rightarrow M$). Las composiciones $B \rightarrow M$ y $M \rightarrow B$ requieren una base probabilística común [Norris, 1997, Sprungk, 2020]. En este marco, el estado inicial no se interpreta sólo como un vector abstracto del símplex, sino como la ley discreta inducida por una variable aleatoria finita.

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad y sea

$$Z_0 : \Omega \longrightarrow I, \quad I := \{1, \dots, n\},$$

una variable aleatoria discreta. Escribimos

$$H_a^{(0)} := \{Z_0 = a\}, \quad a = 1, \dots, n.$$

Si

$$\mathbb{P}(H_a^{(0)}) > 0, \quad a = 1, \dots, n,$$

entonces la ley de Z_0 define el estado interior

$$X = (X_1, \dots, X_n) \in \Delta_n^\circ, \quad X_a := \mathbb{P}(Z_0 = a).$$

Un kernel $K \in \mathcal{S}_n$ tiene lectura markoviana cuando sus entradas se interpretan como

$$K_{ab} = \mathbb{P}(Z_1 = b \mid Z_0 = a), \quad a, b \in I.$$

Por otra parte, una observación finita en el tiempo t se modela mediante una variable

$$O_t : \Omega \longrightarrow \mathcal{E}, \quad \mathcal{E} := \{e_1, \dots, e_m\}.$$

Para cada $e_j \in \mathcal{E}$, denotamos

$$E_j^{(t)} := \{O_t = e_j\}.$$

De acuerdo con la Definición 8.2, la parte bayesiana actúa como una corrección global del estado. En cambio, de acuerdo con la Definición 8.3, la parte markoviana admite una representación local alrededor del estado sobre el cual se aplica.

Así, el orden $B \rightarrow M$ significa primero filtrar la ley de Z_0 con una observación en $t = 0$ y después propagar localmente la ley posterior por K :

$$\text{filtrar la ley de } Z_0 \text{ con } E_j^{(0)} \longrightarrow \text{propagar localmente la ley posterior por } K.$$

El orden $M \rightarrow B$, que será considerado después, invierte estos pasos: primero propaga la ley de Z_0 hacia Z_1 y luego aplica la corrección bayesiana sobre la ley propagada.

Proposición 8.1 (Composición efectiva del orden $B \rightarrow M$). En el marco de la Observación 8.2, supóngase que $K \in \mathcal{K}_\varepsilon$ satisface

$$K_{ab} = \mathbb{P}(Z_1 = b \mid Z_0 = a), \quad a, b \in I.$$

Fíjese una observación $e_j \in \mathcal{E}$ en el tiempo $t = 0$, y escribamos

$$L_a := \mathbb{P}(O_0 = e_j \mid Z_0 = a), \quad a = 1, \dots, n.$$

Supóngase que $L = (L_1, \dots, L_n) \in \mathcal{L}_R$ y que la observación previa no altera la transición condicionada al estado:

$$\mathbb{P}(Z_1 = b \mid Z_0 = a, O_0 = e_j) = \mathbb{P}(Z_1 = b \mid Z_0 = a), \quad a, b \in I.$$

Si

$$X_a^B := \mathbb{P}(Z_0 = a \mid O_0 = e_j), \quad a = 1, \dots, n,$$

entonces

$$X^B = B_L(X).$$

Además, la ley de Z_1 condicionada por la observación $O_0 = e_j$ está dada por

$$\mathbb{P}(Z_1 = b \mid O_0 = e_j) = \left(B_L(X)K \right)_b, \quad b = 1, \dots, n.$$

Finalmente,

$$Y^K(X^B) \in C(X^B)$$

y

$$T_{Y^K(X^B)}^{\text{loc}}(X^B) = B_L(X)K.$$

Por tanto, el orden $B \rightarrow M$ se realiza como una corrección bayesiana global seguida de una corrección markoviana local:

$$X \mapsto B_L(X) \mapsto T_{Y^K(B_L(X))}^{\text{loc}}(B_L(X)).$$

Demostración. Primero verificamos la actualización bayesiana. Como $X_a = \mathbb{P}(Z_0 = a) > 0$ y los eventos $\{Z_0 = a\}$ forman una partición finita, se tiene $X \in \Delta_n^\circ$. Además,

$$\mathbb{P}(O_0 = e_j) = \sum_{r=1}^n \mathbb{P}(Z_0 = r) \mathbb{P}(O_0 = e_j \mid Z_0 = r) = \sum_{r=1}^n X_r L_r.$$

Como $L \in \mathcal{L}_R$, todas sus coordenadas son positivas; por tanto, $\mathbb{P}(O_0 = e_j) > 0$. Por la fórmula de Bayes,

$$X_a^B = \mathbb{P}(Z_0 = a \mid O_0 = e_j) = \frac{\mathbb{P}(Z_0 = a) \mathbb{P}(O_0 = e_j \mid Z_0 = a)}{\mathbb{P}(O_0 = e_j)}.$$

Sustituyendo las definiciones de X y L , obtenemos

$$X_a^B = \frac{X_a L_a}{\sum_{r=1}^n X_r L_r} = B_L(X)_a.$$

Así,

$$X^B = B_L(X).$$

Ahora calculamos la ley de Z_1 condicionada por la observación previa. Por probabilidad total condicionada,

$$\mathbb{P}(Z_1 = b \mid O_0 = e_j) = \sum_{a=1}^n \mathbb{P}(Z_1 = b \mid Z_0 = a, O_0 = e_j) \mathbb{P}(Z_0 = a \mid O_0 = e_j).$$

Usando la hipótesis de compatibilidad entre la observación previa y la transición,

$$\mathbb{P}(Z_1 = b \mid Z_0 = a, O_0 = e_j) = \mathbb{P}(Z_1 = b \mid Z_0 = a) = K_{ab}.$$

Además, $\mathbb{P}(Z_0 = a \mid O_0 = e_j) = X_a^B$. Por tanto,

$$\mathbb{P}(Z_1 = b \mid O_0 = e_j) = \sum_{a=1}^n X_a^B K_{ab} = (X^B K)_b.$$

Como $X^B = B_L(X)$, se sigue que

$$\mathbb{P}(Z_1 = b \mid O_0 = e_j) = (B_L(X)K)_b.$$

Finalmente verificamos la representación local del paso markoviano. Como $X^B = B_L(X) \in \Delta_n^\circ$, el campo

$$Y_b^K(X^B) = \frac{(X^B K)_b}{X_b^B} - 1$$

está bien definido. Por definición,

$$X_b^B (1 + Y_b^K(X^B)) = (X^B K)_b.$$

Como $K \in \mathcal{K}_\varepsilon \subset \mathcal{S}_n$, el vector $X^B K$ pertenece al simplex. De aquí se obtiene

$$X_b^B (1 + Y_b^K(X^B)) \geq 0, \quad b = 1, \dots, n,$$

y

$$\sum_{b=1}^n X_b^B (1 + Y_b^K(X^B)) = \sum_{b=1}^n (X^B K)_b = 1.$$

Por definición de $C(X^B)$,

$$Y^K(X^B) \in C(X^B).$$

Además, por definición del operador local,

$$T_{Y^K(X^B)}^{\text{loc}}(X^B)_b = X_b^B (1 + Y_b^K(X^B)) = (X^B K)_b.$$

Así,

$$T_{Y^K(X^B)}^{\text{loc}}(X^B) = X^B K = B_L(X)K.$$

Esto prueba la composición efectiva del orden $B \rightarrow M$. □

Observación 8.3 (Sentido Markov–Bayes). *El orden Markov–Bayes no usa la observación para corregir la ley inicial. Primero forma la ley predictiva del estado siguiente mediante el operador markoviano. Esta lectura coincide con la descripción de una cadena de Markov por su ley inicial y su matriz de transición, y con la acción del operador markoviano sobre medidas de probabilidad representadas como vectores fila [Norris, 1997, Gaubert and Qu, 2014].*

La actualización bayesiana posterior se aplica después a la ley de Z_1 . En la terminología bayesiana, se actualiza una distribución predictiva mediante una verosimilitud asociada al dato

observado, y se obtiene una distribución posterior sobre los estados posibles después de observar [Sprungk, 2020]. Por tanto, el orden Markov–Bayes tiene la lectura

$$\text{predecir la ley de } Z_1 \text{ por } K \longrightarrow \text{filtrar } Z_1 \text{ con } E_j^{(1)}.$$

Si el mecanismo observacional es homogéneo en el tiempo, el mismo vector $\ell^{(j)}$ puede emplearse antes o después del paso markoviano. Si el mecanismo cambia con el tiempo, las dos composiciones deben escribirse con verosimilitudes distintas.

Proposición 8.2 (Composición Markov–Bayes sobre una cadena observada). Sea $I = \{1, \dots, n\}$. Sean $Z_0, Z_1 : \Omega \rightarrow I$ variables aleatorias sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$. Supóngase que

$$X_a := \mathbb{P}(Z_0 = a) > 0, \quad a = 1, \dots, n,$$

y que Z_0, Z_1 forman un paso markoviano con núcleo $K \in \mathcal{K}_\varepsilon$, es decir,

$$\mathbb{P}(Z_1 = b \mid Z_0 = a) = K_{ab}, \quad a, b \in I.$$

Sea $O_1 : \Omega \rightarrow \mathcal{E}$, con $\mathcal{E} = \{e_1, \dots, e_m\}$, una observación emitida desde Z_1 . Fíjese $e_j \in \mathcal{E}$ y supóngase que

$$\ell_b^{(j)} := \mathbb{P}(O_1 = e_j \mid Z_1 = b) > 0, \quad b = 1, \dots, n.$$

Defínase

$$X^M := XK, \quad X_b^M = \sum_{a=1}^n X_a K_{ab}.$$

Entonces $X^M \in \Delta_n^\circ$. La ley de Z_1 condicionada por la observación posterior $O_1 = e_j$ está dada por

$$\mathbb{P}(Z_1 = b \mid O_1 = e_j) = B_{\ell^{(j)}}(XK)_b, \quad b = 1, \dots, n.$$

Además, si

$$Y_b^K(X) := \frac{(XK)_b}{X_b} - 1, \quad b = 1, \dots, n,$$

entonces

$$Y^K(X) \in C(X), \quad T_{Y^K(X)}^{\text{loc}}(X) = XK,$$

y

$$B_{\ell^{(j)}}(T_{Y^K(X)}^{\text{loc}}(X)) = B_{\ell^{(j)}}(XK).$$

Demostración. Como $X_a = \mathbb{P}(Z_0 = a) > 0$ para todo a y los eventos $\{Z_0 = a\}$ forman una partición de Ω , se tiene

$$\sum_{a=1}^n X_a = \sum_{a=1}^n \mathbb{P}(Z_0 = a) = \mathbb{P}(\Omega) = 1.$$

Por tanto,

$$X \in \Delta_n^\circ.$$

Primero se calcula la ley predictiva de Z_1 . Para cada $b \in I$, la fórmula de probabilidad total da

$$\mathbb{P}(Z_1 = b) = \sum_{a=1}^n \mathbb{P}(Z_0 = a) \mathbb{P}(Z_1 = b \mid Z_0 = a).$$

Usando la ley inicial y el núcleo de transición,

$$\mathbb{P}(Z_1 = b) = \sum_{a=1}^n X_a K_{ab} = (XK)_b = X_b^M.$$

Como $K \in \mathcal{K}_\varepsilon$, para cada b se tiene

$$X_b^M = \sum_{a=1}^n X_a K_{ab} \geq \sum_{a=1}^n X_a \varepsilon = \varepsilon.$$

Además,

$$\sum_{b=1}^n X_b^M = \sum_{b=1}^n \sum_{a=1}^n X_a K_{ab} = \sum_{a=1}^n X_a \sum_{b=1}^n K_{ab} = \sum_{a=1}^n X_a = 1.$$

Luego

$$X^M \in \Delta_n^\circ.$$

Como $X_b > 0$ para todo b , el campo

$$Y_b^K(X) = \frac{(XK)_b}{X_b} - 1$$

está bien definido. Además,

$$1 + Y_b^K(X) = \frac{(XK)_b}{X_b}.$$

Multiplicando por X_b ,

$$X_b(1 + Y_b^K(X)) = (XK)_b.$$

Cada coordenada del lado derecho es no negativa y

$$\sum_{b=1}^n X_b(1 + Y_b^K(X)) = \sum_{b=1}^n (XK)_b = 1.$$

Por definición de $C(X)$,

$$Y^K(X) \in C(X).$$

Por definición del operador local,

$$T_{Y^K(X)}^{\text{loc}}(X)_b = X_b(1 + Y_b^K(X)) = (XK)_b.$$

Así,

$$T_{Y^K(X)}^{\text{loc}}(X) = XK = X^M.$$

Ahora se actualiza la ley predictiva X^M mediante la observación $O_1 = e_j$. Por la fórmula de Bayes,

$$\mathbb{P}(Z_1 = b \mid O_1 = e_j) = \frac{\mathbb{P}(Z_1 = b)\mathbb{P}(O_1 = e_j \mid Z_1 = b)}{\mathbb{P}(O_1 = e_j)}.$$

Como los eventos $\{Z_1 = r\}$ forman una partición,

$$\mathbb{P}(O_1 = e_j) = \sum_{r=1}^n \mathbb{P}(Z_1 = r)\mathbb{P}(O_1 = e_j \mid Z_1 = r).$$

Sustituyendo

$$\mathbb{P}(Z_1 = r) = X_r^M \quad \text{y} \quad \mathbb{P}(O_1 = e_j \mid Z_1 = r) = \ell_r^{(j)},$$

se obtiene

$$\mathbb{P}(O_1 = e_j) = \sum_{r=1}^n X_r^M \ell_r^{(j)} > 0.$$

Por tanto,

$$\mathbb{P}(Z_1 = b \mid O_1 = e_j) = \frac{X_b^M \ell_b^{(j)}}{\sum_{r=1}^n X_r^M \ell_r^{(j)}}.$$

Como $X^M = XK$, esta identidad se escribe

$$\mathbb{P}(Z_1 = b \mid O_1 = e_j) = \frac{(XK)_b \ell_b^{(j)}}{\sum_{r=1}^n (XK)_r \ell_r^{(j)}}.$$

Por definición del operador bayesiano,

$$B_{\ell^{(j)}}(XK)_b = \frac{(XK)_b \ell_b^{(j)}}{\sum_{r=1}^n (XK)_r \ell_r^{(j)}}.$$

Luego

$$\mathbb{P}(Z_1 = b \mid O_1 = e_j) = B_{\ell^{(j)}}(XK)_b.$$

Finalmente, como

$$T_{Y^K(X)}^{\text{loc}}(X) = XK,$$

se tiene

$$B_{\ell^{(j)}}(T_{Y^K(X)}^{\text{loc}}(X)) = B_{\ell^{(j)}}(XK).$$

□

Proposición 8.3 (Conmutación global bajo positividad uniforme). Sea $n \geq 2$. Sea $K \in \mathcal{K}_\varepsilon$ y sea $L \in \mathbb{R}_{>0}^n$. Entonces las siguientes afirmaciones son equivalentes:

$$B_L(XK) = B_L(X)K \quad \text{para todo } X \in \Delta_n^\circ,$$

y

$$L_1 = L_2 = \cdots = L_n.$$

En particular, bajo positividad uniforme de K , las composiciones Markov–Bayes y Bayes–Markov coinciden globalmente si y sólo si la verosimilitud no distingue coordenadas.

Demostración. Supóngase primero que

$$L_1 = L_2 = \cdots = L_n.$$

Entonces existe $c > 0$ tal que

$$L = c\mathbf{1}.$$

Para todo $X \in \Delta_n^\circ$ y todo $i = 1, \dots, n$, se tiene

$$B_L(X)_i = \frac{X_i L_i}{\sum_{r=1}^n X_r L_r} = \frac{X_i c}{\sum_{r=1}^n X_r c} = \frac{X_i c}{c \sum_{r=1}^n X_r} = X_i.$$

Por tanto,

$$B_L(X) = X \quad \text{para todo } X \in \Delta_n^\circ.$$

Como $K \in \mathcal{K}_\varepsilon \subset \mathcal{S}_n$, se tiene $XK \in \Delta_n^\circ$. Aplicando la identidad anterior también al estado XK , resulta

$$B_L(XK) = XK.$$

Además,

$$B_L(X)K = XK.$$

En consecuencia,

$$B_L(XK) = B_L(X)K \quad \text{para todo } X \in \Delta_n^\circ.$$

Recíprocamente, supóngase que

$$B_L(XK) = B_L(X)K \quad \text{para todo } X \in \Delta_n^\circ.$$

Fijemos $a \in \{1, \dots, n\}$. Sea $(X^{(m)})_{m \geq 1} \subset \Delta_n^\circ$ una sucesión tal que

$$X^{(m)} \longrightarrow e_a,$$

donde e_a denota el a -ésimo vector canónico. Por ejemplo, puede tomarse

$$X^{(m)} = \left(1 - \frac{n-1}{m}\right) e_a + \frac{1}{m} \sum_{\substack{r=1 \\ r \neq a}}^n e_r$$

para $m > n-1$.

Como $L \in \mathbb{R}_{>0}^n$, la aplicación

$$X \longmapsto B_L(X) = \left(\frac{X_i L_i}{\sum_{r=1}^n X_r L_r} \right)_{i=1}^n$$

es continua en todo Δ_n , pues

$$\sum_{r=1}^n X_r L_r > 0 \quad \text{para todo } X \in \Delta_n.$$

Por tanto,

$$B_L(X^{(m)}) \longrightarrow B_L(e_a).$$

Ahora bien,

$$B_L(e_a)_i = \frac{(e_a)_i L_i}{\sum_{r=1}^n (e_a)_r L_r}.$$

Si $i \neq a$, entonces $(e_a)_i = 0$, y si $i = a$, entonces

$$B_L(e_a)_a = \frac{L_a}{L_a} = 1.$$

Luego

$$B_L(e_a) = e_a.$$

De aquí,

$$B_L(X^{(m)}) \longrightarrow e_a.$$

Por linealidad de la multiplicación por K ,

$$B_L(X^{(m)})K \longrightarrow e_a K.$$

Además,

$$X^{(m)}K \longrightarrow e_a K.$$

La continuidad de B_L en Δ_n implica entonces

$$B_L(X^{(m)}K) \longrightarrow B_L(e_a K).$$

Usando la hipótesis de conmutación en $X^{(m)}$,

$$B_L(X^{(m)}K) = B_L(X^{(m)})K \quad \text{para todo } m.$$

Al pasar al límite se obtiene

$$B_L(e_a K) = e_a K.$$

Escribamos

$$k^{(a)} := e_a K = (K_{a1}, \dots, K_{an}),$$

la fila a -ésima de K . Como $K \in \mathcal{K}_\varepsilon$, se tiene

$$K_{ab} \geq \varepsilon > 0 \quad \text{para todo } b = 1, \dots, n.$$

La igualdad

$$B_L(e_a K) = e_a K$$

equivale, coordenada a coordenada, a

$$\frac{K_{ab}L_b}{\sum_{r=1}^n K_{ar}L_r} = K_{ab}, \quad b = 1, \dots, n.$$

Como $K_{ab} > 0$, se puede dividir entre K_{ab} , y queda

$$\frac{L_b}{\sum_{r=1}^n K_{ar}L_r} = 1.$$

Por tanto,

$$L_b = \sum_{r=1}^n K_{ar}L_r, \quad b = 1, \dots, n.$$

El lado derecho no depende de b . Luego, para todo $b, c \in \{1, \dots, n\}$,

$$L_b = \sum_{r=1}^n K_{ar}L_r = L_c.$$

Así,

$$L_1 = L_2 = \dots = L_n.$$

Esto concluye la equivalencia. □

Corolario 8.1 (Falla de conmutación global para verosimilitudes no constantes). Sea $n \geq 2$. Sea $K \in \mathcal{K}_\varepsilon$ y sea $L \in \mathbb{R}_{>0}^n$. Si L no es constante, entonces las composiciones Markov–Bayes y Bayes–Markov no conmutan globalmente. Es decir, existe $X \in \Delta_n^\circ$ tal que

$$B_L(XK) \neq B_L(X)K.$$

Equivalente,

$$B_L(XK) = B_L(X)K \quad \text{para todo } X \in \Delta_n^\circ$$

sólo puede ocurrir cuando

$$L_1 = L_2 = \cdots = L_n.$$

Demostración. Supóngase que la identidad

$$B_L(XK) = B_L(X)K \quad \text{para todo } X \in \Delta_n^\circ$$

sí se cumpliera. Consideremos la sucesión interior

$$X^{(m)} := \left(1 - \frac{n-1}{m}\right) e_1 + \frac{1}{m} \sum_{r=2}^n e_r, \quad m > n-1.$$

Entonces $X^{(m)} \in \Delta_n^\circ$ y $X^{(m)} \rightarrow e_1$ cuando $m \rightarrow \infty$. Como la multiplicación por K y la aplicación B_L son continuas en Δ_n , de la hipótesis se obtiene al pasar al límite

$$B_L(e_1 K) = e_1 K.$$

Ahora bien, como $K \in \mathcal{K}_\varepsilon$, la fila $e_1 K$ tiene todas sus coordenadas estrictamente positivas; por tanto $e_1 K \in \Delta_n^\circ$. Escribamos

$$y := e_1 K.$$

La igualdad $B_L(y) = y$ significa que, para cada $b = 1, \dots, n$,

$$\frac{y_b L_b}{\langle y, L \rangle} = y_b.$$

Como $y_b > 0$, se puede dividir entre y_b y queda

$$L_b = \langle y, L \rangle \quad \text{para todo } b = 1, \dots, n.$$

Luego

$$L_1 = L_2 = \cdots = L_n,$$

lo cual contradice que L no sea constante. Por tanto, la identidad no puede cumplirse para todo $X \in \Delta_n^\circ$, y en consecuencia existe al menos un $X \in \Delta_n^\circ$ tal que

$$B_L(XK) \neq B_L(X)K.$$

□

Observación 8.4 (De la falla global al defecto de ordenamiento). *El corolario anterior no afirma que, para una verosimilitud no constante, las dos composiciones difieran en todo estado $X \in \Delta_n^\circ$. Afirma únicamente que la igualdad no puede sostenerse de manera global en todo el símplex.*

Por tanto, la no conmutación debe medirse punto a punto. Para un estado fijo X , puede ocurrir que

$$B_L(XK) = B_L(X)K,$$

aunque L no sea constante. En cambio, si existe un estado X para el cual

$$B_L(XK) \neq B_L(X)K,$$

entonces los dos protocolos producen estados finales distintos: observar después de propagar no coincide con propagar después de observar.

Esto motiva introducir una cantidad vectorial que mida, en cada estado X , la diferencia entre los dos órdenes. Dicha cantidad será el defecto de ordenamiento.

Definición 8.4 (Defecto de ordenamiento). *Sea $n \geq 2$. Sea $K \in \mathcal{K}_\varepsilon$ y sea $L \in \mathbb{R}_{>0}^n$. El defecto de ordenamiento asociado al par (K, L) es la aplicación*

$$\mathcal{D}_{K,L} : \Delta_n^\circ \longrightarrow \mathbb{R}^n$$

definida por

$$\mathcal{D}_{K,L}(X) := B_L(XK) - B_L(X)K.$$

Equivalentemente,

$$\mathcal{D}_{K,L}(X) = (B_L \circ M_K)(X) - (M_K \circ B_L)(X).$$

En terminos de las transiciones ordenadas,

$$\mathcal{D}_{K,L}(X) = T_{MB}^{K,L}(X) - T_{BM}^{K,L}(X).$$

Coordenada a coordenada, para cada $i = 1, \dots, n$,

$$\mathcal{D}_{K,L}(X)_i = \frac{(XK)_i L_i}{\sum_{j=1}^n (XK)_j L_j} - \sum_{r=1}^n \frac{X_r L_r}{\sum_{j=1}^n X_j L_j} K_{ri}.$$

Como

$$B_L(XK) \in \Delta_n^\circ \quad y \quad B_L(X)K \in \Delta_n^\circ,$$

se tiene

$$\sum_{i=1}^n \mathcal{D}_{K,L}(X)_i = 0.$$

Por tanto,

$$\mathcal{D}_{K,L}(X) \in T\Delta_n,$$

donde

$$T\Delta_n := \left\{ v \in \mathbb{R}^n : \sum_{i=1}^n v_i = 0 \right\}.$$

Se dira que el defecto se anula en X si

$$\mathcal{D}_{K,L}(X) = 0.$$

En tal caso, las dos composiciones coinciden en el estado X . Se dirá que el defecto es globalmente nulo si

$$\mathcal{D}_{K,L}(X) = 0 \quad \text{para todo } X \in \Delta_n^\circ.$$

Observación 8.5 (Del defecto de ordenamiento a las cotas de desplazamiento por paso). *El defecto de ordenamiento*

$$\mathcal{D}_{K,L}(X) = B_L(XK) - B_L(X)K$$

mide la discrepancia entre dos estados finales producidos por órdenes distintos de aplicación. Para usar esta diferencia dentro de un problema de control, primero debe acotarse el desplazamiento elemental producido por cada operación admisible.

Las cantidades

$$|B_L(X) - X|_1, \quad |M_K(X) - X|_1,$$

son desplazamientos en el símplex medidos en norma ℓ^1 . No describen derivadas temporales; describen el efecto de una sola operación bayesiana o markoviana.

En lo que sigue se fijan las cotas uniformes

$$v_B(R) := e^{2R} - 1, \quad v_M(\varepsilon) := 2(1 - \varepsilon),$$

Estas cantidades son cotas uniformes de desplazamiento por operación admisible. La comparación válida es entre $v_B(R)$ y $v_M(\varepsilon)$, no entre R y ε , porque ambas cotas viven en la misma escala métrica ℓ^1 del símplex.

Observación 8.6 (Cota de desplazamiento bayesiana por paso y control logarítmico de la verosimilitud). *La referencia sobre estabilidad bayesiana [Sprungk, 2020] se usa aquí solo como contexto. En el marco finito, la actualización posterior normalizada tiene la forma*

$$B_L(X)_i = \frac{X_i L_i}{\langle X, L \rangle},$$

y la restricción

$$\log L \in \mathcal{U}_R$$

permite controlar algebraicamente el cociente

$$\frac{B_L(X)_i}{X_i} = \frac{L_i}{\langle X, L \rangle}.$$

La demostración del lema siguiente es completamente algebraica; la referencia solo justifica la lectura posterior de la corrección bayesiana.

Lema 8.1 (Cota de desplazamiento bayesiano por paso). *Sean $n \geq 2$, $R > 0$, $X \in \Delta_n^\circ$ y $L \in \mathbb{R}_{>0}^n$. Supóngase que*

$$\log L \in \mathcal{U}_R.$$

Entonces

$$|B_L(X) - X|_1 \leq e^{2R} - 1.$$

Demostración. Sea

$$\beta := \langle X, L \rangle = \sum_{j=1}^n X_j L_j.$$

Como $\log L \in \mathcal{U}_R$, se tiene

$$-R \leq \log L_i \leq R \quad \text{para todo } i,$$

y por tanto

$$e^{-R} \leq L_i \leq e^R \quad \text{para todo } i.$$

Dado que $X \in \Delta_n^\circ$, se cumple $X_i > 0$ para todo i y

$$\sum_{i=1}^n X_i = 1.$$

Luego

$$\beta = \sum_{j=1}^n X_j L_j \geq \sum_{j=1}^n X_j e^{-R} = e^{-R},$$

y también

$$\beta = \sum_{j=1}^n X_j L_j \leq \sum_{j=1}^n X_j e^R = e^R.$$

Así,

$$e^{-R} \leq \beta \leq e^R.$$

Para cada i ,

$$B_L(X)_i - X_i = \frac{X_i L_i}{\beta} - X_i = X_i \left(\frac{L_i}{\beta} - 1 \right).$$

Por consiguiente,

$$|B_L(X) - X|_1 = \sum_{i=1}^n X_i \left| \frac{L_i}{\beta} - 1 \right|.$$

Además,

$$\frac{L_i}{\beta} \leq \frac{e^R}{e^{-R}} = e^{2R}.$$

Como $\frac{L_i}{\beta} > 0$, se tiene

$$\left| \frac{L_i}{\beta} - 1 \right| \leq e^{2R} - 1 \quad \text{para todo } i.$$

Por tanto,

$$|B_L(X) - X|_1 \leq \sum_{i=1}^n X_i (e^{2R} - 1) = (e^{2R} - 1) \sum_{i=1}^n X_i = e^{2R} - 1.$$

□

Observación 8.7 (Cota de desplazamiento markoviana por paso y variación total). *La referencia de Doeblin–Dobrushin [Gaubert and Qu, 2014] sólo se usa para justificar que la norma ℓ^1 , equivalente a la variación total salvo el factor $1/2$, es la escala natural para medir cambios de masa probabilística. La cota siguiente no se deduce del coeficiente de Dobrushin; se obtiene directamente de la positividad uniforme*

$$K_{ab} \geq \varepsilon \quad \forall a, b.$$

En particular,

$$K_{aa} \geq \varepsilon \quad \forall a.$$

Lema 8.2 (Cota de desplazamiento markoviano por paso). *Sean $n \geq 2$, $0 < \varepsilon \leq 1/n$, $X \in \Delta_n$ y $K \in \mathcal{K}_\varepsilon$. Entonces*

$$|M_K(X) - X|_1 = |XK - X|_1 \leq 2(1 - \varepsilon).$$

Demostración. Sea $e_1, \dots, e_n$ la base canónica de $\mathbb{R}^n$. Para cada $a \in \{1, \dots, n\}$, el vector $e_a K$ es la fila a de K . Como K es estocástica por filas,

$$\sum_{b=1}^n K_{ab} = 1 \quad \text{y} \quad K_{ab} \geq 0.$$

Luego $e_a K \in \Delta_n$.

Calculemos

$$|e_a K - e_a|_1 = \sum_{b=1}^n |K_{ab} - (e_a)_b|.$$

Separando la coordenada a ,

$$|e_a K - e_a|_1 = |K_{aa} - 1| + \sum_{b \neq a} |K_{ab}|.$$

Como $0 \leq K_{aa} \leq 1$ y $K_{ab} \geq 0$, queda

$$|e_a K - e_a|_1 = (1 - K_{aa}) + \sum_{b \neq a} K_{ab}.$$

Ahora,

$$\sum_{b \neq a} K_{ab} = 1 - K_{aa}.$$

Por tanto,

$$|e_a K - e_a|_1 = 2(1 - K_{aa}).$$

Dado que $K \in \mathcal{K}_\varepsilon$, se tiene $K_{aa} \geq \varepsilon$. Así,

$$|e_a K - e_a|_1 \leq 2(1 - \varepsilon) \quad \text{para todo } a.$$

Como $X \in \Delta_n$,

$$X = \sum_{a=1}^n X_a e_a, \quad XK = \sum_{a=1}^n X_a e_a K.$$

Restando,

$$XK - X = \sum_{a=1}^n X_a (e_a K - e_a).$$

Por la desigualdad triangular,

$$|XK - X|_1 \leq \sum_{a=1}^n X_a |e_a K - e_a|_1.$$

Usando la cota anterior,

$$|XK - X|_1 \leq \sum_{a=1}^n X_a 2(1 - \varepsilon) = 2(1 - \varepsilon) \sum_{a=1}^n X_a.$$

Como $\sum_{a=1}^n X_a = 1$, se concluye

$$|XK - X|_1 \leq 2(1 - \varepsilon).$$

Finalmente, por definición $M_K(X) = XK$, de modo que

$$|M_K(X) - X|_1 \leq 2(1 - \varepsilon).$$

□

Observación 8.8 (Control con variable de ordenamiento). *Los lemas anteriores acotan el desplazamiento elemental producido por una corrección bayesiana admisible y por una corrección markoviana admisible. Por tanto, las dos composiciones ya construidas,*

$$B_L(XK) \quad \text{y} \quad B_L(X)K,$$

pueden interpretarse como pasos compuestos formados por dos correcciones elementales admisibles.

La proposición de conmutación global y su corolario muestran que, salvo el caso de verosimilitud constante, el orden de aplicación no es neutro. En consecuencia, el orden puede incorporarse como una decisión discreta dentro de la acción de control. Esta lectura es compatible con la formulación estado–acción–transición–costo de los problemas de decisión en tiempo discreto, y con la interpretación de costos probabilísticos mediante divergencias entre distribuciones [Todorov, 2009]. Asimismo, la separación entre costo acumulado y costo terminal es consistente con la estructura usual de control óptimo con contribución de trayectoria y costo final [Kappen, 2005].

En lo que sigue no se introduce un nuevo operador. Solamente se fija una variable de ordenamiento que selecciona, en cada paso, cual de las dos composiciones previamente definidas se aplica.

Definición 8.5 (Acción admisible con variable de ordenamiento). *Sean $n \geq 2$, $0 < \varepsilon \leq 1/n$ y $R > 0$. Se define el conjunto de acciones admisibles con variable de ordenamiento por*

$$\mathcal{A}_{\varepsilon, R} := \{(K, L, \sigma) : K \in \mathcal{K}_\varepsilon, \log L \in \mathcal{U}_R, \sigma \in \{MB, BM\}\}.$$

Una acción en el tiempo t es una terna

$$u_t = (K_t, L_t, \sigma_t) \in \mathcal{A}_{\varepsilon, R}.$$

La componente K_t determina la corrección markoviana, la componente L_t determina la corrección bayesiana y la componente σ_t determina el orden de composición.

Si

$$\sigma_t = MB,$$

entonces primero se aplica la correccion markoviana y despues la correccion bayesiana. Si

$$\sigma_t = BM,$$

entonces primero se aplica la correccion bayesiana y despues la correccion markoviana.

Definición 8.6 (Transiciones controladas por orden). Sean $X \in \Delta_n^\circ$, $K \in \mathcal{K}_\varepsilon$ y $\log L \in \mathcal{U}_R$. Se definen las transiciones controladas por orden mediante

$$T_{MB}^{K,L}(X) := B_L(M_K(X)) = B_L(XK),$$

y

$$T_{BM}^{K,L}(X) := M_K(B_L(X)) = B_L(X)K.$$

Por tanto, si $u = (K, L, \sigma) \in \mathcal{A}_{\varepsilon,R}$, la transicion inducida por u se define como

$$T^u(X) := \begin{cases} T_{MB}^{K,L}(X), & \text{si } \sigma = MB, \\ T_{BM}^{K,L}(X), & \text{si } \sigma = BM. \end{cases}$$

Equivalentemente,

$$T^u(X) = \begin{cases} B_L(XK), & \text{si } \sigma = MB, \\ B_L(X)K, & \text{si } \sigma = BM. \end{cases}$$

Con esta notacion, el defecto de ordenamiento ya definido se escribe como

$$\mathcal{D}_{K,L}(X) = T_{MB}^{K,L}(X) - T_{BM}^{K,L}(X).$$

Proposición 8.4 (Dirección terminal de KL bajo pérdida de soporte). Sea $n \geq 2$, sea $P \in \Delta_n^\circ$ y sea $\{X_k\}_{k \geq 1} \subset \Delta_n$. Supóngase que existe $j \in \{1, \dots, n\}$ tal que

$$X_{k,j} \longrightarrow 0.$$

Entonces

$$D_{KL}(P \| X_k) \longrightarrow +\infty.$$

Además, la sucesión $\{D_{KL}(X_k \| P)\}_{k \geq 1}$ permanece acotada. En consecuencia, si el costo terminal debe excluir la pérdida de soporte respecto de P , la dirección admisible es

$$E_P(X) = D_{KL}(P \| X).$$

Demostración. Como $P \in \Delta_n^\circ$, se tiene $P_i > 0$ para todo $i \in \{1, \dots, n\}$. En particular, $P_j > 0$. Por definición de la divergencia de Kullback–Leibler en el simplex,

$$D_{KL}(P \| X_k) = \sum_{i=1}^n P_i \log \frac{P_i}{X_{k,i}},$$

con la convención de que el valor es $+\infty$ si existe i tal que $P_i > 0$ y $X_{k,i} = 0$. Si $X_{k,j} = 0$ para infinitos valores de k , entonces la divergencia vale $+\infty$ en esa subsucesión. Por tanto basta considerar el caso en que, a partir de cierto índice, $X_{k,j} > 0$.

Para esos índices se separa el sumando singular:

$$D_{\text{KL}}(P\|X_k) = P_j \log \frac{P_j}{X_{k,j}} + \sum_{\substack{i=1 \\ i \neq j}}^n P_i \log \frac{P_i}{X_{k,i}}.$$

Como $0 < X_{k,i} \leq 1$ para toda coordenada positiva de X_k , se tiene

$$\log X_{k,i} \leq 0.$$

De aquí se obtiene, para cada $i \neq j$ con $X_{k,i} > 0$,

$$P_i \log \frac{P_i}{X_{k,i}} = P_i \log P_i - P_i \log X_{k,i} \geq P_i \log P_i.$$

Si $X_{k,i} = 0$ y $P_i > 0$, el sumando correspondiente es $+\infty$, por lo cual la desigualdad anterior sigue siendo válida en el sentido extendido. Así,

$$\sum_{\substack{i=1 \\ i \neq j}}^n P_i \log \frac{P_i}{X_{k,i}} \geq \sum_{\substack{i=1 \\ i \neq j}}^n P_i \log P_i =: C_P,$$

donde $C_P \in \mathbb{R}$ depende solo de P . Por consiguiente,

$$D_{\text{KL}}(P\|X_k) \geq P_j \log \frac{P_j}{X_{k,j}} + C_P.$$

Como $X_{k,j} \rightarrow 0$ y $P_j > 0$,

$$\log \frac{P_j}{X_{k,j}} \rightarrow +\infty.$$

Multiplicando por $P_j > 0$, se concluye

$$P_j \log \frac{P_j}{X_{k,j}} \rightarrow +\infty,$$

y por la cota inferior anterior se obtiene

$$D_{\text{KL}}(P\|X_k) \rightarrow +\infty.$$

Resta probar la acotación de la dirección inversa. Como $P_i > 0$ para todo i , la función

$$f_i : [0, 1] \rightarrow \mathbb{R}, \quad f_i(x) = \begin{cases} x \log \frac{x}{P_i}, & x > 0, \\ 0, & x = 0, \end{cases}$$

es continua en $[0, 1]$. En efecto,

$$\lim_{x \downarrow 0} x \log x = 0 \quad \text{y} \quad \lim_{x \downarrow 0} x \log P_i = 0.$$

Por compacidad de $[0, 1]$, existe $M_i < \infty$ tal que

$$|f_i(x)| \leq M_i \quad \text{para todo } x \in [0, 1].$$

Para cada $X \in \Delta_n$,

$$D_{\text{KL}}(X \| P) = \sum_{i=1}^n X_i \log \frac{X_i}{P_i} = \sum_{i=1}^n f_i(X_i).$$

Luego

$$|D_{\text{KL}}(X \| P)| \leq \sum_{i=1}^n M_i < \infty \quad \text{para todo } X \in \Delta_n.$$

Aplicando esta cota a $X = X_k$, se obtiene que

$$\{D_{\text{KL}}(X_k \| P)\}_{k \geq 1}$$

permanece acotada. La diferencia entre ambas direcciones queda determinada por la singularidad de soporte del primer argumento frente al segundo. $\square$

Observación 8.9 (Necesidad de costos de etapa y funciones de valor). *Una vez que el orden de composicion se incorpora como componente de la accion,*

$$u_t = (K_t, L_t, \sigma_t), \quad \sigma_t \in \{MB, BM\},$$

la Seccion G deja de considerar unicamente dos composiciones posibles y pasa a formular una eleccion controlada entre ellas. En este punto, no basta conocer las transiciones

$$T_{MB}^{K,L}(X) = B_L(XK), \quad T_{BM}^{K,L}(X) = B_L(X)K.$$

Para comparar ambos ordenes se requiere medir, primero, el costo elemental de aplicar cada composicion y, segundo, el efecto que el estado resultante tendra sobre los pasos restantes.

Esta separacion corresponde a la estructura usual de los problemas de control en tiempo discreto: un estado actual, una accion admisible, una transicion inducida por la accion, un costo de etapa y un costo futuro representado por una funcion de valor [Todorov, 2009]. En el presente marco, el estado es $X \in \Delta_n^\circ$, la accion es $u = (K, L, \sigma)$, y las transiciones inducidas son precisamente $T_{MB}^{K,L}$ y $T_{BM}^{K,L}$.

La formulacion KL de los problemas de control muestra que una politica optima puede entenderse como una distribucion sobre trayectorias futuras y que el problema se convierte en una minimizacion de divergencia de Kullback–Leibler entre una politica y una referencia dinamica [Kappen et al., 2012]. Esta lectura justifica que, en el presente marco, las cantidades Q_τ^{MB} y Q_τ^{BM} comparen no solo el costo inmediato, sino tambien el costo restante inducido por el estado alcanzado.

Los costos de etapa deben respetar el orden real de aplicacion. Para el orden MB, la trayectoria elemental es

$$X \mapsto XK \mapsto B_L(XK),$$

mientras que para el orden BM, la trayectoria elemental es

$$X \mapsto B_L(X) \mapsto B_L(X)K.$$

Por ello, los costos c_{MB} y c_{BM} se definen como sumas de divergencias de Kullback–Leibler entre estados consecutivos dentro de cada composicion. Esta eleccion es coherente con formulaciones de control probabilistico donde el costo de trayectoria y el costo terminal aparecen separados [Kappen, 2005].

Sin embargo, minimizar solamente el costo de etapa produciria una decision local. El objetivo de la Seccion G es construir trayectorias hacia un estado terminal $P \in \Delta_n^\circ$, evaluadas por

$$E_P(X) = D_{KL}(P\|X).$$

Por tanto, la comparacion entre ordenes debe incorporar tambien el costo futuro asociado al estado alcanzado. Esta es la funcion de las cantidades

$$Q_\tau^{MB} \quad y \quad Q_\tau^{BM},$$

las cuales suman el costo de etapa correspondiente al orden elegido y el valor restante despues de aplicar la transicion controlada. La funcion V_τ recoge el menor costo total posible cuando quedan τ pasos, con condicion terminal

$$V_0(X) = E_P(X).$$

Asi, la separacion entre costo acumulado y costo terminal queda alineada con la formulacion variacional de problemas de control con contribucion de trayectoria y costo final [Kappen, 2005].

Definición 8.7 (Costos de etapa ordenados). Sean $X \in \Delta_n^\circ$, $K \in \mathcal{K}_\varepsilon$ y $\log L \in \mathcal{U}_R$. El costo de etapa asociado al orden MB se define por

$$c_{MB}(X; K, L) := D_{KL}(XK\|X) + D_{KL}(B_L(XK)\|XK).$$

Este costo corresponde a la composicion

$$X \mapsto XK \mapsto B_L(XK).$$

El costo de etapa asociado al orden BM se define por

$$c_{BM}(X; K, L) := D_{KL}(B_L(X)\|X) + D_{KL}(B_L(X)K\|B_L(X)).$$

Este costo corresponde a la composicion

$$X \mapsto B_L(X) \mapsto B_L(X)K.$$

Para $u = (K, L, \sigma) \in \mathcal{A}_{\varepsilon, R}$, se define

$$c(X, u) := \begin{cases} c_{MB}(X; K, L), & \text{si } \sigma = MB, \\ c_{BM}(X; K, L), & \text{si } \sigma = BM. \end{cases}$$

Definición 8.8 (Funcion de valor y funciones de accion–valor por orden). Sea $P \in \Delta_n^\circ$. Se define el valor terminal por

$$V_0(X) := E_P(X) = D_{KL}(P\|X), \quad X \in \Delta_n^\circ.$$

Para $\tau \geq 1$, suponiendo definida $V_{\tau-1}$, se definen las funciones de accion-valor por orden mediante

$$Q_{\tau}^{MB}(X; K, L) := c_{MB}(X; K, L) + V_{\tau-1}(T_{MB}^{K,L}(X)),$$

es decir,

$$Q_{\tau}^{MB}(X; K, L) = c_{MB}(X; K, L) + V_{\tau-1}(B_L(XK)),$$

y

$$Q_{\tau}^{BM}(X; K, L) := c_{BM}(X; K, L) + V_{\tau-1}(T_{BM}^{K,L}(X)),$$

es decir,

$$Q_{\tau}^{BM}(X; K, L) = c_{BM}(X; K, L) + V_{\tau-1}(B_L(X)K).$$

La funcion de valor con τ pasos restantes se define por

$$V_{\tau}(X) := \inf_{\substack{K \in \mathcal{K}_{\varepsilon} \\ \log L \in \mathcal{U}_R}} \min \{Q_{\tau}^{MB}(X; K, L), Q_{\tau}^{BM}(X; K, L)\}.$$

Equivalentemente,

$$V_{\tau}(X) = \inf_{u \in \mathcal{A}_{\varepsilon, R}} [c(X, u) + V_{\tau-1}(T^u(X))].$$

Observación 8.10 (De la recurrencia de Bellman a la regularidad local). La definicion de V_{τ} convierte el problema de ordenamiento Bayes-Markov en una recurrencia de horizonte finito:

$$V_{\tau}(X) = \inf_{u \in \mathcal{A}_{\varepsilon, R}} [c(X, u) + V_{\tau-1}(T^u(X))].$$

Esta forma separa la decision presente del costo restante. En el sentido de la programacion dinamica de Bellman, el problema de elegir una secuencia de operaciones se reduce, en cada etapa, a elegir una primera operacion y trasladar el resto del problema al estado alcanzado [Bellman, 1952]. En formulaciones de control probabilistico, esta separacion aparece como estado, accion, transicion, costo inmediato y costo futuro [Todorov, 2009]; en formulaciones de control KL, la recurrencia puede interpretarse como una propagacion hacia atras del costo optimo [Kappen et al., 2012].

En la Seccion G ya se fijaron las acciones

$$u = (K, L, \sigma), \quad \sigma \in \{MB, BM\},$$

las transiciones

$$T_{MB}^{K,L}(X) = B_L(XK), \quad T_{BM}^{K,L}(X) = B_L(X)K,$$

los costos de etapa c_{MB}, c_{BM} , y la condicion terminal

$$V_0(X) = E_P(X) = D_{KL}(P\|X).$$

La pregunta natural ya no es solamente si la recurrencia esta bien definida, sino si su dependencia respecto del estado inicial es controlada. Por ello se busca probar una cota de la forma

$$|V_{\tau}(X) - V_{\tau}(Y)| \leq L_{\tau}(m)\|X - Y\|_1$$

en regiones interiores del simplex.

Observación 8.11 (Fuentes de regularidad en la recurrencia). *La regularidad de V_τ no se obtiene directamente de la definicion recursiva. En la expresion*

$$c(X, u) + V_{\tau-1}(T^u(X))$$

intervienen tres dependencias respecto de X : la transicion controlada, el costo de etapa y el valor futuro evaluado en el estado alcanzado.

Por tanto, antes de estudiar V_τ , se deben controlar algebraicamente las piezas que alimentan la recurrencia:

$$B_L, \quad M_K, \quad T_{MB}^{K,L}, \quad T_{BM}^{K,L}, \quad D_{KL}.$$

El uso de divergencias KL en los costos de etapa es coherente con formulaciones donde el costo mide la modificacion de una distribucion o de una trayectoria probabilistica inducida por una accion [Todorov, 2009, Kappen et al., 2012]. En este bloque las referencias solo motivan la estructura; las cotas se prueban directamente a partir de las definiciones de la Seccion G.

Lema 8.3 (Regularidad Lipschitz de las transiciones ordenadas). *Sea*

$$\Lambda_B(R) := 2e^{2R}.$$

Si $X, Y \in \Delta_n^\circ$, $K \in \mathcal{K}_\varepsilon$ y $\log L \in \mathcal{U}_R$, entonces

$$\|B_L(X) - B_L(Y)\|_1 \leq \Lambda_B(R)\|X - Y\|_1.$$

En consecuencia,

$$\|T_{MB}^{K,L}(X) - T_{MB}^{K,L}(Y)\|_1 \leq \Lambda_B(R)\|X - Y\|_1,$$

y

$$\|T_{BM}^{K,L}(X) - T_{BM}^{K,L}(Y)\|_1 \leq \Lambda_B(R)\|X - Y\|_1.$$

Demostración. Como $\log L \in \mathcal{U}_R$, se tiene

$$e^{-R} \leq L_i \leq e^R \quad \text{para todo } i.$$

Escribamos

$$s_X := \langle X, L \rangle.$$

Entonces

$$e^{-R} \leq s_X \leq e^R.$$

La aplicacion bayesiana tiene coordenadas

$$B_L(X)_i = \frac{X_i L_i}{s_X}.$$

Para $j \in \{1, \dots, n\}$,

$$\frac{\partial}{\partial X_j} B_L(X)_i = \frac{\delta_{ij} L_i s_X - X_i L_i L_j}{s_X^2}.$$

Por tanto, la suma de valores absolutos en la columna j del jacobiano es

$$\sum_{i=1}^n \left| \frac{\partial}{\partial X_j} B_L(X)_i \right| = \frac{2L_j}{s_X^2} \sum_{i \neq j} X_i L_i.$$

Como

$$\sum_{i \neq j} X_i L_i \leq s_X,$$

se obtiene

$$\sum_{i=1}^n \left| \frac{\partial}{\partial X_j} B_L(X)_i \right| \leq \frac{2L_j}{s_X} \leq 2e^{2R}.$$

Luego la norma inducida $\ell^1 \rightarrow \ell^1$ del jacobiano queda acotada por $2e^{2R}$. Por el teorema del valor medio sobre el segmento que une X con Y ,

$$\|B_L(X) - B_L(Y)\|_1 \leq 2e^{2R} \|X - Y\|_1.$$

Ademas, como K es estocastica,

$$\|(X - Y)K\|_1 \leq \|X - Y\|_1.$$

Por tanto,

$$\|T_{MB}^{K,L}(X) - T_{MB}^{K,L}(Y)\|_1 = \|B_L(XK) - B_L(YK)\|_1 \leq \Lambda_B(R) \|(X - Y)K\|_1 \leq \Lambda_B(R) \|X - Y\|_1.$$

Asimismo,

$$\|T_{BM}^{K,L}(X) - T_{BM}^{K,L}(Y)\|_1 = \|(B_L(X) - B_L(Y))K\|_1 \leq \|B_L(X) - B_L(Y)\|_1 \leq \Lambda_B(R) \|X - Y\|_1.$$

□

Lema 8.4 (Invariancia interior uniforme de las transiciones ordenadas). *Sea*

$$\alpha := \varepsilon e^{-2R}.$$

Si $X \in \Delta_n^\circ$, $K \in \mathcal{K}_\varepsilon$ *y* $\log L \in \mathcal{U}_R$, *entonces*

$$T_{MB}^{K,L}(X) \in \Delta_n(\alpha), \quad T_{BM}^{K,L}(X) \in \Delta_n(\alpha),$$

donde

$$\Delta_n(\alpha) := \{Z \in \Delta_n^\circ : Z_i \geq \alpha \text{ para todo } i\}.$$

Demostración. Como $K \in \mathcal{K}_\varepsilon$, se tiene $K_{ij} \geq \varepsilon$. Por tanto,

$$(XK)_j = \sum_{i=1}^n X_i K_{ij} \geq \varepsilon \sum_{i=1}^n X_i = \varepsilon.$$

Luego $XK \in \Delta_n(\varepsilon)$. Ademas,

$$e^{-R} \leq L_j \leq e^R, \quad \langle XK, L \rangle \leq e^R.$$

Asi,

$$B_L(XK)_j = \frac{(XK)_j L_j}{\langle XK, L \rangle} \geq \frac{\varepsilon e^{-R}}{e^R} = \varepsilon e^{-2R} = \alpha.$$

Por tanto,

$$T_{MB}^{K,L}(X) = B_L(XK) \in \Delta_n(\alpha).$$

Por otro lado, $B_L(X) \in \Delta_n^\circ$. Al aplicar K ,

$$(B_L(X)K)_j = \sum_{i=1}^n B_L(X)_i K_{ij} \geq \varepsilon \sum_{i=1}^n B_L(X)_i = \varepsilon.$$

Como $\alpha = \varepsilon e^{-2R} \leq \varepsilon$, se concluye que

$$T_{BM}^{K,L}(X) = B_L(X)K \in \Delta_n(\alpha).$$

□

Lema 8.5 (Cota local para la divergencia de Kullback–Leibler). *Sea $0 < \eta \leq 1/n$ y definamos*

$$\kappa(\eta) := 1 + \log \frac{1}{\eta} + \frac{1}{\eta}.$$

Si

$$A, A', B, B' \in \Delta_n(\eta),$$

entonces

$$|D_{\text{KL}}(A\|B) - D_{\text{KL}}(A'\|B')| \leq \kappa(\eta) (\|A - A'\|_1 + \|B - B'\|_1).$$

Demostración. Considérese la función

$$F(A, B) := D_{\text{KL}}(A\|B) = \sum_{i=1}^n A_i \log \frac{A_i}{B_i}.$$

En $\Delta_n(\eta) \times \Delta_n(\eta)$ se tiene

$$\eta \leq A_i, B_i \leq 1.$$

Las derivadas parciales son

$$\frac{\partial F}{\partial A_i} = 1 + \log \frac{A_i}{B_i}, \quad \frac{\partial F}{\partial B_i} = -\frac{A_i}{B_i}.$$

Como

$$\frac{A_i}{B_i} \leq \frac{1}{\eta},$$

se obtiene

$$\left| \frac{\partial F}{\partial A_i} \right| \leq 1 + \log \frac{1}{\eta}, \quad \left| \frac{\partial F}{\partial B_i} \right| \leq \frac{1}{\eta}.$$

Por convexidad de $\Delta_n(\eta)$, el segmento que une (A, B) con (A', B') permanece en $\Delta_n(\eta) \times \Delta_n(\eta)$.

Aplicando el teorema del valor medio,

$$|F(A, B) - F(A', B')| \leq \left(1 + \log \frac{1}{\eta}\right) \|A - A'\|_1 + \frac{1}{\eta} \|B - B'\|_1.$$

La cota afirmada se sigue de la definicion de $\kappa(\eta)$.

□

Lema 8.6 (Regularidad Lipschitz de los costos de etapa). Sea $m \in (0, 1/n]$. Definamos

$$\Lambda_B(R) := 2e^{2R}, \quad \alpha := \varepsilon e^{-2R}, \quad \beta_m := m e^{-2R}.$$

Definamos ademas

$$C_{MB}(m, \varepsilon, R) := 2\kappa(\min\{m, \varepsilon\}) + (\Lambda_B(R) + 1)\kappa(\alpha),$$

$$C_{BM}(m, \varepsilon, R) := (\Lambda_B(R) + 1)\kappa(\beta_m) + 2\Lambda_B(R)\kappa(\min\{\varepsilon, \beta_m\}),$$

y

$$C_c(m, \varepsilon, R) := \max\{C_{MB}(m, \varepsilon, R), C_{BM}(m, \varepsilon, R)\}.$$

Si

$$X, Y \in \Delta_n(m), \quad K \in \mathcal{K}_\varepsilon, \quad \log L \in \mathcal{U}_R, \quad \sigma \in \{MB, BM\},$$

entonces

$$|c_\sigma(X; K, L) - c_\sigma(Y; K, L)| \leq C_c(m, \varepsilon, R)\|X - Y\|_1.$$

Demostración. Primero consideremos el orden MB . Se tiene

$$c_{MB}(X; K, L) = D_{\text{KL}}(XK \| X) + D_{\text{KL}}(B_L(XK) \| XK).$$

Como $X, Y \in \Delta_n(m)$ y $K \in \mathcal{K}_\varepsilon$, entonces

$$XK, YK \in \Delta_n(\varepsilon).$$

Ademas,

$$\|XK - YK\|_1 \leq \|X - Y\|_1.$$

Aplicando el Lema 8.5 con $\eta = \min\{m, \varepsilon\}$, se obtiene

$$|D_{\text{KL}}(XK \| X) - D_{\text{KL}}(YK \| Y)| \leq 2\kappa(\min\{m, \varepsilon\})\|X - Y\|_1.$$

Por otra parte, por el Lema 8.4,

$$B_L(XK), B_L(YK) \in \Delta_n(\alpha),$$

y $XK, YK \in \Delta_n(\varepsilon) \subseteq \Delta_n(\alpha)$. Ademas, por el Lema 8.3,

$$\|B_L(XK) - B_L(YK)\|_1 \leq \Lambda_B(R)\|X - Y\|_1.$$

Aplicando nuevamente el Lema 8.5 con $\eta = \alpha$, se obtiene

$$\begin{aligned} & \left| D_{\text{KL}}(B_L(XK) \| XK) - D_{\text{KL}}(B_L(YK) \| YK) \right| \\ & \leq \kappa(\alpha) (\|B_L(XK) - B_L(YK)\|_1 + \|XK - YK\|_1) \\ & \leq (\Lambda_B(R) + 1)\kappa(\alpha)\|X - Y\|_1. \end{aligned}$$

Por tanto,

$$|c_{MB}(X; K, L) - c_{MB}(Y; K, L)| \leq C_{MB}(m, \varepsilon, R)\|X - Y\|_1.$$

Ahora consideremos el orden BM . Se tiene

$$c_{BM}(X; K, L) = D_{KL}(B_L(X) \| X) + D_{KL}(B_L(X)K \| B_L(X)).$$

Como $X, Y \in \Delta_n(m)$, entonces

$$B_L(X), B_L(Y) \in \Delta_n(\beta_m), \quad \beta_m = me^{-2R}.$$

Ademas,

$$\|B_L(X) - B_L(Y)\|_1 \leq \Lambda_B(R)\|X - Y\|_1.$$

Aplicando el Lema 8.5 con $\eta = \beta_m$, se obtiene

$$\begin{aligned} & \left| D_{KL}(B_L(X) \| X) - D_{KL}(B_L(Y) \| Y) \right| \\ & \leq \kappa(\beta_m) (\|B_L(X) - B_L(Y)\|_1 + \|X - Y\|_1) \\ & \leq (\Lambda_B(R) + 1)\kappa(\beta_m)\|X - Y\|_1. \end{aligned}$$

Por otra parte,

$$B_L(X)K, B_L(Y)K \in \Delta_n(\varepsilon),$$

y

$$B_L(X), B_L(Y) \in \Delta_n(\beta_m).$$

Aplicando el Lema 8.5 con

$$\eta = \min\{\varepsilon, \beta_m\},$$

se obtiene

$$\begin{aligned} & \left| D_{KL}(B_L(X)K \| B_L(X)) - D_{KL}(B_L(Y)K \| B_L(Y)) \right| \\ & \leq \kappa(\min\{\varepsilon, \beta_m\}) (\|(B_L(X) - B_L(Y))K\|_1 + \|B_L(X) - B_L(Y)\|_1) \\ & \leq 2\Lambda_B(R)\kappa(\min\{\varepsilon, \beta_m\})\|X - Y\|_1. \end{aligned}$$

Por tanto,

$$|c_{BM}(X; K, L) - c_{BM}(Y; K, L)| \leq C_{BM}(m, \varepsilon, R)\|X - Y\|_1.$$

La conclusión se sigue tomando el máximo entre las dos constantes. □

Observación 8.12 (Propagacion de regularidad por Bellman). *Los lemas anteriores separan las dos fuentes de variacion que aparecen en la recurrencia. La primera es el costo de etapa,*

$$c(X, u),$$

que cambia con X . La segunda es el estado alcanzado,

$$T^u(X),$$

donde se evalua el valor futuro. La recurrencia de Bellman combina ambas piezas en la forma

$$c(X, u) + V_{\tau-1}(T^u(X)).$$

La literatura de programacion dinamica introduce precisamente esta separacion entre decision presente y subproblema restante [Bellman, 1952]. En control optimo, esta estructura se interpreta como una contribucion acumulada de trayectoria junto con un costo terminal [Kappen, 2005]; en control KL, el costo probabilistico se expresa mediante divergencias y el problema se propaga hacia atras por funciones de valor o mensajes [Kappen et al., 2012]. En la Seccion G, esta lectura se concreta en el hecho de que la regularidad de $V_{\tau-1}$, junto con las cotas uniformes para c y T^u , produce regularidad de V_τ .

Como las cotas anteriores son uniformes en la accion admisible $u \in \mathcal{A}_{\varepsilon,R}$, el paso final consiste en verificar que el infimo sobre acciones conserva la misma cota Lipschitz.

Proposición 8.5 (Regularidad Lipschitz de V_τ). Sea $P \in \Delta_n^\circ$, $0 < \varepsilon \leq 1/n$, $R > 0$ y $m \in (0, 1/n]$. Definamos

$$\Lambda_B(R) := 2e^{2R}, \quad \alpha := \varepsilon e^{-2R}.$$

Sea

$$L_0(m) := \frac{1}{m}.$$

Para $\tau \geq 1$, definamos recursivamente

$$L_\tau(m) := C_c(m, \varepsilon, R) + \Lambda_B(R)L_{\tau-1}(\alpha).$$

Entonces, para todo $\tau \in \mathbb{N}$ y para cualesquiera $X, Y \in \Delta_n(m)$, se cumple

$$|V_\tau(X) - V_\tau(Y)| \leq L_\tau(m)\|X - Y\|_1.$$

En particular, sobre la region $\Delta_n(\alpha)$,

$$L_\tau(\alpha) = \Lambda_B(R)^\tau \frac{1}{\alpha} + C_c(\alpha, \varepsilon, R) \sum_{j=0}^{\tau-1} \Lambda_B(R)^j.$$

Demostración. Para $\tau = 0$,

$$V_0(X) = D_{\text{KL}}(P\|X) = \sum_{i=1}^n P_i \log \frac{P_i}{X_i}.$$

Si $X, Y \in \Delta_n(m)$, entonces

$$|V_0(X) - V_0(Y)| = \left| \sum_{i=1}^n P_i \log \frac{Y_i}{X_i} \right|.$$

Como $X_i, Y_i \geq m$, la funcion $x \mapsto \log x$ tiene derivada acotada por $1/m$ sobre $[m, 1]$. Por tanto,

$$|\log Y_i - \log X_i| \leq \frac{1}{m}|Y_i - X_i|.$$

Luego

$$|V_0(X) - V_0(Y)| \leq \frac{1}{m} \sum_{i=1}^n P_i |X_i - Y_i| \leq \frac{1}{m} \|X - Y\|_1.$$

Asi,

$$L_0(m) = \frac{1}{m}.$$

Supongamos ahora que la afirmacion vale para $\tau - 1$ en la region $\Delta_n(\alpha)$. Para $u \in \mathcal{A}_{\varepsilon, R}$, escribamos

$$F_u(X) := c(X, u) + V_{\tau-1}(T^u(X)).$$

Por el Lema 8.6,

$$|c(X, u) - c(Y, u)| \leq C_c(m, \varepsilon, R) \|X - Y\|_1.$$

Por el Lema 8.4,

$$T^u(X), T^u(Y) \in \Delta_n(\alpha).$$

Por hipotesis inductiva,

$$|V_{\tau-1}(T^u(X)) - V_{\tau-1}(T^u(Y))| \leq L_{\tau-1}(\alpha) \|T^u(X) - T^u(Y)\|_1.$$

Por el Lema 8.3,

$$\|T^u(X) - T^u(Y)\|_1 \leq \Lambda_B(R) \|X - Y\|_1.$$

Combinando estas cotas,

$$|F_u(X) - F_u(Y)| \leq [C_c(m, \varepsilon, R) + \Lambda_B(R) L_{\tau-1}(\alpha)] \|X - Y\|_1.$$

Es decir,

$$|F_u(X) - F_u(Y)| \leq L_\tau(m) \|X - Y\|_1$$

uniformemente en $u \in \mathcal{A}_{\varepsilon, R}$.

Como

$$V_\tau(X) = \inf_{u \in \mathcal{A}_{\varepsilon, R}} F_u(X),$$

el infimo de una familia de funciones Lipschitz con la misma constante tambien es Lipschitz con esa constante. En efecto, dado $\delta > 0$, elijase $u_\delta \in \mathcal{A}_{\varepsilon, R}$ tal que

$$F_{u_\delta}(Y) \leq V_\tau(Y) + \delta.$$

Entonces

$$V_\tau(X) - V_\tau(Y) \leq F_{u_\delta}(X) - F_{u_\delta}(Y) + \delta \leq L_\tau(m) \|X - Y\|_1 + \delta.$$

Haciendo $\delta \downarrow 0$,

$$V_\tau(X) - V_\tau(Y) \leq L_\tau(m) \|X - Y\|_1.$$

Intercambiando X y Y , se obtiene

$$V_\tau(Y) - V_\tau(X) \leq L_\tau(m) \|X - Y\|_1.$$

Por tanto,

$$|V_\tau(X) - V_\tau(Y)| \leq L_\tau(m) \|X - Y\|_1.$$

Finalmente, si $m = \alpha$, la recurrencia queda

$$L_\tau(\alpha) = C_c(\alpha, \varepsilon, R) + \Lambda_B(R) L_{\tau-1}(\alpha), \quad L_0(\alpha) = \frac{1}{\alpha}.$$

Iterando,

$$L_\tau(\alpha) = \Lambda_B(R)^\tau \frac{1}{\alpha} + C_c(\alpha, \varepsilon, R) \sum_{j=0}^{\tau-1} \Lambda_B(R)^j.$$

□

Corolario 8.2 (Control del valor futuro por el defecto de ordenamiento). *Bajo las hipotesis de la Proposicion 8.5, si*

$$X \in \Delta_n^\circ, \quad K \in \mathcal{K}_\varepsilon, \quad \log L \in \mathcal{U}_R,$$

entonces, para todo $\tau \geq 1$,

$$\left| V_{\tau-1}(T_{MB}^{K,L}(X)) - V_{\tau-1}(T_{BM}^{K,L}(X)) \right| \leq L_{\tau-1}(\alpha) \|\mathcal{D}_{K,L}(X)\|_1.$$

Demostración. Por el Lema 8.4,

$$T_{MB}^{K,L}(X), T_{BM}^{K,L}(X) \in \Delta_n(\alpha).$$

Aplicando la Proposicion 8.5 en la region $\Delta_n(\alpha)$, se obtiene

$$\left| V_{\tau-1}(T_{MB}^{K,L}(X)) - V_{\tau-1}(T_{BM}^{K,L}(X)) \right| \leq L_{\tau-1}(\alpha) \|T_{MB}^{K,L}(X) - T_{BM}^{K,L}(X)\|_1.$$

Por la definicion del defecto de ordenamiento,

$$\mathcal{D}_{K,L}(X) = T_{MB}^{K,L}(X) - T_{BM}^{K,L}(X).$$

Sustituyendo,

$$\left| V_{\tau-1}(T_{MB}^{K,L}(X)) - V_{\tau-1}(T_{BM}^{K,L}(X)) \right| \leq L_{\tau-1}(\alpha) \|\mathcal{D}_{K,L}(X)\|_1.$$

□

Observación 8.13 (De la regularidad de Bellman a la comparacion entre ordenes). *El corolario anterior controla unicamente la diferencia de valor futuro producida por los dos estados alcanzados. En efecto,*

$$\mathcal{D}_{K,L}(X) = T_{MB}^{K,L}(X) - T_{BM}^{K,L}(X),$$

y la regularidad local de $V_{\tau-1}$ da

$$\left| V_{\tau-1}(T_{MB}^{K,L}(X)) - V_{\tau-1}(T_{BM}^{K,L}(X)) \right| \leq L_{\tau-1}(\alpha) \|\mathcal{D}_{K,L}(X)\|_1.$$

Esta estimacion no compara todavia las decisiones ordenadas completas, porque las funciones de accion-valor incorporan tambien el costo de etapa:

$$Q_\tau^{MB}(X; K, L) = c_{MB}(X; K, L) + V_{\tau-1}(T_{MB}^{K,L}(X)),$$

$$Q_\tau^{BM}(X; K, L) = c_{BM}(X; K, L) + V_{\tau-1}(T_{BM}^{K,L}(X)).$$

Por tanto,

$$Q_\tau^{MB}(X; K, L) - Q_\tau^{BM}(X; K, L) = (c_{MB}(X; K, L) - c_{BM}(X; K, L)) + (V_{\tau-1}(T_{MB}^{K,L}(X)) - V_{\tau-1}(T_{BM}^{K,L}(X))).$$

La primera diferencia mide el cambio de costo producido por el orden de aplicacion; la segunda diferencia mide el cambio de valor futuro producido por los estados alcanzados.

La justificacion estructural de separar costo presente y problema restante ya fue fijada en las Observaciones 8.9, 8.10 y 8.12. En este punto no se introduce una nueva lectura bibliografica; se usa esa separacion para aislar la cantidad que falta controlar:

$$|c_{MB}(X; K, L) - c_{BM}(X; K, L)|.$$

Definición 8.9 (Defecto escalar de accion–valor por orden). Sea $\tau \geq 1$. Sea $X \in \Delta_n^\circ$, sea $K \in \mathcal{K}_\varepsilon$ y sea $L \in \mathbb{R}_{>0}^n$. El defecto escalar de accion–valor por orden asociado al par (K, L) se define por

$$\eta_\tau(X; K, L) := Q_\tau^{MB}(X; K, L) - Q_\tau^{BM}(X; K, L).$$

Equivalentemente, se introducen las diferencias

$$\Delta c(X; K, L) := c_{MB}(X; K, L) - c_{BM}(X; K, L),$$

y

$$\Delta v_\tau(X; K, L) := V_{\tau-1}(T_{MB}^{K,L}(X)) - V_{\tau-1}(T_{BM}^{K,L}(X)).$$

Con esta notacion,

$$\eta_\tau(X; K, L) = \Delta c(X; K, L) + \Delta v_\tau(X; K, L).$$

La cantidad $\eta_\tau(X; K, L)$ es firmada. Si

$$\eta_\tau(X; K, L) > 0,$$

entonces el orden BM tiene menor accion–valor que el orden MB para el mismo par (K, L) . Si

$$\eta_\tau(X; K, L) < 0,$$

entonces el orden MB tiene menor accion–valor que el orden BM para el mismo par (K, L) . Si

$$\eta_\tau(X; K, L) = 0,$$

ambos ordenes tienen el mismo accion–valor en X para el par (K, L) . Por tanto, $\eta_\tau(X; K, L)$ no mide diferencia de estados. La diferencia de estados esta dada por $\mathcal{D}_{K,L}(X)$. El defecto $\eta_\tau(X; K, L)$ mide la diferencia total entre las dos funciones de accion–valor ordenadas.

Lema 8.7 (Control del defecto de costos de etapa). Sea $m \in (0, 1/n]$. Sea

$$X \in \Delta_n(m), \quad K \in \mathcal{K}_\varepsilon, \quad \log L \in \mathcal{U}_R.$$

Definamos

$$m_* := e^{-2R} \min\{m, \varepsilon\}.$$

Entonces

$$|\Delta c(X; K, L)| \leq \kappa(m_*) (2\|XK - B_L(X)\|_1 + \|\mathcal{D}_{K,L}(X)\|_1).$$

Demostración. Por definicion,

$$\Delta \mathbf{c}(X; K, L) = c_{MB}(X; K, L) - c_{BM}(X; K, L).$$

Usando las definiciones de c_{MB} y c_{BM} , se tiene

$$\begin{aligned} \Delta \mathbf{c}(X; K, L) &= D_{\text{KL}}(XK \| X) - D_{\text{KL}}(B_L(X) \| X) \\ &\quad + D_{\text{KL}}(B_L(XK) \| XK) - D_{\text{KL}}(B_L(X)K \| B_L(X)). \end{aligned}$$

Como $X \in \Delta_n(m)$, se tiene $X \in \Delta_n(m_*)$. Como $K \in \mathcal{K}_\varepsilon$, se tiene

$$XK \in \Delta_n(\varepsilon) \subseteq \Delta_n(m_*).$$

Como $\log L \in \mathcal{U}_R$, se tiene

$$B_L(X) \in \Delta_n(me^{-2R}) \subseteq \Delta_n(m_*),$$

y

$$B_L(XK) \in \Delta_n(\varepsilon e^{-2R}) \subseteq \Delta_n(m_*).$$

Finalmente,

$$B_L(X)K \in \Delta_n(\varepsilon) \subseteq \Delta_n(m_*).$$

Por tanto, todos los argumentos de las divergencias anteriores pertenecen a $\Delta_n(m_*)$.

Aplicando el Lema 8.5 a los pares

$$(XK, X) \quad \text{y} \quad (B_L(X), X),$$

se obtiene

$$|D_{\text{KL}}(XK \| X) - D_{\text{KL}}(B_L(X) \| X)| \leq \kappa(m_*) \|XK - B_L(X)\|_1.$$

Aplicando nuevamente el Lema 8.5 a los pares

$$(B_L(XK), XK) \quad \text{y} \quad (B_L(X)K, B_L(X)),$$

se obtiene

$$\begin{aligned} &|D_{\text{KL}}(B_L(XK) \| XK) - D_{\text{KL}}(B_L(X)K \| B_L(X))| \\ &\leq \kappa(m_*) (\|B_L(XK) - B_L(X)K\|_1 + \|XK - B_L(X)\|_1). \end{aligned}$$

Por la definicion del defecto de ordenamiento,

$$B_L(XK) - B_L(X)K = \mathcal{D}_{K,L}(X).$$

Sumando las dos estimaciones,

$$|\Delta \mathbf{c}(X; K, L)| \leq \kappa(m_*) (2\|XK - B_L(X)\|_1 + \|\mathcal{D}_{K,L}(X)\|_1).$$

□

Proposición 8.6 (Control del defecto escalar de acción–valor). Sea $\tau \geq 1$. Sea $m \in (0, 1/n]$. Supongamos que

$$X \in \Delta_n(m), \quad K \in \mathcal{K}_\varepsilon, \quad \log L \in \mathcal{U}_R.$$

Definamos

$$m_* := e^{-2R} \min\{m, \varepsilon\}, \quad \alpha := \varepsilon e^{-2R}.$$

Entonces

$$|\eta_\tau(X; K, L)| \leq \kappa(m_*) (2\|XK - B_L(X)\|_1 + \|\mathcal{D}_{K,L}(X)\|_1) + L_{\tau-1}(\alpha) \|\mathcal{D}_{K,L}(X)\|_1.$$

Equivalentemente,

$$|\eta_\tau(X; K, L)| \leq 2\kappa(m_*)\|XK - B_L(X)\|_1 + (\kappa(m_*) + L_{\tau-1}(\alpha))\|\mathcal{D}_{K,L}(X)\|_1.$$

Demostración. Por la Definición 8.9,

$$\eta_\tau(X; K, L) = \Delta \mathfrak{c}(X; K, L) + \Delta \mathfrak{v}_\tau(X; K, L).$$

Por la desigualdad triangular,

$$|\eta_\tau(X; K, L)| \leq |\Delta \mathfrak{c}(X; K, L)| + |\Delta \mathfrak{v}_\tau(X; K, L)|.$$

El Lema 8.7 da

$$|\Delta \mathfrak{c}(X; K, L)| \leq \kappa(m_*) (2\|XK - B_L(X)\|_1 + \|\mathcal{D}_{K,L}(X)\|_1).$$

Por el Corolario 8.2, aplicado a

$$\mathcal{D}_{K,L}(X) = T_{MB}^{K,L}(X) - T_{BM}^{K,L}(X),$$

se obtiene

$$|\Delta \mathfrak{v}_\tau(X; K, L)| \leq L_{\tau-1}(\alpha) \|\mathcal{D}_{K,L}(X)\|_1.$$

Sustituyendo ambas cotas en la desigualdad triangular,

$$|\eta_\tau(X; K, L)| \leq \kappa(m_*) (2\|XK - B_L(X)\|_1 + \|\mathcal{D}_{K,L}(X)\|_1) + L_{\tau-1}(\alpha) \|\mathcal{D}_{K,L}(X)\|_1.$$

Agrupando los terminos con $\|\mathcal{D}_{K,L}(X)\|_1$, resulta

$$|\eta_\tau(X; K, L)| \leq 2\kappa(m_*)\|XK - B_L(X)\|_1 + (\kappa(m_*) + L_{\tau-1}(\alpha))\|\mathcal{D}_{K,L}(X)\|_1.$$

□

Proposición 8.7 (Suboptimalidad de un paso por eleccion de orden). Sea $\tau \geq 1$. Sea $m \in (0, 1/n]$. Supongamos que

$$X \in \Delta_n(m), \quad K \in \mathcal{K}_\varepsilon, \quad \log L \in \mathcal{U}_R.$$

Definamos

$$m_* := e^{-2R} \min\{m, \varepsilon\}, \quad \alpha := \varepsilon e^{-2R}.$$

Entonces

$$0 \leq Q_\tau^{MB}(X; K, L) - \min\{Q_\tau^{MB}(X; K, L), Q_\tau^{BM}(X; K, L)\} \leq |\eta_\tau(X; K, L)|,$$

y

$$0 \leq Q_\tau^{BM}(X; K, L) - \min\{Q_\tau^{MB}(X; K, L), Q_\tau^{BM}(X; K, L)\} \leq |\eta_\tau(X; K, L)|.$$

En particular,

$$\begin{aligned} Q_\tau^{MB}(X; K, L) - \min\{Q_\tau^{MB}(X; K, L), Q_\tau^{BM}(X; K, L)\} \\ \leq 2\kappa(m_*)\|XK - B_L(X)\|_1 + (\kappa(m_*) + L_{\tau-1}(\alpha))\|\mathcal{D}_{K,L}(X)\|_1, \end{aligned}$$

y

$$\begin{aligned} Q_\tau^{BM}(X; K, L) - \min\{Q_\tau^{MB}(X; K, L), Q_\tau^{BM}(X; K, L)\} \\ \leq 2\kappa(m_*)\|XK - B_L(X)\|_1 + (\kappa(m_*) + L_{\tau-1}(\alpha))\|\mathcal{D}_{K,L}(X)\|_1. \end{aligned}$$

Demostración. Pongamos

$$a := Q_\tau^{MB}(X; K, L), \quad b := Q_\tau^{BM}(X; K, L).$$

Por definicion,

$$\eta_\tau(X; K, L) = a - b.$$

Si $a \leq b$, entonces

$$a - \min\{a, b\} = a - a = 0,$$

y

$$b - \min\{a, b\} = b - a = |\eta_\tau(X; K, L)|.$$

Si $b < a$, entonces

$$b - \min\{a, b\} = b - b = 0,$$

y

$$a - \min\{a, b\} = a - b = |\eta_\tau(X; K, L)|.$$

En ambos casos,

$$0 \leq a - \min\{a, b\} \leq |\eta_\tau(X; K, L)|,$$

y

$$0 \leq b - \min\{a, b\} \leq |\eta_\tau(X; K, L)|.$$

Por la Proposicion 8.6,

$$|\eta_\tau(X; K, L)| \leq 2\kappa(m_*)\|XK - B_L(X)\|_1 + (\kappa(m_*) + L_{\tau-1}(\alpha))\|\mathcal{D}_{K,L}(X)\|_1.$$

Sustituyendo esta cota en las dos desigualdades anteriores, se obtienen las estimaciones afirmadas. $\square$

Definición 8.10 (Trayectoria admisible ordenada y costo realizado). Sea $N \geq 1$. Sea $X_0 \in \Delta_n^\circ$ y sea

$$u_t = (K_t, L_t, \sigma_t) \in \mathcal{A}_{\varepsilon, R}, \quad t = 0, \dots, N-1.$$

La trayectoria admisible ordenada generada por

$$(X_0; u_0, \dots, u_{N-1})$$

es la sucesion $(X_t)_{t=0}^N \subset \Delta_n^\circ$ definida recursivamente por

$$X_{t+1} := T^{u_t}(X_t), \quad t = 0, \dots, N-1.$$

Equivalentemente, si $u_t = (K_t, L_t, \sigma_t)$, entonces

$$X_{t+1} = \begin{cases} T_{MB}^{K_t, L_t}(X_t), & \text{si } \sigma_t = MB, \\ T_{BM}^{K_t, L_t}(X_t), & \text{si } \sigma_t = BM. \end{cases}$$

El costo realizado en N pasos por la sucesion de acciones

$$u_0, \dots, u_{N-1}$$

desde el estado inicial X_0 se define por

$$J_N(X_0; u_0, \dots, u_{N-1}) := \sum_{t=0}^{N-1} c(X_t, u_t) + V_0(X_N).$$

Como $V_0 = E_P$, tambien puede escribirse

$$J_N(X_0; u_0, \dots, u_{N-1}) = \sum_{t=0}^{N-1} c(X_t, u_t) + E_P(X_N).$$

Teorema 8.1 (Cota de suboptimalidad multi-paso (Q-función)). Sean $\varepsilon > 0$, $R > 0$ y $\tau \geq 1$. Sean $X \in \Delta_n^\circ$, $K \in \mathcal{K}_\varepsilon$ y $\log L \in \mathcal{U}_R$. Sea $\mathcal{C} \subset \Delta_n^\circ$ un compacto que contenga a X y a las imágenes relevantes de X bajo las composiciones admisibles de B_L y M_K hasta el horizonte τ . Supóngase que existe una constante $L_{\tau-1}(\mathcal{C})$ tal que $V_{\tau-1}$ es Lipschitz en $\mathcal{C}$ con esa constante, y definamos

$$m(\mathcal{C}) := \min_{Y \in \mathcal{C}} \min_{1 \leq i \leq n} Y_i, \quad m_{**} := \min\{m(\mathcal{C}), \varepsilon\} e^{-2R}.$$

Entonces

$$\left| Q_\tau^{MB}(X; K, L) - Q_\tau^{BM}(X; K, L) \right| \leq C_\tau(\mathcal{C}, \varepsilon, R) \left(\|XK - B_L(X)\|_1 + \|\mathcal{D}_{K,L}(X)\|_1 \right),$$

donde

$$C_\tau(\mathcal{C}, \varepsilon, R) := 2\Lambda(m_{**}) + L_{\tau-1}(\mathcal{C}).$$

En particular, si $XK = B_L(X)$ y $\mathcal{D}_{K,L}(X) = 0$, entonces

$$Q_\tau^{MB}(X; K, L) = Q_\tau^{BM}(X; K, L).$$

Demostración. Se escribe

$$Q_{\tau}^{MB}(X; K, L) - Q_{\tau}^{BM}(X; K, L) = [c_{MB}(X; K, L) - c_{BM}(X; K, L)] + [V_{\tau-1}(B_L(XK)) - V_{\tau-1}(B_L(X)K)].$$

Para el primer corchete, la comparación local de las dos sumas de KL da

$$|c_{MB}(X; K, L) - c_{BM}(X; K, L)| \leq 2\Lambda(m_{**}) \left(\|XK - B_L(X)\|_1 + \|\mathcal{D}_{K,L}(X)\|_1 \right).$$

Para el segundo corchete, la condición de Lipschitz de $V_{\tau-1}$ en $\mathcal{C}$ implica

$$|V_{\tau-1}(B_L(XK)) - V_{\tau-1}(B_L(X)K)| \leq L_{\tau-1}(\mathcal{C}) \|B_L(XK) - B_L(X)K\|_1 = L_{\tau-1}(\mathcal{C}) \|\mathcal{D}_{K,L}(X)\|_1.$$

Sumando ambas cotas y absorbiendo el término de $\|\mathcal{D}_{K,L}(X)\|_1$ en la constante $C_{\tau}(\mathcal{C}, \varepsilon, R)$, se obtiene la desigualdad anunciada. $\square$

Referencias

- John Aitchison. *The Statistical Analysis of Compositional Data*. Chapman and Hall, London, 1986. Reprinted in 2003.
- Richard Bellman. On the theory of dynamic programming. *Proceedings of the National Academy of Sciences of the United States of America*, 38(8):716–719, 1952.
- Stephane Gaubert and Zheng Qu. Dobrushin’s ergodicity coefficient for markov operators on cones, 2014. Preprint.
- Hilbert J. Kappen. A linear theory for control of non-linear stochastic systems. *Physical Review Letters*, 95(20):200201, 2005.
- Hilbert J. Kappen, Vicenc Gomez, and Manfred Opper. Optimal control as a graphical model inference problem, 2012. arXiv:0901.0633v3 [math.OC].
- Andrei Nikolaevich Kolmogorov. *Grundbegriffe der Wahrscheinlichkeitsrechnung*. Springer, Berlin, 1933. English translation: *Foundations of the Theory of Probability*, Chelsea Publishing, New York, 1956.
- J. R. Norris. *Markov Chains*. Cambridge University Press, Cambridge, 1997. Cambridge Series in Statistical and Probabilistic Mathematics.
- Bjoern Sprungk. On the local lipschitz stability of bayesian inverse problems, 2020. Preprint.
- Emanuel Todorov. Efficient computation of optimal actions. *Proceedings of the National Academy of Sciences of the United States of America*, 106(28):11478–11483, 2009.