

Control Informativa

Proyecto de Investigación II — ProInt_II

Alejandro Cruz López

Universidad Autónoma Metropolitana
Unidad Iztapalapa

Asesores

Dr. Asael Fabián Martínez Martínez
Dr. Joaquín Delgado Fernández 26 de mayo de 2026

Índice

1. Mapa de trabajo	2
2. Sección A – Probabilidad y simplex	2
3. Sección B – Correcciones locales y cambio de medida	3
4. Sección C – Operadores globales multiplicativos y composición	4
5. Sección D – Divergencia KL, métrica de Fisher y dinámica inducida	5
6. Sección E – Semántica bayesiana	7
6.1. Ruta de lectura	7
6.2. Modelos continuos como estados informacionales discretos	10
7. Ejercicios de referencia bayesiana	12
8. Sección F — Semántica markoviana	17

1. Mapa de trabajo

Este archivo es un borrador de trabajo para avanzar por capas. La ruta lógica es:

- Sección A: espacio de probabilidad, particiones finitas y símplex.
- Sección B: correcciones locales y cambio de medida discreto.
- Sección C: operadores globales multiplicativos y composición.
- Sección D: divergencia KL, métrica de Fisher y dinámica inducida.
- Sección E0: semántica bayesiana como caso particular del operador global.

Las proposiciones que realmente sostienen la transición hacia la semántica bayesiana son:

Prop. 2.1, Prop. 3.1, Prop. 3.2, Prop. 3.3,
Prop. 4.1, Prop. 4.2, Prop. 5.1, Prop. 5.2, Teo. 5.1.

2. Sección A – Probabilidad y símplex

Este bloque fija el dominio probabilístico discreto. El punto de partida es un espacio de probabilidad en el sentido de Kolmogórov [?]. A partir de una partición medible finita se asocia a la medida un vector de probabilidades, que se interpreta como estado informacional discreto.

Definición 2.1 (Espacio de probabilidad). *Un espacio de probabilidad es una terna $(\Omega, \mathcal{F}, P)$ tal que:*

1. Ω es un conjunto no vacío;
2. $\mathcal{F}$ es una σ -álgebra de subconjuntos de Ω ;
3. $P : \mathcal{F} \rightarrow [0, 1]$ es una medida con $P(\Omega) = 1$.

Definición 2.2 (Partición medible finita). *Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad. Una partición medible finita de Ω es una familia finita*

$$\Pi = \{E_1, \dots, E_n\} \subset \mathcal{F}, \quad n \geq 1,$$

tal que:

1. $E_i \cap E_j = \emptyset$ si $i \neq j$;
2. $\bigcup_{i=1}^n E_i = \Omega$.

Diremos que Π es no degenerada si además

$$P(E_i) > 0, \quad i = 1, \dots, n.$$

Definición 2.3 (Símplex de probabilidad e interior). Para $n \geq 1$ se define el símplex de probabilidad por

$$\Delta_n := \left\{ x \in \mathbb{R}^n : x_i \geq 0, \sum_{i=1}^n x_i = 1 \right\}.$$

Su interior relativo viene dado por

$$\Delta_n^\circ := \{ x \in \Delta_n : x_i > 0 \text{ para todo } i \}.$$

Definición 2.4 (Estado informacional discreto). Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sea $\Pi = \{E_1, \dots, E_n\}$ una partición medible finita. El estado informacional discreto asociado a Π es el vector

$$X = (X_1, \dots, X_n) \in \mathbb{R}^n, \quad X_i := P(E_i), \quad i = 1, \dots, n.$$

Proposición 2.1. Sea X el estado informacional discreto asociado a una partición medible finita $\Pi = \{E_1, \dots, E_n\}$. Entonces:

1. $X \in \Delta_n$;
2. si Π es no degenerada, entonces $X \in \Delta_n^\circ$.

Definición 2.5 (Operador de cierre). Sea

$$\mathbb{R}_{>0}^n := \{ z = (z_1, \dots, z_n) \in \mathbb{R}^n : z_i > 0 \text{ para todo } i \}.$$

El operador de cierre es la aplicación

$$\mathcal{C} : \mathbb{R}_{>0}^n \rightarrow \Delta_n^\circ, \quad \mathcal{C}(z) := \frac{1}{\sum_{i=1}^n z_i} z.$$

Observación 2.1. El cierre conserva únicamente la información relativa entre coordenadas. Esta idea es la que conecta el símplex con el formalismo composicional de Aitchison [?].

3. Sección B – Correcciones locales y cambio de medida

Aquí se introduce el mecanismo elemental de actualización. Dado un estado $X \in \Delta_n$, se definen correcciones relativas admisibles que preservan la masa total y se asocia a cada una de ellas un operador local. El resultado puede interpretarse como un cambio de medida discreto sobre la partición subyacente.

Definición 3.1 (Conjunto de correcciones admisibles en X). Sea $X = (X_1, \dots, X_n) \in \Delta_n$. Se define el conjunto de correcciones admisibles en X por

$$C(X) := \left\{ Y = (Y_1, \dots, Y_n) \in \mathbb{R}^n \mid X_i(1 + Y_i) \geq 0 \text{ para todo } i, \sum_{i=1}^n X_i(1 + Y_i) = 1 \right\}.$$

Definición 3.2 (Operador informacional local). Sea $X \in \Delta_n$ y sea $Y \in C(X)$. El operador informacional local asociado a Y en X es el vector

$$T_Y^{\text{loc}}(X) = (T_Y^{\text{loc}}(X)_1, \dots, T_Y^{\text{loc}}(X)_n) \in \mathbb{R}^n,$$

definido por

$$T_Y^{\text{loc}}(X)_i := X_i(1 + Y_i), \quad i = 1, \dots, n.$$

Proposición 3.1 (Preservación local del simplex). Sea $X \in \Delta_n$ y sea $Y \in C(X)$. Entonces

$$T_Y^{\text{loc}}(X) \in \Delta_n.$$

Proposición 3.2 (Cambio de medida discreto inducido por una corrección local). Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sea $\Pi = \{E_1, \dots, E_n\} \subset \mathcal{F}$ una partición medible finita no degenerada. Defínase

$$X_i := P(E_i), \quad i = 1, \dots, n,$$

de modo que $X = (X_1, \dots, X_n) \in \Delta_n^\circ$.

Sea $Y \in C(X)$ y defínase

$$h(\omega) := 1 + Y_i \quad \text{si } \omega \in E_i.$$

Sea además

$$Q_Y(A) := \int_A h(\omega) dP(\omega), \quad A \in \mathcal{F}.$$

Entonces Q_Y es una medida de probabilidad sobre $(\Omega, \mathcal{F})$.

Proposición 3.3 (Compatibilidad entre T_Y^{loc} y el cambio de medida). Con la notación anterior, para cada $i = 1, \dots, n$ se cumple

$$Q_Y(E_i) = T_Y^{\text{loc}}(X)_i.$$

4. Sección C – Operadores globales multiplicativos y composición

Se pasa ahora al operador global, definido mediante correcciones multiplicativas positivas y renormalización. Esta es la versión que se usa después para la semántica bayesiana.

Definición 4.1 (Correcciones globales). Se define el conjunto de correcciones globales por

$$C_{\text{glob}} := \left\{ Y = (Y_1, \dots, Y_n) \in \mathbb{R}^n \mid 1 + Y_i > 0 \text{ para todo } i \right\}.$$

Para cada $Y \in C_{\text{glob}}$, el vector de factores multiplicativos asociado viene dado por

$$a(Y) := (1 + Y_1, \dots, 1 + Y_n) \in \mathbb{R}_{>0}^n.$$

Definición 4.2 (Operador informacional global). Sea $Y \in C_{\text{glob}}$. El operador informacional global asociado a Y es la aplicación

$$T_Y : \Delta_n^\circ \rightarrow \Delta_n^\circ, \quad T_Y(X) := \frac{X \circ a(Y)}{\sum_{j=1}^n X_j a_j(Y)},$$

donde $\circ$ denota el producto coordenada a coordenada. En forma explícita,

$$T_Y(X)_i = \frac{X_i(1 + Y_i)}{\sum_{j=1}^n X_j(1 + Y_j)}, \quad i = 1, \dots, n.$$

Proposición 4.1 (Preservación del interior del simplex). Sea $Y \in C_{\text{glob}}$. Entonces, para todo $X \in \Delta_n^\circ$,

$$T_Y(X) \in \Delta_n^\circ.$$

Proposición 4.2 (Ley de composición). Sean $Y_1, Y_2 \in C_{\text{glob}}$. Entonces existe un único $Y_{\text{tot}} \in C_{\text{glob}}$ tal que

$$T_{Y_2} \circ T_{Y_1} = T_{Y_{\text{tot}}},$$

y está determinado por

$$1 + Y_{\text{tot}} = (1 + Y_1) \circ (1 + Y_2).$$

Observación 4.1 (Coordenadas log-multiplicativas). Para $Y \in C_{\text{glob}}$ se definen las coordenadas

$$\theta_i := \log(1 + Y_i), \quad i = 1, \dots, n.$$

Entonces

$$T_\theta(X) = \frac{X \circ e^\theta}{\sum_{j=1}^n X_j e^{\theta_j}},$$

y la ley de composición se vuelve aditiva en θ .

5. Sección D – Divergencia KL, métrica de Fisher y dinámica inducida

En esta parte se introduce el funcional informacional

$$E_P(X) := D_{\text{KL}}(P \| X),$$

se calcula su gradiente respecto de la métrica de Fisher en el interior del simplex y se obtiene la dinámica continua asociada. Esta dinámica es la base para pasar de la corrección multiplicativa al flujo de descenso.

Definición 5.1 (Divergencia de Kullback–Leibler discreta). Sea $P \in \Delta_n^\circ$ fija. Para $X \in \Delta_n$ se define

$$D_{\text{KL}}(P \| X) = \begin{cases} \sum_{i=1}^n P_i \log\left(\frac{P_i}{X_i}\right), & \text{si } X_i > 0 \text{ para todo } i, \\ +\infty, & \text{si existe } i \text{ tal que } P_i > 0 \text{ y } X_i = 0. \end{cases}$$

Se define además el funcional

$$E_P : \Delta_n^\circ \rightarrow \mathbb{R}, \quad E_P(X) := D_{\text{KL}}(P \| X).$$

Definición 5.2 (Espacio tangente del simplex). Sea $X \in \Delta_n^\circ$. El espacio tangente en X viene dado por

$$T_X \Delta_n^\circ = \left\{ u \in \mathbb{R}^n \mid \sum_{i=1}^n u_i = 0 \right\}.$$

Definición 5.3 (Métrica de Fisher discreta). Para $X \in \Delta_n^\circ$, la métrica de Fisher en $T_X \Delta_n^\circ$ es

$$g_X(u, v) := \sum_{i=1}^n \frac{u_i v_i}{X_i}, \quad u, v \in T_X \Delta_n^\circ.$$

Definición 5.4 (Gradiente riemanniano respecto de la métrica de Fisher). Sea $E : \Delta_n^\circ \rightarrow \mathbb{R}$ una función suave. El gradiente riemanniano de E respecto de g es el campo $\text{grad}_g E$ caracterizado por

$$g_X(\text{grad}_g E(X), u) = dE(X)[u], \quad \forall u \in T_X \Delta_n^\circ.$$

Proposición 5.1 (Gradiente Fisher de la divergencia KL). Sea $P \in \Delta_n^\circ$ fija y sea

$$E_P(X) = D_{\text{KL}}(P \| X) = \sum_{i=1}^n P_i \log\left(\frac{P_i}{X_i}\right), \quad X \in \Delta_n^\circ.$$

Entonces

$$\text{grad}_g E_P(X) = X - P, \quad X \in \Delta_n^\circ.$$

Definición 5.5 (Flujo de gradiente Fisher–KL). El flujo de gradiente asociado a E_P es la ecuación diferencial

$$\dot{X}(t) = -\text{grad}_g E_P(X(t)), \quad X(t) \in \Delta_n^\circ.$$

Por la Proposición 5.1, esta ecuación toma la forma

$$\dot{X}(t) = P - X(t).$$

Proposición 5.2 (Solución explícita del flujo). Sea $X_0 \in \Delta_n^\circ$. La solución de

$$\dot{X}(t) = P - X(t), \quad X(0) = X_0,$$

viene dada por

$$X(t) = e^{-t} X_0 + (1 - e^{-t}) P, \quad t \geq 0.$$

En particular, $X(t) \in \Delta_n^\circ$ para todo $t \geq 0$ y $X(t) \rightarrow P$ cuando $t \rightarrow \infty$.

Proposición 5.3 (Monotonidad de E_P a lo largo del flujo). Sea $X(\cdot)$ una solución del flujo Fisher–KL. Entonces

$$\frac{d}{dt} E_P(X(t)) = -g_{X(t)}(\text{grad}_g E_P(X(t)), \text{grad}_g E_P(X(t))) \leq 0.$$

La igualdad sólo ocurre si $X(t) = P$.

Proposición 5.4 (Mínimo global de E_P). Para todo $X \in \Delta_n^\circ$ se cumple

$$E_P(X) \geq 0,$$

y además

$$E_P(X) = 0 \iff X = P.$$

En particular, P es el único minimizador global de E_P en Δ_n° .

Teorema 5.1 (Equivalencia estructural Sección C $\leftrightarrow$ Sección D). Sea $P \in \Delta_n^\circ$ fijo. Considérese el operador informacional global T_Y del Sección C, definido para $Y \in C_{\text{glob}}$ por

$$T_Y(X) = \frac{X \circ (1 + Y)}{\langle X, 1 + Y \rangle}.$$

Defínase, para cada $X \in \Delta_n^\circ$, el campo de corrección óptima

$$Y^*(X, P)_i := \frac{P_i}{X_i} - 1, \quad i = 1, \dots, n.$$

Entonces:

1. $T_{Y^*(X, P)}(X) = P$;
2. la iteración $X_{k+1} = T_{\alpha Y^*(X_k, P)}(X_k)$ se reduce a la interpolación convexa $X_{k+1} = (1 - \alpha)X_k + \alpha P$;
3. el límite infinitesimal de la regla global conduce a $\dot{X} = P - X$, que coincide con el flujo de gradiente Fisher-KL.

6. Sección E – Semántica bayesiana

Esta es la parte que queremos desarrollar con más calma. La idea es fijar un espacio conjunto hipótesis-observaciones, identificar la verosimilitud como una corrección global y demostrar que la actualización de Bayes aparece exactamente como un caso particular del operador T_Y . Esta lectura no se introduce de manera aislada: está alineada con la interpretación de Bayes spaces de Egozcue, Pawlowsky-Glahn, Tolosana-Delgado, Ortego y van den Boogaart (2013), donde la regla de Bayes se entiende como una perturbación entre densidades proporcionales, y también con la geometría afín del simplex de Pistone y Shoaib (2024), que permite leer las actualizaciones como operadores internos sobre el espacio de estados.

En paralelo, la parte diferencial del marco se apoya en la geometría de la información de Amari (2016), mientras que la interpretación variacional y del statistical bundle remite a Pistone (2018). Por eso, el objetivo de esta sección no es solo obtener una fórmula de actualización, sino situarla en una narración geométrica y probabilística coherente con la bibliografía ya revisada.

6.1. Ruta de lectura

La semántica bayesiana usa como soporte directo:

- la representación del estado como punto de Δ_n° ;
- la actualización multiplicativa global T_Y ;
- la composición de correcciones por producto coordinado;
- la lectura dinámica via KL y el gradiente Fisher;
- la equivalencia estructural que conecta la corrección óptima con el flujo de descenso.

En términos bibliográficos, la base composicional del símplex se apoya en Egozcue, Pawlowsky-Glahn, Mateu-Figueras y Barcelo-Vidal (2003), así como en las notas de Pawlowsky-Glahn, Egozcue y Tolosana-Delgado (2011). Esa base es la que hace natural pasar de vectores positivos a composiciones normalizadas y, por ello, prepara el terreno para la lectura bayesiana posterior.

Definición 6.1 (Espacio conjunto hipótesis-observaciones). *Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad (Definición 2.1) y sea*

$$\Pi_H = \{H_1, \dots, H_n\} \subset \mathcal{F}$$

una partición medible finita no degenerada de Ω , cuyos elementos se interpretan como hipótesis alternativas. Sea $\Pi_E = \{E_1, \dots, E_m\} \subset \mathcal{F}$ una segunda partición medible finita no degenerada de Ω , cuyos elementos se interpretan como observaciones posibles.

El estado informacional previo es

$$X_i := P(H_i), \quad i = 1, \dots, n,$$

que por la Proposición 2.1 pertenece a Δ_n° .

Observación 6.1 (Por qué una sola medida P). *Las particiones Π_H y Π_E viven sobre el mismo espacio $(\Omega, \mathcal{F}, P)$. Esto permite definir las probabilidades conjuntas y condicionales necesarias directamente desde P , sin introducir objetos adicionales.*

Definición 6.2 (Probabilidad condicional en el espacio conjunto). *Sean $H_i \in \Pi_H$ y $E_j \in \Pi_E$. Si $P(H_i) > 0$, definimos la probabilidad condicional de la observación E_j dada la hipótesis H_i por*

$$P(E_j | H_i) := \frac{P(H_i \cap E_j)}{P(H_i)}.$$

Decimos que E_j es compatible con H_i si $P(H_i \cap E_j) > 0$, o equivalentemente si $P(E_j | H_i) > 0$.

Definición 6.3 (Verosimilitud como corrección global). *Sea $j \in \{1, \dots, m\}$ con $P(E_j) > 0$. Usando la Definición 6.2, la verosimilitud de la observación E_j bajo la hipótesis H_i es*

$$\ell_i^{(j)} := P(E_j | H_i) = \frac{P(H_i \cap E_j)}{P(H_i)}, \quad i = 1, \dots, n.$$

Cuando $\ell_i^{(j)} > 0$ para todo i , el vector $\ell^{(j)} = (\ell_1^{(j)}, \dots, \ell_n^{(j)}) \in \mathbb{R}_{>0}^n$ define una corrección global $Y^{\ell^{(j)}} \in C_{\text{glob}}$ mediante

$$1 + Y_i^{\ell^{(j)}} := \ell_i^{(j)}, \quad i = 1, \dots, n.$$

Con esta identificación, la actualización posterior puede formularse ya como una transformación del propio estado en el símplex.

Proposición 6.1 (El operador bayesiano como caso particular de T_Y). *Sea $X \in \Delta_n^\circ$ el prior con $X_i = P(H_i)$, y sea $\ell^{(j)}$ la verosimilitud de E_j . Entonces*

$$T_{Y^{\ell^{(j)}}}(X)_i = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}} = P(H_i | E_j), \quad i = 1, \dots, n.$$

Es decir, $T_{Y^{\ell^{(j)}}}(X)$ es el posterior dado que se observó E_j .

Demostración. Por definición del operador global,

$$T_{Y^{\ell(j)}}(X)_i = \frac{X_i(1 + Y_i^{\ell(j)})}{\sum_{k=1}^n X_k(1 + Y_k^{\ell(j)})} = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}}.$$

Como $X_i = P(H_i)$ y $\ell_i^{(j)} = P(E_j | H_i)$,

$$X_i \ell_i^{(j)} = P(H_i) P(E_j | H_i) = P(H_i \cap E_j).$$

Además, como Π_H es una partición de Ω ,

$$\sum_{k=1}^n X_k \ell_k^{(j)} = \sum_{k=1}^n P(H_k \cap E_j) = P(E_j).$$

Por tanto,

$$T_{Y^{\ell(j)}}(X)_i = \frac{P(H_i \cap E_j)}{P(E_j)} = P(H_i | E_j).$$

□

La unicidad de esta representación fija la regla de actualización dentro de $\mathcal{G}$ y evita ambigüedades al pasar del prior al posterior.

Proposición 6.2 (Unicidad: $T_{Y^{\ell(j)}}$ es el único operador coherente con P). *Sea $(\Omega, \mathcal{F}, P)$ el espacio conjunto de la Definición 6.1 con particiones Π_H y Π_E . Sea $j \in \{1, \dots, m\}$ con $P(H_i \cap E_j) > 0$ para todo i . Un operador $T \in \mathcal{G}$ satisface*

$$T(X)_i = P(H_i | E_j) \quad \text{para todo } i = 1, \dots, n$$

si y sólo si $T = T_{Y^{\ell(j)}}$.

Demostración. Sea $T \in \mathcal{G}$. Entonces existe $Y \in C_{\text{glob}}$ tal que $T = T_Y$. Si

$$T(X)_i = P(H_i | E_j),$$

entonces

$$\frac{X_i(1 + Y_i)}{\sum_{k=1}^n X_k(1 + Y_k)} = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}} \quad \text{para todo } i.$$

Como $X_i > 0$ para todo i , se sigue que existe una constante $c > 0$ tal que

$$1 + Y_i = c \ell_i^{(j)}, \quad i = 1, \dots, n.$$

La constante común desaparece en la normalización de T_Y , de modo que $T = T_{Y^{\ell(j)}}$. La implicación recíproca es precisamente la Proposición 6.1. □

Corolario 6.1 (Actualización bayesiana secuencial como composición en $\mathcal{G}$). *Sean $E_{j_1}, \dots, E_{j_m}$ observaciones sucesivas con $P(H_i \cap E_{j_s}) > 0$ para todo i, s . Sea $X_0 = X \in \Delta_n^\circ$ el prior inicial. El posterior tras las m observaciones es*

$$X_m = T_{Y^{\ell(j_m)}} \circ \dots \circ T_{Y^{\ell(j_1)}}(X_0).$$

Si además las observaciones son condicionalmente independientes dadas las hipótesis, la actualización secuencial coincide con la simultánea.

La misma lectura multiplicativa permite comparar un prior con un posterior dado sin salir del formalismo global.

Proposición 6.3 (Corrección óptima hacia el posterior). *Sean $X, \pi \in \Delta_n^\circ$. El único elemento de $\mathcal{G}$ que lleva X a π en un paso, salvo escala proyectiva, es T_{Y^*} con*

$$1 + Y_i^* = c \frac{\pi_i}{X_i}, \quad c > 0.$$

Si $\pi = P(H_i | E_j)$ es el posterior, entonces por la Proposición 6.2 este operador coincide con $T_{Y^{\ell(j)}}$, y la corrección óptima satisface

$$\ell_i^{(j)} \propto \frac{\pi_i}{X_i}.$$

Demostración. El campo que lleva X a π satisface $1 + Y_i^* = \pi_i/X_i$ a escala proyectiva. La unicidad salvo escala se sigue de la estructura de grupo de $\mathcal{G}$ (Corolario de la Proposición 4.2). La identificación con $\ell^{(j)}$ se sigue de la Proposición 6.2: el único operador de $\mathcal{G}$ que produce $P(H_i | E_j)$ desde X tiene factores proporcionales a $P(H_i | E_j)/X_i$. $\square$

6.2. Modelos continuos como estados informacionales discretos

Aunque el marco de las Secciones A–D opera sobre Δ_n con n finito, ciertos modelos clásicos tienen parámetros continuos. Aquí se muestra cómo ingresarlos al marco de CI: el espacio continuo se convierte en un espacio de probabilidad concreto, se discretiza con una partición medible finita no degenerada y luego se aplica la actualización bayesiana global.

En problemas bayesianos de gran escala, lo importante no es solo el valor puntual del parámetro, sino la manera en que la posterior se concentra y cómo las densidades predictivas acompañan esa concentración. Martin y Hong (2018) estudian precisamente tasas de convergencia de densidades predictivas y distribuciones posteriores, y ponen de relieve que ambos objetos son centrales en la inferencia bayesiana. Bajo esa lectura, discretizar un modelo continuo no altera el principio bayesiano, sino que ofrece una representación finita del estado informacional sobre el que actúa la actualización.

Esa discretización es solo un cambio de escala, no de principio: las mismas ideas de evidencia, corrección y normalización siguen operando.

Definición 6.4 (Partición paramétrica uniforme). *Sea $\Omega = (a, b) \subset \mathbb{R}$ y sea $\mathcal{F}$ la σ -álgebra de Borel en Ω . Sea P_0 una medida de probabilidad absolutamente continua sobre $(\Omega, \mathcal{F})$ con densidad $f : \Omega \rightarrow (0, \infty)$.*

Dado $n \geq 1$, sea $h := (b - a)/n$ el paso de discretización y defínase la partición paramétrica uniforme

$$\Pi_n := \{E_1, \dots, E_n\}, \quad E_i := (a + (i - 1)h, a + ih], \quad i = 1, \dots, n.$$

Como $f > 0$ en Ω , se tiene $P_0(E_i) > 0$ para todo i , de modo que Π_n es no degenerada.

El estado informacional previo asociado a $(\Omega, \mathcal{F}, P_0, \Pi_n)$ es

$$X_{0,i} := P_0(E_i) = \int_{E_i} f(\theta) d\theta, \quad i = 1, \dots, n,$$

y por la Proposición 2.1, $X_0 \in \Delta_n^\circ$.

Definición 6.5 (Verosimilitud como corrección global admisible). Sea e un dato observado y sea $\ell : (a, b) \rightarrow (0, \infty)$ una función de verosimilitud, es decir, $\ell(\theta) = P(e \mid \theta)$ para cada valor del parámetro θ . La verosimilitud discreta del dato e bajo el evento E_i se define como la esperanza condicional de ℓ respecto de P_0 dado E_i :

$$\ell_i := E_{P_0}[\ell \mid E_i] = \frac{\int_{E_i} \ell(\theta) dP_0(\theta)}{P_0(E_i)} = \frac{\int_{E_i} \ell(\theta) f(\theta) d\theta}{\int_{E_i} f(\theta) d\theta}.$$

Como $\ell > 0$ y $f > 0$ en Ω , se tiene $\ell_i > 0$ para todo i . Definiendo $Y^\ell \in \mathbb{R}^n$ por $1 + Y_i^\ell := \ell_i$, se obtiene $Y^\ell \in C_{\text{glob}}$.

Observación 6.2 (Radon–Nikodym y cambio de medida exacto). Sea Q la medida de probabilidad posterior sobre $(\Omega, \mathcal{F})$ definida por su derivada de Radon–Nikodym respecto de P_0 :

$$\frac{dQ}{dP_0}(\theta) := \frac{\ell(\theta)}{\int_{\Omega} \ell dP_0}.$$

Con la definición de ℓ_i de la Definición 6.5, la masa que Q asigna a cada celda E_i satisface

$$Q(E_i) = \int_{E_i} \frac{\ell}{\int_{\Omega} \ell dP_0} dP_0 = \frac{\int_{E_i} \ell dP_0}{\int_{\Omega} \ell dP_0} = \frac{P_0(E_i) \ell_i}{\sum_{k=1}^n P_0(E_k) \ell_k} = T_{Y^\ell}(X_0)_i.$$

La igualdad $T_{Y^\ell}(X_0)_i = Q(E_i)$ es una identidad exacta: el operador global recupera la masa que la posterior continua asigna a cada celda de Π_n , sin aproximación.

Con esa estructura, el posterior discreto coincide exactamente con la masa que la posterior continua asigna a cada celda.

Proposición 6.4 (Actualización bayesiana paramétrica en CI). Sea $(\Omega, \mathcal{F}, P_0, \Pi_n)$ una partición paramétrica uniforme con estado previo $X_0 \in \Delta_n^\circ$ y sea $Y^\ell \in C_{\text{glob}}$ la corrección de verosimilitud de la Definición 6.5. Sea Q la medida posterior sobre $(\Omega, \mathcal{F})$ con derivada de Radon–Nikodym $dQ/dP_0 = \ell / \int_{\Omega} \ell dP_0$. Entonces

$$T_{Y^\ell}(X_0)_i = Q(E_i), \quad i = 1, \dots, n,$$

y en particular $T_{Y^\ell}(X_0) \in \Delta_n^\circ$. El vector $T_{Y^\ell}(X_0)$ es la distribución de probabilidad que la posterior continua Q induce sobre la partición Π_n .

Demostración. Por la Definición 6.5, $\ell_i = \int_{E_i} \ell dP_0 / P_0(E_i)$, de modo que $P_0(E_i) \ell_i = \int_{E_i} \ell dP_0$. Sustituyendo en el operador global y usando que $\{E_1, \dots, E_n\}$ es una partición de Ω ,

$$T_{Y^\ell}(X_0)_i = \frac{P_0(E_i) \ell_i}{\sum_{k=1}^n P_0(E_k) \ell_k} = \frac{\int_{E_i} \ell dP_0}{\sum_{k=1}^n \int_{E_k} \ell dP_0} = \frac{\int_{E_i} \ell dP_0}{\int_{\Omega} \ell dP_0} = Q(E_i).$$

La positividad y la suma unitaria se siguen de que Q es una medida de probabilidad. $\square$

El mismo resultado se verifica cuando prior y verosimilitud pertenecen a una familia exponencial, separando con precisión el nivel discreto del continuo.

Proposición 6.5 (Modelo conjugado exponencial como caso particular). Sea $f(\theta) \propto \exp(\eta_0 \cdot T(\theta))$ un prior de la familia exponencial con parámetro natural η_0 y estadístico suficiente $T : \Omega \rightarrow \mathbb{R}^k$, y sea $\ell(\theta) \propto \exp(\eta_\ell \cdot T(\theta))$ la verosimilitud. Sea Q la medida posterior de la Proposición 6.4.

(i) **Nivel discreto.** Para todo $n \geq 1$ y toda partición Π_n ,

$$T_{Y^\ell}(X_0)_i = Q(E_i) = \frac{\int_{E_i} \exp((\eta_0 + \eta_\ell) \cdot T(\theta)) d\theta}{\int_{\Omega} \exp((\eta_0 + \eta_\ell) \cdot T(\theta)) d\theta}, \quad i = 1, \dots, n.$$

(ii) **Nivel continuo.** La medida posterior Q es absolutamente continua con densidad proporcional a $\exp((\eta_0 + \eta_\ell) \cdot T(\theta))$. En particular, Q pertenece a la misma familia exponencial con parámetro natural actualizado $\eta_n := \eta_0 + \eta_\ell$.

El operador T_{Y^ℓ} produce exactamente la distribución que la posterior conjugada continua induce sobre la partición Π_n .

Demostración. (i) Por la Proposición 6.4, $T_{Y^\ell}(X_0)_i = Q(E_i)$. La expresión explícita se obtiene sustituyendo $f(\theta) \ell(\theta) \propto \exp(\eta_0 \cdot T(\theta)) \cdot \exp(\eta_\ell \cdot T(\theta)) = \exp((\eta_0 + \eta_\ell) \cdot T(\theta))$ en la fórmula de $Q(E_i) = \int_{E_i} \ell dP_0 / \int_{\Omega} \ell dP_0$.

(ii) La densidad de Q respecto de la medida de Lebesgue es proporcional a $f(\theta) \ell(\theta) \propto \exp((\eta_0 + \eta_\ell) \cdot T(\theta))$, que es la densidad de la familia exponencial con parámetro natural $\eta_n = \eta_0 + \eta_\ell$. $\square$

7. Ejercicios de referencia bayesiana

Se presentan cinco ejercicios resueltos. En cada uno se formula primero una proposición y se demuestra por dos vías: *Solución Via CI* y *Método tradicional*. La vía CI explicita qué objeto del marco se usa en cada paso: estado informacional (Sec. A), corrección global (Sec. C), operador T_Y (Sec. C), o proposición de equivalencia bayesiana (Sec. E).

Ejercicio 7.1 (Prueba diagnóstica y teorema de Bayes). Una enfermedad afecta al 1% de la población. Una prueba tiene sensibilidad del 99% y especificidad del 95%. Si un paciente da positivo, ¿cuál es la probabilidad de que realmente tenga la enfermedad?

Proposición 7.1 (Diagnóstico bayesiano). Sea $X = (0,01, 0,99) \in \Delta_2^\circ$ el estado previo y sea $\ell^{(+)} = (0,99, 0,05)$ la corrección asociada al positivo. Entonces

$$T_{Y^{\ell^{(+)}}}(X) = \left(\frac{1}{6}, \frac{5}{6}\right), \quad P(D \mid +) = \frac{1}{6}.$$

Solución Via CI. Paso 1 (estado previo, Def. 2.4). Se trabaja con $n = 2$ hipótesis: $H_1 = \{\text{enfermo}\}$, $H_2 = \{\text{sano}\}$. El estado informacional previo

$$X = (X_1, X_2) = (0,01, 0,99) \in \Delta_2^\circ$$

codifica la prevalencia poblacional como un punto del interior del s mplex.

Paso 2 (correcci n global, Def. 6.3 y Def. 4.1). La observaci n $E_+ = \{\text{test positivo}\}$ fija las probabilidades condicionales:

$$\ell_1^{(+)} := P(+ | H_1) = 0,99, \quad \ell_2^{(+)} := P(+ | H_2) = 0,05.$$

Definiendo $1 + Y_i^{\ell^{(+)}} := \ell_i^{(+)} > 0$ para $i = 1, 2$, se obtiene $Y^{\ell^{(+)}} \in C_{\text{glob}}$.

Paso 3 (operador global, Def. 4.2). El denominador del operador es $\langle X, \ell^{(+)} \rangle = 0,01 \times 0,99 + 0,99 \times 0,05 = 0,0594$. El operador produce

$$T_{Y^{\ell^{(+)}}}(X)_i = \frac{X_i \ell_i^{(+)}}{\langle X, \ell^{(+)} \rangle}, \quad i = 1, 2.$$

Paso 4 (equivalencia bayesiana, Prop. 6.1). Por esa proposici n, $T_{Y^{\ell^{(+)}}}(X)_i = P(H_i | +)$. Calculando:

$$T_{Y^{\ell^{(+)}}}(X) = \left(\frac{0,0099}{0,0594}, \frac{0,0495}{0,0594} \right) = \left(\frac{1}{6}, \frac{5}{6} \right).$$

La rareza de la enfermedad ($X_1 = 0,01$) hace que los falsos positivos dominen la posterior aunque la sensibilidad sea alta. $\square$

M todo tradicional.

$$P(D | +) = \frac{P(+ | D) P(D)}{P(+ | D) P(D) + P(+ | D^c) P(D^c)} = \frac{0,99 \times 0,01}{0,99 \times 0,01 + 0,05 \times 0,99} = \frac{1}{6}.$$

$\square$

Ejercicio 7.2 (Prior y posterior Beta-Binomial). *Se quiere estimar la probabilidad p de  xito en un proceso. Se usa una prior $p \sim \text{Beta}(2, 2)$. Se observan 7  xitos en 10 ensayos. Calcule la distribuci n posterior e interprete la media posterior.*

Proposici n 7.2 (Actualizaci n Beta-Binomial en CI). *Sea $P_0 = \text{Beta}(2, 2)$ sobre $\Omega = (0, 1)$ con densidad $f(p) = 6p(1 - p)$, y sea $\ell(p) = \binom{10}{7} p^7 (1 - p)^3$ la verosimilitud. Para toda partici n Π_n de $(0, 1)$,*

$$T_{Y^\ell}(X_0)_i = Q(E_i), \quad i = 1, \dots, n,$$

donde $Q = \text{Beta}(9, 5)$ es la posterior exacta y $\mathbb{E}_Q[p] = 9/14$.

Soluci n Via CI. **Paso 1 (espacio de probabilidad, Def. 2.1).** Se fija $(\Omega, \mathcal{F}, P_0)$ con $\Omega = (0, 1)$, $\mathcal{F}$ la σ - lgebra de Borel y $P_0 = \text{Beta}(2, 2)$ con densidad $f(p) = 6p(1 - p)$.

Paso 2 (partici n y estado previo, Def. 6.4). Se fija una partici n $\Pi_n = \{E_1, \dots, E_n\}$ de $(0, 1)$ en n celdas iguales de longitud $h = 1/n$. El estado informacional previo es

$$X_{0,i} := P_0(E_i) = \int_{E_i} 6p(1 - p) dp \in \Delta_n^\circ.$$

Paso 3 (corrección global exacta, Def. 6.5 y Def. 4.1). La verosimilitud $\ell(p) = \binom{10}{7} p^7 (1-p)^3$ determina la corrección exacta

$$\ell_i := E_{P_0}[\ell \mid E_i] = \frac{\int_{E_i} p^7 (1-p)^3 dP_0(p)}{P_0(E_i)} > 0.$$

Con $1 + Y_i^\ell := \ell_i$ se obtiene $Y^\ell \in C_{\text{glob}}$.

Paso 4 (operador, Prop. 6.4). Por esa proposición, $T_{Y^\ell}(X_0)_i = Q(E_i)$ exactamente, donde Q es la medida posterior con $dQ/dP_0 \propto \ell$.

Paso 5 (familia conjugada, Prop. 6.5). Las densidades pertenecen a la familia exponencial con estadístico $T(p) = (\log p, \log(1-p))$:

$$f(p) \propto \exp(1 \cdot \log p + 1 \cdot \log(1-p)), \quad \ell(p) \propto \exp(7 \cdot \log p + 3 \cdot \log(1-p)).$$

Los parámetros naturales son $\eta_0 = (1, 1)$ y $\eta_\ell = (7, 3)$. Por la Prop. 6.5(ii), la posterior Q tiene parámetro

$$\eta_n = \eta_0 + \eta_\ell = (8, 4),$$

que corresponde a Beta(9, 5) (los parámetros de la Beta son $\eta_i + 1$). En particular,

$$\mathbb{E}_Q[p] = \frac{9}{9+5} = \frac{9}{14} \approx 0,6429.$$

La prior centrada en 0,5 y los datos que sugieren 0,7 producen una posterior en $\approx 0,643$, ponderando ambas fuentes por su masa informacional relativa. $\square$

Método tradicional. Se multiplica prior por likelihood y se reconoce la forma Beta:

$$p^{2-1}(1-p)^{2-1} \times p^7(1-p)^3 \propto p^8(1-p)^4 = p^{9-1}(1-p)^{5-1}.$$

Luego $p \mid \mathcal{D} \sim \text{Beta}(9, 5)$ y $\mathbb{E}[p \mid \mathcal{D}] = 9/14 \approx 0,6429$. $\square$

Ejercicio 7.3 (Actualización secuencial con prior Normal). *La estatura de adultos sigue $N(\mu, \sigma^2)$ con $\sigma^2 = 25$ conocido. La prior es $\mu \sim N(170, 100)$. Se observa una muestra de tamaño $n = 10$ con media muestral $\bar{y} = 175$. Calcule la distribución posterior de μ .*

Proposición 7.3 (Actualización Normal-Normal en CI). *Sea $P_0 = N(170, 100)$ sobre $\Omega \subset \mathbb{R}$ y sea*

$$\ell(\mu) \propto \exp\left(-\frac{(\mu - 175)^2}{5}\right)$$

la verosimilitud de $n = 10$ observaciones con $\bar{y} = 175$ y $\sigma^2 = 25$. Para toda partición Π_n de Ω ,

$$T_{Y^\ell}(X_0)_i = Q(E_i), \quad i = 1, \dots, n,$$

donde la posterior exacta es

$$Q = N\left(\frac{7170}{41}, \frac{100}{41}\right) \approx N(174,878, 2,439).$$

Solución Via CI. Paso 1 (espacio de probabilidad, Def. 2.1). Se fija $(\Omega, \mathcal{F}, P_0)$ con $P_0 = N(170, 100)$, densidad $f(\mu) \propto \exp(-(\mu - 170)^2/200)$, y Ω un intervalo que contiene el soporte efectivo de f y ℓ .

Paso 2 (partición y estado previo, Def. 6.4). Se fija $\Pi_n = \{E_1, \dots, E_n\}$ sobre Ω . El estado previo es $X_{0,i} = P_0(E_i) \in \Delta_n^\circ$.

Paso 3 (corrección global exacta, Def. 6.5). La verosimilitud conjunta de $n = 10$ observaciones con $\bar{y} = 175$ y $\sigma^2 = 25$ es

$$\ell(\mu) \propto \exp\left(-\frac{n(\mu - \bar{y})^2}{2\sigma^2}\right) = \exp\left(-\frac{(\mu - 175)^2}{5}\right),$$

donde $5 = 2\sigma^2/n$. La corrección exacta es $\ell_i = E_{P_0}[\ell \mid E_i] > 0$, con $Y^\ell \in C_{\text{glob}}$.

Paso 4 (operador, Prop. 6.4). $T_{Y^\ell}(X_0)_i = Q(E_i)$ exactamente, donde Q tiene $dQ/dP_0 \propto \ell$.

Paso 5 (familia conjugada, Prop. 6.5). Por la Prop. 6.5(ii), la posterior Q tiene densidad proporcional a $f(\mu) \ell(\mu)$:

$$f(\mu) \ell(\mu) \propto \exp\left(-\frac{(\mu - 170)^2}{200} - \frac{(\mu - 175)^2}{5}\right).$$

Usando la parametrización de precisión $\tau_0 = 1/\sigma_0^2$ y $\tau_\ell = n/\sigma^2$, la suma de las cuadráticas da:

$$\begin{aligned} \tau_n &= \tau_0 + \tau_\ell = \frac{1}{100} + \frac{10}{25} = \frac{41}{100}, & \sigma_{\text{post}}^2 &= \frac{1}{\tau_n} = \frac{100}{41}, \\ \mu_{\text{post}} &= \frac{\tau_0 \mu_0 + \tau_\ell \bar{y}}{\tau_n} = \frac{170/100 + 10 \times 175/25}{41/100} = \frac{7170}{41} \approx 174,878. \end{aligned}$$

La prior centrada en 170 y los datos que sugieren 175 producen una posterior en $\approx 174,88$, desplazada hacia los datos en proporción a la precisión relativa de cada fuente. $\square$

Método tradicional. Para el modelo Normal-Normal conjugado con varianza conocida:

$$\begin{aligned} \sigma_{\text{post}}^2 &= \left(\frac{1}{100} + \frac{10}{25}\right)^{-1} = \frac{100}{41}, & \mu_{\text{post}} &= \frac{7170}{41}, \\ \mu \mid \mathcal{D} &\sim N\left(\frac{7170}{41}, \frac{100}{41}\right) \approx N(174,878, 2,439). \end{aligned}$$

$\square$

Ejercicio 7.4 (Factor de Bayes y comparación de modelos). *Compare dos modelos para un conjunto de conteos: M_1 con distribución Poisson($\lambda = 3$) y M_2 con distribución Poisson($\lambda = 5$). Se observan los datos $\{2, 4, 3, 5, 2\}$. Calcule el factor de Bayes B_{12} .*

Proposición 7.4 (Factor de Bayes en CI). *Sea $X = (1/2, 1/2) \in \Delta_2^\circ$ el prior sobre modelos y sean $\ell_r = \prod_{k=1}^5 P(x_k \mid M_r)$ las verosimilitudes globales, $r = 1, 2$. Entonces*

$$T_{Y^\ell}(X)_r = \frac{\ell_r}{\ell_1 + \ell_2}, \quad B_{12} = \frac{\ell_1}{\ell_2} = e^{10} \left(\frac{3}{5}\right)^{16} \approx 6,214.$$

Solución Via Cl. Paso 1 (estado previo, Def. 2.4). Se trabaja con $n = 2$ hipótesis: $H_r = \{\text{modelo } M_r\}$. El estado

$$X = \left(\frac{1}{2}, \frac{1}{2}\right) \in \Delta_2^\circ$$

expresa indiferencia a priori entre los modelos.

Paso 2 (composición de correcciones, Cor. 6.1 y Prop. 4.2). Las cinco observaciones $\{2, 4, 3, 5, 2\}$ son condicionalmente independientes dado el modelo. Por el Cor. 6.1, las correcciones individuales de cada dato se componen multiplicativamente (Prop. 4.2): la corrección acumulada satisface

$$1 + (Y^{\ell(1:5)})_r = \prod_{k=1}^5 (1 + (Y^{\ell(k)})_r) = \prod_{k=1}^5 P(x_k | M_r) =: \ell_r.$$

Para $\text{Poisson}(\lambda_r)$ con $\sum_k x_k = 16$ y cinco observaciones:

$$\ell_1 \propto e^{-15} \cdot 3^{16}, \quad \ell_2 \propto e^{-25} \cdot 5^{16}.$$

Paso 3 (operador, Prop. 6.1). Con $X_1 = X_2 = 1/2$, el operador global simplifica a:

$$T_{Y^{\ell(1:5)}}(X)_r = \frac{(1/2) \ell_r}{(1/2)(\ell_1 + \ell_2)} = \frac{\ell_r}{\ell_1 + \ell_2}.$$

El factor de Bayes emerge como la razón de los factores multiplicativos de la corrección:

$$B_{12} = \frac{\ell_1}{\ell_2} = \frac{T_{Y^{\ell}}(X)_1 / X_1}{T_{Y^{\ell}}(X)_2 / X_2} = \frac{\text{odds posterior}}{\text{odds prior}}.$$

Paso 4 (cómputo).

$$B_{12} = \frac{e^{-15} \cdot 3^{16}}{e^{-25} \cdot 5^{16}} = e^{10} \left(\frac{3}{5}\right)^{16} \approx 6,214.$$

Los datos son $\approx 6,2$ veces más probables bajo M_1 : evidencia moderada a favor del modelo con tasa menor. □

Método tradicional.

$$B_{12} = \frac{\prod_{k=1}^5 P(x_k | M_1)}{\prod_{k=1}^5 P(x_k | M_2)} = \frac{e^{-15} \cdot 3^{16}}{e^{-25} \cdot 5^{16}} = e^{10} \left(\frac{3}{5}\right)^{16} \approx 6,214.$$

□

Ejercicio 7.5 (Intervalo de credibilidad e intervalo de confianza). *Con la posterior $Q \sim \text{Beta}(9, 5)$ obtenida en el Ejercicio 7.2, calcule un intervalo de credibilidad al 95 % y compare su interpretación estructural con la de un intervalo de confianza frecuentista.*

Proposición 7.5 (Intervalo de credibilidad en CI). Sea $T_{Y^\ell}(X_0) \in \Delta_n^\circ$ el estado posterior de la Proposición 7.2, con $T_{Y^\ell}(X_0)_i = Q(E_i)$ y $Q = \text{Beta}(9, 5)$. El intervalo de credibilidad equi-cola al 95 % es

$$\text{IC}_{0,95}^{\text{cred}} = (Q_{0,025}, Q_{0,975}) \approx (0,428, 0,891),$$

donde Q_α denota el cuantil α de $\text{Beta}(9, 5)$. El intervalo de confianza de Wald al 95 % con $\hat{p} = 7/10$ y $n = 10$ es

$$\text{IC}_{0,95}^{\text{freq}} = \hat{p} \pm 1,96\sqrt{\hat{p}(1 - \hat{p})/n} \approx (0,416, 0,984).$$

Solución Via CI. Paso 1 (el estado posterior como distribución, Prop. 6.4). Por esa proposición, $T_{Y^\ell}(X_0)_i = Q(E_i)$ es la probabilidad exacta de que $p \in E_i$ condicionada al dato. El vector $T_{Y^\ell}(X_0) \in \Delta_n^\circ$ representa la distribución de probabilidad completa sobre el parámetro p a la resolución de Π_n : no es una estimación puntual, es un estado informacional.

Paso 2 (región de credibilidad como subconjunto de celdas). Un intervalo de credibilidad al 95 % es una colección $I_n^* \subset \{1, \dots, n\}$ minimal con

$$\sum_{i \in I_n^*} T_{Y^\ell}(X_0)_i \geq 0,95.$$

En el límite continuo ($n \rightarrow \infty$), esto equivale a encontrar $(a, b) \subset (0, 1)$ con $Q((a, b)) \geq 0,95$. El criterio equi-cola usa los cuantiles $Q_{0,025}$ y $Q_{0,975}$ de $\text{Beta}(9, 5)$, obtenidos numéricamente:

$$Q_{0,025} \approx 0,428, \quad Q_{0,975} \approx 0,891.$$

Paso 3 (comparación estructural con el frecuentista). El intervalo de Wald usa únicamente $\hat{p} = 7/10$ y $n = 10$:

$$0,7 \pm 1,96\sqrt{\frac{0,7 \times 0,3}{10}} = 0,7 \pm 0,284 = (0,416, 0,984).$$

La diferencia no es solo numérica sino estructural. En CI, $T_{Y^\ell}(X_0)_i = Q(E_i)$ es la probabilidad de que $p \in E_i$ dado el dato: una afirmación directa sobre el parámetro como cantidad incerta. El intervalo frecuentista no hace una afirmación sobre p ; garantiza que el 95 % de los intervalos contruidos bajo el mismo procedimiento en muestras repetidas contienen al verdadero p fijo. El IC bayesiano es más angosto porque la prior $\text{Beta}(2, 2)$ concentra la masa hacia valores intermedios, reduciendo la incertidumbre efectiva sobre p . $\square$

Método tradicional. Se calculan numéricamente los cuantiles $Q_{0,025} \approx 0,428$ y $Q_{0,975} \approx 0,891$ de $\text{Beta}(9, 5)$, obteniendo $\text{IC}_{0,95}^{\text{cred}} \approx (0,428, 0,891)$. El intervalo de Wald frecuentista con $\hat{p} = 7/10$ y $n = 10$ da $\text{IC}_{0,95}^{\text{freq}} \approx (0,416, 0,984)$. $\square$

8. Sección F — Semántica markoviana

Las Secciones B–E establecieron el marco de CI y su semántica bayesiana. Esta sección identifica, dentro del mismo marco, el caso particular que corresponde al operador de Markov clásico. El resultado estructural central es que las cadenas de Markov entran en CI a través de la Sección B (correcciones locales dependientes del estado), mientras que la actualización bayesiana entra por la Sección C (correcciones globales independientes del estado). Esta asimetría algebraica es la que hace no trivial el problema de ordenamiento del Proyecto II.

Definición 8.1 (Matrices estocásticas por filas). Se denota por $\mathcal{S}_n$ el conjunto de matrices estocásticas por filas de orden n :

$$\mathcal{S}_n := \left\{ K \in \mathbb{R}^{n \times n} : K_{ij} \geq 0 \ \forall i, j, \quad \sum_j K_{ij} = 1 \ \forall i \right\}.$$

El operador de Markov asociado a $K \in \mathcal{S}_n$ es

$$L_K : \Delta_n \longrightarrow \mathbb{R}^n, \quad L_K(X) := XK,$$

donde X se considera vector fila y el producto es el matricial estándar.

Proposición 8.1 (El simplex es invariante bajo $\mathcal{S}_n$). Sea $K \in \mathcal{S}_n$ y sea $X \in \Delta_n$. Entonces $L_K(X) = XK \in \Delta_n$. En particular, L_K es un operador bien definido de Δ_n en Δ_n .

Demostración. Para cada j ,

$$(XK)_j = \sum_{i=1}^n X_i K_{ij} \geq 0,$$

pues $X_i \geq 0$ y $K_{ij} \geq 0$. Además,

$$\sum_{j=1}^n (XK)_j = \sum_{j=1}^n \sum_{i=1}^n X_i K_{ij} = \sum_{i=1}^n X_i \underbrace{\sum_{j=1}^n K_{ij}}_{=1} = \sum_{i=1}^n X_i = 1.$$

Luego $XK \in \Delta_n$. □

Observación 8.1 (Preservación del interior). La Proposición 8.1 garantiza $L_K(\Delta_n) \subset \Delta_n$, pero no $L_K(\Delta_n^\circ) \subset \Delta_n^\circ$ en general. Una condición suficiente para preservar el interior es $K_{ij} > 0$ para todo i, j . La corrección local $Y_i^K(X) = (XK)_i / X_i - 1$ requiere $X \in \Delta_n^\circ$ para que los cocientes estén definidos; en ese contexto se impondrá dicha hipótesis explícitamente.

Proposición 8.2 (Markov entra por la Sección B, no por la Sección C). Sea $K \in \mathcal{S}_n$ y sea $X \in \Delta_n^\circ$. El paso markoviano $L_K(X) = XK$ puede representarse como una corrección local de la Sección B mediante

$$Y_i^K(X) := \frac{(XK)_i}{X_i} - 1, \quad i = 1, \dots, n.$$

Se tiene $Y^K(X) \in C(X)$ y $T_{Y^K(X)}^{\text{loc}}(X) = XK$.

Por el contrario, salvo el caso trivial $K = I$, el operador L_K no puede representarse como un operador global $T_Y \in \mathcal{G}$ con Y independiente de X .

Demostración. Para cada i : $X_i(1 + Y_i^K(X)) = (XK)_i \geq 0$ y $\sum_i X_i(1 + Y_i^K(X)) = \sum_i (XK)_i = 1$. Luego $Y^K(X) \in C(X)$ y $T_{Y^K(X)}^{\text{loc}}(X)_i = (XK)_i$ por la Definición 3.2.

Para la segunda parte: supóngase que existe $a \in \mathbb{R}_{>0}^n$ tal que $T_a(X) = XK$ para todo $X \in \Delta_n^\circ$. La función $X \mapsto T_a(X)_i = X_i a_i / \sum_k X_k a_k$ es no lineal en X (por el denominador) salvo que a sea constante, en cuyo caso $T_a(X) = X$, que coincide con XK solo si $K = I$. En cambio, $(XK)_i = \sum_j X_j K_{ji}$ es lineal en X . Una función lineal y una no lineal no pueden coincidir en todo Δ_n° , lo que concluye la prueba. □

Observación 8.2 (Local frente a global: la asimetría estructural). *La corrección $Y^K(X)$ depende del estado base X : es local en el sentido de la Sección B. La verosimilitud bayesiana Y^ℓ no depende de X : es global en el sentido de la Sección C. Esta asimetría es estructural: Markov mezcla coordenadas mediante K ; Bayes escala coordenadas por factores fijos. El puente queda así:*

$$\underbrace{A : X \in \Delta_n}_{\text{dominio}} \longrightarrow \underbrace{B : T_{Y^K(X)}^{\text{loc}}}_{\text{Markov}} \quad y \quad \underbrace{A : X \in \Delta_n^\circ}_{\text{dominio}} \longrightarrow \underbrace{C : T_{Y^\ell} \in \mathcal{G}}_{\text{Bayes}}.$$

Definición 8.2 (Distribución estacionaria en CI). *Sea $K \in \mathcal{S}_n$. Una distribución $\pi \in \Delta_n^\circ$ se llama estacionaria para K si*

$$\pi K = \pi.$$

En el lenguaje de CI: π es estacionaria si y solo si $Y^K(\pi) = 0$, pues $Y_i^K(\pi) = (\pi K)_i / \pi_i - 1 = 0$ para todo i .

Proposición 8.3 (Disipación de la divergencia KL hacia la estacionaria). *Sea $K \in \mathcal{S}_n$ con distribución estacionaria $\pi \in \Delta_n^\circ$. Sea $E_\pi(X) = D_{\text{KL}}(\pi \| X)$ el funcional de la Sección D. Entonces para todo $X \in \Delta_n^\circ$,*

$$E_\pi(L_K(X)) = D_{\text{KL}}(\pi \| XK) \leq D_{\text{KL}}(\pi \| X) = E_\pi(X).$$

Un paso del operador de Markov no incrementa la divergencia KL hacia la estacionaria.

Demostración. Como π es estacionaria, $\pi_j = \sum_i \pi_i K_{ij}$ para todo j . Por tanto,

$$D_{\text{KL}}(\pi \| XK) = \sum_j \pi_j \log \frac{\pi_j}{(XK)_j} = \sum_j \left(\sum_i \pi_i K_{ij} \right) \log \frac{\sum_i \pi_i K_{ij}}{\sum_i X_i K_{ij}}.$$

Para cada j fijo, los pesos $w_{ij} := \pi_i K_{ij} / \pi_j$ satisfacen $w_{ij} \geq 0$ y $\sum_i w_{ij} = 1$. Aplicando la desigualdad de Jensen a la función cóncava $\log$,

$$\log \frac{\sum_i \pi_i K_{ij}}{\sum_i X_i K_{ij}} \leq \sum_i w_{ij} \log \frac{\pi_i}{X_i}.$$

Multiplicando por π_j y sumando en j ,

$$D_{\text{KL}}(\pi \| XK) \leq \sum_j \sum_i \pi_i K_{ij} \log \frac{\pi_i}{X_i} = \sum_i \pi_i \log \frac{\pi_i}{X_i} \underbrace{\sum_j K_{ij}}_{=1} = D_{\text{KL}}(\pi \| X). \quad \square$$

Proposición 8.4 (Trayectoria markoviana como trayectoria local de CI). *Sea $K \in \mathcal{S}_n$ y sea $X_0 \in \Delta_n$. La trayectoria $X_{t+1} = X_t K$ satisface $X_t \in \Delta_n$ para todo $t \geq 0$. Cuando $X_t \in \Delta_n^\circ$, cada paso se escribe como*

$$X_{t+1} = T_{Y^K(X_t)}^{\text{loc}}(X_t),$$

y en forma cerrada $X_t = X_0 K^t$.

Si K es primitiva (existe $m \geq 1$ con $K_{ij}^m > 0$ para todo i, j), entonces K tiene una única distribución estacionaria $\pi \in \Delta_n^\circ$, y para todo $X_0 \in \Delta_n^\circ$,

$$E_\pi(X_t) = D_{\text{KL}}(\pi \| X_t) \searrow 0 \quad (t \rightarrow \infty).$$

Demostración. La invariancia $X_t \in \Delta_n$ es la Proposición 8.1. Para $X_t \in \Delta_n^\circ$, la representación como operador local es la Proposición 8.2. La forma cerrada $X_t = X_0 K^t$ se obtiene por inducción: si $X_t = X_0 K^t$, entonces $X_{t+1} = X_t K = X_0 K^{t+1}$.

Para la convergencia: por la Proposición 8.3, la sucesión $E_\pi(X_t)$ es decreciente y acotada por abajo por 0 (Proposición 5.4), luego converge a algún $L \geq 0$. Si $L > 0$, entonces X_t no converge a π ; como Δ_n es compacto, existe una subsucesión $X_{t_k} \rightarrow X^* \neq \pi$. Por continuidad de L_K y la disipación, $E_\pi(X^* K) \leq E_\pi(X^*) = L > 0$. Pero la primitividad de K implica, por el teorema de Perron–Frobenius, que $K^t \rightarrow \mathbf{1}\pi$ (matriz cuyas filas son todas π), de modo que $X^* K^t \rightarrow \pi$ para cualquier X^* , contradiciendo $E_\pi(X^*) > 0$. Luego $L = 0$ y $X_t \rightarrow \pi$. $\square$

Referencias