

Control Informacional

Proyecto de Investigación II — ProInt_II

Alejandro Cruz López

Universidad Autónoma Metropolitana
Unidad Iztapalapa

Asesores

Dr. Asael Fabián Martínez Martínez
Dr. Joaquín Delgado Fernández 26 de mayo de 2026

Índice

1. Mapa de trabajo	2
2. Sección A – Probabilidad y simplex	2
3. Sección B – Correcciones locales y cambio de medida	3
4. Sección C – Operadores globales multiplicativos y composición	4
5. Sección D – Divergencia KL, métrica de Fisher y dinámica inducida	5
6. Sección E – Semántica bayesiana	7
6.1. Modelos continuos como estados informacionales discretos	12
6.2. Trayectorias Bayesianas	21
7. Sección F — Semántica markoviana	33

1. Mapa de trabajo

Este archivo es un borrador de trabajo para avanzar por capas. La ruta lógica es:

- Sección A: espacio de probabilidad, particiones finitas y símplex.
- Sección B: correcciones locales y cambio de medida discreto.
- Sección C: operadores globales multiplicativos y composición.
- Sección D: divergencia KL, métrica de Fisher y dinámica inducida.
- Sección E0: semántica bayesiana como caso particular del operador global.

Las proposiciones que realmente sostienen la transición hacia la semántica bayesiana son:

Prop. 2.1, Prop. 3.1, Prop. 3.2, Prop. 3.3,
Prop. 4.1, Prop. 4.2, Prop. 5.1, Prop. 5.2, Teo. 5.1.

2. Sección A – Probabilidad y símplex

Este bloque fija el dominio probabilístico discreto. El punto de partida es un espacio de probabilidad en el sentido de Kolmogórov [Kolmogorov, 1933]. A partir de una partición medible finita se asocia a la medida un vector de probabilidades, que se interpreta como estado informacional discreto.

Definición 2.1 (Espacio de probabilidad). *Un espacio de probabilidad es una terna $(\Omega, \mathcal{F}, P)$ tal que:*

1. Ω es un conjunto no vacío;
2. $\mathcal{F}$ es una σ -álgebra de subconjuntos de Ω ;
3. $P : \mathcal{F} \rightarrow [0, 1]$ es una medida con $P(\Omega) = 1$.

Definición 2.2 (Partición medible finita). *Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad. Una partición medible finita de Ω es una familia finita*

$$\Pi = \{E_1, \dots, E_n\} \subset \mathcal{F}, \quad n \geq 1,$$

tal que:

1. $E_i \cap E_j = \emptyset$ si $i \neq j$;
2. $\bigcup_{i=1}^n E_i = \Omega$.

Diremos que Π es no degenerada si además

$$P(E_i) > 0, \quad i = 1, \dots, n.$$

Definición 2.3 (Símplex de probabilidad e interior). Para $n \geq 1$ se define el símplex de probabilidad por

$$\Delta_n := \left\{ x \in \mathbb{R}^n : x_i \geq 0, \sum_{i=1}^n x_i = 1 \right\}.$$

Su interior relativo viene dado por

$$\Delta_n^\circ := \{ x \in \Delta_n : x_i > 0 \text{ para todo } i \}.$$

Definición 2.4 (Estado informacional discreto). Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sea $\Pi = \{E_1, \dots, E_n\}$ una partición medible finita. El estado informacional discreto asociado a Π es el vector

$$X = (X_1, \dots, X_n) \in \mathbb{R}^n, \quad X_i := P(E_i), \quad i = 1, \dots, n.$$

Proposición 2.1. Sea X el estado informacional discreto asociado a una partición medible finita $\Pi = \{E_1, \dots, E_n\}$. Entonces:

1. $X \in \Delta_n$;
2. si Π es no degenerada, entonces $X \in \Delta_n^\circ$.

Definición 2.5 (Operador de cierre). Sea

$$\mathbb{R}_{>0}^n := \{ z = (z_1, \dots, z_n) \in \mathbb{R}^n : z_i > 0 \text{ para todo } i \}.$$

El operador de cierre es la aplicación

$$\mathcal{C} : \mathbb{R}_{>0}^n \rightarrow \Delta_n^\circ, \quad \mathcal{C}(z) := \frac{1}{\sum_{i=1}^n z_i} z.$$

Observación 2.1. El cierre conserva únicamente la información relativa entre coordenadas. Esta idea es la que conecta el símplex con el formalismo composicional de Aitchison [Aitchison, 1986].

3. Sección B – Correcciones locales y cambio de medida

Aquí se introduce el mecanismo elemental de actualización. Dado un estado $X \in \Delta_n$, se definen correcciones relativas admisibles que preservan la masa total y se asocia a cada una de ellas un operador local. El resultado puede interpretarse como un cambio de medida discreto sobre la partición subyacente.

Definición 3.1 (Conjunto de correcciones admisibles en X). Sea $X = (X_1, \dots, X_n) \in \Delta_n$. Se define el conjunto de correcciones admisibles en X por

$$C(X) := \left\{ Y = (Y_1, \dots, Y_n) \in \mathbb{R}^n \mid X_i(1 + Y_i) \geq 0 \text{ para todo } i, \sum_{i=1}^n X_i(1 + Y_i) = 1 \right\}.$$

Definición 3.2 (Operador informacional local). Sea $X \in \Delta_n$ y sea $Y \in C(X)$. El operador informacional local asociado a Y en X es el vector

$$T_Y^{\text{loc}}(X) = (T_Y^{\text{loc}}(X)_1, \dots, T_Y^{\text{loc}}(X)_n) \in \mathbb{R}^n,$$

definido por

$$T_Y^{\text{loc}}(X)_i := X_i(1 + Y_i), \quad i = 1, \dots, n.$$

Proposición 3.1 (Preservación local del simplex). Sea $X \in \Delta_n$ y sea $Y \in C(X)$. Entonces

$$T_Y^{\text{loc}}(X) \in \Delta_n.$$

Proposición 3.2 (Cambio de medida discreto inducido por una corrección local). Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sea $\Pi = \{E_1, \dots, E_n\} \subset \mathcal{F}$ una partición medible finita no degenerada. Defínase

$$X_i := P(E_i), \quad i = 1, \dots, n,$$

de modo que $X = (X_1, \dots, X_n) \in \Delta_n^\circ$.

Sea $Y \in C(X)$ y defínase

$$h(\omega) := 1 + Y_i \quad \text{si } \omega \in E_i.$$

Sea además

$$Q_Y(A) := \int_A h(\omega) dP(\omega), \quad A \in \mathcal{F}.$$

Entonces Q_Y es una medida de probabilidad sobre $(\Omega, \mathcal{F})$.

Proposición 3.3 (Compatibilidad entre T_Y^{loc} y el cambio de medida). Con la notación anterior, para cada $i = 1, \dots, n$ se cumple

$$Q_Y(E_i) = T_Y^{\text{loc}}(X)_i.$$

4. Sección C – Operadores globales multiplicativos y composición

Se pasa ahora al operador global, definido mediante correcciones multiplicativas positivas y renormalización. Esta es la versión que se usa después para la semántica bayesiana.

Definición 4.1 (Correcciones globales). Se define el conjunto de correcciones globales por

$$C_{\text{glob}} := \left\{ Y = (Y_1, \dots, Y_n) \in \mathbb{R}^n \mid 1 + Y_i > 0 \text{ para todo } i \right\}.$$

Para cada $Y \in C_{\text{glob}}$, el vector de factores multiplicativos asociado viene dado por

$$a(Y) := (1 + Y_1, \dots, 1 + Y_n) \in \mathbb{R}_{>0}^n.$$

Definición 4.2 (Operador informacional global). Sea $Y \in C_{\text{glob}}$. El operador informacional global asociado a Y es la aplicación

$$T_Y : \Delta_n^\circ \rightarrow \Delta_n^\circ, \quad T_Y(X) := \frac{X \circ a(Y)}{\sum_{j=1}^n X_j a_j(Y)},$$

donde $\circ$ denota el producto coordenada a coordenada. En forma explícita,

$$T_Y(X)_i = \frac{X_i(1 + Y_i)}{\sum_{j=1}^n X_j(1 + Y_j)}, \quad i = 1, \dots, n.$$

Proposición 4.1 (Preservación del interior del simplex). Sea $Y \in C_{\text{glob}}$. Entonces, para todo $X \in \Delta_n^\circ$,

$$T_Y(X) \in \Delta_n^\circ.$$

Proposición 4.2 (Ley de composición). Sean $Y_1, Y_2 \in C_{\text{glob}}$. Entonces existe un único $Y_{\text{tot}} \in C_{\text{glob}}$ tal que

$$T_{Y_2} \circ T_{Y_1} = T_{Y_{\text{tot}}},$$

y está determinado por

$$1 + Y_{\text{tot}} = (1 + Y_1) \circ (1 + Y_2).$$

Observación 4.1 (Coordenadas log-multiplicativas). Para $Y \in C_{\text{glob}}$ se definen las coordenadas

$$\theta_i := \log(1 + Y_i), \quad i = 1, \dots, n.$$

Entonces

$$T_\theta(X) = \frac{X \circ e^\theta}{\sum_{j=1}^n X_j e^{\theta_j}},$$

y la ley de composición se vuelve aditiva en θ .

5. Sección D – Divergencia KL, métrica de Fisher y dinámica inducida

En esta parte se introduce el funcional informacional

$$E_P(X) := D_{\text{KL}}(P \| X),$$

se calcula su gradiente respecto de la métrica de Fisher en el interior del simplex y se obtiene la dinámica continua asociada. Esta dinámica es la base para pasar de la corrección multiplicativa al flujo de descenso.

Definición 5.1 (Divergencia de Kullback–Leibler discreta). Sea $P \in \Delta_n^\circ$ fija. Para $X \in \Delta_n$ se define

$$D_{\text{KL}}(P \| X) = \begin{cases} \sum_{i=1}^n P_i \log\left(\frac{P_i}{X_i}\right), & \text{si } X_i > 0 \text{ para todo } i, \\ +\infty, & \text{si existe } i \text{ tal que } P_i > 0 \text{ y } X_i = 0. \end{cases}$$

Se define además el funcional

$$E_P : \Delta_n^\circ \rightarrow \mathbb{R}, \quad E_P(X) := D_{\text{KL}}(P \| X).$$

Definición 5.2 (Espacio tangente del simplex). Sea $X \in \Delta_n^\circ$. El espacio tangente en X viene dado por

$$T_X \Delta_n^\circ = \left\{ u \in \mathbb{R}^n \mid \sum_{i=1}^n u_i = 0 \right\}.$$

Definición 5.3 (Métrica de Fisher discreta). Para $X \in \Delta_n^\circ$, la métrica de Fisher en $T_X \Delta_n^\circ$ es

$$g_X(u, v) := \sum_{i=1}^n \frac{u_i v_i}{X_i}, \quad u, v \in T_X \Delta_n^\circ.$$

Definición 5.4 (Gradiente riemanniano respecto de la métrica de Fisher). Sea $E : \Delta_n^\circ \rightarrow \mathbb{R}$ una función suave. El gradiente riemanniano de E respecto de g es el campo $\text{grad}_g E$ caracterizado por

$$g_X(\text{grad}_g E(X), u) = dE(X)[u], \quad \forall u \in T_X \Delta_n^\circ.$$

Proposición 5.1 (Gradiente Fisher de la divergencia KL). Sea $P \in \Delta_n^\circ$ fija y sea

$$E_P(X) = D_{\text{KL}}(P \| X) = \sum_{i=1}^n P_i \log\left(\frac{P_i}{X_i}\right), \quad X \in \Delta_n^\circ.$$

Entonces

$$\text{grad}_g E_P(X) = X - P, \quad X \in \Delta_n^\circ.$$

Definición 5.5 (Flujo de gradiente Fisher–KL). El flujo de gradiente asociado a E_P es la ecuación diferencial

$$\dot{X}(t) = -\text{grad}_g E_P(X(t)), \quad X(t) \in \Delta_n^\circ.$$

Por la Proposición 5.1, esta ecuación toma la forma

$$\dot{X}(t) = P - X(t).$$

Proposición 5.2 (Solución explícita del flujo). Sea $X_0 \in \Delta_n^\circ$. La solución de

$$\dot{X}(t) = P - X(t), \quad X(0) = X_0,$$

viene dada por

$$X(t) = e^{-t} X_0 + (1 - e^{-t}) P, \quad t \geq 0.$$

En particular, $X(t) \in \Delta_n^\circ$ para todo $t \geq 0$ y $X(t) \rightarrow P$ cuando $t \rightarrow \infty$.

Proposición 5.3 (Monotonidad de E_P a lo largo del flujo). Sea $X(\cdot)$ una solución del flujo Fisher–KL. Entonces

$$\frac{d}{dt} E_P(X(t)) = -g_{X(t)}(\text{grad}_g E_P(X(t)), \text{grad}_g E_P(X(t))) \leq 0.$$

La igualdad sólo ocurre si $X(t) = P$.

Proposición 5.4 (Mínimo global de E_P). Para todo $X \in \Delta_n^\circ$ se cumple

$$E_P(X) \geq 0,$$

y además

$$E_P(X) = 0 \iff X = P.$$

En particular, P es el único minimizador global de E_P en Δ_n° .

Teorema 5.1 (Equivalencia estructural Sección C $\leftrightarrow$ Sección D). Sea $P \in \Delta_n^\circ$ fijo. Considérese el operador informacional global T_Y del Sección C, definido para $Y \in C_{\text{glob}}$ por

$$T_Y(X) = \frac{X \circ (1 + Y)}{\langle X, 1 + Y \rangle}.$$

Defínase, para cada $X \in \Delta_n^\circ$, el campo de corrección óptima

$$Y^*(X, P)_i := \frac{P_i}{X_i} - 1, \quad i = 1, \dots, n.$$

Entonces:

1. $T_{Y^*(X, P)}(X) = P$;
2. la iteración $X_{k+1} = T_{\alpha Y^*(X_k, P)}(X_k)$ se reduce a la interpolación convexa $X_{k+1} = (1 - \alpha)X_k + \alpha P$;
3. el límite infinitesimal de la regla global conduce a $\dot{X} = P - X$, que coincide con el flujo de gradiente Fisher–KL.

6. Sección E – Semántica bayesiana

La idea es fijar un espacio bayesiano, identificar la verosimilitud como una corrección global y demostrar que la actualización de Bayes aparece exactamente como un caso particular del operador T_Y . Esta lectura no se introduce de manera aislada: está alineada con la interpretación de Bayes spaces de Egozcue, Pawlowsky-Glahn, Tolosana-Delgado, Ortego y van den Boogaart (2013), donde la regla de Bayes se entiende como una perturbación entre densidades proporcionales, y también con la geometría afín del simplex de Pistone y Shoaib (2024), que permite leer las actualizaciones como operadores internos sobre el espacio de estados.

En paralelo, la parte diferencial del marco se apoya en la geometría de la información de Amari (2016), mientras que la interpretación variacional y del statistical bundle remite a Pistone (2018). Por eso, el objetivo de esta sección no es solo obtener una fórmula de actualización, sino situarla en una narración geométrica y probabilística coherente con la bibliografía ya revisada.

Definición 6.1 (Espacio Bayesiano). Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad. Sean $n, m \in \mathbb{N}$ y sean

$$\Pi_H = \{H_1, \dots, H_n\}, \quad \Pi_E = \{E_1, \dots, E_m\},$$

dos particiones medibles finitas de Ω . Supongamos que

$$P(H_i) > 0 \quad \text{para todo } i = 1, \dots, n, \quad P(E_j) > 0 \quad \text{para todo } j = 1, \dots, m.$$

Interpretamos los elementos de Π_H como hipótesis alternativas y los elementos de Π_E como observaciones posibles.

El estado informacional previo asociado a Π_H es el vector

$$X = (X_1, \dots, X_n) \in \Delta_n^\circ, \quad X_i := P(H_i), \quad i = 1, \dots, n,$$

de modo que $\sum_{i=1}^n X_i = 1$ y $X_i > 0$ para todo i .

Definición 6.2 (Probabilidad condicional en el espacio conjunto). Sea $(\Omega, \mathcal{F}, P)$ el espacio de probabilidad de la Definición 6.1, y sean $\Pi_H = \{H_1, \dots, H_n\}$ y $\Pi_E = \{E_1, \dots, E_m\}$ las particiones medibles finitas allí fijadas. Sean $i \in \{1, \dots, n\}$ y $j \in \{1, \dots, m\}$. Si $P(H_i) > 0$, se define la probabilidad condicional de la observación E_j dada la hipótesis H_i por

$$P(E_j | H_i) := \frac{P(H_i \cap E_j)}{P(H_i)}.$$

Se dirá que la observación E_j es compatible con la hipótesis H_i si $P(H_i \cap E_j) > 0$. Equivalentemente, puesto que $P(H_i) > 0$, esta compatibilidad se cumple si y sólo si $P(E_j | H_i) > 0$.

Definición 6.3 (Verosimilitud como corrección global). Sea $j \in \{1, \dots, m\}$ con $P(E_j) > 0$. Denótese por

$$\ell^{(j)} = (\ell_1^{(j)}, \dots, \ell_n^{(j)}) \in \mathbb{R}_{>0}^n$$

el vector de verosimilitud asociado a la observación E_j , donde

$$\ell_i^{(j)} := P(E_j | H_i), \quad i = 1, \dots, n.$$

Cuando $\ell_i^{(j)} > 0$ para todo i , el vector $\ell^{(j)}$ determina una corrección global $Y^{\ell^{(j)}} \in C_{\text{glob}}$ mediante

$$1 + Y_i^{\ell^{(j)}} := \ell_i^{(j)}, \quad i = 1, \dots, n.$$

En particular, la verosimilitud queda incorporada al formalismo global como un representante multiplicativo positivo.

Con esta identificación, la actualización posterior puede formularse ya como una transformación del propio estado en el simplex.

Proposición 6.1 (El operador bayesiano como caso particular de T_Y). Sean $(\Omega, \mathcal{F}, P)$ el espacio de probabilidad y $\Pi_H = \{H_1, \dots, H_n\}$, $\Pi_E = \{E_1, \dots, E_m\}$ las particiones de la Definición 6.1. Sea $j \in \{1, \dots, m\}$ tal que $P(E_j) > 0$, y supóngase que la verosimilitud asociada a E_j satisface

$$\ell^{(j)} = (\ell_1^{(j)}, \dots, \ell_n^{(j)}) \in \mathbb{R}_{>0}^n, \quad \ell_i^{(j)} := P(E_j | H_i), \quad i = 1, \dots, n.$$

Sea además $X \in \Delta_n^\circ$ el estado previo asociado a Π_H , dado por $X_i = P(H_i)$ para todo $i = 1, \dots, n$. Entonces, para cada $i = 1, \dots, n$, se tiene

$$T_{Y^{\ell^{(j)}}}(X)_i = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}} = P(H_i | E_j).$$

En particular, $T_{Y^{\ell^{(j)}}}(X)$ coincide con el estado posterior condicionado a la observación E_j .

Demostración. Como $\ell_i^{(j)} > 0$ para todo $i = 1, \dots, n$, el vector $Y^{\ell^{(j)}}$ pertenece a C_{glob} , y por tanto el operador global $T_{Y^{\ell^{(j)}}}$ está bien definido. Por la Definición 4.2, para cada $i = 1, \dots, n$,

$$T_{Y^{\ell^{(j)}}}(X)_i = \frac{X_i(1 + Y_i^{\ell^{(j)}})}{\sum_{k=1}^n X_k(1 + Y_k^{\ell^{(j)}})}.$$

Puesto que $1 + Y_i^{\ell^{(j)}} = \ell_i^{(j)}$, esta expresión se reduce a

$$T_{Y^{\ell^{(j)}}}(X)_i = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}}.$$

Ahora bien, por definición del estado previo y de la verosimilitud, $X_i = P(H_i)$ y $\ell_i^{(j)} = P(E_j | H_i)$, de modo que

$$X_i \ell_i^{(j)} = P(H_i) P(E_j | H_i) = P(H_i \cap E_j).$$

Además, como $\Pi_H = \{H_1, \dots, H_n\}$ es una partición de Ω , los conjuntos $H_1 \cap E_j, \dots, H_n \cap E_j$ son disjuntos y su unión es E_j . En consecuencia,

$$\sum_{k=1}^n X_k \ell_k^{(j)} = \sum_{k=1}^n P(H_k \cap E_j) = P(E_j).$$

Sustituyendo estas identidades en la expresión anterior, se obtiene

$$T_{Y^{\ell^{(j)}}}(X)_i = \frac{P(H_i \cap E_j)}{P(E_j)} = P(H_i | E_j), \quad i = 1, \dots, n.$$

□

La unicidad de esta representación fija la regla de actualización dentro de $\mathcal{G}$ y evita ambigüedades al pasar del prior al posterior.

Proposición 6.2 (Unicidad: $T_{Y^{\ell^{(j)}}}$ es el único operador coherente con P). Sean $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad,

$$\Pi_H = \{H_1, \dots, H_n\}, \quad \Pi_E = \{E_1, \dots, E_m\},$$

particiones medibles finitas de Ω , y

$$X = (X_1, \dots, X_n) \in \Delta_n^\circ, \quad X_i := P(H_i), \quad i = 1, \dots, n.$$

Sea $j \in \{1, \dots, m\}$ tal que

$$P(H_i \cap E_j) > 0, \quad i = 1, \dots, n,$$

y defínase

$$\ell_i^{(j)} := P(E_j | H_i), \quad i = 1, \dots, n.$$

Entonces, para un operador $T \in \mathcal{G}$, se tiene

$$T(X)_i = P(H_i | E_j), \quad i = 1, \dots, n,$$

si y sólo si

$$T = T_{Y^{\ell^{(j)}}}.$$

Demostración. Sea $T \in \mathcal{G}$. Entonces existe $Y \in C_{\text{glob}}$ tal que $T = T_Y$. Supóngase primero que

$$T(X)_i = P(H_i \mid E_j), \quad i = 1, \dots, n.$$

Por definición del operador global,

$$T_Y(X)_i = \frac{X_i(1 + Y_i)}{\sum_{k=1}^n X_k(1 + Y_k)}, \quad i = 1, \dots, n.$$

Por otra parte, como $X_i = P(H_i)$ y $\ell_i^{(j)} = P(E_j \mid H_i)$, se tiene

$$X_i \ell_i^{(j)} = P(H_i) P(E_j \mid H_i) = P(H_i \cap E_j),$$

y, puesto que Π_H es una partición de Ω ,

$$\sum_{k=1}^n X_k \ell_k^{(j)} = \sum_{k=1}^n P(H_k \cap E_j) = P(E_j).$$

De aquí se sigue que

$$P(H_i \mid E_j) = \frac{P(H_i \cap E_j)}{P(E_j)} = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}}, \quad i = 1, \dots, n.$$

Por consiguiente,

$$\frac{X_i(1 + Y_i)}{\sum_{k=1}^n X_k(1 + Y_k)} = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}}, \quad i = 1, \dots, n.$$

Como $X_i > 0$ para todo $i = 1, \dots, n$, se deduce que

$$\frac{1 + Y_i}{\ell_i^{(j)}} = \frac{\sum_{k=1}^n X_k(1 + Y_k)}{\sum_{k=1}^n X_k \ell_k^{(j)}} =: c, \quad i = 1, \dots, n.$$

La constante c es positiva e independiente de i , y por tanto

$$1 + Y_i = c \ell_i^{(j)}, \quad i = 1, \dots, n.$$

Sea ahora $Z \in \Delta_n^\circ$. Entonces, para cada $i = 1, \dots, n$,

$$T_Y(Z)_i = \frac{Z_i(1 + Y_i)}{\sum_{k=1}^n Z_k(1 + Y_k)} = \frac{Z_i c \ell_i^{(j)}}{\sum_{k=1}^n Z_k c \ell_k^{(j)}} = \frac{Z_i \ell_i^{(j)}}{\sum_{k=1}^n Z_k \ell_k^{(j)}} = T_{Y \ell^{(j)}}(Z)_i.$$

Se sigue que $T = T_{Y \ell^{(j)}}$.

Recíprocamente, si $T = T_{Y \ell^{(j)}}$, entonces para cada $i = 1, \dots, n$,

$$T(X)_i = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}} = \frac{P(H_i \cap E_j)}{P(E_j)} = P(H_i \mid E_j).$$

Esto concluye la demostración. □

Corolario 6.1 (Actualización bayesiana secuencial como composición en $\mathcal{G}$). Sean $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad,

$$\Pi_H = \{H_1, \dots, H_n\}, \quad \Pi_E = \{E_1, \dots, E_m\},$$

particiones medibles finitas de Ω , y

$$X_0 = (X_{0,1}, \dots, X_{0,n}) \in \Delta_n^\circ, \quad X_{0,i} := P(H_i), \quad i = 1, \dots, n.$$

Sean $j_1, \dots, j_r \in \{1, \dots, m\}$ y, para cada $s = 1, \dots, r$, supóngase que

$$P(H_i \cap E_{j_s}) > 0, \quad i = 1, \dots, n.$$

Para cada $s = 1, \dots, r$, defínase la verosimilitud asociada a la observación E_{j_s} por

$$\ell_i^{(j_s)} := P(E_{j_s} \mid H_i), \quad i = 1, \dots, n.$$

Entonces el estado posterior obtenido tras aplicar sucesivamente las r actualizaciones bayesianas viene dado por

$$X_r = T_{Y^{\ell(j_r)}} \circ \dots \circ T_{Y^{\ell(j_1)}}(X_0).$$

Si, además, las observaciones son condicionalmente independientes dadas las hipótesis, entonces la actualización secuencial coincide con la actualización en un solo paso asociada a la verosimilitud acumulada

$$\tilde{\ell}_i := \prod_{s=1}^r \ell_i^{(j_s)}, \quad i = 1, \dots, n,$$

es decir,

$$X_r = T_{Y^{\tilde{\ell}}}(X_0).$$

Demostración. Para cada $s = 1, \dots, r$, la hipótesis $P(H_i \cap E_{j_s}) > 0$ para todo $i = 1, \dots, n$ implica que

$$\ell_i^{(j_s)} = P(E_{j_s} \mid H_i) > 0, \quad i = 1, \dots, n.$$

Por consiguiente, cada vector $\ell^{(j_s)}$ determina una corrección global $Y^{\ell^{(j_s)}} \in C_{\text{glob}}$, y el operador

$$T_{Y^{\ell^{(j_s)}}} : \Delta_n^\circ \rightarrow \Delta_n^\circ$$

está bien definido.

Aplicando en cada paso la actualización bayesiana asociada a la observación correspondiente, se obtiene sucesivamente

$$X_1 = T_{Y^{\ell(j_1)}}(X_0), \quad X_2 = T_{Y^{\ell(j_2)}}(X_1), \quad \dots, \quad X_r = T_{Y^{\ell(j_r)}}(X_{r-1}).$$

Por sustitución iterada, resulta

$$X_r = T_{Y^{\ell(j_r)}} \circ \dots \circ T_{Y^{\ell(j_1)}}(X_0).$$

Supóngase ahora, además, que las observaciones son condicionalmente independientes dadas las hipótesis. Entonces, para cada $i = 1, \dots, n$, la verosimilitud conjunta es el producto de las verosimilitudes individuales:

$$\tilde{\ell}_i = \prod_{s=1}^r \ell_i^{(j_s)}.$$

Por la ley de composición de los operadores globales, la composición

$$T_{Y^{\ell(j_r)}} \circ \cdots \circ T_{Y^{\ell(j_1)}}$$

es nuevamente un operador global, cuyo factor multiplicativo es proporcional al producto coordinado de los factores individuales. Como dichos factores son precisamente

$$\ell^{(j_1)}, \dots, \ell^{(j_r)},$$

el operador compuesto coincide con $T_{Y^{\tilde{\ell}}}$. Por tanto,

$$X_r = T_{Y^{\tilde{\ell}}}(X_0).$$

Esto concluye la demostración. □

6.1. Modelos continuos como estados informacionales discretos

Observación 6.1 (Criterio medible para la discretización paramétrica). *La discretización paramétrica que se usa en este bloque descansa en dos planos ya fijados. En el plano interno, las Secciones A–D proporcionan el espacio de probabilidad, la partición medible finita, el símplex, el conjunto de correcciones globales y el operador multiplicativo normalizado; en particular, se usan los objetos introducidos en las Definiciones 2.1, 2.2, 2.3, 4.1 y 4.2. En el plano de teoría de la medida, la referencia de Tao, An Introduction to Measure Theory, justifica trabajar con conjuntos borelianos, funciones indicadoras, funciones medibles no negativas e integrales de Lebesgue sobre espacios de medida. Así, las masas de las celdas pueden escribirse como integrales de funciones indicadoras contra una densidad.*

Definición 6.4 (Partición paramétrica uniforme). *Sea $\Omega = (a, b) \subset \mathbb{R}$, con $a < b$, y sea $\mathcal{F} = \mathcal{B}(\Omega)$ la σ -álgebra de Borel relativa en Ω . Sea P_0 una medida de probabilidad sobre $(\Omega, \mathcal{F})$ absolutamente continua respecto de la medida de Lebesgue restringida a Ω . Sea*

$$f := \frac{dP_0}{d\lambda}$$

una densidad de P_0 respecto de λ , donde λ denota la medida de Lebesgue restringida a Ω . Se supone que

$$f : \Omega \rightarrow (0, \infty)$$

es $\mathcal{F}$ -medible y satisface

$$\int_{\Omega} f(\theta) d\theta = 1.$$

Dado $n \geq 1$, sea

$$h := \frac{b-a}{n}.$$

La partición paramétrica uniforme de orden n asociada a Ω es la familia

$$\Pi_n := \{E_1, \dots, E_n\},$$

donde

$$E_i := \begin{cases} [a + (i-1)h, a + ih) \cap \Omega, & i = 1, \dots, n-1, \\ [a + (n-1)h, b) \cap \Omega, & i = n. \end{cases}$$

El estado informacional previo asociado a $(\Omega, \mathcal{F}, P_0, \Pi_n)$ es el vector

$$X_0 = (X_{0,1}, \dots, X_{0,n}), \quad X_{0,i} := P_0(E_i) = \int_{E_i} f(\theta) d\theta, \quad i = 1, \dots, n.$$

Proposición 6.3 (Estado previo inducido por una partición paramétrica uniforme). Sea $\Omega = (a, b) \subset \mathbb{R}$, con $a < b$, y sea $\mathcal{F} = \mathcal{B}(\Omega)$. Sea P_0 una medida de probabilidad sobre $(\Omega, \mathcal{F})$ absolutamente continua respecto de la medida de Lebesgue restringida a Ω , con densidad $f : \Omega \rightarrow (0, \infty)$ medible y tal que

$$\int_{\Omega} f(\theta) d\theta = 1.$$

Sea $n \geq 1$, sea $h = (b - a)/n$ y sean

$$E_i := \begin{cases} [a + (i-1)h, a + ih) \cap \Omega, & i = 1, \dots, n-1, \\ [a + (n-1)h, b) \cap \Omega, & i = n. \end{cases}$$

Defínase

$$X_{0,i} := P_0(E_i) = \int_{E_i} f(\theta) d\theta, \quad i = 1, \dots, n.$$

Entonces $\Pi_n = \{E_1, \dots, E_n\}$ es una partición medible finita no degenerada de Ω y

$$X_0 = (X_{0,1}, \dots, X_{0,n}) \in \Delta_n^\circ.$$

Demostración. Para $i = 1, \dots, n$, cada E_i es intersección de un intervalo boreliano de $\mathbb{R}$ con Ω ; por tanto,

$$E_i \in \mathcal{F}.$$

Además,

$$E_i \cap E_j = \emptyset \quad (i \neq j), \quad \bigcup_{i=1}^n E_i = \Omega.$$

Luego Π_n es una partición medible finita de Ω .

Como cada E_i contiene un intervalo relativo no vacío de Ω y $f(\theta) > 0$ para todo $\theta \in \Omega$, se tiene

$$X_{0,i} = P_0(E_i) = \int_{E_i} f(\theta) d\theta > 0, \quad i = 1, \dots, n.$$

Por otra parte,

$$\sum_{i=1}^n X_{0,i} = \sum_{i=1}^n P_0(E_i) = P_0\left(\bigcup_{i=1}^n E_i\right) = P_0(\Omega) = 1.$$

Así,

$$X_{0,i} > 0 \quad (i = 1, \dots, n), \quad \sum_{i=1}^n X_{0,i} = 1,$$

y por consiguiente

$$X_0 \in \Delta_n^\circ.$$

□

Observación 6.2 (Promedio condicional de la verosimilitud). *La integral que aparece en la verosimilitud discreta es una integral de Lebesgue respecto de P_0 . La referencia de Tao permite tratar $\int_{E_i} \ell dP_0$ como integral de una función medible no negativa sobre un espacio de medida. La condición $0 < \int_{\Omega} \ell dP_0 < \infty$ evita cantidades extendidas en el normalizador; esta precaución es necesaria porque las operaciones algebraicas con $+\infty$ no admiten cancelación ordinaria. En la semántica bayesiana ya desarrollada en la Sección E, la verosimilitud actúa como factor multiplicativo; esta lectura concuerda con los espacios de Bayes de Egozcue, Pawlowsky-Glahn, Tolosana-Delgado, Ortego y van den Boogaart, donde la perturbación corresponde a multiplicación de densidades seguida de normalización.*

Definición 6.5 (Verosimilitud discreta inducida por una partición). *Sea $\Omega = (a, b) \subset \mathbb{R}$, sea $\mathcal{F} = \mathcal{B}(\Omega)$ y sea P_0 una medida de probabilidad sobre $(\Omega, \mathcal{F})$. Sea $\Pi_n = \{E_1, \dots, E_n\}$ una partición medible finita no degenerada de Ω . Sea e un dato observado y sea*

$$\ell : \Omega \rightarrow (0, \infty)$$

una función de verosimilitud medible, asociada al dato e , tal que

$$0 < \int_{\Omega} \ell(\theta) dP_0(\theta) < \infty.$$

La verosimilitud discreta del dato e bajo la celda E_i se define por

$$\ell_i := E_{P_0}[\ell \mid E_i] := \frac{\int_{E_i} \ell(\theta) dP_0(\theta)}{P_0(E_i)}, \quad i = 1, \dots, n.$$

Si, además, P_0 tiene densidad f respecto de la medida de Lebesgue restringida a Ω , entonces

$$\ell_i = \frac{\int_{E_i} \ell(\theta) f(\theta) d\theta}{\int_{E_i} f(\theta) d\theta}, \quad i = 1, \dots, n.$$

El vector asociado a la verosimilitud discreta se define por

$$1 + Y_i^\ell := \ell_i, \quad i = 1, \dots, n.$$

Proposición 6.4 (Admisibilidad de la corrección de verosimilitud). *Sea $(\Omega, \mathcal{F}, P_0)$ un espacio de probabilidad. Sea $\Pi_n = \{E_1, \dots, E_n\}$ una partición medible finita de Ω tal que*

$$P_0(E_i) > 0, \quad i = 1, \dots, n.$$

Sea $\ell : \Omega \rightarrow (0, \infty)$ una función medible tal que

$$0 < \int_{\Omega} \ell dP_0 < \infty.$$

Para cada $i = 1, \dots, n$, defínase

$$\ell_i := \frac{\int_{E_i} \ell dP_0}{P_0(E_i)}$$

y defínase $Y^\ell \in \mathbb{R}^n$ por

$$1 + Y_i^\ell := \ell_i, \quad i = 1, \dots, n.$$

Entonces

$$Y^\ell \in C_{\text{glob}}.$$

Demostración. Como $\ell(\omega) > 0$ para todo $\omega \in \Omega$ y $P_0(E_i) > 0$, se tiene

$$\int_{E_i} \ell dP_0 > 0.$$

Además,

$$0 < \int_{E_i} \ell dP_0 \leq \int_{\Omega} \ell dP_0 < \infty.$$

Por tanto,

$$0 < \frac{\int_{E_i} \ell dP_0}{P_0(E_i)} < \infty, \quad i = 1, \dots, n.$$

Es decir,

$$0 < \ell_i < \infty, \quad i = 1, \dots, n.$$

Como

$$1 + Y_i^\ell = \ell_i,$$

se obtiene

$$1 + Y_i^\ell > 0, \quad i = 1, \dots, n.$$

Así,

$$Y^\ell = (Y_1^\ell, \dots, Y_n^\ell) \in \mathbb{R}^n, \quad 1 + Y_i^\ell > 0 \quad (i = 1, \dots, n),$$

y por consiguiente

$$Y^\ell \in C_{\text{glob}}.$$

□

Observación 6.3 (Radon–Nikodym y construcción de la posterior). *En la teoría de la medida, una medida absolutamente continua puede representarse mediante una derivada de Radon–Nikodym respecto de una medida dominante. En este bloque no se invoca el teorema para obtener existencia abstracta: la posterior se construye directamente mediante la densidad ℓ/Z respecto de P_0 , donde $Z = \int_{\Omega} \ell dP_0$. La referencia de Tao proporciona el marco de espacios de medida e integración; la lectura bayesiana de los espacios de Bayes proporciona la interpretación multiplicativa de la actualización.*

Lema 6.1 (Cambio de medida exacto por celdas). *Sea $(\Omega, \mathcal{F}, P_0)$ un espacio de probabilidad. Sea $\Pi_n = \{E_1, \dots, E_n\}$ una partición medible finita de Ω tal que*

$$P_0(E_i) > 0, \quad i = 1, \dots, n.$$

Sea $\ell : \Omega \rightarrow (0, \infty)$ una función medible tal que

$$Z := \int_{\Omega} \ell dP_0$$

satisface

$$0 < Z < \infty.$$

Defínase, para $A \in \mathcal{F}$,

$$Q(A) := \int_A \frac{\ell}{Z} dP_0.$$

Defínase también

$$\ell_i := \frac{\int_{E_i} \ell dP_0}{P_0(E_i)}, \quad i = 1, \dots, n.$$

Entonces Q es una medida de probabilidad sobre $(\Omega, \mathcal{F})$, se cumple

$$\frac{dQ}{dP_0} = \frac{\ell}{Z},$$

y, para cada $i = 1, \dots, n$,

$$Q(E_i) = \frac{P_0(E_i)\ell_i}{\sum_{k=1}^n P_0(E_k)\ell_k}.$$

Demostración. Para $A \in \mathcal{F}$,

$$Q(A) = \int_A \frac{\ell}{Z} dP_0 \geq 0.$$

Además,

$$Q(\Omega) = \int_{\Omega} \frac{\ell}{Z} dP_0 = \frac{1}{Z} \int_{\Omega} \ell dP_0 = \frac{Z}{Z} = 1.$$

La aditividad numerable se hereda de la integral respecto de P_0 , pues la densidad ℓ/Z es medible y no negativa. Luego Q es una medida de probabilidad.

Por definición de Q ,

$$Q(A) = \int_A \frac{\ell}{Z} dP_0, \quad A \in \mathcal{F},$$

de modo que

$$\frac{dQ}{dP_0} = \frac{\ell}{Z}.$$

Para cada $i = 1, \dots, n$,

$$P_0(E_i)\ell_i = P_0(E_i) \frac{\int_{E_i} \ell dP_0}{P_0(E_i)} = \int_{E_i} \ell dP_0.$$

Por tanto,

$$\sum_{k=1}^n P_0(E_k)\ell_k = \sum_{k=1}^n \int_{E_k} \ell dP_0 = \int_{\bigcup_{k=1}^n E_k} \ell dP_0 = \int_{\Omega} \ell dP_0 = Z.$$

Así,

$$Q(E_i) = \int_{E_i} \frac{\ell}{Z} dP_0 = \frac{\int_{E_i} \ell dP_0}{Z} = \frac{P_0(E_i)\ell_i}{\sum_{k=1}^n P_0(E_k)\ell_k}.$$

□

Observación 6.4 (Identidad entre actualización bayesiana y operador global). La Sección C introduce el operador informacional global como multiplicación coordinada a coordinada seguida de normalización. La semántica bayesiana de la Sección E identifica la verosimilitud con los factores multiplicativos de esa corrección. En la bibliografía de espacios de Bayes, la fórmula de Bayes se lee precisamente como perturbación: se multiplican densidades positivas proporcionales y se normaliza. En consecuencia, la proposición siguiente formaliza que el operador T_Y no aproxima la posterior continua, sino que coincide con la masa que esa posterior asigna a cada celda de la partición.

Proposición 6.5 (Actualización bayesiana paramétrica en CI). Sea $\Omega = (a, b) \subset \mathbb{R}$, con $a < b$, y sea $\mathcal{F} = \mathcal{B}(\Omega)$. Sea P_0 una medida de probabilidad sobre $(\Omega, \mathcal{F})$ absolutamente continua respecto de la medida de Lebesgue restringida a Ω , con densidad $f : \Omega \rightarrow (0, \infty)$ medible y tal que

$$\int_{\Omega} f(\theta) d\theta = 1.$$

Sea $n \geq 1$, sea $h = (b - a)/n$ y sean

$$E_i := \begin{cases} [a + (i - 1)h, a + ih) \cap \Omega, & i = 1, \dots, n - 1, \\ [a + (n - 1)h, b) \cap \Omega, & i = n. \end{cases}$$

Defínase

$$X_{0,i} := P_0(E_i) = \int_{E_i} f(\theta) d\theta, \quad i = 1, \dots, n.$$

Sea $\ell : \Omega \rightarrow (0, \infty)$ una función medible tal que

$$Z := \int_{\Omega} \ell dP_0$$

satisface

$$0 < Z < \infty.$$

Defínase

$$\ell_i := \frac{\int_{E_i} \ell dP_0}{P_0(E_i)}, \quad 1 + Y_i^\ell := \ell_i, \quad i = 1, \dots, n.$$

Defínase, para $A \in \mathcal{F}$,

$$Q(A) := \int_A \frac{\ell}{Z} dP_0.$$

Finalmente, defínase

$$T_{Y^\ell}(X_0)_i := \frac{X_{0,i}(1 + Y_i^\ell)}{\sum_{k=1}^n X_{0,k}(1 + Y_k^\ell)}, \quad i = 1, \dots, n.$$

Entonces

$$T_{Y^\ell}(X_0)_i = Q(E_i), \quad i = 1, \dots, n.$$

En particular,

$$T_{Y^\ell}(X_0) \in \Delta_n^\circ.$$

Demostración. Para cada $i = 1, \dots, n$,

$$X_{0,i} = P_0(E_i), \quad 1 + Y_i^\ell = \ell_i.$$

Por tanto,

$$T_{Y^\ell}(X_0)_i = \frac{X_{0,i}(1 + Y_i^\ell)}{\sum_{k=1}^n X_{0,k}(1 + Y_k^\ell)} = \frac{P_0(E_i)\ell_i}{\sum_{k=1}^n P_0(E_k)\ell_k}.$$

Como

$$\ell_i = \frac{\int_{E_i} \ell dP_0}{P_0(E_i)},$$

se tiene

$$P_0(E_i)\ell_i = \int_{E_i} \ell dP_0.$$

Luego

$$\sum_{k=1}^n P_0(E_k)\ell_k = \sum_{k=1}^n \int_{E_k} \ell dP_0 = \int_{\Omega} \ell dP_0 = Z.$$

Sustituyendo,

$$T_{Y^\ell}(X_0)_i = \frac{\int_{E_i} \ell dP_0}{Z} = \int_{E_i} \frac{\ell}{Z} dP_0 = Q(E_i).$$

Además, como $f > 0$ en Ω y cada E_i tiene longitud positiva,

$$X_{0,i} > 0.$$

Como $\ell_i > 0$,

$$X_{0,i}(1 + Y_i^\ell) = X_{0,i}\ell_i > 0.$$

Así,

$$T_{Y^\ell}(X_0)_i > 0, \quad i = 1, \dots, n.$$

Finalmente,

$$\sum_{i=1}^n T_{Y^\ell}(X_0)_i = \sum_{i=1}^n Q(E_i) = Q(\Omega) = 1.$$

Por consiguiente,

$$T_{Y^\ell}(X_0) \in \Delta_n^\circ.$$

□

Observación 6.5 (Familias exponenciales y separación de niveles). *En los espacios de Bayes, las familias exponenciales aparecen como estructuras afines o cónicas de densidades positivas. Este hecho justifica separar dos niveles: el nivel continuo, donde la conjugación se expresa por suma de parámetros naturales, y el nivel discreto, donde el operador global recupera las masas de la posterior sobre una partición finita. La proposición siguiente no modifica el teorema bayesiano anterior; únicamente lo especializa al caso en que el producto entre densidad previa y verosimilitud conserva forma exponencial.*

Proposición 6.6 (Modelo conjugado exponencial como caso particular). Sea $\Omega = (a, b) \subset \mathbb{R}$, con $a < b$, y sea $\mathcal{F} = \mathcal{B}(\Omega)$. Sea $T : \Omega \rightarrow \mathbb{R}^m$ una función medible. Sean $\eta_0, \eta_\ell \in \mathbb{R}^m$ tales que

$$0 < I_0 := \int_{\Omega} \exp(\eta_0 \cdot T(\theta)) d\theta < \infty$$

y

$$0 < I_1 := \int_{\Omega} \exp((\eta_0 + \eta_\ell) \cdot T(\theta)) d\theta < \infty.$$

Defínase

$$f(\theta) := \frac{\exp(\eta_0 \cdot T(\theta))}{I_0}, \quad \theta \in \Omega,$$

y sea P_0 la medida de probabilidad sobre $(\Omega, \mathcal{F})$ dada por

$$dP_0(\theta) = f(\theta) d\theta.$$

Sea $c_\ell > 0$ y defínase la verosimilitud

$$\ell(\theta) := c_\ell \exp(\eta_\ell \cdot T(\theta)), \quad \theta \in \Omega.$$

Sea $n \geq 1$, sea $h = (b - a)/n$ y sean

$$E_i := \begin{cases} [a + (i - 1)h, a + ih) \cap \Omega, & i = 1, \dots, n - 1, \\ [a + (n - 1)h, b) \cap \Omega, & i = n. \end{cases}$$

Defínase

$$X_{0,i} := P_0(E_i), \quad \ell_i := \frac{\int_{E_i} \ell dP_0}{P_0(E_i)}, \quad 1 + Y_i^\ell := \ell_i.$$

Defínase Q por

$$Q(A) := \frac{\int_A \ell dP_0}{\int_{\Omega} \ell dP_0}, \quad A \in \mathcal{F}.$$

Entonces, para cada $i = 1, \dots, n$,

$$T_{Y^\ell}(X_0)_i = Q(E_i) = \frac{\int_{E_i} \exp((\eta_0 + \eta_\ell) \cdot T(\theta)) d\theta}{\int_{\Omega} \exp((\eta_0 + \eta_\ell) \cdot T(\theta)) d\theta}.$$

Además, Q es absolutamente continua respecto de la medida de Lebesgue restringida a Ω y su densidad es

$$q(\theta) = \frac{\exp((\eta_0 + \eta_\ell) \cdot T(\theta))}{\int_{\Omega} \exp((\eta_0 + \eta_\ell) \cdot T(u)) du}.$$

En particular, la posterior pertenece a la misma familia exponencial, con parámetro natural

$$\eta_{\text{post}} := \eta_0 + \eta_\ell.$$

Demostración. Primero,

$$\int_{\Omega} f(\theta) d\theta = \frac{1}{I_0} \int_{\Omega} \exp(\eta_0 \cdot T(\theta)) d\theta = 1.$$

Luego P_0 es probabilidad. Además,

$$\int_{\Omega} \ell dP_0 = \int_{\Omega} c_{\ell} \exp(\eta_{\ell} \cdot T(\theta)) \frac{\exp(\eta_0 \cdot T(\theta))}{I_0} d\theta.$$

Por tanto,

$$\int_{\Omega} \ell dP_0 = \frac{c_{\ell}}{I_0} \int_{\Omega} \exp((\eta_0 + \eta_{\ell}) \cdot T(\theta)) d\theta = \frac{c_{\ell} I_1}{I_0}.$$

Como $c_{\ell} > 0$, $0 < I_0 < \infty$ y $0 < I_1 < \infty$,

$$0 < \int_{\Omega} \ell dP_0 < \infty.$$

Para $A \in \mathcal{F}$,

$$Q(A) = \frac{\int_A \ell dP_0}{\int_{\Omega} \ell dP_0}.$$

El numerador satisface

$$\int_A \ell dP_0 = \frac{c_{\ell}}{I_0} \int_A \exp((\eta_0 + \eta_{\ell}) \cdot T(\theta)) d\theta.$$

El denominador satisface

$$\int_{\Omega} \ell dP_0 = \frac{c_{\ell}}{I_0} \int_{\Omega} \exp((\eta_0 + \eta_{\ell}) \cdot T(\theta)) d\theta.$$

Luego

$$Q(A) = \frac{\int_A \exp((\eta_0 + \eta_{\ell}) \cdot T(\theta)) d\theta}{\int_{\Omega} \exp((\eta_0 + \eta_{\ell}) \cdot T(\theta)) d\theta}.$$

Tomando $A = E_i$,

$$Q(E_i) = \frac{\int_{E_i} \exp((\eta_0 + \eta_{\ell}) \cdot T(\theta)) d\theta}{\int_{\Omega} \exp((\eta_0 + \eta_{\ell}) \cdot T(\theta)) d\theta}.$$

Por otra parte,

$$T_{Y^{\ell}}(X_0)_i = \frac{X_{0,i}(1 + Y_i^{\ell})}{\sum_{k=1}^n X_{0,k}(1 + Y_k^{\ell})} = \frac{P_0(E_i)\ell_i}{\sum_{k=1}^n P_0(E_k)\ell_k}.$$

Como

$$P_0(E_i)\ell_i = \int_{E_i} \ell dP_0, \quad \sum_{k=1}^n P_0(E_k)\ell_k = \int_{\Omega} \ell dP_0,$$

se obtiene

$$T_{Y^\ell}(X_0)_i = \frac{\int_{E_i} \ell dP_0}{\int_{\Omega} \ell dP_0} = Q(E_i).$$

Finalmente, la densidad de Q respecto de Lebesgue es

$$q(\theta) = \frac{\exp((\eta_0 + \eta_\ell) \cdot T(\theta))}{\int_{\Omega} \exp((\eta_0 + \eta_\ell) \cdot T(u)) du},$$

de modo que el parámetro natural posterior es

$$\eta_{\text{post}} = \eta_0 + \eta_\ell.$$

□

6.2. Trayectorias Bayesianas

El interés de esta sección es estudiar cómo un estado de creencia sobre un conjunto de hipótesis puede ser guiado deliberadamente hacia un estado destino, y no solamente actualizado de forma pasiva a medida que llega evidencia. La pregunta no es únicamente qué se concluye con la evidencia que se tiene, sino cuál evidencia disponible conviene adoptar cuando ya se tiene en mente un estado al que se quiere llegar.

La manera de hacerlo, en términos generales, es comparar en cada momento las observaciones que están disponibles, ver qué estado produciría cada una si se adoptara, y quedarse con la que más acerca al destino buscado. Repitiendo esta elección paso a paso se obtiene un recorrido que avanza progresivamente hacia ese destino, con un grado de avance medible en cada etapa.

La idea de elegir activamente qué observación adoptar, en vez de recibirla impuesta por un proceso externo, viene de Chernoff (1959): un decisor escoge entre experimentos disponibles para acumular evidencia sobre cuál hipótesis es la verdadera. Naghshvar y Javidi (2013) formalizan esa elección con un criterio explícito de divergencia, pero el destino sigue siendo la certeza sobre la hipótesis verdadera, y el efecto de cada observación es incierto hasta que se realiza. Csiszár (1975), en cambio, sí permite que el destino sea cualquier distribución y no solo una hipótesis verdadera, pero su construcción no tiene observación ni elección activa de por medio: es una proyección geométrica determinista entre distribuciones. Esta sección retoma la elección activa de los dos primeros, pero dirigida hacia un destino arbitrario como en el tercero — sin que ese destino represente la verdad, ni el resultado de elegir una observación sea incierto.

Definición 6.6 (Notación: operador bayesiano inducido por una verosimilitud). *Sea $\ell = (\ell_1, \dots, \ell_n) \in \mathbb{R}_{>0}^n$ un vector de verosimilitudes positivas. Por la Definición 6.3, ℓ determina una corrección global*

$$Y^\ell \in C_{\text{glob}}, \quad 1 + Y_i^\ell := \ell_i, \quad i = 1, \dots, n,$$

y, por la Definición 4.2, el operador informacional global asociado satisface

$$T_{Y^\ell}(X)_i = \frac{X_i \ell_i}{\sum_{k=1}^n X_k \ell_k}, \quad X \in \Delta_n^\circ, \quad i = 1, \dots, n.$$

Por la Proposición 6.1, cuando ℓ proviene de una verosimilitud genuina, $\ell_i = P(E \mid H_i)$, y X es el estado informacional previo asociado a Π_H , el operador $T_{Y^\ell}(X)$ coincide con el posterior bayesiano real $P(H_i \mid E)$. Por brevedad, en esta subsección se escribe $T_\ell := T_{Y^\ell}$.

Definición 6.7 (Objetivo bayesiano interior). Sea

$$\Pi_H = \{H_1, \dots, H_n\}$$

una partición finita de hipótesis, con $n \geq 2$, y sea

$$\Delta_n^\circ = \left\{ X \in \mathbb{R}^n \mid X_i > 0, \sum_{i=1}^n X_i = 1 \right\}.$$

Un objetivo bayesiano interior es un vector

$$\mathcal{P} = (\mathcal{P}_1, \dots, \mathcal{P}_n) \in \Delta_n^\circ$$

interpretado como una distribución objetivo sobre la partición de hipótesis Π_H .

Cada coordenada $\mathcal{P}_i$ representa la masa informacional que se desea asignar a la hipótesis H_i . En particular,

$$\mathcal{P}_i > 0 \quad \text{para todo } i = 1, \dots, n,$$

y

$$\sum_{i=1}^n \mathcal{P}_i = 1.$$

El vector $\mathcal{P}$ no representa una hipótesis individual. Si se quisiera seleccionar únicamente una hipótesis H_j , el vector asociado sería el vértice

$$e_j = (0, \dots, 0, 1, 0, \dots, 0),$$

con la entrada 1 en la posición j . Para $n \geq 2$, dicho vector satisface

$$e_j \notin \Delta_n^\circ,$$

pues posee coordenadas nulas. Por tanto, dentro de la semántica bayesiana interior, el objetivo admisible no es una hipótesis aislada, sino una distribución estrictamente positiva sobre las hipótesis de Π_H .

Corolario 6.2 (Realización bayesiana del paso discreto determinista). Sea

$$\Pi_H = \{H_1, \dots, H_n\}$$

una partición finita de hipótesis, con $n \geq 2$, y sea

$$\Delta_n^\circ = \left\{ X \in \mathbb{R}^n \mid X_i > 0, \sum_{i=1}^n X_i = 1 \right\}.$$

Sean

$$X = (X_1, \dots, X_n) \in \Delta_n^\circ$$

un estado informacional (Definición 6.1), y

$$\mathcal{P} = (\mathcal{P}_1, \dots, \mathcal{P}_n) \in \Delta_n^\circ$$

un objetivo bayesiano interior sobre la misma partición Π_H .

Para $\alpha \in [0, 1]$, defínase

$$\ell^{(\alpha)}(X, \mathcal{P}) = (\ell_1^{(\alpha)}(X, \mathcal{P}), \dots, \ell_n^{(\alpha)}(X, \mathcal{P}))$$

por

$$\ell_i^{(\alpha)}(X, \mathcal{P}) := 1 - \alpha + \alpha \frac{\mathcal{P}_i}{X_i}, \quad i = 1, \dots, n.$$

Entonces

$$\ell^{(\alpha)}(X, \mathcal{P}) \in \mathbb{R}_{>0}^n$$

y la actualización bayesiana inducida por $\ell^{(\alpha)}(X, \mathcal{P})$ satisface

$$T_{\ell^{(\alpha)}(X, \mathcal{P})}(X) = (1 - \alpha)X + \alpha\mathcal{P}.$$

Demostración. Como $X, \mathcal{P} \in \Delta_n^\circ$, se tiene

$$X_i > 0, \quad \mathcal{P}_i > 0, \quad i = 1, \dots, n.$$

Luego

$$\frac{\mathcal{P}_i}{X_i} > 0.$$

Si $\alpha \in [0, 1]$, entonces

$$1 - \alpha \geq 0 \quad \text{y} \quad \alpha \frac{\mathcal{P}_i}{X_i} \geq 0.$$

Además,

$$1 - \alpha + \alpha \frac{\mathcal{P}_i}{X_i} > 0$$

para todo $i = 1, \dots, n$. Por tanto,

$$\ell^{(\alpha)}(X, \mathcal{P}) \in \mathbb{R}_{>0}^n.$$

Defínase

$$Y^*(X, \mathcal{P})_i := \frac{\mathcal{P}_i}{X_i} - 1.$$

Entonces

$$\ell_i^{(\alpha)}(X, \mathcal{P}) = 1 + \alpha Y^*(X, \mathcal{P})_i.$$

Por la equivalencia estructural entre el corrector informacional y el paso discreto inducido, se tiene

$$T_{\ell^{(\alpha)}(X, \mathcal{P})}(X) = T_{\alpha Y^*(X, \mathcal{P})}(X) = (1 - \alpha)X + \alpha\mathcal{P}.$$

□

Observación 6.6 (Selección observacional guiada por el objetivo bayesiano). Sea

$$\Pi_H = \{H_1, \dots, H_n\}$$

una partición finita de hipótesis, y sea

$$\mathcal{P} \in \Delta_n^\circ$$

un objetivo bayesiano interior sobre dicha partición.

En una dinámica bayesiana controlada, el paso siguiente no debe entenderse como la elección libre de un parámetro de relajación. La actualización bayesiana estricta exige que el estado posterior se obtenga a partir de una verosimilitud asociada a información disponible o admisible.

Por ello, dado un estado

$$X_t \in \Delta_n^\circ,$$

el problema natural consiste en comparar observaciones candidatas. Cada observación admisible debe inducir, al menos en sentido algebraico-composicional, un vector de verosimilitudes positivas

$$\ell^{(E)} \in \mathbb{R}_{>0}^n,$$

y por tanto un posterior candidato

$$T_{\ell^{(E)}}(X_t).$$

Así, el criterio de Control Informacional no consiste primero en fijar un número α_t , sino en decidir qué observación conviene seleccionar para aproximar el posterior al objetivo $\mathcal{P}$. El parámetro de avance debe aparecer después, como una medida del efecto que una observación candidata produce sobre la divergencia entre el posterior obtenido y el objetivo bayesiano.

En consecuencia, la dinámica buscada no parte de una interpolación impuesta entre X_t y $\mathcal{P}$, sino de una selección observacional paso a paso:

$$E \longmapsto \ell^{(E)} \longmapsto T_{\ell^{(E)}}(X_t) \longmapsto \text{comparación con } \mathcal{P}.$$

Sólo después de esta comparación tiene sentido hablar de un coeficiente de avance asociado a la observación seleccionada.

Definición 6.8 (Familia observacional admisible y posterior candidato). Sea

$$\Pi_H = \{H_1, \dots, H_n\}$$

una partición finita de hipótesis, y sea

$$\Pi_E$$

una familia de observaciones posibles. Sea

$$X_t \in \Delta_n^\circ$$

un estado informacional en el tiempo t .

Una familia observacional admisible en el tiempo t es un conjunto finito no vacío

$$\mathcal{E}_t \subseteq \Pi_E$$

tal que a cada observación candidata

$$E \in \mathcal{E}_t$$

se le asocia un vector de verosimilitudes positivas

$$\ell_t^{(E)} = (\ell_{t,1}^{(E)}, \dots, \ell_{t,n}^{(E)}) \in \mathbb{R}_{>0}^n.$$

En sentido algebraico-composicional, la condición de admisibilidad queda dada por

$$\ell_t^{(E)} \in \mathbb{R}_{>0}^n.$$

En sentido observacional estricto, se exige además que exista una constante

$$c_E > 0$$

tal que

$$\ell_{t,i}^{(E)} = c_E P(E \mid H_i), \quad i = 1, \dots, n.$$

El posterior candidato inducido por E desde el estado X_t se define por

$$X_t^E := T_{\ell_t^{(E)}}(X_t).$$

Es decir,

$$X_{t,i}^E = \frac{X_{t,i} \ell_{t,i}^{(E)}}{\sum_{k=1}^n X_{t,k} \ell_{t,k}^{(E)}}, \quad i = 1, \dots, n.$$

En el sentido observacional estricto, esta construcción es congruente con la Proposición 6.1: si X_t coincide con el estado informacional previo real, $X_{t,i} = P(H_i)$, entonces $X_{t,i}^E = P(H_i \mid E)$, de modo que el posterior candidato no es solamente un punto del simplex, sino la probabilidad condicional genuina de H_i dada E .

Definición 6.9 (Coeficiente de avance KL). Sea

$$\Pi_H = \{H_1, \dots, H_n\}$$

una partición finita de hipótesis. Para

$$P, Q \in \Delta_n^\circ,$$

se define

$$D_{\text{KL}}(P \parallel Q) := \sum_{i=1}^n P_i \log \frac{P_i}{Q_i}.$$

Sea

$$X_t \in \Delta_n^\circ$$

un estado informacional, sea

$$\mathcal{P} \in \Delta_n^\circ$$

un objetivo bayesiano interior, y supóngase que

$$X_t \neq \mathcal{P}.$$

Sea además

$$\mathcal{E}_t$$

una familia observacional admisible en el tiempo t . Para cada

$$E \in \mathcal{E}_t,$$

sea

$$X_t^E := T_{\ell^{(E)}}(X_t)$$

el posterior candidato inducido por E .

Se define el coeficiente de avance KL de la observación candidata E , relativo al par $(X_t, \mathcal{P})$, por

$$\alpha_{\text{KL}}(E; X_t, \mathcal{P}) := 1 - \frac{D_{\text{KL}}(\mathcal{P} \| X_t^E)}{D_{\text{KL}}(\mathcal{P} \| X_t)}.$$

La interpretación del signo es la siguiente:

$$\alpha_{\text{KL}}(E; X_t, \mathcal{P}) > 0$$

si y sólo si

$$D_{\text{KL}}(\mathcal{P} \| X_t^E) < D_{\text{KL}}(\mathcal{P} \| X_t),$$

es decir, la observación E produce avance hacia $\mathcal{P}$ en divergencia KL.

Asimismo,

$$\alpha_{\text{KL}}(E; X_t, \mathcal{P}) = 0$$

si y sólo si

$$D_{\text{KL}}(\mathcal{P} \| X_t^E) = D_{\text{KL}}(\mathcal{P} \| X_t),$$

es decir, la observación E no produce avance KL.

Finalmente,

$$\alpha_{\text{KL}}(E; X_t, \mathcal{P}) < 0$$

si y sólo si

$$D_{\text{KL}}(\mathcal{P} \| X_t^E) > D_{\text{KL}}(\mathcal{P} \| X_t),$$

es decir, la observación E aleja el posterior candidato del objetivo $\mathcal{P}$ en divergencia KL.

Proposición 6.7 (Elección observacional óptima). Sea

$$\Pi_H = \{H_1, \dots, H_n\}$$

una partición finita de hipótesis. Sean

$$X_t \in \Delta_n^\circ, \quad \mathcal{P} \in \Delta_n^\circ, \quad X_t \neq \mathcal{P}.$$

Sea

$$\mathcal{E}_t$$

una familia observacional admisible finita no vacía en el tiempo t . Para cada

$$E \in \mathcal{E}_t,$$

sea

$$X_t^E := T_{\ell_t^{(E)}}(X_t)$$

el posterior candidato inducido por E .

Entonces una observación

$$E_t^* \in \mathcal{E}_t$$

maximiza el coeficiente de avance KL,

$$E_t^* \in \arg \max_{E \in \mathcal{E}_t} \alpha_{\text{KL}}(E; X_t, \mathcal{P}),$$

si y sólo si minimiza la divergencia KL posterior hacia el objetivo:

$$E_t^* \in \arg \min_{E \in \mathcal{E}_t} D_{\text{KL}}(\mathcal{P} \| X_t^E).$$

Demostración. Como

$$X_t \neq \mathcal{P},$$

y ambos vectores pertenecen a Δ_n° , se tiene

$$D_{\text{KL}}(\mathcal{P} \| X_t) > 0.$$

Por definición del coeficiente de avance KL, para cada

$$E \in \mathcal{E}_t$$

se cumple

$$\alpha_{\text{KL}}(E; X_t, \mathcal{P}) = 1 - \frac{D_{\text{KL}}(\mathcal{P} \| X_t^E)}{D_{\text{KL}}(\mathcal{P} \| X_t)}.$$

El término

$$D_{\text{KL}}(\mathcal{P} \| X_t)$$

no depende de E y es estrictamente positivo. Por tanto, para $E, F \in \mathcal{E}_t$,

$$\alpha_{\text{KL}}(E; X_t, \mathcal{P}) \geq \alpha_{\text{KL}}(F; X_t, \mathcal{P})$$

si y sólo si

$$1 - \frac{D_{\text{KL}}(\mathcal{P} \| X_t^E)}{D_{\text{KL}}(\mathcal{P} \| X_t)} \geq 1 - \frac{D_{\text{KL}}(\mathcal{P} \| X_t^F)}{D_{\text{KL}}(\mathcal{P} \| X_t)}.$$

Restando 1 en ambos lados,

$$-\frac{D_{\text{KL}}(\mathcal{P} \| X_t^E)}{D_{\text{KL}}(\mathcal{P} \| X_t)} \geq -\frac{D_{\text{KL}}(\mathcal{P} \| X_t^F)}{D_{\text{KL}}(\mathcal{P} \| X_t)}.$$

Multiplicando por el número positivo

$$D_{\text{KL}}(\mathcal{P} \| X_t)$$

y cambiando el signo, se obtiene

$$D_{\text{KL}}(\mathcal{P} \| X_t^E) \leq D_{\text{KL}}(\mathcal{P} \| X_t^F).$$

Así, ordenar las observaciones por mayor coeficiente de avance KL es equivalente a ordenarlas por menor divergencia KL posterior.

Como

$$\mathcal{E}_t$$

es finita y no vacía, existen maximizadores y minimizadores. Por la equivalencia anterior, ambos conjuntos coinciden. En consecuencia,

$$E_t^* \in \arg \max_{E \in \mathcal{E}_t} \alpha_{\text{KL}}(E; X_t, \mathcal{P})$$

si y sólo si

$$E_t^* \in \arg \min_{E \in \mathcal{E}_t} D_{\text{KL}}(\mathcal{P} \| X_t^E).$$

□

Definición 6.10 (Trayectoria bayesiana guiada por selección observacional). Sea

$$\Pi_H = \{H_1, \dots, H_n\}$$

una partición finita de hipótesis, y sea

$$\mathcal{P} \in \Delta_n^\circ$$

un objetivo bayesiano interior sobre Π_H . Sea

$$X_0 \in \Delta_n^\circ$$

un estado inicial.

Para cada tiempo

$$t \geq 0,$$

supóngase dada una familia observacional admisible finita no vacía

$$\mathcal{E}_t \subseteq \Pi_E.$$

La trayectoria bayesiana guiada por selección observacional se define recursivamente del siguiente modo.

Si

$$X_t = \mathcal{P},$$

se fija

$$X_{t+1} := \mathcal{P}.$$

Si

$$X_t \neq \mathcal{P},$$

para cada

$$E \in \mathcal{E}_t$$

se considera el posterior candidato

$$X_t^E = T_{\ell_t^{(E)}}(X_t),$$

y se elige una observación

$$E_t^* \in \mathcal{E}_t$$

tal que

$$E_t^* \in \arg \min_{E \in \mathcal{E}_t} D_{\text{KL}}(\mathcal{P} \| X_t^E).$$

Entonces se define

$$X_{t+1} := T_{\ell_t^{(E_t^*)}}(X_t).$$

Equivalente, mientras $X_t \neq \mathcal{P}$, la regla de evolución queda dada por

$$X_{t+1} = X_t^{E_t^*},$$

donde

$$E_t^* \in \arg \min_{E \in \mathcal{E}_t} D_{\text{KL}}(\mathcal{P} \| X_t^E).$$

Así, cada paso de la trayectoria se obtiene por una actualización bayesiana global, y la observación aplicada en el tiempo t es aquella que produce, entre los candidatos admisibles, el posterior más cercano al objetivo bayesiano $\mathcal{P}$ en divergencia KL.

Proposición 6.8 (Disipación y convergencia bajo progreso acumulado). Sea

$$\mathcal{P} \in \Delta_n^\circ$$

un objetivo bayesiano interior, y sea

$$(X_t)_{t \geq 0} \subset \Delta_n^\circ$$

una trayectoria bayesiana guiada por selección observacional.

Para cada $t \geq 0$ tal que

$$X_t \neq \mathcal{P},$$

denótese por

$$E_t^* \in \mathcal{E}_t$$

una observación óptima seleccionada según la regla

$$E_t^* \in \arg \min_{E \in \mathcal{E}_t} D_{\text{KL}}(\mathcal{P} \| X_t^E),$$

y escribase

$$X_{t+1} = T_{\ell_t^{(E_t^*)}}(X_t).$$

Supóngase que existe una sucesión

$$(\eta_t)_{t \geq 0} \subset [0, 1]$$

tal que, para todo $t \geq 0$ con $X_t \neq \mathcal{P}$,

$$\alpha_{\text{KL}}(E_t^*; X_t, \mathcal{P}) \geq \eta_t,$$

y además

$$\prod_{t=0}^{\infty} (1 - \eta_t) = 0.$$

Entonces

$$D_{\text{KL}}(\mathcal{P} \| X_t) \longrightarrow 0.$$

En consecuencia,

$$X_t \longrightarrow \mathcal{P}.$$

Demostración. Defínase

$$D_t := D_{\text{KL}}(\mathcal{P} \| X_t).$$

Si existe $t_0 \geq 0$ tal que

$$X_{t_0} = \mathcal{P},$$

entonces, por definición de la trayectoria,

$$X_t = \mathcal{P} \quad \text{para todo } t \geq t_0.$$

Por tanto,

$$D_t = 0 \quad \text{para todo } t \geq t_0,$$

y la conclusión queda probada.

Supóngase entonces que

$$X_t \neq \mathcal{P} \quad \text{para todo } t \geq 0.$$

Como $\mathcal{P}, X_t \in \Delta_n^\circ$, se tiene

$$D_t > 0 \quad \text{para todo } t \geq 0.$$

Por definición del coeficiente de avance KL,

$$\alpha_{\text{KL}}(E_t^*; X_t, \mathcal{P}) = 1 - \frac{D_{\text{KL}}(\mathcal{P} \| X_{t+1})}{D_{\text{KL}}(\mathcal{P} \| X_t)}.$$

Con la notación $D_t = D_{\text{KL}}(\mathcal{P} \| X_t)$, esto equivale a

$$\alpha_{\text{KL}}(E_t^*; X_t, \mathcal{P}) = 1 - \frac{D_{t+1}}{D_t}.$$

Luego

$$D_{t+1} = (1 - \alpha_{\text{KL}}(E_t^*; X_t, \mathcal{P})) D_t.$$

Por hipótesis,

$$\alpha_{\text{KL}}(E_t^*; X_t, \mathcal{P}) \geq \eta_t.$$

Como $\eta_t \in [0, 1]$, se obtiene

$$1 - \alpha_{\text{KL}}(E_t^*; X_t, \mathcal{P}) \leq 1 - \eta_t.$$

Por tanto,

$$D_{t+1} \leq (1 - \eta_t) D_t.$$

Iterando esta desigualdad desde 0 hasta $t - 1$, se obtiene

$$D_t \leq \left(\prod_{s=0}^{t-1} (1 - \eta_s) \right) D_0.$$

Como

$$\prod_{s=0}^{\infty} (1 - \eta_s) = 0,$$

se sigue que

$$\prod_{s=0}^{t-1} (1 - \eta_s) \longrightarrow 0.$$

En consecuencia,

$$D_t \longrightarrow 0.$$

Es decir,

$$D_{\text{KL}}(\mathcal{P} \| X_t) \longrightarrow 0.$$

Finalmente, por la desigualdad de Pinsker,

$$\|\mathcal{P} - X_t\|_1^2 \leq 2D_{\text{KL}}(\mathcal{P} \| X_t).$$

Como el lado derecho converge a 0, se obtiene

$$\|\mathcal{P} - X_t\|_1 \longrightarrow 0.$$

Por tanto,

$$X_t \longrightarrow \mathcal{P}.$$

□

Ejercicio 6.1 (Priorización secuencial de pruebas para la confirmación de un patógeno causante de un brote). **Contexto**

Un brote respiratorio puede deberse a tres patógenos candidatos, $\Pi_H = \{H_1, H_2, H_3\}$, correspondientes a los patógenos α , β y γ . El estado $X_t \in \Delta_3^\circ$ no representa la verdad biológica sobre la causa del brote, sino el estado de creencia institucional del equipo de vigilancia, actualizado con la evidencia de laboratorio disponible.

Estado previo

La vigilancia histórica fija el estado previo

$$X_0 = (0,50, 0,30, 0,20) \in \Delta_3^\circ.$$

Pruebas disponibles

El laboratorio puede aplicar una sola prueba por día, y el menú disponible cambia según el suministro de reactivos. El universo de pruebas es $\Pi_E = \{\text{I}, \text{II}, \text{III}\}$, cada una caracterizada por estudios de validación previos (sensibilidad frente al patógeno objetivo, reactividad cruzada frente a los otros dos):

$$\ell^{(\text{I})} = (0,8, 0,1, 0,1), \quad \ell^{(\text{II})} = (0,6, 0,3, 0,3), \quad \ell^{(\text{III})} = (0,5, 0,5, 0,1).$$

Disponibilidad diaria

El día 0: $\mathcal{E}_0 = \{I, II\}$. El día 1: se agota el reactivo de I y llega III, $\mathcal{E}_1 = \{II, III\}$.

Criterio de decisión

Sin protocolo estandarizado para ordenar las pruebas, el equipo fija un objetivo interno $\mathcal{P} = (0,96, 0,02, 0,02)$ y aplica cada día la prueba que más reduce

$$D_{KL}(\mathcal{P} \| X_t).$$

Cuando

$$D_{KL}(\mathcal{P} \| X_t) < \delta = 0,01,$$

se prioriza H_1 para remisión a confirmación de referencia.

Pregunta

¿Qué prueba se aplica cada día, cuál es la trayectoria (X_0, X_1, X_2) , y se alcanza el umbral al final del día 1?

Solución. Respuesta

$$E_0^* = I, X_1 = (8/9, 1/15, 2/45) \approx (0,8889, 0,0667, 0,0444), D_{KL}(\mathcal{P} \| X_1) \approx 0,0338.$$

$$E_1^* = II, X_2 = (16/17, 3/85, 2/85) \approx (0,9412, 0,0353, 0,0235), D_{KL}(\mathcal{P} \| X_2) \approx 0,0044 < \delta;$$

H_1 alcanza el umbral al final del día 1.

Verosimilitud ideal

Por el Corolario de realización bayesiana del paso discreto determinista, llegar a $\mathcal{P}$ en un solo paso desde X_0 exigiría la verosimilitud ideal $\ell^{(1)}(X_0, \mathcal{P})_i = \mathcal{P}_i / X_{0,i}$:

$$\ell^{(1)}(X_0, \mathcal{P}) = \left(\frac{0,96}{0,5}, \frac{0,02}{0,3}, \frac{0,02}{0,2} \right) = (1,92, 0,0667, 0,1).$$

Esto no coincide con $\ell^{(I)}$ ni con $\ell^{(II)}$: el salto directo no es admisible en $\mathcal{E}_0$, así que se procede por selección observacional.

Día 0

Con $\mathcal{E}_0 = \{I, II\}$:

$$X_0 \circ \ell^{(I)} = (0,40, 0,03, 0,02), \Sigma = 0,45 \Rightarrow X_0^I = \left(\frac{8}{9}, \frac{1}{15}, \frac{2}{45} \right) \approx (0,8889, 0,0667, 0,0444);$$

$$X_0 \circ \ell^{(II)} = (0,30, 0,09, 0,06), \Sigma = 0,45 \Rightarrow X_0^{II} = \left(\frac{2}{3}, \frac{1}{5}, \frac{2}{15} \right) \approx (0,6667, 0,2, 0,1333).$$

$$D_{KL}(\mathcal{P} \| X_0) = 0,96 \ln(1,92) + 0,02 \ln(0,0667) + 0,02 \ln(0,1) = 0,6262 - 0,0542 - 0,0461 = 0,5260.$$

$$D_{KL}(\mathcal{P} \| X_0^I) = 0,96 \ln(1,08) + 0,02 \ln(0,30) + 0,02 \ln(0,45) = 0,0739 - 0,0241 - 0,0160 = 0,0338.$$

$$D_{KL}(\mathcal{P} \| X_0^{II}) = 0,96 \ln(1,44) + 0,02 \ln(0,10) + 0,02 \ln(0,15) = 0,3501 - 0,0461 - 0,0379 = 0,2661.$$

$$\alpha_{KL}(I) = 1 - \frac{0,0338}{0,5260} = 0,9357, \quad \alpha_{KL}(II) = 1 - \frac{0,2661}{0,5260} = 0,4942.$$

$$E_0^* = I. X_1 := X_0^I = \left(\frac{8}{9}, \frac{1}{15}, \frac{2}{45} \right).$$

Día 1

Con $\mathcal{E}_1 = \{\text{II}, \text{III}\}$:

$$X_1 \circ \ell^{(\text{II})} = \left(\frac{8}{15}, \frac{1}{50}, \frac{1}{75} \right), \quad \Sigma = \frac{17}{30} \Rightarrow X_1^{\text{II}} = \left(\frac{16}{17}, \frac{3}{85}, \frac{2}{85} \right) \approx (0,9412, 0,0353, 0,0235);$$

$$X_1 \circ \ell^{(\text{III})} = \left(\frac{4}{9}, \frac{1}{30}, \frac{1}{225} \right), \quad \Sigma = \frac{217}{450} \Rightarrow X_1^{\text{III}} = \left(\frac{200}{217}, \frac{15}{217}, \frac{2}{217} \right) \approx (0,9217, 0,0691, 0,0092).$$

$$D_{\text{KL}}(\mathcal{P} \| X_1) = 0,0338 \text{ (ya calculada).}$$

$$D_{\text{KL}}(\mathcal{P} \| X_1^{\text{II}}) = 0,96 \ln(1,02) + 0,02 \ln(0,5667) + 0,02 \ln(0,85) = 0,0190 - 0,0114 - 0,0033 = 0,0044.$$

$$D_{\text{KL}}(\mathcal{P} \| X_1^{\text{III}}) = 0,96 \ln(1,0416) + 0,02 \ln(0,2893) + 0,02 \ln(2,17) = 0,0391 - 0,0248 + 0,0155 = 0,0298.$$

$$\alpha_{\text{KL}}(\text{II}) = 1 - \frac{0,0044}{0,0338} = 0,8699, \quad \alpha_{\text{KL}}(\text{III}) = 1 - \frac{0,0298}{0,0338} = 0,1187.$$

$E_1^* = \text{II}$ ($\ell_1^{(\text{III})} = \ell_2^{(\text{III})}$ no separa H_1 de H_2). $X_2 := X_1^{\text{II}} \approx (0,9412, 0,0353, 0,0235)$, $D_{\text{KL}}(\mathcal{P} \| X_2) \approx 0,0044 < \delta$.

Contraste: selección pasiva

Aplicando II el día 0 y III el día 1 sin comparar: $X_0^{\text{II}} = (2/3, 1/5, 2/15)$; luego $X_0^{\text{II}} \circ \ell^{(\text{III})} = (1/3, 1/10, 1/75)$, $\Sigma = 67/150$, da $X_2^{\text{pasiva}} = (50/67, 15/67, 2/67) \approx (0,7463, 0,2239, 0,0299)$, con $D_{\text{KL}}(\mathcal{P} \| X_2^{\text{pasiva}}) \approx 0,1855$: 42 veces más lejos del umbral. La prueba I solo estuvo disponible el día 0; no priorizarla cuesta la oportunidad.

Convergencia

El salto de un solo paso (Corolario, $\alpha = 1$) no era admisible; en su lugar, $\alpha_{\text{KL}}(E_0^*) = 0,9357 \geq 0,85$ y $\alpha_{\text{KL}}(E_1^*) = 0,8699 \geq 0,85$. Con $\eta_t = 0,85$, $\prod_t (1 - \eta_t) = \lim 0,15^t = 0$: el resultado de disipación y convergencia garantiza $X_t \rightarrow \mathcal{P}$ aunque el umbral no se alcance tan rápido en otra realización del proceso. $\square$

7. Sección F — Semántica markoviana

Las Secciones B–E establecieron el marco de CI y su semántica bayesiana. Esta sección identifica, dentro del mismo marco, el caso particular que corresponde al operador de Markov clásico. El resultado estructural central es que las cadenas de Markov entran en CI a través de la Sección B (correcciones locales dependientes del estado), mientras que la actualización bayesiana entra por la Sección C (correcciones globales independientes del estado). Esta asimetría algebraica es la que hace no trivial el problema de ordenamiento del Proyecto II.

Definición 7.1 (Base discreta). Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sea

$$\Pi = \{A_1, \dots, A_n\}$$

una partición medible finita de Ω tal que

$$P(A_i) > 0, \quad i = 1, \dots, n.$$

Identificamos cada celda A_i con el índice i , y escribimos

$$I := \{1, \dots, n\}.$$

Un estado discreto sobre Π es un vector fila

$$X = (X_1, \dots, X_n) \in \Delta_n,$$

donde X_i representa la masa asignada a la celda A_i .

Lema 7.1 (Distribución inducida por una partición finita). Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sea

$$\Pi = \{A_1, \dots, A_n\}$$

una partición medible finita de Ω tal que

$$P(A_i) > 0, \quad i = 1, \dots, n.$$

Defínase

$$X^P = (X_1^P, \dots, X_n^P), \quad X_i^P := P(A_i).$$

Entonces

$$X^P \in \Delta_n^\circ.$$

Demostración. Para cada $i = 1, \dots, n$, por hipótesis,

$$X_i^P = P(A_i) > 0.$$

Además, como Π es una partición de Ω , los conjuntos $A_1, \dots, A_n$ son disjuntos y satisfacen

$$\bigcup_{i=1}^n A_i = \Omega.$$

Por aditividad finita de P ,

$$\sum_{i=1}^n X_i^P = \sum_{i=1}^n P(A_i) = P\left(\bigcup_{i=1}^n A_i\right) = P(\Omega) = 1.$$

Por tanto,

$$X_i^P > 0 \quad (i = 1, \dots, n), \quad \sum_{i=1}^n X_i^P = 1,$$

y en consecuencia

$$X^P \in \Delta_n^\circ.$$

□

Definición 7.2 (Matrices estocásticas por filas). Sea $n \in \mathbb{N}$ y sea

$$I := \{1, \dots, n\}.$$

Se denota por $\mathcal{S}_n$ el conjunto de matrices estocásticas por filas de orden n :

$$\mathcal{S}_n := \left\{ K = (K_{ab})_{a,b=1}^n \in \mathbb{R}^{n \times n} : K_{ab} \geq 0 \ \forall a, b \in I, \quad \sum_{b=1}^n K_{ab} = 1 \ \forall a \in I \right\}.$$

Para $K \in \mathcal{S}_n$, el operador markoviano asociado es

$$M_K : \Delta_n \longrightarrow \mathbb{R}^n, \quad M_K(X) := XK,$$

donde X se considera vector fila y el producto es el producto matricial usual.

Observación 7.1 (Lectura markoviana). Si $K \in \mathcal{S}_n$, entonces para cada $a \in I$ la fila

$$(K_{a1}, \dots, K_{an})$$

es una distribución de probabilidad discreta sobre I . El número K_{ab} se interpreta como la fracción de masa que, en un paso markoviano, se transporta desde el estado a hacia el estado b .

Esta lectura sólo usa la base discreta $I = \{1, \dots, n\}$. En particular, si más adelante una partición de hipótesis se identifica con una base discreta, el mismo operador M_K podrá actuar sobre el simplex asociado a dicha partición.

Proposición 7.1 (El simplex es invariante bajo matrices estocásticas por filas). Sea $K \in \mathcal{S}_n$ y sea $X \in \Delta_n$. Entonces

$$M_K(X) = XK \in \Delta_n.$$

En particular,

$$M_K : \Delta_n \longrightarrow \Delta_n$$

está bien definido.

Demostración. Para cada $b = 1, \dots, n$,

$$(M_K(X))_b = (XK)_b = \sum_{a=1}^n X_a K_{ab}.$$

Como

$$X_a \geq 0 \quad \text{y} \quad K_{ab} \geq 0,$$

se tiene

$$(M_K(X))_b \geq 0.$$

Además,

$$\sum_{b=1}^n (M_K(X))_b = \sum_{b=1}^n \sum_{a=1}^n X_a K_{ab} = \sum_{a=1}^n X_a \sum_{b=1}^n K_{ab}.$$

Como $K \in \mathcal{S}_n$,

$$\sum_{b=1}^n K_{ab} = 1 \quad \text{para todo } a.$$

Luego

$$\sum_{b=1}^n (M_K(X))_b = \sum_{a=1}^n X_a = 1.$$

Por tanto,

$$M_K(X) \in \Delta_n.$$

□

Observación 7.2 (Interior del símplex y dominio de las correcciones locales). *La Proposición 7.1 garantiza*

$$M_K(\Delta_n) \subseteq \Delta_n,$$

pero no garantiza, en general,

$$M_K(\Delta_n^\circ) \subseteq \Delta_n^\circ.$$

Para preservar el interior basta imponer que ninguna columna de K sea nula, es decir, que para cada $b \in I$ exista al menos un $a \in I$ tal que

$$K_{ab} > 0.$$

Esta es precisamente la condición de compatibilidad con el interior del símplex. La condición más fuerte

$$K_{ab} > 0 \quad \forall a, b \in I$$

también preserva el interior, pero no es necesaria.

La corrección local asociada a un paso markoviano se escribirá mediante cocientes de la forma

$$\frac{(XK)_i}{X_i}.$$

Por ello, para definir dicha corrección local se requiere

$$X \in \Delta_n^\circ.$$

Si además se desea que el estado transformado permanezca en Δ_n° , se impondrá explícitamente la compatibilidad de K con el interior del símplex.

Proposición 7.2 (Representación local de un paso markoviano). *Sea $K \in \mathcal{S}_n$ y sea $X \in \Delta_n^\circ$. Defínase*

$$Y_i^K(X) := \frac{(M_K(X))_i}{X_i} - 1, \quad i = 1, \dots, n.$$

Entonces

$$Y^K(X) \in C(X)$$

y

$$T_{Y^K(X)}^{\text{loc}}(X) = M_K(X) = XK.$$

Demostración. Como $X \in \Delta_n^\circ$, se tiene

$$X_i > 0, \quad i = 1, \dots, n.$$

Por tanto, los cocientes

$$\frac{(M_K(X))_i}{X_i}$$

están bien definidos.

Para cada $i = 1, \dots, n$,

$$1 + Y_i^K(X) = \frac{(M_K(X))_i}{X_i}.$$

Multiplicando por X_i , se obtiene

$$X_i(1 + Y_i^K(X)) = (M_K(X))_i.$$

Por la Proposición 7.1,

$$M_K(X) \in \Delta_n.$$

En consecuencia,

$$X_i(1 + Y_i^K(X)) \geq 0 \quad \text{para todo } i,$$

y

$$\sum_{i=1}^n X_i(1 + Y_i^K(X)) = \sum_{i=1}^n (M_K(X))_i = 1.$$

Por definición de $C(X)$,

$$Y^K(X) \in C(X).$$

Además, por definición del operador local,

$$T_{Y^K(X)}^{\text{loc}}(X)_i = X_i(1 + Y_i^K(X)) = (M_K(X))_i.$$

Como esto vale para todo $i = 1, \dots, n$, se concluye que

$$T_{Y^K(X)}^{\text{loc}}(X) = M_K(X) = XK.$$

□

Proposición 7.3 (No globalidad de un operador markoviano no trivial). *Sea $K \in \mathcal{S}_n$. Supóngase que existe un vector*

$$a = (a_1, \dots, a_n) \in \mathbb{R}_{>0}^n$$

tal que

$$T_a(X) = M_K(X) \quad \text{para todo } X \in \Delta_n^\circ,$$

donde

$$T_a(X)_i = \frac{X_i a_i}{\sum_{k=1}^n X_k a_k}.$$

Entonces

$$K = I.$$

En consecuencia, si $K \neq I$, el operador markoviano M_K no puede representarse como un operador global con factor multiplicativo independiente de X .

Demostración. Sea $r \in I$. Tomemos una sucesión

$$(X^{(m)})_{m \geq 1} \subset \Delta_n^\circ$$

tal que

$$X^{(m)} \rightarrow e_r,$$

donde e_r denota el r -ésimo vector canónico.

Por hipótesis,

$$T_a(X^{(m)}) = M_K(X^{(m)}) = X^{(m)}K \quad \text{para todo } m.$$

Para cada $i = 1, \dots, n$,

$$T_a(X^{(m)})_i = \frac{X_i^{(m)}a_i}{\sum_{k=1}^n X_k^{(m)}a_k}.$$

Como $X^{(m)} \rightarrow e_r$, se tiene

$$\sum_{k=1}^n X_k^{(m)}a_k \rightarrow a_r > 0.$$

Además,

$$X_r^{(m)}a_r \rightarrow a_r, \quad X_i^{(m)}a_i \rightarrow 0 \quad (i \neq r).$$

Por tanto,

$$T_a(X^{(m)}) \rightarrow e_r.$$

Por otro lado, como $X \mapsto XK$ es lineal,

$$X^{(m)}K \rightarrow e_rK.$$

Al pasar al límite en

$$T_a(X^{(m)}) = X^{(m)}K,$$

se obtiene

$$e_r = e_rK.$$

Esto significa que la fila r -ésima de K coincide con e_r .

Como $r \in I$ fue arbitrario, todas las filas de K coinciden con las filas correspondientes de la matriz identidad. En consecuencia,

$$K = I.$$

Por tanto, si $K \neq I$, no existe un vector $a \in \mathbb{R}_{>0}^n$ tal que

$$T_a(X) = M_K(X) \quad \text{para todo } X \in \Delta_n^\circ.$$

□

Observación 7.3 (Local frente a global). *La corrección $Y^K(X)$ depende del estado base X . Por tanto, el paso markoviano entra en el formalismo como una corrección local. En cambio, la verosimilitud bayesiana actúa mediante un factor multiplicativo positivo que no depende del estado base; por ello entra como corrección global.*

En términos estructurales, el operador markoviano mezcla coordenadas mediante una matriz estocástica por filas:

$$X \mapsto XK.$$

El operador bayesiano reescala coordenadas por factores positivos y normaliza:

$$X_i \mapsto \frac{X_i \ell_i}{\sum_{k=1}^n X_k \ell_k}.$$

Esta diferencia algebraica es la que permite formular posteriormente el problema de conmutación entre el paso markoviano y la actualización bayesiana.

Definición 7.3 (Distribución estacionaria). Sea $K \in \mathcal{S}_n$. Una distribución $\pi \in \Delta_n^\circ$ se llama estacionaria para K si

$$\pi K = \pi.$$

Equivalente, en términos del operador markoviano M_K , esto significa que

$$M_K(\pi) = \pi.$$

Observación 7.4 (Estacionariedad y corrección local nula). Sea $K \in \mathcal{S}_n$ y sea $\pi \in \Delta_n^\circ$. Entonces π es estacionaria para K si y sólo si

$$Y^K(\pi) = 0.$$

En efecto, para cada $i = 1, \dots, n$,

$$Y_i^K(\pi) = \frac{(M_K(\pi))_i}{\pi_i} - 1 = \frac{(\pi K)_i}{\pi_i} - 1.$$

Como $\pi_i > 0$, se tiene

$$Y_i^K(\pi) = 0 \iff (\pi K)_i = \pi_i.$$

Por tanto,

$$Y^K(\pi) = 0 \iff \pi K = \pi.$$

Así, en el lenguaje local de CI, una distribución estacionaria es un estado cuya corrección markoviana local es nula.

Lema 7.2 (Estacionariedad positiva y compatibilidad con el interior). Sea $K \in \mathcal{S}_n$. Supóngase que existe una distribución estacionaria

$$\pi \in \Delta_n^\circ$$

para K , es decir,

$$\pi K = \pi.$$

Entonces K es compatible con el interior del símplex. En consecuencia,

$$M_K(\Delta_n^\circ) \subseteq \Delta_n^\circ.$$

Demostración. Sea $b \in I$. Como π es estacionaria para K , se tiene

$$\pi K = \pi.$$

Por tanto,

$$\pi_b = (\pi K)_b = \sum_{a=1}^n \pi_a K_{ab}.$$

Como $\pi \in \Delta_n^\circ$, se tiene

$$\pi_b > 0 \quad \text{y} \quad \pi_a > 0 \quad \text{para todo } a \in I.$$

Además, como $K \in \mathcal{S}_n$,

$$K_{ab} \geq 0 \quad \text{para todo } a, b \in I.$$

Si se tuviera

$$K_{ab} = 0 \quad \text{para todo } a \in I,$$

entonces

$$\sum_{a=1}^n \pi_a K_{ab} = 0,$$

lo cual contradice que

$$\pi_b = \sum_{a=1}^n \pi_a K_{ab} > 0.$$

Por tanto, existe al menos un $a \in I$ tal que

$$K_{ab} > 0.$$

Como $b \in I$ fue arbitrario, para cada $b \in I$ existe al menos un $a \in I$ tal que

$$K_{ab} > 0.$$

Así, K es compatible con el interior del símplex.

La inclusión

$$M_K(\Delta_n^\circ) \subseteq \Delta_n^\circ$$

se sigue de la Proposición ??.

□

Proposición 7.4 (Disipación de la divergencia KL hacia la estacionaria). *Sea $K \in \mathcal{S}_n$ y sea $\pi \in \Delta_n^\circ$ una distribución estacionaria para K , es decir,*

$$\pi K = \pi.$$

Defínase

$$E_\pi(X) := D_{\text{KL}}(\pi \| X), \quad X \in \Delta_n^\circ.$$

Entonces, para todo $X \in \Delta_n^\circ$,

$$E_\pi(M_K(X)) = D_{\text{KL}}(\pi \| XK) \leq D_{\text{KL}}(\pi \| X) = E_\pi(X).$$

En particular, un paso markoviano no incrementa la divergencia KL hacia la distribución estacionaria.

Demostración. Sea $X \in \Delta_n^\circ$. Como $\pi \in \Delta_n^\circ$ es estacionaria para K , por el Lema 7.2 se tiene

$$M_K(X) = XK \in \Delta_n^\circ.$$

Por tanto,

$$D_{\text{KL}}(\pi \| XK)$$

está bien definida.

Como $\pi K = \pi$, para cada $j = 1, \dots, n$,

$$\pi_j = (\pi K)_j = \sum_{i=1}^n \pi_i K_{ij}.$$

Además,

$$(XK)_j = \sum_{i=1}^n X_i K_{ij}.$$

Entonces

$$D_{\text{KL}}(\pi \| XK) = \sum_{j=1}^n \pi_j \log \frac{\pi_j}{(XK)_j}.$$

Fijemos $j \in I$. Como $\pi_j > 0$, definimos

$$w_{ij} := \frac{\pi_i K_{ij}}{\pi_j}, \quad i = 1, \dots, n.$$

Entonces

$$w_{ij} \geq 0,$$

y, usando $\pi_j = \sum_i \pi_i K_{ij}$,

$$\sum_{i=1}^n w_{ij} = \frac{1}{\pi_j} \sum_{i=1}^n \pi_i K_{ij} = 1.$$

Además,

$$(XK)_j = \sum_{i=1}^n X_i K_{ij} = \sum_{i=1}^n \pi_i K_{ij} \frac{X_i}{\pi_i} = \pi_j \sum_{i=1}^n w_{ij} \frac{X_i}{\pi_i}.$$

Por tanto,

$$\frac{\pi_j}{(XK)_j} = \left(\sum_{i=1}^n w_{ij} \frac{X_i}{\pi_i} \right)^{-1}.$$

Luego

$$\log \frac{\pi_j}{(XK)_j} = -\log \left(\sum_{i=1}^n w_{ij} \frac{X_i}{\pi_i} \right).$$

Como la función $u \mapsto -\log u$ es convexa en $(0, \infty)$, por la desigualdad de Jensen se obtiene

$$-\log \left(\sum_{i=1}^n w_{ij} \frac{X_i}{\pi_i} \right) \leq \sum_{i=1}^n w_{ij} \left(-\log \frac{X_i}{\pi_i} \right).$$

Es decir,

$$\log \frac{\pi_j}{(XK)_j} \leq \sum_{i=1}^n w_{ij} \log \frac{\pi_i}{X_i}.$$

Multiplicando por π_j ,

$$\pi_j \log \frac{\pi_j}{(XK)_j} \leq \sum_{i=1}^n \pi_i K_{ij} \log \frac{\pi_i}{X_i}.$$

Sumando en j , se obtiene

$$D_{\text{KL}}(\pi \| XK) = \sum_{j=1}^n \pi_j \log \frac{\pi_j}{(XK)_j} \leq \sum_{j=1}^n \sum_{i=1}^n \pi_i K_{ij} \log \frac{\pi_i}{X_i}.$$

Como las sumas son finitas,

$$\sum_{j=1}^n \sum_{i=1}^n \pi_i K_{ij} \log \frac{\pi_i}{X_i} = \sum_{i=1}^n \pi_i \log \frac{\pi_i}{X_i} \sum_{j=1}^n K_{ij}.$$

Como $K \in \mathcal{S}_n$,

$$\sum_{j=1}^n K_{ij} = 1 \quad \text{para todo } i.$$

Por tanto,

$$D_{\text{KL}}(\pi \| XK) \leq \sum_{i=1}^n \pi_i \log \frac{\pi_i}{X_i} = D_{\text{KL}}(\pi \| X).$$

En consecuencia,

$$E_\pi(M_K(X)) \leq E_\pi(X).$$

□

Proposición 7.5 (Trayectoria markoviana como trayectoria local de CI). *Sea $K \in \mathcal{S}_n$ y sea $X_0 \in \Delta_n$. Defínase la trayectoria discreta*

$$X_{t+1} := M_K(X_t) = X_t K, \quad t \geq 0.$$

Entonces

$$X_t \in \Delta_n \quad \text{para todo } t \geq 0,$$

y

$$X_t = X_0 K^t \quad \text{para todo } t \geq 0.$$

Además, si $X_t \in \Delta_n^\circ$, entonces el paso $X_t \mapsto X_{t+1}$ admite la representación local

$$X_{t+1} = T_{Y^K(X_t)}^{\log}(X_t).$$

En particular, si $X_0 \in \Delta_n^\circ$ y K es compatible con el interior del simplex, entonces

$$X_t \in \Delta_n^\circ \quad \text{para todo } t \geq 0,$$

y cada paso de la trayectoria es una corrección local de CI.

Demostración. Primero probamos que $X_t \in \Delta_n$ para todo $t \geq 0$. Para $t = 0$, esto se cumple por hipótesis, pues

$$X_0 \in \Delta_n.$$

Supóngase ahora que

$$X_t \in \Delta_n.$$

Como $K \in \mathcal{S}_n$, por la Proposición 7.1 se tiene

$$M_K(X_t) = X_t K \in \Delta_n.$$

Por definición de la trayectoria,

$$X_{t+1} = X_t K,$$

luego

$$X_{t+1} \in \Delta_n.$$

Por inducción,

$$X_t \in \Delta_n \quad \text{para todo } t \geq 0.$$

Probamos ahora la forma cerrada. Para $t = 0$,

$$X_0 = X_0 K^0.$$

Supóngase que

$$X_t = X_0 K^t.$$

Entonces

$$X_{t+1} = X_t K = (X_0 K^t) K = X_0 K^{t+1}.$$

Por inducción,

$$X_t = X_0 K^t \quad \text{para todo } t \geq 0.$$

Si $X_t \in \Delta_n^\circ$, entonces, por la Proposición 7.2,

$$M_K(X_t) = T_{Y^K(X_t)}^{\text{loc}}(X_t).$$

Como

$$X_{t+1} = M_K(X_t),$$

se obtiene

$$X_{t+1} = T_{Y^K(X_t)}^{\text{loc}}(X_t).$$

Finalmente, supóngase que $X_0 \in \Delta_n^\circ$ y que K es compatible con el interior del simplex. Por la Proposición ??,

$$M_K(\Delta_n^\circ) \subseteq \Delta_n^\circ.$$

Como $X_0 \in \Delta_n^\circ$, se sigue por inducción que

$$X_t \in \Delta_n^\circ \quad \text{para todo } t \geq 0.$$

Por lo demostrado en el párrafo anterior, cada paso de la trayectoria admite la representación local

$$X_{t+1} = T_{Y^K(X_t)}^{\text{loc}}(X_t).$$

□

Observación 7.5 (Primitividad y convergencia a equilibrio). *La disipación de la divergencia KL hacia una distribución estacionaria no implica, por sí sola, la convergencia de la trayectoria markoviana hacia dicha distribución. Para obtener convergencia se requiere una hipótesis dinámica adicional sobre la matriz de transición.*

Una condición suficiente estándar es la primitividad: se dirá que $K \in \mathcal{S}_n$ es primitiva si existe $m \geq 1$ tal que

$$(K^m)_{ij} > 0 \quad \text{para todo } i, j \in I.$$

Bajo esta hipótesis, el teorema de Perron–Frobenius para matrices estocásticas finitas garantiza la existencia de una única distribución estacionaria

$$\pi \in \Delta_n^\circ$$

y la convergencia

$$K^t \longrightarrow \mathbf{1}\pi, \quad t \rightarrow \infty,$$

donde $\mathbf{1}\pi$ denota la matriz cuyas filas son todas iguales a π .

En consecuencia, si $X_0 \in \Delta_n$, entonces

$$X_0 K^t \longrightarrow X_0(\mathbf{1}\pi) = \pi.$$

La proposición siguiente incorpora esta convergencia al lenguaje de trayectorias informacionales.

Proposición 7.6 (Convergencia hacia la estacionaria bajo primitividad). Sea $K \in \mathcal{S}_n$ una matriz primitiva, es decir, supóngase que existe $m \geq 1$ tal que

$$(K^m)_{ij} > 0 \quad \text{para todo } i, j \in I.$$

Entonces existe una única distribución estacionaria

$$\pi \in \Delta_n^\circ$$

para K .

Sea $X_0 \in \Delta_n^\circ$ y defínase la trayectoria markoviana

$$X_{t+1} := M_K(X_t) = X_t K, \quad t \geq 0.$$

Entonces

$$X_t \longrightarrow \pi \quad \text{cuando } t \rightarrow \infty.$$

Además, si

$$E_\pi(X) := D_{\text{KL}}(\pi \| X),$$

entonces

$$E_\pi(X_{t+1}) \leq E_\pi(X_t) \quad \text{para todo } t \geq 0,$$

y

$$\lim_{t \rightarrow \infty} E_\pi(X_t) = 0.$$

Demostración. Como K es primitiva, por la Observación 7.5 existe una única distribución estacionaria

$$\pi \in \Delta_n^\circ$$

y se tiene

$$K^t \longrightarrow \mathbf{1}\pi.$$

Por la Proposición 7.5, la trayectoria satisface

$$X_t = X_0 K^t \quad \text{para todo } t \geq 0.$$

Por tanto,

$$X_t = X_0 K^t \longrightarrow X_0(\mathbf{1}\pi).$$

Como $X_0 \in \Delta_n$, se tiene

$$\sum_{i=1}^n X_{0,i} = 1.$$

Luego

$$X_0(\mathbf{1}\pi) = \left(\sum_{i=1}^n X_{0,i} \right) \pi = \pi.$$

Así,

$$X_t \longrightarrow \pi.$$

Ahora, como $\pi \in \Delta_n^\circ$ es estacionaria para K , por la Proposición 7.4 se tiene, para todo $t \geq 0$,

$$D_{\text{KL}}(\pi \| X_{t+1}) = D_{\text{KL}}(\pi \| X_t K) \leq D_{\text{KL}}(\pi \| X_t).$$

Es decir,

$$E_\pi(X_{t+1}) \leq E_\pi(X_t).$$

Finalmente, como $X_t \rightarrow \pi$ y $X_t \in \Delta_n^\circ$ para todo $t \geq 0$, por continuidad de la divergencia KL en el interior del símplex se obtiene

$$\lim_{t \rightarrow \infty} E_\pi(X_t) = \lim_{t \rightarrow \infty} D_{\text{KL}}(\pi \| X_t) = D_{\text{KL}}(\pi \| \pi) = 0.$$

□

Referencias

John Aitchison. *The Statistical Analysis of Compositional Data*. Chapman and Hall, London, 1986. Reprinted in 2003.

Andrei Nikolaevich Kolmogorov. *Grundbegriffe der Wahrscheinlichkeitsrechnung*. Springer, Berlin, 1933. English translation: *Foundations of the Theory of Probability*, Chelsea Publishing, New York, 1956.