

Semántica Bayesiana en Control Informacional

Proposiciones, demostraciones y estructura

Alejandro Cruz López

Universidad Autónoma Metropolitana – Unidad Iztapalapa

Asesores: Dr. Asael F. Martínez M. Dr. Joaquín Delgado F.

2026

Contenido

- 1 Contexto: ¿qué es Control Informacional?
- 2 Espacio conjunto hipótesis-observaciones
- 3 Proposición principal: Bayes como T_Y
- 4 Unicidad del operador bayesiano
- 5 Actualización secuencial
- 6 Corrección óptima hacia el posterior
- 7 Modelos continuos: partición paramétrica
- 8 Familia exponencial conjugada
- 9 Resumen estructural

¿De dónde venimos?

La ruta lógica del marco CI

- 1 **Sección A.** Espacios de probabilidad, particiones finitas y el *simplex* Δ_n como dominio.
- 2 **Sección B.** Correcciones locales: cambio de medida discreto.
- 3 **Sección C.** Operador global multiplicativo T_Y y su grupo $\mathcal{G}$.
- 4 **Sección D.** Divergencia KL, métrica de Fisher y dinámica inducida.
- 5 **Sección E₀.** **Semántica bayesiana** como caso particular de T_Y . ← **Esto es lo que veremos hoy.**

Idea central

Bayes no es un axioma externo: es el operador T_Y aplicado con la verosimilitud como corrección global.

Recordatorio esencial (Secciones A y C)

Símplex de probabilidad

$$\Delta_n = \left\{ X \in \mathbb{R}^n : X_i \geq 0, \sum_{i=1}^n X_i = 1 \right\}$$

El *interior* Δ_n° es el subconjunto donde $X_i > 0$ para todo i .

Un estado informacional es un punto $X \in \Delta_n^\circ$.

Operador global T_Y (Secc. C)

Dado un vector $Y \in \mathbb{R}^n$ con $1 + Y_i > 0$,

$$T_Y(X)_i = \frac{X_i (1 + Y_i)}{\sum_{k=1}^n X_k (1 + Y_k)}.$$

El grupo de estos operadores se llama $\mathcal{G}$.

Propiedad clave: $T_Y(X) \in \Delta_n^\circ$ si $X \in \Delta_n^\circ$.

Definición: espacio conjunto

Definición (Espacio conjunto hipótesis-observaciones)

Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad. Se fijan **dos particiones medibles finitas no degeneradas**:

$$\Pi_H = \{H_1, \dots, H_n\} \subset \mathcal{F} \quad (\text{hipótesis})$$

$$\Pi_E = \{E_1, \dots, E_m\} \subset \mathcal{F} \quad (\text{observaciones})$$

El **estado informacional previo** (prior) es el vector

$$X_i := P(H_i), \quad i = 1, \dots, n,$$

que pertenece a Δ_n° porque $P(H_i) > 0$ para todo i (partición no degenerada).

¿Por qué una sola medida P ?

El mismo P determina $P(H_i \cap E_j)$ y $P(E_j \mid H_i)$; no se necesitan medidas adicionales.

Definición: verosimilitud como corrección global

Probabilidad condicional (recordatorio)

Si $P(H_i) > 0$, la probabilidad condicional de observar E_j dado H_i es

$$P(E_j \mid H_i) = \frac{P(H_i \cap E_j)}{P(H_i)}.$$

Definición (Verosimilitud)

Fijada la observación E_j (con $P(E_j) > 0$), la **verosimilitud de E_j bajo H_i** es

$$\ell_i^{(j)} := P(E_j \mid H_i), \quad i = 1, \dots, n.$$

Cuando $\ell_i^{(j)} > 0$ para todo i , se define la corrección global $Y^{\ell^{(j)}} \in C_{\text{glob}}$ mediante

$$1 + Y_i^{\ell^{(j)}} := \ell_i^{(j)}.$$

Proposición: el operador bayesiano como T_Y

Proposición (Bayes como caso particular de T_Y)

Sea $X \in \Delta_n^\circ$ el prior con $X_i = P(H_i)$, y sea $\ell^{(j)}$ la verosimilitud de E_j . Entonces

$$T_{Y^{\ell^{(j)}}}(X)_i = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}} = P(H_i \mid E_j).$$

Es decir, $T_{Y^{\ell^{(j)}}}(X)$ es exactamente el posterior de Bayes.

La actualización bayesiana no es un axioma aparte: es la acción del operador global T_Y de la Sección C, con $1 + Y_i = \ell_i^{(j)}$.

Demostración (Parte 1 de 3): aplicar T_Y

Punto de partida: la definición del operador global T_Y (Sección C).

Para cualquier corrección global Y con $1 + Y_i > 0$,

$$T_Y(X)_i = \frac{X_i (1 + Y_i)}{\sum_{k=1}^n X_k (1 + Y_k)}.$$

Sustituimos $1 + Y_i^{\ell(j)} = \ell_i^{(j)}$:

$$T_{Y^{\ell(j)}}(X)_i = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}}.$$

Demostración (Parte 2 de 3): identificar numerador y denominador

El numerador. Recordamos que $X_i = P(H_i)$ y $\ell_i^{(j)} = P(E_j \mid H_i)$. Por la regla del producto:

$$X_i \ell_i^{(j)} = P(H_i) \cdot P(E_j \mid H_i) = P(H_i \cap E_j).$$

El denominador. Como $\Pi_H = \{H_1, \dots, H_n\}$ es una *partición* de Ω , los eventos H_k son disjuntos y su unión es Ω . Por la ley de probabilidad total:

$$\sum_{k=1}^n X_k \ell_k^{(j)} = \sum_{k=1}^n P(H_k \cap E_j) = P(E_j).$$

Demostración (Parte 3 de 3): concluir con Bayes

Reuniendo los dos pasos anteriores:

$$T_{Y^{\ell(j)}}(X)_i = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}} = \frac{P(H_i \cap E_j)}{P(E_j)}.$$

Por la **definición de probabilidad condicional**:

$$\frac{P(H_i \cap E_j)}{P(E_j)} = P(H_i \mid E_j).$$

Conclusión

$$T_{Y^{\ell(j)}}(X)_i = P(H_i \mid E_j).$$

Proposición: unicidad en $\mathcal{G}$

Proposición (Unicidad)

Supóngase que $P(H_i \cap E_j) > 0$ para todo i . Un operador $T \in \mathcal{G}$ satisface

$$T(X)_i = P(H_i \mid E_j) \quad \text{para todo } i$$

si y sólo si $T = T_{Y^{\ell(j)}}$.

Dentro de $\mathcal{G}$, la actualización bayesiana no tiene alternativas: el posterior determinado por P es producido por un único operador global.

Demostración: unicidad

($\Leftarrow$) La Proposición anterior ya prueba la suficiencia.

($\Rightarrow$) **Necesidad.** Si $T_Y(X)_i = P(H_i \mid E_j)$ para todo i , entonces

$$\frac{X_i(1 + Y_i)}{\sum_{k=1}^n X_k(1 + Y_k)} = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}}.$$

Como $X_i > 0$, existe $c > 0$ tal que

$$1 + Y_i = c \ell_i^{(j)} \quad \text{para todo } i.$$

La normalización absorbe c , luego $T_Y = T_{Y \ell^{(j)}}$.



Corolario: actualización secuencial como composición en $\mathcal{G}$

Corolario (Actualización secuencial)

Sean $E_{j_1}, \dots, E_{j_m}$ observaciones sucesivas con $P(H_i \cap E_{j_s}) > 0$ para todo i, s . Sea $X_0 \in \Delta_n^\circ$ el prior inicial.

El posterior tras las m observaciones es

$$X_m = T_{Y^{\ell(j_m)}} \circ \dots \circ T_{Y^{\ell(j_1)}}(X_0).$$

El operador compuesto tiene factores coordinados

$$1 + (Y^{\text{tot}})_i = \prod_{s=1}^m \ell_i^{(j_s)}.$$

Si los datos son condicionalmente independientes dadas las hipótesis, la actualización secuencial coincide con la simultánea.

Demostración: composición de operadores globales

Ley de composición de $\mathcal{G}$ (Sección C). Para dos correcciones globales $Y^{(1)}$ y $Y^{(2)}$:

$$T_{Y^{(2)}} \circ T_{Y^{(1)}}(X)_i = \frac{X_i (1 + Y_i^{(1)})(1 + Y_i^{(2)})}{\sum_k X_k (1 + Y_k^{(1)})(1 + Y_k^{(2)})}.$$

Los factores se **multiplican coordenada a coordenada**.

Aplicando m veces con $1 + Y_i^{(s)} = \ell_i^{(j_s)}$:

$$X_m = T_{Y^{\ell(j_m)}} \circ \cdots \circ T_{Y^{\ell(j_1)}}(X_0), \quad 1 + (Y^{\text{tot}})_i = \prod_{s=1}^m \ell_i^{(j_s)}.$$

Si $P(E_{j_1} \cap \cdots \cap E_{j_m} \mid H_i) = \prod_s P(E_{j_s} \mid H_i)$, el factor total del dato conjunto es $\prod_s \ell_i^{(j_s)}$, que coincide con el operador compuesto. □

Proposición: corrección óptima

Proposición (Corrección óptima hacia el posterior)

Sean $X, \pi \in \Delta_n^\circ$. El único elemento de $\mathcal{G}$ que lleva X a π en un paso, salvo escala proyectiva, es T_{Y^*} con

$$1 + Y_i^* = c \frac{\pi_i}{X_i}, \quad c > 0.$$

Si $\pi = P(H_i | E_j)$ es el posterior bayesiano, entonces por la Proposición de Unicidad,

$$\ell_i^{(j)} \propto \frac{\pi_i}{X_i}.$$

Lectura geométrica (Sección D)

La corrección óptima Y^* coincide con el gradiente de la divergencia KL $E_\pi(X) = D_{\text{KL}}(\pi \| X)$ en Δ_n° . Llegar al posterior es descender en E_π .

Demostración: corrección óptima

Existencia. Queremos $T_Y(X) = \pi$, es decir:

$$\frac{X_i (1 + Y_i)}{\sum_k X_k (1 + Y_k)} = \pi_i \quad \text{para todo } i.$$

Esto se cumple si y sólo si $X_i (1 + Y_i) = c \pi_i$ para alguna constante $c > 0$. Despejando:

$$1 + Y_i^* = c \frac{\pi_i}{X_i}.$$

Unicidad salvo escala proyectiva. Si $1 + Y_i = c' \pi_i / X_i$ para cualquier $c' > 0$, la normalización absorbe c' y el operador resultante es el mismo. Por la estructura de grupo de $\mathcal{G}$, no existe otra solución.

Identificación con $\ell^{(j)}$. Cuando $\pi = P(H_i \mid E_j)$, la Proposición de Unicidad garantiza que $T_{Y^*} = T_{Y^{\ell^{(j)}}}$, luego $\ell_i^{(j)} \propto \pi_i / X_i$. □

Definición: partición paramétrica uniforme

Definición (Partición paramétrica uniforme)

Sea $\Omega = (a, b) \subset \mathbb{R}$ con medida P_0 de densidad continua $f > 0$.

Para $n \geq 1$, sea $h := (b - a)/n$ y defínase

$$E_i := \left(a + (i - 1)h, a + ih \right], \quad i = 1, \dots, n.$$

El **punto representativo** de E_i es el punto medio $\theta_i := a + (i - \frac{1}{2})h$.

El **estado informacional previo exacto** es

$$X_{0,i} := P_0(E_i) = \int_{E_i} f(\theta) d\theta \in \Delta_n^\circ.$$

En la práctica, $\widetilde{X}_{0,i} \propto f(\theta_i)$.

Proposición: actualización bayesiana paramétrica

Proposición (Actualización bayesiana paramétrica en CI)

Sea $X_0 \in \Delta_n^\circ$ el estado previo sobre Π_n , y sea $Y^\ell \in C_{\text{glob}}$ la corrección de verosimilitud con $1 + Y_i^\ell := \ell(\theta_i)$. Entonces

$$T_{Y^\ell}(X_0)_i = \frac{P_0(E_i) \ell(\theta_i)}{\sum_{k=1}^n P_0(E_k) \ell(\theta_k)}.$$

Cuando $n \rightarrow \infty$ (con $h \rightarrow 0$), esta suma converge a $\int_a^b f(\theta) \ell(\theta) d\theta$, y el estado converge al posterior continuo con densidad proporcional a $f(\theta) \ell(\theta)$.

Se sustituye $X_{0,i} = P_0(E_i)$ en la fórmula de T_{Y^ℓ} ; la convergencia es una suma de Riemann estándar. □

Proposición: modelo conjugado exponencial

Proposición (Modelo conjugado exponencial como caso particular)

Sea el prior de la familia exponencial con parámetro natural η_0 :

$$f(\theta) \propto \exp(\eta_0 \cdot T(\theta)).$$

Sea la verosimilitud de la forma exponencial con contribución η_ℓ :

$$\ell(\theta) \propto \exp(\eta_\ell \cdot T(\theta)).$$

Entonces el operador T_{Y^ℓ} produce un posterior en la **misma familia** con parámetro natural actualizado

$$\eta_n := \eta_0 + \eta_\ell.$$

Casos clásicos: Beta-Binomial y Normal-Normal.

Demostración (Parte 1 de 2): el producto de exponenciales

Prior por punto medio:

$$\widetilde{X}_{0,i} \propto f(\theta_i) = \exp(\eta_0 \cdot T(\theta_i)).$$

Verosimilitud evaluada en θ_i :

$$\ell_i = \ell(\theta_i) = \exp(\eta_\ell \cdot T(\theta_i)).$$

El operador T_{Y^ℓ} multiplica prior y verosimilitud coordenada a coordenada:

$$T_{Y^\ell}(\widetilde{X}_0)_i \propto \widetilde{X}_{0,i} \cdot \ell_i = \exp(\eta_0 \cdot T(\theta_i)) \cdot \exp(\eta_\ell \cdot T(\theta_i)).$$

Usando la propiedad de exponenciales $e^a \cdot e^b = e^{a+b}$:

$$T_{Y^\ell}(\widetilde{X}_0)_i \propto \exp((\eta_0 + \eta_\ell) \cdot T(\theta_i)).$$

Demostración (Parte 2 de 2): identificar el posterior

Del paso anterior:

$$T_{Y^\ell}(\widetilde{X}_0)_i \propto \exp(\eta_n \cdot T(\theta_i)), \quad \eta_n := \eta_0 + \eta_\ell.$$

Esto es exactamente la **evaluación en la cuadrícula** de una densidad de la misma familia exponencial con parámetro natural η_n .

La constante de proporcionalidad se cancela en la normalización de T_{Y^ℓ} (invariancia de escala de $\mathcal{G}$, Sección C).

Conclusión

La actualización conjugada —sumar parámetros naturales— emerge automáticamente de la ley multiplicativa del operador T_{Y^ℓ} . No se impone: **se deduce del marco**. □

Mapa de proposiciones de la semántica bayesiana

Proposiciones nucleares

- ❶ **Bayes como T_Y :**
 $T_{Y^{\ell(j)}}(X)_i = P(H_i \mid E_j)$
- ❷ **Unicidad en $\mathcal{G}$:** solo $T_{Y^{\ell(j)}}$ produce el posterior correcto
- ❸ **Actualización secuencial:** composición en $\mathcal{G}$, factores se multiplican
- ❹ **Corrección óptima:** $1 + Y_i^* = c \pi_i / X_i$, ligada a E_π (Secc. D)

Extensión a modelos continuos

- ❺ **Partición paramétrica:**
discretizar (Ω, P_0) con Π_n
- ❻ **Actualización paramétrica:**
 $T_{Y^\ell}(X_0)$ converge al posterior continuo
- ❼ **Familia exponencial:**
 $\eta_n = \eta_0 + \eta_\ell$ (Beta-Binomial, Normal-Normal, ...)

Conclusión

Lo que se mostró

- La regla de Bayes no es un axioma externo: es el operador global T_Y de la Sección C con $1 + Y_i = \ell_i$.
- Dentro del grupo $\mathcal{G}$, la actualización bayesiana es **única**: no hay alternativa coherente con P .
- La actualización secuencial es **composición** en $\mathcal{G}$; los factores se multiplican coordenada a coordenada.
- Los modelos conjugados (Beta-Binomial, Normal-Normal) emergen de la ley multiplicativa de T_{Y^ℓ} : sumar parámetros naturales es consecuencia, no supuesto.

Próximo paso

Con esta semántica bayesiana establecida, el marco CI puede combinarse con la semántica markoviana (Sección B).