

Control Informacional

Proyecto de Investigación II — ProInt_II

Alejandro Cruz López

Universidad Autónoma Metropolitana
Unidad Iztapalapa

Asesores

Dr. Asael Fabián Martínez Martínez
Dr. Joaquín Delgado Fernández 26 de mayo de 2026

Introducción general

El estudio de distribuciones de probabilidad finitas suele abordarse desde dos perspectivas principales: como objetos estáticos sujetos a estimación, o como estados que se actualizan mediante reglas inferenciales o dinámicas específicas. En distintos contextos, sin embargo, aparecen secuencias de distribuciones cuya evolución constituye por sí misma el fenómeno de interés. Esto conduce a una pregunta distinta: ¿Cómo describir transformaciones entre estados probabilísticos preservando su estructura intrínseca, sin reducir necesariamente el análisis a un modelo estocástico externo?

En el caso finito, toda distribución de probabilidad puede representarse como un punto del simplex. Esta representación aparece de manera natural en la teoría axiomática de la probabilidad (?). A partir de esta observación, el problema del cambio informacional puede reformularse como el estudio de transformaciones internas del simplex compatibles con la interpretación probabilística. En este trabajo se fija un dominio preciso —estados informacionales discretos inducidos por particiones medibles finitas— y se introducen transformaciones elementales definidas mediante correcciones relativas. Estas transformaciones dan lugar a operadores bien definidos sobre el simplex y permiten incorporar funcionales informacionales para comparar estados (?).

El punto de vista adoptado no pretende reemplazar marcos ya establecidos para dinámicas estocásticas o reglas particulares de actualización. Un ejemplo clásico de tales marcos lo proporcionan las cadenas de Markov. También existen formulaciones variacionales para la evolución de medidas en espacios métricos (?). Más modestamente, el objetivo aquí es aislar un formalismo matemático en el que las transformaciones entre distribuciones finitas puedan estudiarse directamente como objeto de análisis. En esta formulación, los cambios entre estados se modelan mediante correcciones relativas que preservan la masa total. En el desarrollo posterior, estas correcciones admitirán interpretación composicional (?). También admitirán una interpretación por

cambio de medida en el caso discreto. Cuando sea pertinente, se indicará además su interpretación geométrica local en términos de la métrica de Fisher (?).

El interés de este problema no es únicamente formal. En diversas situaciones aparecen familias finitas de probabilidades o vectores normalizados cuya evolución contiene información relevante sobre estabilidad, convergencia o respuesta al entorno. En particular, las actualizaciones multiplicativas sobre el simplex aparecen en optimización y aprendizaje (?). Por otra parte, la estructura geométrica del simplex ha sido estudiada sistemáticamente en análisis composicional (?). También ha sido analizada desde la geometría de la información (?).

El objetivo central de este manuscrito unificado es construir y organizar un marco básico para el estudio de transformaciones deterministas de estados probabilísticos finitos. En particular, se busca:

1. fijar con precisión el dominio probabilístico discreto en el que se trabajará;
2. introducir correcciones relativas y operadores asociados que preserven la estructura del simplex;
3. relacionar dichas transformaciones con cambios discretos de medida;
4. incorporar funcionales informacionales y estudiar la dinámica que inducen en el caso discreto.

El alcance del trabajo es deliberadamente acotado. Se considera exclusivamente el caso de distribuciones finitas, formuladas como puntos del simplex de probabilidad, y se estudian las estructuras mínimas necesarias para pasar de estados aislados a transformaciones y dinámicas entre ellos. En este sentido, el documento tiene un carácter fundacional: no pretende agotar el problema general, sino establecer con rigor el núcleo matemático que servirá de base para desarrollos posteriores.

La organización del texto es la siguiente. En la Sección A se fija el dominio probabilístico y su representación geométrica en el simplex. En la Sección B se introducen correcciones locales que preservan la estructura probabilística y se muestra su interpretación como cambios discretos de medida. En la Sección C se construyen operadores globales asociados a dichas correcciones y se estudia su estructura algebraica. Finalmente, en la Sección D se incorporan funcionales informacionales, en particular la divergencia de Kullback–Leibler (?). Sobre esta base se analiza una dinámica determinista sobre el interior del simplex con interpretación geométrica de tipo Fisher (?).

Relación con marcos de referencia

El desarrollo del trabajo utiliza herramientas provenientes de varios marcos que actúan sobre el mismo dominio, el simplex de probabilidades Δ_n , pero que cumplen funciones distintas dentro de la exposición.

- **Análisis composicional (Aitchison).** Proporciona la estructura algebraico–geométrica interna del simplex cuando las transformaciones relevantes son multiplicativas y seguidas de cierre o normalización. En particular, las operaciones de perturbación y potenciación permiten trabajar con cantidades relativas dentro del simplex (?).

- **Geometría de divergencias (Csiszár).** Aporta funcionales de comparación entre distribuciones. En particular, las f -divergencias proporcionan un marco general para medir discrepancias entre estados probabilísticos (?). Dentro de esta familia, la divergencia de Kullback–Leibler ocupa un lugar central en este trabajo (?).
- **Geometría de la información (Amari).** Proporciona la métrica de Fisher y el lenguaje diferencial que permite interpretar gradientes y direcciones de cambio en el interior del simplex (?). Este punto de vista se utilizará sólo cuando sea necesario para interpretar localmente la dinámica (?).
- **Formulaciones variacionales en espacios de medidas (Wasserstein/JKO).** Este marco no se desarrolla en el documento como teoría principal. Sin embargo, se toma como referencia cuando se discuten analogías entre funcionales, esquemas discretos y dinámicas de descenso (?). La formulación abstracta de estos flujos en espacios métricos puede consultarse en (?).

La convención adoptada será la siguiente. Las transformaciones elementales se formulan principalmente en la geometría composicional del simplex (?). Los funcionales de comparación se expresan mediante divergencias informacionales (?). Cuando resulte necesario, las interpretaciones diferenciales se harán explícitas en términos de la métrica de Fisher (?). De manera análoga, las referencias a esquemas variacionales se entenderán sólo como punto de comparación conceptual (?).

1. Sección A — Probabilidad y simplex

Esta sección fija el dominio probabilístico discreto en el que se desarrollará el trabajo. El punto de partida es un espacio de probabilidad en el sentido de Kolmogórov (?). A partir de una partición medible finita se asocia a la medida un vector de probabilidades, que se interpretará como estado informacional discreto. Dicho vector pertenece naturalmente al simplex de probabilidad.

Observación 1.1. *Conviene distinguir desde el inicio entre la medida P sobre $(\Omega, \mathcal{F})$ y el estado discreto X inducido por una partición Π . Un mismo espacio de probabilidad puede dar lugar a distintos estados al variar la partición considerada.*

Definición 1.1 (Espacio de probabilidad). *Un espacio de probabilidad es una terna $(\Omega, \mathcal{F}, P)$ tal que:*

1. Ω es un conjunto no vacío;
2. $\mathcal{F}$ es una σ -álgebra de subconjuntos de Ω ;
3. $P : \mathcal{F} \rightarrow [0, 1]$ es una medida con $P(\Omega) = 1$.

Definición 1.2 (Partición medible finita). *Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad. Una partición medible finita de Ω es una familia finita*

$$\Pi = \{E_1, \dots, E_n\} \subset \mathcal{F}, \quad n \geq 1,$$

tal que:

1. $E_i \cap E_j = \emptyset$ si $i \neq j$;
2. $\bigcup_{i=1}^n E_i = \Omega$.

Diremos que Π es no degenerada si además

$$P(E_i) > 0, \quad i = 1, \dots, n.$$

Observación 1.2. La hipótesis de no degeneración no forma parte de la definición general de partición, pero será útil cuando intervengan cocientes o logaritmos.

Definición 1.3 (Símplex de probabilidad e interior). Para $n \geq 1$ se define el símplex de probabilidad por

$$\Delta_n := \left\{ x \in \mathbb{R}^n : x_i \geq 0, \sum_{i=1}^n x_i = 1 \right\}.$$

Su interior relativo en el hiperplano $\sum_{i=1}^n x_i = 1$ está dado por

$$\Delta_n^\circ := \{ x \in \Delta_n : x_i > 0 \text{ para todo } i \}.$$

Observación 1.3. El conjunto Δ_n será el espacio general de estados. Cuando se requiera positividad estricta, por ejemplo en expresiones con cocientes o logaritmos, se trabajará en Δ_n° .

Definición 1.4 (Estado informacional discreto). Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sea $\Pi = \{E_1, \dots, E_n\}$ una partición medible finita. El estado informacional discreto asociado a Π es el vector

$$X = (X_1, \dots, X_n) \in \mathbb{R}^n, \quad X_i := P(E_i), \quad i = 1, \dots, n.$$

Proposición 1.1. Sea X el estado informacional discreto asociado a una partición medible finita $\Pi = \{E_1, \dots, E_n\}$. Entonces:

1. $X \in \Delta_n$;
2. si Π es no degenerada, entonces $X \in \Delta_n^\circ$.

Demostración. Como $E_i \in \mathcal{F}$, se tiene $X_i = P(E_i) \geq 0$ para todo i . Además, por disjunción de la partición y aditividad numerable de P ,

$$\sum_{i=1}^n X_i = \sum_{i=1}^n P(E_i) = P\left(\bigcup_{i=1}^n E_i\right) = P(\Omega) = 1.$$

Por tanto, $X \in \Delta_n$. Si además $P(E_i) > 0$ para todo i , entonces $X_i > 0$ para todo i , y en consecuencia $X \in \Delta_n^\circ$. $\square$

Observación 1.4. El paso de $(\Omega, \mathcal{F}, P)$ a X depende de la partición elegida. En consecuencia, X no representa a la medida P en toda su estructura, sino sólo su distribución sobre las clases de observación determinadas por Π .

Definición 1.5 (Operador de cierre). Sea

$$\mathbb{R}_{>0}^n := \{z = (z_1, \dots, z_n) \in \mathbb{R}^n : z_i > 0 \text{ para todo } i\}.$$

El operador de cierre es la aplicación

$$\mathcal{C} : \mathbb{R}_{>0}^n \rightarrow \Delta_n^\circ, \quad \mathcal{C}(z) := \frac{1}{\sum_{i=1}^n z_i} z.$$

Observación 1.5. Para todo $\lambda > 0$ y todo $z \in \mathbb{R}_{>0}^n$ se cumple

$$\mathcal{C}(\lambda z) = \mathcal{C}(z).$$

Esta invarianza de escala expresa que el cierre conserva únicamente la información relativa entre coordenadas y además la normalización coincide con la operación de cierre utilizada en análisis composicional para pasar de vectores positivos a composiciones sobre el símplex (?).

Observación 1.6. Cuando se requiera interpretar transformaciones multiplicativas internas del símplex, se utilizará el formalismo composicional introducido por Aitchison (?). En particular, el interior del símplex admite una estructura algebraica natural mediante perturbación y potenciación. Para los resultados de esa teoría que sean necesarios más adelante, se remitirá a la bibliografía correspondiente.

2. Sección B — Correcciones locales y cambio de medida

En esta sección se introduce el mecanismo elemental de transformación sobre el símplex. Dado un estado $X \in \Delta_n$, se definen correcciones relativas admisibles que preservan la no negatividad y la normalización, se asocia a cada una de ellas un operador local sobre el espacio de estados y se muestra que dicha actualización coincide con un cambio de medida discreto sobre la partición subyacente.

Definición 2.1 (Conjunto de correcciones admisibles en X). Sea $X = (X_1, \dots, X_n) \in \Delta_n$. Se define el conjunto de correcciones admisibles en X por

$$C(X) := \left\{ Y = (Y_1, \dots, Y_n) \in \mathbb{R}^n \mid X_i(1 + Y_i) \geq 0 \text{ para todo } i, \sum_{i=1}^n X_i(1 + Y_i) = 1 \right\}.$$

Observación 2.1. Si $Y \in C(X)$, entonces

$$\sum_{i=1}^n X_i Y_i = 0.$$

En efecto, como $\sum_{i=1}^n X_i = 1$ y $\sum_{i=1}^n X_i(1 + Y_i) = 1$, se obtiene

$$\sum_{i=1}^n X_i Y_i = \sum_{i=1}^n X_i(1 + Y_i) - \sum_{i=1}^n X_i = 1 - 1 = 0.$$

Esta identidad expresa la neutralidad de masa de la corrección, es decir, $\sum_{i=1}^n X_i Y_i = 0$.

Definición 2.2 (Operador informacional local). Sea $X \in \Delta_n$ y sea $Y \in C(X)$. El operador informacional local asociado a Y en X es el vector

$$T_Y^{\text{loc}}(X) = (T_Y^{\text{loc}}(X)_1, \dots, T_Y^{\text{loc}}(X)_n) \in \mathbb{R}^n,$$

definido por

$$T_Y^{\text{loc}}(X)_i := X_i(1 + Y_i), \quad i = 1, \dots, n.$$

Observación 2.2. No es necesario exigir $X \in \Delta_n^\circ$ para definir T_Y^{loc} . Si $X_i = 0$, entonces

$$T_Y^{\text{loc}}(X)_i = 0$$

independientemente del valor de Y_i . Por tanto, el operador local está bien definido en todo Δ_n . La restricción al interior Δ_n° sólo será necesaria más adelante, cuando intervengan expresiones que requieran positividad estricta.

Proposición 2.1 (Preservación local del simplex). Sea $X \in \Delta_n$ y sea $Y \in C(X)$. Entonces

$$T_Y^{\text{loc}}(X) \in \Delta_n.$$

Demostración. Por definición de $C(X)$,

$$X_i(1 + Y_i) \geq 0, \quad i = 1, \dots, n,$$

y

$$\sum_{i=1}^n X_i(1 + Y_i) = 1.$$

Como

$$T_Y^{\text{loc}}(X)_i = X_i(1 + Y_i),$$

se sigue que todas las coordenadas de $T_Y^{\text{loc}}(X)$ son no negativas y que su suma es 1. Por tanto,

$$T_Y^{\text{loc}}(X) \in \Delta_n.$$

□

Proposición 2.2 (Cambio de medida discreto inducido por una corrección local). Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sea

$$\Pi = \{E_1, \dots, E_n\} \subset \mathcal{F}$$

una partición medible finita no degenerada. Defínase

$$X_i := P(E_i), \quad i = 1, \dots, n,$$

de modo que $X = (X_1, \dots, X_n) \in \Delta_n^\circ$.

Sea $Y \in C(X)$ y defínase

$$h : \Omega \rightarrow [0, \infty), \quad h(\omega) := 1 + Y_i \quad \text{si } \omega \in E_i.$$

Sea además

$$Q_Y : \mathcal{F} \rightarrow [0, \infty], \quad Q_Y(A) := \int_A h(\omega) dP(\omega), \quad A \in \mathcal{F}.$$

Entonces Q_Y es una medida de probabilidad sobre $(\Omega, \mathcal{F})$.

Demostración. Como $Y \in C(X)$, se tiene

$$X_i(1 + Y_i) \geq 0, \quad i = 1, \dots, n.$$

Puesto que $X_i = P(E_i) > 0$, se sigue que

$$1 + Y_i \geq 0, \quad i = 1, \dots, n.$$

Por tanto,

$$h(\omega) \geq 0, \quad \omega \in \Omega.$$

En consecuencia, la aplicación

$$A \mapsto \int_A h dP$$

define una medida no negativa sobre $(\Omega, \mathcal{F})$.

Además, usando que $\Pi = \{E_1, \dots, E_n\}$ es una partición de Ω y que h es constante en cada sección ,

$$Q_Y(\Omega) = \int_{\Omega} h dP = \sum_{i=1}^n \int_{E_i} h dP = \sum_{i=1}^n (1 + Y_i)P(E_i) = \sum_{i=1}^n X_i(1 + Y_i) = 1.$$

Por tanto, Q_Y es una medida de probabilidad. □

Proposición 2.3 (Compatibilidad entre T_Y^{loc} y el cambio de medida). *Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sea*

$$\Pi = \{E_1, \dots, E_n\} \subset \mathcal{F}$$

una partición medible finita no degenerada. Defínase

$$X_i := P(E_i), \quad i = 1, \dots, n,$$

de modo que $X = (X_1, \dots, X_n) \in \Delta_n^\circ$.

Sea $\omega \in \Omega$. Sea $Y \in C(X)$ y defínase $h : \Omega \rightarrow (0, \infty)$ por

$$h(\omega) := 1 + Y_i \quad \text{si } \omega \in E_i.$$

Sea además

$$Q_Y(A) := \int_A h(\omega) dP(\omega), \quad A \in \mathcal{F}.$$

Entonces, para cada $i = 1, \dots, n$, se cumple

$$Q_Y(E_i) = T_Y^{\text{loc}}(X)_i.$$

Demostración. Como h es constante sobre cada sección E_i y vale $1 + Y_i$ en dicho sección ,

$$Q_Y(E_i) = \int_{E_i} h(\omega) dP(\omega) = (1 + Y_i)P(E_i) = (1 + Y_i)X_i.$$

Por la definición del operador local,

$$(1 + Y_i)X_i = T_Y^{\text{loc}}(X)_i.$$

Por tanto,

$$Q_Y(E_i) = T_Y^{\text{loc}}(X)_i.$$

□

Observación 2.3. La proposición anterior identifica la actualización local con la redistribución de probabilidad inducida por la medida Q_Y sobre la partición original. En este sentido, el operador T_Y^{loc} no actúa sólo como transformación algebraica sobre el simplex, sino como representación discreta de un cambio de medida por sección s .

3. Sección C — Operadores globales multiplicativos y composición

En esta sección se pasa del mecanismo local del sección 2 a una familia de operadores definida de manera uniforme sobre el interior del simplex. La idea es considerar correcciones multiplicativas positivas y renormalizar el resultado para conservar la suma unitaria. Esto da lugar a operadores globales sobre Δ_n° y permite describir su composición de forma explícita.

Definición 3.1 (Correcciones globales). Se define el conjunto de correcciones globales por

$$C_{\text{glob}} := \left\{ Y = (Y_1, \dots, Y_n) \in \mathbb{R}^n \mid 1 + Y_i > 0 \text{ para todo } i \right\}.$$

Para cada $Y \in C_{\text{glob}}$, el vector de factores multiplicativos asociado viene dado por

$$a(Y) := (1 + Y_1, \dots, 1 + Y_n) \in \mathbb{R}_{>0}^n.$$

Definición 3.2 (Operador informacional global). Sea $Y \in C_{\text{glob}}$. El operador informacional global asociado a Y es la aplicación

$$T_Y : \Delta_n^\circ \rightarrow \Delta_n^\circ, \quad T_Y(X) := \frac{X \circ a(Y)}{\sum_{j=1}^n X_j a_j(Y)},$$

donde $\circ$ denota el producto coordenada a coordenada. En forma explícita,

$$T_Y(X)_i = \frac{X_i(1 + Y_i)}{\sum_{j=1}^n X_j(1 + Y_j)}, \quad i = 1, \dots, n.$$

Observación 3.1. La fórmula de T_Y tiene sentido también para $X \in \Delta_n$, no sólo para $X \in \Delta_n^\circ$. En efecto, si $Y \in C_{\text{glob}}$, entonces $1 + Y_i > 0$ para todo i , y por tanto

$$\sum_{j=1}^n X_j(1 + Y_j) > 0$$

para todo $X \in \Delta_n$. Así, $T_Y(X)$ está bien definido en todo Δ_n . No obstante, la restricción a Δ_n° será la natural cuando se estudie la estructura de composición e inversión de estos operadores.

Proposición 3.1 (Preservación del interior del simplex). Sea $Y \in C_{\text{glob}}$. Entonces, para todo $X \in \Delta_n^\circ$,

$$T_Y(X) \in \Delta_n^\circ.$$

Demostración. Si $X_i > 0$ y $a_i(Y) = 1 + Y_i > 0$ para todo i , entonces

$$X_i a_i(Y) > 0, \quad i = 1, \dots, n.$$

Además,

$$\sum_{i=1}^n T_Y(X)_i = \frac{\sum_{i=1}^n X_i a_i(Y)}{\sum_{j=1}^n X_j a_j(Y)} = 1.$$

Por tanto, todas las coordenadas de $T_Y(X)$ son estrictamente positivas y su suma es 1, es decir,

$$T_Y(X) \in \Delta_n^\circ.$$

□

Observación 3.2 (Relación con el operador local del sección 2). Sea $X \in \Delta_n^\circ$ y sea $Y \in C_{\text{glob}}$. Si además

$$\sum_{i=1}^n X_i(1 + Y_i) = 1,$$

entonces

$$T_Y(X)_i = X_i(1 + Y_i), \quad i = 1, \dots, n,$$

y por tanto

$$T_Y(X) = T_Y^{\text{loc}}(X).$$

En este sentido, el operador global extiende el mecanismo local del sección 2 al incorporar una renormalización dependiente del estado base.

Definición 3.3 (Familia global de operadores). Se define

$$\mathcal{G} := \left\{ T_Y : \Delta_n^\circ \rightarrow \Delta_n^\circ \mid Y \in C_{\text{glob}} \right\},$$

dotada de la composición usual de aplicaciones.

Proposición 3.2 (Ley de composición). Sean $Y_1, Y_2 \in C_{\text{glob}}$. Entonces existe un único $Y_{\text{tot}} \in C_{\text{glob}}$ tal que

$$T_{Y_2} \circ T_{Y_1} = T_{Y_{\text{tot}}},$$

y está determinado por la condición

$$1 + Y_{\text{tot}} = (1 + Y_1) \circ (1 + Y_2).$$

En coordenadas,

$$1 + (Y_{\text{tot}})_i = (1 + (Y_1)_i)(1 + (Y_2)_i), \quad i = 1, \dots, n.$$

Demostración. Sean $Y^{(1)}, Y^{(2)} \in C_{\text{glob}}$. Para $r = 1, 2$, recordemos que el vector de factores multiplicativos esta dado por:

$$a^{(r)} := (a_1^{(r)}, \dots, a_n^{(r)}), \quad a_i^{(r)} := 1 + Y_i^{(r)}.$$

Como $Y^{(r)} \in C_{\text{glob}}$, se tiene

$$a_i^{(r)} > 0 \quad \text{para todo } i = 1, \dots, n.$$

Sea ahora $X \in \Delta_n^\circ$. Entonces, por definición,

$$T_{Y^{(1)}}(X)_i = \frac{X_i a_i^{(1)}}{\sum_{j=1}^n X_j a_j^{(1)}}, \quad i = 1, \dots, n.$$

Aplicando después $T_{Y^{(2)}}$, para cada $i = 1, \dots, n$ se obtiene

$$T_{Y^{(2)}}(T_{Y^{(1)}}(X))_i = \frac{T_{Y^{(1)}}(X)_i a_i^{(2)}}{\sum_{j=1}^n T_{Y^{(1)}}(X)_j a_j^{(2)}}.$$

Sustituyendo la expresión de $T_{Y^{(1)}}(X)$,

$$T_{Y^{(2)}}(T_{Y^{(1)}}(X))_i = \frac{\frac{X_i a_i^{(1)}}{\sum_{k=1}^n X_k a_k^{(1)}} a_i^{(2)}}{\sum_{j=1}^n \frac{X_j a_j^{(1)}}{\sum_{k=1}^n X_k a_k^{(1)}} a_j^{(2)}}.$$

El factor común $\sum_{k=1}^n X_k a_k^{(1)}$ aparece en numerador y denominador, por lo que se cancela. Así,

$$T_{Y^{(2)}}(T_{Y^{(1)}}(X))_i = \frac{X_i a_i^{(1)} a_i^{(2)}}{\sum_{j=1}^n X_j a_j^{(1)} a_j^{(2)}}.$$

Definimos ahora

$$a^{(\text{tot})} := (a_1^{(1)} a_1^{(2)}, \dots, a_n^{(1)} a_n^{(2)}) \in \mathbb{R}_{>0}^n.$$

Como $a_i^{(1)} > 0$ y $a_i^{(2)} > 0$ para todo i , se tiene

$$a_i^{(\text{tot})} > 0 \quad \text{para todo } i.$$

Definimos $Y^{(\text{tot})} \in \mathbb{R}^n$ por

$$1 + Y_i^{(\text{tot})} := a_i^{(\text{tot})}, \quad i = 1, \dots, n.$$

Entonces $Y^{(\text{tot})} \in C_{\text{glob}}$ y, para cada $i = 1, \dots, n$,

$$T_{Y^{(\text{tot})}}(X)_i = \frac{X_i a_i^{(\text{tot})}}{\sum_{j=1}^n X_j a_j^{(\text{tot})}} = \frac{X_i a_i^{(1)} a_i^{(2)}}{\sum_{j=1}^n X_j a_j^{(1)} a_j^{(2)}}.$$

Por consiguiente,

$$T_{Y^{(2)}}(T_{Y^{(1)}}(X))_i = T_{Y^{(\text{tot})}}(X)_i \quad \text{para todo } i = 1, \dots, n,$$

y por tanto

$$T_{Y^{(2)}} \circ T_{Y^{(1)}} = T_{Y^{(\text{tot})}}.$$

□

Corolario 3.1 (Estructura de grupo abeliano). *El conjunto $\mathcal{G}$, dotado de la composición de aplicaciones, es un grupo abeliano.*

Demostración. Por la Proposición 3.2, si $Y^{(1)}, Y^{(2)} \in C_{\text{glob}}$, entonces la composición

$$T_{Y^{(2)}} \circ T_{Y^{(1)}}$$

vuelve a ser de la forma $T_{Y^{(\text{tot})}}$, donde

$$1 + Y_i^{(\text{tot})} = (1 + Y_i^{(1)})(1 + Y_i^{(2)}), \quad i = 1, \dots, n.$$

Por tanto, la composición en $\mathcal{G}$ corresponde al producto coordinado de los factores multiplicativos positivos.

Como el producto coordinado en $(0, \infty)^n$ es asociativo y conmutativo, la composición en $\mathcal{G}$ hereda estas propiedades.

El elemento neutro corresponde al vector

$$a = (1, \dots, 1),$$

es decir, a $Y = 0$, y en ese caso

$$T_0(X) = X \quad \text{para todo } X \in \Delta_n^\circ.$$

Ahora sea $Y \in C_{\text{glob}}$ y sea

$$a(Y) = (1 + Y_1, \dots, 1 + Y_n) \in (0, \infty)^n.$$

Definimos

$$a(Y)^{-1} := \left(\frac{1}{1 + Y_1}, \dots, \frac{1}{1 + Y_n} \right) \in (0, \infty)^n.$$

Sea $Z \in \mathbb{R}^n$ dado por

$$1 + Z_i := \frac{1}{1 + Y_i}, \quad i = 1, \dots, n.$$

Entonces $1 + Z_i > 0$ para todo i , de modo que $Z \in C_{\text{glob}}$. Además,

$$(1 + Y_i)(1 + Z_i) = 1, \quad i = 1, \dots, n.$$

Por la ley de composición,

$$T_Z \circ T_Y = T_0.$$

Análogamente,

$$T_Y \circ T_Z = T_0.$$

Así, todo elemento de $\mathcal{G}$ es invertible.

En consecuencia, $\mathcal{G}$ es un grupo abeliano. □

Observación 3.3 (Coordenadas log-multiplicativas). Para $Y \in C_{\text{glob}}$ se definen las coordenadas

$$\theta(Y) := (\theta_1, \dots, \theta_n), \quad \theta_i := \log(1 + Y_i), \quad i = 1, \dots, n.$$

Entonces

$$1 + Y_i = e^{\theta_i},$$

y el operador global puede escribirse como

$$T_\theta(X) = \frac{X \circ e^\theta}{\sum_{j=1}^n X_j e^{\theta_j}}, \quad e^\theta := (e^{\theta_1}, \dots, e^{\theta_n}).$$

Bajo esta parametrización, la ley de composición del corolario anterior se traduce en

$$\theta_{\text{tot}} = \theta^{(1)} + \theta^{(2)}.$$

En este sentido, la estructura multiplicativa de los factores positivos se convierte en una estructura aditiva en coordenadas logarítmicas la cual es compatible con el uso de coordenadas relativas en análisis composicional (?).

4. Sección D — Divergencia KL, métrica de Fisher y dinámica inducida

En esta sección se introduce el funcional informacional

$$E_P(X) := D_{\text{KL}}(P \| X),$$

se calcula su gradiente respecto de la métrica de Fisher en el interior del simplex y se obtiene la dinámica continua asociada. Finalmente, se muestra que esta dinámica es compatible con la familia de operadores globales introducida en la sección 3.

El resultado principal de la sección será el Teorema 4.1, donde se establece la compatibilidad estructural entre la dinámica Fisher–KL y la familia de operadores globales de la sección 3.

Definición 4.1 (Divergencia de Kullback–Leibler discreta). Sea $P \in \Delta_n^\circ$ fija. Para $X \in \Delta_n$ se define

$$D_{\text{KL}}(P \| X) = \begin{cases} \sum_{i=1}^n P_i \log\left(\frac{P_i}{X_i}\right), & \text{si } X_i > 0 \text{ para todo } i, \\ +\infty, & \text{si existe } i \text{ tal que } P_i > 0 \text{ y } X_i = 0. \end{cases}$$

Se define además el funcional

$$E_P : \Delta_n^\circ \rightarrow \mathbb{R}, \quad E_P(X) := D_{\text{KL}}(P \| X).$$

Observación 4.1 (Dominio natural de E_P). Como $P \in \Delta_n^\circ$, se tiene $P_i > 0$ para todo i . Por tanto,

$$D_{\text{KL}}(P \| X) < \infty \iff X \in \Delta_n^\circ.$$

En consecuencia, el dominio natural de E_P es el interior del simplex.

Definición 4.2 (Espacio tangente del símplex). Sea $X \in \Delta_n^\circ$. El espacio tangente en X se define como el conjunto de velocidades de curvas suaves del símplex que pasan por X , es decir,

$$T_X \Delta_n^\circ := \left\{ u \in \mathbb{R}^n \mid \exists \varepsilon > 0, \exists \gamma : (-\varepsilon, \varepsilon) \rightarrow \Delta_n^\circ \text{ de clase } C^1, \gamma(0) = X, \gamma'(0) = u \right\}.$$

Observación 4.2. Para todo $X \in \Delta_n^\circ$,

$$T_X \Delta_n^\circ = \left\{ u = (u_1, \dots, u_n) \in \mathbb{R}^n \mid \sum_{i=1}^n u_i = 0 \right\}.$$

Definición 4.3 (Métrica de Fisher discreta). Para $X \in \Delta_n^\circ$, la métrica de Fisher en $T_X \Delta_n$ es la forma bilineal

$$g_X(u, v) := \sum_{i=1}^n \frac{u_i v_i}{X_i}, \quad u, v \in T_X \Delta_n.$$

Esta es la realización discreta de la métrica de Fisher–Rao en la variedad de distribuciones finitas (???).

Definición 4.4 (Gradiente riemanniano respecto de la métrica de Fisher). Sea $E : \Delta_n^\circ \rightarrow \mathbb{R}$ una función suave. El gradiente riemanniano de E respecto de g es el campo

$$\text{grad}_g E : \Delta_n^\circ \rightarrow T \Delta_n, \quad X \mapsto \text{grad}_g E(X) \in T_X \Delta_n,$$

caracterizado por

$$g_X(\text{grad}_g E(X), u) = dE(X)[u], \quad \forall u \in T_X \Delta_n.$$

Proposición 4.1 (Gradiente Fisher de la divergencia KL). Sea $P \in \Delta_n^\circ$ fija y sea

$$E_P(X) = D_{\text{KL}}(P \| X) = \sum_{i=1}^n P_i \log \left(\frac{P_i}{X_i} \right), \quad X \in \Delta_n^\circ.$$

Entonces

$$\text{grad}_g E_P(X) = X - P, \quad X \in \Delta_n^\circ.$$

Demostración. Fijemos $X \in \Delta_n^\circ$ y sea $u \in T_X \Delta_n^\circ$. Entonces

$$dE_P(X)[u] = \left. \frac{d}{dt} E_P(X + tu) \right|_{t=0}.$$

Como

$$E_P(X + tu) = \sum_{i=1}^n P_i \log \left(\frac{P_i}{X_i + t u_i} \right),$$

se obtiene

$$\frac{d}{dt} E_P(X + tu) = - \sum_{i=1}^n P_i \frac{u_i}{X_i + t u_i}.$$

Evaluando en $t = 0$,

$$dE_P(X)[u] = - \sum_{i=1}^n \frac{P_i}{X_i} u_i.$$

Por otra parte, por definición de la métrica de Fisher,

$$g_X(v, u) = \sum_{i=1}^n \frac{v_i u_i}{X_i}.$$

Tomando $v = X - P$, se tiene

$$g_X(X - P, u) = \sum_{i=1}^n \frac{(X_i - P_i)u_i}{X_i} = \sum_{i=1}^n u_i - \sum_{i=1}^n \frac{P_i}{X_i} u_i.$$

Como $u \in T_X \Delta_n^\circ$, se cumple $\sum_{i=1}^n u_i = 0$, y por tanto

$$g_X(X - P, u) = - \sum_{i=1}^n \frac{P_i}{X_i} u_i = dE_P(X)[u].$$

Por la definición del gradiente riemanniano, se concluye que

$$\text{grad}_g E_P(X) = X - P.$$

□

Definición 4.5 (Flujo de gradiente Fisher–KL). *El flujo de gradiente asociado a E_P es la ecuación diferencial*

$$\dot{X}(t) = -\text{grad}_g E_P(X(t)), \quad X(t) \in \Delta_n^\circ.$$

Por la Proposición 4.1, esta ecuación toma la forma

$$\dot{X}(t) = P - X(t).$$

Proposición 4.2 (Solución explícita del flujo). *Sea $X_0 \in \Delta_n^\circ$. La solución del problema*

$$\dot{X}(t) = P - X(t), \quad X(0) = X_0,$$

está dada por

$$X(t) = e^{-t} X_0 + (1 - e^{-t}) P, \quad t \geq 0.$$

En particular, $X(t) \in \Delta_n^\circ$ para todo $t \geq 0$ y

$$X(t) \longrightarrow P \quad (t \rightarrow \infty).$$

Demostración. La ecuación

$$\dot{X}(t) = P - X(t), \quad X(0) = X_0,$$

se desacopla coordenada a coordenada. En efecto, para cada $i = 1, \dots, n$,

$$\dot{X}_i(t) = P_i - X_i(t), \quad X_i(0) = (X_0)_i.$$

La solución de esta ecuación lineal escalar es

$$X_i(t) = e^{-t} (X_0)_i + (1 - e^{-t}) P_i, \quad i = 1, \dots, n.$$

Por tanto,

$$X(t) = e^{-t}X_0 + (1 - e^{-t})P.$$

Como $X_0 \in \Delta_n^\circ$ y $P \in \Delta_n^\circ$, se tiene

$$(X_0)_i > 0, \quad P_i > 0, \quad i = 1, \dots, n.$$

Además, para todo $t \geq 0$,

$$e^{-t} > 0, \quad 1 - e^{-t} \geq 0.$$

De aquí se sigue que, para cada $i = 1, \dots, n$,

$$X_i(t) = e^{-t}(X_0)_i + (1 - e^{-t})P_i > 0.$$

Por otra parte,

$$\sum_{i=1}^n X_i(t) = e^{-t} \sum_{i=1}^n (X_0)_i + (1 - e^{-t}) \sum_{i=1}^n P_i = e^{-t} + (1 - e^{-t}) = 1.$$

Por tanto,

$$X(t) \in \Delta_n^\circ \quad \text{para todo } t \geq 0.$$

Finalmente,

$$X(t) - P = e^{-t}X_0 + (1 - e^{-t})P - P = e^{-t}(X_0 - P).$$

Como $e^{-t} \rightarrow 0$ cuando $t \rightarrow \infty$, se concluye que

$$X(t) \rightarrow P \quad (t \rightarrow \infty).$$

□

Proposición 4.3 (Monotonidad de E_P a lo largo del flujo). *Sea $X(\cdot)$ una solución del flujo Fisher–KL. Entonces la función*

$$t \mapsto E_P(X(t))$$

es decreciente y satisface

$$\frac{d}{dt} E_P(X(t)) = -g_{X(t)}(\text{grad}_g E_P(X(t)), \text{grad}_g E_P(X(t))) \leq 0.$$

La igualdad sólo ocurre si $X(t) = P$.

Demostración. Por la regla de la cadena,

$$\frac{d}{dt} E_P(X(t)) = dE_P(X(t))[\dot{X}(t)].$$

Como

$$\dot{X}(t) = -\text{grad}_g E_P(X(t)),$$

y por definición del gradiente riemanniano,

$$dE_P(X(t))[\dot{X}(t)] = -g_{X(t)}(\text{grad}_g E_P(X(t)), \text{grad}_g E_P(X(t))).$$

La no positividad es inmediata porque g es definida positiva en cada espacio tangente. Además,

$$g_{X(t)}(\text{grad}_g E_P(X(t)), \text{grad}_g E_P(X(t))) = 0$$

si y sólo si

$$\text{grad}_g E_P(X(t)) = 0 \iff X(t) - P = 0,$$

por la Proposición 4.1. Por tanto, la igualdad sólo ocurre en el equilibrio $X(t) = P$. $\square$

Proposición 4.4 (Mínimo global de E_P). *Para todo $X \in \Delta_n^\circ$ se cumple*

$$E_P(X) \geq 0,$$

y además

$$E_P(X) = 0 \iff X = P.$$

En particular, P es el único minimizador global de E_P en Δ_n° .

Demostración. La no negatividad y el criterio de igualdad corresponden a la desigualdad de Gibbs para la divergencia de Kullback–Leibler (??). Aplicando ese resultado a

$$E_P(X) = D_{\text{KL}}(P \| X),$$

se obtiene inmediatamente

$$E_P(X) \geq 0 \quad \text{y} \quad E_P(X) = 0 \iff X = P.$$

De aquí se sigue que P es el único minimizador global. $\square$

Teorema 4.1 (Equivalencia estructural Sección C $\leftrightarrow$ Sección D). *Sea $P \in \Delta_n^\circ$ fijo. Considérese el operador informacional global T_Y de la sección C (Def. 3.2), definido para $Y \in C_{\text{glob}}$ (Def. 3.1) por*

$$T_Y(X) = \frac{X \circ (1 + Y)}{\langle X, 1 + Y \rangle}.$$

Defínase, para cada $X \in \Delta_n^\circ$, el campo de corrección óptima

$$Y^*(X, P) \in \mathbb{R}^n, \quad Y_i^*(X, P) := \frac{P_i}{X_i} - 1, \quad i = 1, \dots, n.$$

Entonces se verifican las siguientes afirmaciones.

(i) Nivel algebraico (corrección multiplicativa). *Para todo $X \in \Delta_n^\circ$ se tiene $Y^*(X, P) \in C(X)$ (Def. 2.1) y*

$$T_{Y^*(X, P)}(X) = P.$$

(ii) Nivel discreto (dinámica inducida). *Fijado $\alpha \in (0, 1]$, la iteración*

$$X_{k+1} := T_{\alpha Y^*(X_k, P)}(X_k), \quad X_0 \in \Delta_n^\circ,$$

se reduce a la interpolación convexa

$$X_{k+1} = (1 - \alpha)X_k + \alpha P,$$

y por tanto permanece en Δ_n° (Prop. 3.1).

(iii) Nivel continuo (límite infinitesimal y geometría Fisher). El límite de primer orden $\alpha \rightarrow 0$ de la regla $T_{\alpha Y}(X)$ conduce a la ecuación diferencial

$$\dot{X} = X \circ Y - X \langle X, Y \rangle.$$

Aplicada al campo óptimo $Y = Y^*(X, P)$, esta ecuación se reduce a

$$\dot{X} = P - X,$$

que coincide con el flujo de gradiente Fisher-KL del funcional E_P (Def. 4.5), es decir,

$$\dot{X} = -\text{grad}_g E_P(X) \quad (\text{Prop. 4.1}).$$

Demostración. (i) Sea $X \in \Delta_n^\circ$. Como $X_i > 0$ y $P_i > 0$ para todo i , se tiene $1 + Y_i^*(X, P) = P_i/X_i > 0$, luego $Y^*(X, P) \in C_{\text{glob}}$ (Def. 3.1). Además,

$$X_i(1 + Y_i^*(X, P)) = P_i \geq 0, \quad \sum_{i=1}^n X_i(1 + Y_i^*(X, P)) = \sum_{i=1}^n P_i = 1,$$

luego $Y^*(X, P) \in C(X)$ (Def. 2.1). Sustituyendo en el operador global,

$$T_{Y^*(X, P)}(X)_i = \frac{X_i(P_i/X_i)}{\sum_{j=1}^n X_j(P_j/X_j)} = \frac{P_i}{\sum_{j=1}^n P_j} = P_i,$$

y por tanto $T_{Y^*(X, P)}(X) = P$.

(ii) Sea $\alpha \in (0, 1]$ y $X \in \Delta_n^\circ$. Entonces

$$1 + \alpha Y_i^*(X, P) = (1 - \alpha) + \alpha \frac{P_i}{X_i},$$

y al sustituir en $T_{\alpha Y^*}(X)$ se obtiene, coordenada a coordenada,

$$T_{\alpha Y^*(X, P)}(X)_i = \frac{(1 - \alpha)X_i + \alpha P_i}{(1 - \alpha) \sum_j X_j + \alpha \sum_j P_j} = (1 - \alpha)X_i + \alpha P_i,$$

pues $\sum_j X_j = \sum_j P_j = 1$. Iterando, $X_{k+1} = (1 - \alpha)X_k + \alpha P$, y por ser combinación convexa de puntos de Δ_n° se mantiene $X_k \in \Delta_n^\circ$ (Prop. 3.1).

(iii) Partimos de

$$T_{\alpha Y}(X) = \frac{X + \alpha(X \circ Y)}{1 + \alpha \langle X, Y \rangle}.$$

Usando la expansión $\frac{1}{1+\alpha a} = 1 - \alpha a + o(\alpha)$,

$$T_{\alpha Y}(X) = X + \alpha(X \circ Y - X \langle X, Y \rangle) + o(\alpha),$$

lo que conduce a la ecuación diferencial anunciada.

Tomando $Y = Y^*(X, P)$,

$$X \circ Y^*(X, P) = P - X, \quad \langle X, Y^*(X, P) \rangle = \sum_i P_i - \sum_i X_i = 0,$$

y sustituyendo se obtiene $\dot{X} = P - X$. Por la Proposición 4.1, $\text{grad}_g E_P(X) = X - P$, de modo que

$$\dot{X} = P - X = -\text{grad}_g E_P(X).$$

Esto establece la equivalencia estructural entre los tres niveles. □

5. Sección E_0 — Semántica probabilística: Bayes y Markov como casos particulares

Esta sección dota al marco de Control Informacional de la semántica necesaria para que los operadores de las Secciones B–D puedan interpretarse y utilizarse como la actualización bayesiana clásica y el operador de Markov clásico, respectivamente. El objetivo no es ampliar el marco sino identificar, dentro de él, los casos particulares que corresponden a esos dos paradigmas, de manera que los problemas clásicos de Bayes y Markov puedan plantearse y resolverse en el lenguaje de CI.

5.1. Semántica bayesiana

La fundamentación bayesiana se construye en cuatro pasos, todos dentro del marco ya establecido. Primero se define el espacio conjunto hipótesis-observaciones como un espacio de probabilidad en el sentido de la Sección A. Segundo, se identifica la verosimilitud como la corrección global inducida por la probabilidad condicional sobre ese espacio. Tercero, se prueba que T_{Y^ℓ} coincide con el posterior de Bayes. Cuarto, se establece la unicidad: T_{Y^ℓ} es el único operador en $\mathcal{G}$ que es coherente con la probabilidad condicional del espacio conjunto.

Definición 5.1 (Espacio conjunto hipótesis-observaciones). *Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad (Definición 1.1) y sea*

$$\Pi_H = \{H_1, \dots, H_n\} \subset \mathcal{F}$$

una partición medible finita no degenerada de Ω , cuyos elementos se interpretan como hipótesis alternativas. Sea $\Pi_E = \{E_1, \dots, E_m\} \subset \mathcal{F}$ una segunda partición medible finita no degenerada de Ω , cuyos elementos se interpretan como observaciones posibles.

El espacio conjunto es el mismo espacio $(\Omega, \mathcal{F}, P)$, equipado con las dos particiones simultáneamente. El estado informacional previo (prior) es el vector

$$X_i := P(H_i), \quad i = 1, \dots, n,$$

que por la Proposición 1.1 pertenece a Δ_n° .

Observación 5.1 (Por qué una sola medida P). *Las dos particiones Π_H y Π_E viven sobre el mismo espacio $(\Omega, \mathcal{F}, P)$. Esto permite definir todas las probabilidades conjuntas y condicionales necesarias directamente desde P , sin recurrir a estructuras adicionales. En particular, $P(H_i \cap E_j)$, $P(H_i | E_j)$ y $P(E_j | H_i)$ son todos objetos bien definidos dentro de la Definición 1.1.*

Definición 5.2 (Verosimilitud como corrección global). *Sea $j \in \{1, \dots, m\}$ un índice de observación con $P(E_j) > 0$. La verosimilitud de la observación E_j bajo la hipótesis H_i es*

$$\ell_i^{(j)} := P(E_j | H_i) = \frac{P(H_i \cap E_j)}{P(H_i)}, \quad i = 1, \dots, n.$$

Como $P(H_i) > 0$ (partición no degenerada) y $P(H_i \cap E_j) \geq 0$, se tiene $\ell_i^{(j)} \geq 0$. La condición $\ell_i^{(j)} > 0$ para todo i equivale a que la observación E_j sea compatible con cada hipótesis, es decir, $P(H_i \cap E_j) > 0$ para todo i .

Cuando esta condición se satisface, el vector $\ell^{(j)} = (\ell_1^{(j)}, \dots, \ell_n^{(j)}) \in \mathbb{R}_{>0}^n$ define una corrección global $Y^{\ell^{(j)}} \in C_{\text{glob}}$ (Definición 3.1) mediante

$$1 + Y_i^{\ell^{(j)}} := \ell_i^{(j)} = P(E_j | H_i).$$

Proposición 5.1 (El operador bayesiano como caso particular de T_Y). Sea $X \in \Delta_n^\circ$ el prior con $X_i = P(H_i)$, y sea $\ell^{(j)} \in \mathbb{R}_{>0}^n$ la verosimilitud de E_j . Entonces

$$T_{Y^{\ell^{(j)}}}(X)_i = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}} = P(H_i | E_j), \quad i = 1, \dots, n.$$

Es decir, $T_{Y^{\ell^{(j)}}}(X)$ es el estado informacional posterior dado que se observó E_j .

Demostración. Por la regla de Bayes y la ley de probabilidad total,

$$P(H_i | E_j) = \frac{P(E_j | H_i) P(H_i)}{P(E_j)} = \frac{\ell_i^{(j)} X_i}{\sum_{k=1}^n P(E_j | H_k) P(H_k)} = \frac{\ell_i^{(j)} X_i}{\sum_{k=1}^n \ell_k^{(j)} X_k}.$$

Por la Definición 3.2 con factores $a_i = 1 + Y_i^{\ell^{(j)}} = \ell_i^{(j)}$,

$$T_{Y^{\ell^{(j)}}}(X)_i = \frac{X_i \ell_i^{(j)}}{\sum_{k=1}^n X_k \ell_k^{(j)}}.$$

Ambas expresiones coinciden. □

Proposición 5.2 (Unicidad: $T_{Y^{\ell^{(j)}}}$ es el único operador coherente con P). Sea $(\Omega, \mathcal{F}, P)$ el espacio conjunto de la Definición 5.1 con particiones Π_H y Π_E . Sea $j \in \{1, \dots, m\}$ con $P(H_i \cap E_j) > 0$ para todo i . Un operador $T \in \mathcal{G}$ satisface

$$T(X)_i = P(H_i | E_j) \quad \text{para todo } i = 1, \dots, n$$

si y sólo si $T = T_{Y^{\ell^{(j)}}}$, donde $Y^{\ell^{(j)}}$ es la corrección de la Definición 5.2.

En otras palabras, dentro de $\mathcal{G}$, la actualización bayesiana es la única que produce el posterior correcto determinado por P .

Demostración. La suficiencia es la Proposición 5.1.

Para la necesidad: supóngase que $T_Y \in \mathcal{G}$ satisface $T_Y(X)_i = P(H_i | E_j)$ para todo i . Por la Definición 3.2,

$$T_Y(X)_i = \frac{X_i(1 + Y_i)}{\sum_{k=1}^n X_k(1 + Y_k)}.$$

Igualando con $P(H_i | E_j) = \ell_i^{(j)} X_i / \sum_k \ell_k^{(j)} X_k$, se obtiene para cada i :

$$\frac{X_i(1 + Y_i)}{\sum_k X_k(1 + Y_k)} = \frac{X_i \ell_i^{(j)}}{\sum_k X_k \ell_k^{(j)}}.$$

Como $X_i > 0$, dividiendo numerador y denominador:

$$\frac{1 + Y_i}{\sum_k X_k(1 + Y_k)} = \frac{\ell_i^{(j)}}{\sum_k X_k \ell_k^{(j)}}.$$

Sea $c := \frac{\sum_k X_k(1+Y_k)}{\sum_k X_k \ell_k^{(j)}} > 0$. Entonces $1 + Y_i = c \ell_i^{(j)}$ para todo i , es decir, $Y = Y^{c\ell^{(j)}}$. Por la invariancia de escala (Proposición 3.2), $T_{Y^{c\ell^{(j)}}} = T_{Y^{\ell^{(j)}}}$. Luego $T_Y = T_{Y^{\ell^{(j)}}}$. $\square$

Observación 5.2 (Alcance de la unicidad). *La Proposición 5.2 establece unicidad dentro de $\mathcal{G}$: dado el espacio conjunto $(\Omega, \mathcal{F}, P)$, el posterior $P(H_i | E_j)$ está unívocamente determinado, y el único operador global que lo produce es $T_{Y^{\ell^{(j)}}}$. Lo que no establece es que $\mathcal{G}$ sea la única familia de operadores razonable en general; eso requeriría un argumento de coherencia normativa (tipo Cox o De Finetti) que queda fuera del alcance de este trabajo. Lo que sí se garantiza es que, dentro del marco de CI, la regla de Bayes no admite alternativas en $\mathcal{G}$.*

Corolario 5.1 (Actualización bayesiana secuencial como composición en $\mathcal{G}$). *Sean $E_{j_1}, \dots, E_{j_m}$ observaciones sucesivas con $P(H_i \cap E_{j_s}) > 0$ para todo i, s . Sea $X_0 = X \in \Delta_n^\circ$ el prior inicial. Por la Proposición 5.2, cada paso s produce el único operador coherente con $P(\cdot | E_{j_s})$. El posterior tras las m observaciones es*

$$X_m = T_{Y^{\ell^{(j_m)}}} \circ \dots \circ T_{Y^{\ell^{(j_1)}}}(X_0),$$

y por la Proposición 3.2 este operador compuesto tiene factores

$$1 + (Y^{\text{tot}})_i = \prod_{s=1}^m \ell_i^{(j_s)}.$$

Si además las observaciones son condicionalmente independientes dadas las hipótesis, es decir,

$$P(E_{j_1} \cap \dots \cap E_{j_m} | H_i) = \prod_{s=1}^m P(E_{j_s} | H_i),$$

entonces Y^{tot} coincide con la corrección de la observación conjunta $E_{j_1} \cap \dots \cap E_{j_m}$, y la actualización secuencial es idéntica a la simultánea.

En coordenadas logarítmicas (Observación 3.3), la acumulación de evidencia es aditiva:

$$\log(1 + (Y^{\text{tot}})_i) = \sum_{s=1}^m \log \ell_i^{(j_s)}.$$

Demostración. La forma del operador compuesto es la Proposición 3.2. La identificación del operador compuesto con la observación conjunta bajo independencia condicional se sigue de que $P(E_{j_1} \cap \dots \cap E_{j_m} | H_i) = \prod_s \ell_i^{(j_s)}$, que es precisamente el factor del operador compuesto. $\square$

Proposición 5.3 (Corrección óptima hacia el posterior). *Sean $X, \pi \in \Delta_n^\circ$. El único elemento de $\mathcal{G}$ (salvo escala proyectiva) que lleva X a π en un paso es T_{Y^*} con*

$$1 + Y_i^* = c \frac{\pi_i}{X_i}, \quad c > 0.$$

Si $\pi = P(H_i | E_j)$ es el posterior, entonces por la Proposición 5.2 este operador coincide con $T_{Y^{\ell^{(j)}}}$, y la corrección óptima satisface $\ell_i^{(j)} \propto \pi_i / X_i$.

Demostración. Por el Teorema 4.1(i), el campo que lleva X a π satisface $1 + Y_i^* = \pi_i / X_i$. La unicidad salvo escala se sigue de la estructura de grupo de $\mathcal{G}$ (Corolario de la Proposición 3.2). La identificación con $\ell^{(j)}$ se sigue de la Proposición 5.2: el único operador de $\mathcal{G}$ que produce $P(H_i | E_j)$ desde X tiene factores proporcionales a $P(H_i | E_j) / X_i = \ell_i^{(j)} / \sum_k \ell_k^{(j)} X_k$. $\square$

5.2. Puente estructural hacia Markov

Antes de introducir la semántica markoviana conviene precisar por qué las cadenas de Markov entran en CI a través de la Sección B y no de la Sección C. La diferencia es estructural: la actualización bayesiana repondera coordenadas por factores fijos independientes del estado, mientras que un operador de Markov redistribuye masa entre coordenadas mediante una matriz, produciendo una corrección que depende del estado base.

Definición 5.3 (Conjunto de matrices estocásticas por filas). *Se define*

$$\mathcal{S}_n := \left\{ K \in \mathbb{R}^{n \times n} \mid K_{ij} \geq 0 \text{ para todo } i, j, \quad \sum_{j=1}^n K_{ij} = 1 \text{ para todo } i \right\}.$$

Los elementos de $\mathcal{S}_n$ se llaman matrices estocásticas por filas o matrices de transición.

Proposición 5.4 (El simplex es invariante bajo $\mathcal{S}_n$). *Sea $K \in \mathcal{S}_n$ y sea $X \in \Delta_n$. Entonces $XK \in \Delta_n$. En particular, toda $K \in \mathcal{S}_n$ induce un operador bien definido*

$$L_K : \Delta_n \longrightarrow \Delta_n, \quad L_K(X) := XK.$$

Demostración. Para cada j ,

$$(XK)_j = \sum_{i=1}^n X_i K_{ij} \geq 0,$$

pues $X_i \geq 0$ y $K_{ij} \geq 0$. Además,

$$\sum_{j=1}^n (XK)_j = \sum_{j=1}^n \sum_{i=1}^n X_i K_{ij} = \sum_{i=1}^n X_i \underbrace{\sum_{j=1}^n K_{ij}}_{=1} = \sum_{i=1}^n X_i = 1.$$

Luego $XK \in \Delta_n$. $\square$

Observación 5.3 (Sobre la preservación del interior). *La Proposición 5.4 garantiza $L_K(\Delta_n) \subset \Delta_n$, pero no $L_K(\Delta_n^\circ) \subset \Delta_n^\circ$ para una $K \in \mathcal{S}_n$ general. Una condición suficiente para preservar el interior es $K_{ij} > 0$ para todo i, j , pero no es necesaria: la matriz identidad, por ejemplo, preserva Δ_n° y tiene ceros fuera de la diagonal. En lo que sigue se trabajará con $X_t \in \Delta_n$ salvo que se indique explícitamente una hipótesis de positividad. La corrección local $Y^K(X)$ requiere $X \in \Delta_n^\circ$ para que los cocientes $(XK)_i / X_i$ estén definidos, por lo que en esa proposición se impondrá dicha hipótesis.*

Proposición 5.5 (Markov entra por la Sección B, no por la Sección C). *Sea $K \in \mathcal{S}_n$ y sea $X \in \Delta_n^\circ$. El paso markoviano $L_K(X) = XK$ puede representarse como una corrección local en el sentido de la Sección B mediante*

$$Y_i^K(X) := \frac{(XK)_i}{X_i} - 1, \quad i = 1, \dots, n.$$

Se tiene $Y^K(X) \in C(X)$ y $T_{Y^K(X)}^{\text{loc}}(X) = XK$.

Por el contrario, salvo el caso trivial $K = I$, el operador L_K no puede representarse como un operador global $T_Y \in \mathcal{G}$ con Y independiente de X .

Demostración. Para cada i : $X_i(1 + Y_i^K(X)) = (XK)_i \geq 0$, y $\sum_i X_i(1 + Y_i^K(X)) = \sum_i (XK)_i = 1$. Luego $Y^K(X) \in C(X)$ y $T_{Y^K(X)}^{\text{loc}}(X)_i = (XK)_i$ por la Definición 2.2.

Para la segunda parte: supóngase que existe $a \in \mathbb{R}_{>0}^n$ tal que $T_a(X) = XK$ para todo $X \in \Delta_n^\circ$. Si $a_i = c$ para todo i , entonces $T_a(X)_i = X_i$ para todo X , que coincide con XK sólo si $K = I$. Si a no es proporcional a $(1, \dots, 1)$, entonces $T_a(X)$ depende de X de forma no lineal a través del denominador $\sum_k X_k a_k$, mientras que $(XK)_i = \sum_j X_j K_{ji}$ es lineal en X ; estas dos funciones no pueden coincidir para todo $X \in \Delta_n^\circ$ salvo en el caso degenerado anterior. En consecuencia, para $K \neq I$ no existe $Y \in C_{\text{glob}}$ independiente de X tal que $T_Y(X) = XK$ para todo X . $\square$

Observación 5.4 (La ruta conceptual de cada paradigma). *El puente queda así fijado:*

$$\underbrace{A : X \in \Delta_n}_{\text{dominio}} \longrightarrow \underbrace{B : T_{Y^K(X)}^{\text{loc}}}_{\text{Markov}} \quad y \quad \underbrace{A : X \in \Delta_n^\circ}_{\text{dominio}} \longrightarrow \underbrace{C : T_Y \in \mathcal{G}}_{\text{Bayes}}.$$

La Sección D interviene en ambos casos: para Bayes, el funcional $E_P(X) = D_{\text{KL}}(P||X)$ mide la distancia al posterior y el flujo $\dot{X} = P - X$ describe la convergencia continua; para Markov, el mismo funcional con $P = \pi$ estacionaria mide el desfase hacia el equilibrio y la Proposición 5.7 garantiza su disipación paso a paso.

5.3. Semántica markoviana

Definición 5.4 (Proceso de Markov discreto sobre Δ_n). Sea $\mathcal{S} = \{1, \dots, n\}$ un espacio de estados finito. Una cadena de Markov homogénea sobre $\mathcal{S}$ con distribución inicial $X_0 \in \Delta_n$ y matriz de transición $K \in \mathcal{S}_n$ es una sucesión de variables aleatorias $(\xi_t)_{t \geq 0}$ sobre $\mathcal{S}$ tal que:

- (I) $P(\xi_0 = i) = X_{0,i}$ para todo $i = 1, \dots, n$;
- (II) $P(\xi_{t+1} = j \mid \xi_t = i, \xi_{t-1}, \dots, \xi_0) = K_{ij}$ para todo $t \geq 0$ y todo i, j .

El estado informacional en el tiempo t es el vector

$$X_t = (P(\xi_t = 1), \dots, P(\xi_t = n)) \in \Delta_n,$$

que representa la distribución marginal de ξ_t . Por la Proposición 5.4, $X_t \in \Delta_n$ para todo $t \geq 0$. Si además $K_{ij} > 0$ para todo i, j , entonces $X_t \in \Delta_n^\circ$ para todo $t \geq 1$.

Proposición 5.6 (El operador de Markov como corrección local dependiente del estado). Sea $K \in \mathcal{S}_n$ y sea $X \in \Delta_n^\circ$. El vector de corrección local $Y^K(X)$ definido en la Proposición 5.5 satisface $Y^K(X) \in C(X)$ y

$$T_{Y^K(X)}^{\text{loc}}(X) = XK.$$

Demostración. Probado en la Proposición 5.5. $\square$

Observación 5.5 (Carácter local de Markov frente al carácter global de Bayes). La corrección $Y^K(X)$ depende del estado base X : es una corrección local en el sentido de la Sección B. La verosimilitud bayesiana Y^ℓ no depende de X : es una corrección global en el sentido de la Sección C. La Proposición 5.5 demuestra que esta asimetría es estructural: Markov mezcla coordenadas mediante K ; Bayes escala coordenadas por factores fijos.

Definición 5.5 (Distribución estacionaria en CI). Sea $K \in \mathcal{S}_n$. Una distribución $\pi \in \Delta_n^\circ$ se llama estacionaria para K si

$$\pi K = \pi.$$

Equivalentemente en CI: π es estacionaria si y sólo si $Y^K(\pi) = 0$, pues $Y_i^K(\pi) = (\pi K)_i / \pi_i - 1 = 0$ para todo i .

Proposición 5.7 (Disipación de la divergencia KL hacia la estacionaria). Sea $K \in \mathcal{S}_n$ y sea $\pi \in \Delta_n^\circ$ su distribución estacionaria. Sea $E_\pi(X) = D_{\text{KL}}(\pi \| X)$ el funcional de la Sección D. Entonces, para todo $X \in \Delta_n^\circ$,

$$E_\pi(XK) \leq E_\pi(X).$$

Es decir, un paso del operador de Markov no incrementa la divergencia KL hacia la estacionaria.

Demostración. Como π es estacionaria, $\pi_j = \sum_i \pi_i K_{ij}$ para todo j . Por tanto,

$$D_{\text{KL}}(\pi \| XK) = \sum_j \pi_j \log \frac{\pi_j}{(XK)_j} = \sum_j \left(\sum_i \pi_i K_{ij} \right) \log \frac{\sum_i \pi_i K_{ij}}{\sum_i X_i K_{ij}}.$$

Para cada j fijo, los pesos $w_{ij} := \pi_i K_{ij} / \pi_j$ satisfacen $w_{ij} \geq 0$ y $\sum_i w_{ij} = 1$. Aplicando la desigualdad de Jensen a la función cóncava $\log$,

$$\log \frac{\sum_i \pi_i K_{ij}}{\sum_i X_i K_{ij}} \leq \sum_i w_{ij} \log \frac{\pi_i}{X_i}.$$

Multiplicando por π_j y sumando en j ,

$$D_{\text{KL}}(\pi \| XK) \leq \sum_j \sum_i \pi_i K_{ij} \log \frac{\pi_i}{X_i} = \sum_i \pi_i \log \frac{\pi_i}{X_i} \underbrace{\sum_j K_{ij}}_{=1} = D_{\text{KL}}(\pi \| X).$$

□

Proposición 5.8 (Trayectoria markoviana como trayectoria local de CI). Sea $K \in \mathcal{S}_n$ y sea $X_0 \in \Delta_n$. La trayectoria markoviana $X_{t+1} = X_t K$ satisface $X_t \in \Delta_n$ para todo $t \geq 0$ (Proposición 5.4). Cuando $X_t \in \Delta_n^\circ$, cada paso puede escribirse como

$$X_{t+1} = T_{Y^K(X_t)}^{\text{loc}}(X_t),$$

y en forma cerrada,

$$X_t = X_0 K^t.$$

Si además K es primitiva (existe $m \geq 1$ con $K_{ij}^m > 0$ para todo i, j), entonces K admite una única distribución estacionaria $\pi \in \Delta_n^\circ$, y para todo $X_0 \in \Delta_n^\circ$,

$$E_\pi(X_t) = D_{\text{KL}}(\pi \| X_t) \searrow 0 \quad (t \rightarrow \infty),$$

con convergencia garantizada por la Proposición 5.7 y la ergodicidad de K .

Demostración. La invariancia de Δ_n es la Proposición 5.4. Para $X_t \in \Delta_n^\circ$, la representación como operador local es la Proposición 5.6. La forma cerrada $X_t = X_0 K^t$ se obtiene por inducción: si $X_t = X_0 K^t$, entonces $X_{t+1} = X_t K = X_0 K^{t+1}$. La convergencia $E_\pi(X_t) \rightarrow 0$ se sigue de la Proposición 5.7 y del teorema de Perron–Frobenius aplicado a matrices primitivas, que garantiza $X_t \rightarrow \pi$. $\square$

5.4. Cadenas absorbentes y frontera del símplex

Las cadenas absorbentes extienden el marco markoviano hacia la frontera $\partial\Delta_n$. Los estados absorbentes son vértices canónicos $\delta_a \in \partial\Delta_n$ que son puntos fijos de L_K ; los estados transitorios viven inicialmente en el interior pero convergen a la frontera. Esta subsección formaliza esa extensión dentro del lenguaje de CI, fundándose en la Proposición 5.4 y en la Proposición 5.8.

Definición 5.6 (Estado absorbente en CI). Sea $K \in \mathcal{S}_n$. Un estado $a \in \{1, \dots, n\}$ se llama absorbente si $K_{aa} = 1$ (y por tanto $K_{aj} = 0$ para $j \neq a$). El vértice canónico $\delta_a \in \partial\Delta_n$ satisface

$$\delta_a K = \delta_a,$$

es decir, δ_a es un punto fijo de L_K en la frontera del símplex.

En una cadena absorbente se distinguen los estados absorbentes $\mathcal{A}$ y los estados transitorios $\mathcal{T}$, entendidos como aquellos desde los cuales la cadena alcanza algún estado absorbente con probabilidad uno. La cadena se dice absorbente si todo estado no absorbente pertenece a $\mathcal{T}$, es decir, si desde cualquier estado no absorbente existe una trayectoria con probabilidad positiva hacia algún estado de $\mathcal{A}$.

Observación 5.6 (Estados absorbentes y frontera de Δ_n). Los estados absorbentes viven en la frontera $\partial\Delta_n = \Delta_n \setminus \Delta_n^\circ$. Por eso la corrección local $Y_i^K(X) = (XK)_i / X_i - 1$ no está definida en δ_a : la coordenada a vale 1 y las demás valen 0, haciendo los cocientes indefinidos en las coordenadas nulas. La trayectoria $X_t = X_0 K^t$ sí está bien definida para todo t por la Proposición 5.4, incluso cuando X_t alcanza la frontera. La representación como corrección local (Proposición 5.6) aplica solo mientras $X_t \in \Delta_n^\circ$.

Definición 5.7 (Forma canónica de una cadena absorbente). Sea $K \in \mathcal{S}_n$ una cadena absorbente con r estados absorbentes y $s = n - r$ estados transitorios. Reordenando los estados con los transitorios primero y los absorbentes al final, la matriz K toma la forma canónica

$$K = \begin{pmatrix} Q & R \\ 0 & I_r \end{pmatrix},$$

donde $Q \in \mathbb{R}^{s \times s}$ es la submatriz de transición entre estados transitorios, $R \in \mathbb{R}^{s \times r}$ es la submatriz de transición de estados transitorios a absorbentes, 0 es la matriz nula $r \times s$, e I_r es la identidad $r \times r$.

Proposición 5.9 (Matriz fundamental y absorción). Sea K una cadena absorbente en forma canónica (Definición 5.7). Entonces:

(I) La serie $\sum_{t=0}^{\infty} Q^t$ converge y su suma es la matriz fundamental

$$N := (I_s - Q)^{-1}.$$

(II) La entrada N_{ij} es el número esperado de veces que la cadena visita el estado transitorio j antes de ser absorbida, dado que parte del estado transitorio i .

(III) La matriz de probabilidades de absorción es

$$B := NR \in \mathbb{R}^{s \times r},$$

donde B_{ia} es la probabilidad de ser absorbido en el estado absorbente a , dado que la cadena parte del estado transitorio i .

(IV) El tiempo esperado de absorción desde el estado transitorio i es

$$\tau_i = (N\mathbf{1})_i = \sum_{j=1}^s N_{ij},$$

donde $\mathbf{1}$ es el vector de unos.

Demostración. Como K es absorbente, todos los valores propios de Q tienen módulo estrictamente menor que 1. Por tanto $(I_s - Q)$ es invertible y $Q^t \rightarrow 0$ cuando $t \rightarrow \infty$, lo que garantiza la convergencia de $\sum_{t=0}^{\infty} Q^t = (I_s - Q)^{-1} = N$.

Para (ii): la entrada $(Q^t)_{ij}$ es la probabilidad de estar en el estado transitorio j en el tiempo t habiendo partido de i sin haber sido absorbido. Sumando en t , $N_{ij} = \sum_{t=0}^{\infty} (Q^t)_{ij}$ es el número esperado de visitas a j antes de absorción.

Para (iii): R_{ia} es la probabilidad de pasar del estado transitorio i al absorbente a en un paso. Condicionando sobre el primer paso, la probabilidad total de absorción en a desde i es $(NR)_{ia}$. Como la cadena es absorbente, $B\mathbf{1} = \mathbf{1}$ (la cadena es absorbida con probabilidad 1).

Para (iv): el número esperado de pasos hasta la absorción desde i es la suma de las visitas esperadas a todos los estados transitorios, que es $\sum_j N_{ij} = (N\mathbf{1})_i$. $\square$

Observación 5.7 (Lectura en CI: absorción como convergencia a la frontera). *En el lenguaje de CI, la Proposición 5.9 describe cómo la trayectoria $X_t = X_0 K^t$ converge a un punto de la frontera $\partial\Delta_n$. Si $X_0 = \delta_i$ (estado transitorio i), entonces*

$$\lim_{t \rightarrow \infty} X_t = \sum_a B_{ia} \delta_a,$$

que es una combinación convexa de los vértices absorbentes con pesos dados por las probabilidades de absorción B_{ia} . Este límite pertenece a la cara del simplex generada por los vértices absorbentes.

Definición 5.8 (Ecuaciones de primer paso). *Sea K una cadena absorbente con estados absorbentes $\mathcal{A}$ y estados transitorios $\mathcal{T}$. Sea $a \in \mathcal{A}$ un estado absorbente fijo. La probabilidad de absorción en a desde i es $h_i^{(a)} := P_i(T_a < T_{\mathcal{A} \setminus \{a\}})$, donde T_b denota el primer tiempo de llegada al estado b .*

Estas probabilidades satisfacen las ecuaciones de primer paso:

$$h_i^{(a)} = \sum_{j \in \mathcal{T}} K_{ij} h_j^{(a)} + K_{ia}, \quad i \in \mathcal{T},$$

con condiciones de frontera $h_a^{(a)} = 1$ y $h_{a'}^{(a)} = 0$ para $a' \in \mathcal{A}$, $a' \neq a$.

En forma matricial: $h^{(a)} = Qh^{(a)} + R_{\cdot a}$, es decir,

$$h^{(a)} = (I_s - Q)^{-1} R_{\cdot a} = NR_{\cdot a} = B_{\cdot a},$$

que es la columna a de la matriz $B = NR$.

Corolario 5.2 (Ruina del jugador en CI). Sea $\mathcal{S} = \{0, 1, \dots, N\}$ con estados absorbentes $\{0, N\}$ y estados transitorios $\{1, \dots, N-1\}$. En cada paso, desde el estado $i \in \{1, \dots, N-1\}$, la cadena transita a $i+1$ con probabilidad p y a $i-1$ con probabilidad $q = 1-p$.

La probabilidad de absorción en N (no arruinarse) desde el estado i satisface las ecuaciones de primer paso

$$h_i = ph_{i+1} + qh_{i-1}, \quad 1 \leq i \leq N-1,$$

con $h_0 = 0$ y $h_N = 1$. La solución es:

$$h_i = \begin{cases} \frac{1 - (q/p)^i}{1 - (q/p)^N} & \text{si } p \neq q, \\ \frac{i}{N} & \text{si } p = q = \frac{1}{2}. \end{cases}$$

El tiempo esperado de absorción desde i satisface

$$\tau_i = 1 + p\tau_{i+1} + q\tau_{i-1}, \quad 1 \leq i \leq N-1,$$

con $\tau_0 = \tau_N = 0$. La solución es:

$$\tau_i = \begin{cases} \frac{1}{q-p} \left[i - N \frac{1 - (q/p)^i}{1 - (q/p)^N} \right] & \text{si } p \neq q, \\ i(N-i) & \text{si } p = q = \frac{1}{2}. \end{cases}$$

En CI: la trayectoria informacional converge a la cara generada por $\{\delta_0, \delta_N\}$ de $\partial\Delta_{N+1}$,

$$\lim_{t \rightarrow \infty} \delta_i K^t = (1 - h_i)\delta_0 + h_i\delta_N,$$

con pesos $(1 - h_i, h_i)$.

Demostración. Las ecuaciones de primer paso para h_i son la Definición 5.8 aplicada a la cadena de ruina del jugador, que tiene $Q_{i,i+1} = p$ y $Q_{i,i-1} = q$ para $1 \leq i \leq N-1$ (ceros en el resto). La solución de la recurrencia lineal de segundo orden $h_i = ph_{i+1} + qh_{i-1}$, equivalente a $p(h_{i+1} - h_i) = q(h_i - h_{i-1})$, es geométrica si $p \neq q$ y lineal si $p = q$, con constantes determinadas por las condiciones de frontera $h_0 = 0$, $h_N = 1$.

Las ecuaciones para τ_i son la Definición 5.8 aplicada al tiempo esperado, que satisface $\tau_i = 1 + p\tau_{i+1} + q\tau_{i-1}$ con $\tau_0 = \tau_N = 0$. La solución se obtiene por variación de parámetros sobre la solución homogénea.

La lectura en CI se sigue de la Observación 5.7: $\lim_{t \rightarrow \infty} \delta_i K^t = B_{i,0}\delta_0 + B_{i,N}\delta_N = (1 - h_i)\delta_0 + h_i\delta_N$. $\square$

5.5. Clasificación de estados en CI

La clasificación de estados de una cadena de Markov —comunicación, recurrencia, transitividad y periodicidad— se puede formular completamente dentro de CI usando únicamente el operador L_K y la trayectoria $X_t = X_0 K^t$ ya establecidos. El objeto clave es la potencia K^t , cuyas entradas $(K^t)_{ij}$ son accesibles como coordenadas de la trayectoria $\delta_i K^t \in \Delta_n$.

Definición 5.9 (Accesibilidad y comunicación). Sea $K \in \mathcal{S}_n$. Se dice que el estado j es accesible desde el estado i , y se escribe $i \rightarrow j$, si existe $t \geq 0$ tal que

$$(K^t)_{ij} > 0.$$

En el lenguaje de CI, esto equivale a que la trayectoria $\delta_i K^t$ tenga masa positiva en la coordenada j para algún t , es decir,

$$(\delta_i K^t)_j > 0 \quad \text{para algún } t \geq 0.$$

Dos estados i y j se dicen comunicantes, y se escribe $i \leftrightarrow j$, si $i \rightarrow j$ y $j \rightarrow i$.

Proposición 5.10 (Comunicación es relación de equivalencia). La relación $\leftrightarrow$ es una relación de equivalencia sobre $\{1, \dots, n\}$. Sus clases de equivalencia se llaman clases comunicantes.

Demostración. Reflexividad: $(K^0)_{ii} = 1 > 0$, luego $i \rightarrow i$ para todo i .

Simetría: por definición de $\leftrightarrow$.

Transitividad: si $i \rightarrow j$ y $j \rightarrow k$, existen $s, t \geq 0$ con $(K^s)_{ij} > 0$ y $(K^t)_{jk} > 0$. Entonces

$$(K^{s+t})_{ik} = \sum_m (K^s)_{im} (K^t)_{mk} \geq (K^s)_{ij} (K^t)_{jk} > 0,$$

luego $i \rightarrow k$. Si además $j \rightarrow i$ y $k \rightarrow j$, entonces $k \rightarrow i$ por el mismo argumento. $\square$

Definición 5.10 (Clase cerrada). Una clase comunicante $C \subset \{1, \dots, n\}$ se dice cerrada si

$$K_{ij} = 0 \quad \text{para todo } i \in C, j \notin C.$$

En CI: C es cerrada si y sólo si $L_K(\delta_i) = \delta_i K$ tiene soporte contenido en C para todo $i \in C$, es decir, la trayectoria desde cualquier estado de C permanece en C .

Observación 5.8 (Clases cerradas y caras del simplex). Una clase cerrada C corresponde a una cara del simplex Δ_n : el subconjunto

$$F_C := \{X \in \Delta_n : X_i = 0 \ \forall i \notin C\}$$

es cerrado bajo L_K , pues si $X \in F_C$ entonces $(XK)_j = \sum_i X_i K_{ij} = 0$ para todo $j \notin C$ (ya que $K_{ij} = 0$ cuando $i \in C$ y $j \notin C$). Los estados absorbentes de la subsección anterior son el caso particular $|C| = 1$.

Definición 5.11 (Estados recurrentes y transitorios). Sea $i \in \{1, \dots, n\}$. El estado i se llama recurrente si

$$\sum_{t=1}^{\infty} (K^t)_{ii} = +\infty,$$

y transitorio si

$$\sum_{t=1}^{\infty} (K^t)_{ii} < +\infty.$$

En CI: $(K^t)_{ii} = (\delta_i K^t)_i$ es la masa que la trayectoria $\delta_i K^t$ devuelve a la coordenada i en el tiempo t . El estado i es recurrente si la masa acumulada de retorno es infinita, y transitorio si es finita.

Proposición 5.11 (Recurrencia y transitividad son propiedades de clase). *Si $i \leftrightarrow j$, entonces i es recurrente si y sólo si j es recurrente. En particular, todos los estados de una clase comunicante son simultáneamente recurrentes o simultáneamente transitorios.*

Demostración. Si $i \leftrightarrow j$, existen $s, t \geq 0$ con $\alpha := (K^s)_{ij} > 0$ y $\beta := (K^t)_{ji} > 0$. Para todo $m \geq 0$,

$$(K^{s+m+t})_{ii} \geq (K^s)_{ij}(K^m)_{jj}(K^t)_{ji} = \alpha\beta(K^m)_{jj}.$$

Sumando en m : $\sum_m (K^{s+m+t})_{ii} \geq \alpha\beta \sum_m (K^m)_{jj}$. Si j es recurrente, el lado derecho diverge, luego i es recurrente. Por simetría ($i \leftrightarrow j$ implica $j \leftrightarrow i$), también se tiene la implicación inversa. $\square$

Proposición 5.12 (Caracterización de clases recurrentes). *Una clase comunicante C es recurrente si y sólo si es cerrada. En particular:*

(I) *Todo estado absorbente (clase cerrada de tamaño uno) es recurrente.*

(II) *Todo estado en una clase no cerrada es transitorio.*

(III) *En una cadena con espacio de estados finito, existe al menos una clase recurrente.*

Demostración. Si C es cerrada, la trayectoria desde $i \in C$ permanece en C (Definición 5.10). Como C es finita, la masa $(\delta_i K^t)_i$ no puede tender a cero sin retornar, y $\sum_t (K^t)_{ii} = +\infty$.

Si C no es cerrada, existe $i \in C$ y $j \notin C$ con $K_{ij} > 0$. Una vez que la trayectoria sale de C no puede regresar (pues $j \notin C$ y C no es accesible desde fuera por definición de clase comunicante). Luego $\sum_t (K^t)_{ii} < +\infty$ y i es transitorio.

Para (iii): en un espacio finito, la masa de la trayectoria debe acumularse en algún lugar; ese lugar es necesariamente una clase cerrada, que es recurrente por lo anterior. $\square$

Definición 5.12 (Periodo de un estado). *Sea $i \in \{1, \dots, n\}$. El periodo del estado i es*

$$d(i) := \gcd\{t \geq 1 : (K^t)_{ii} > 0\}.$$

Si el conjunto es vacío, se conviene $d(i) = +\infty$. En Cl: $d(i)$ es el máximo común divisor de los tiempos t para los cuales la trayectoria $\delta_i K^t$ devuelve masa positiva a la coordenada i .

El estado i se llama aperiódico si $d(i) = 1$.

Proposición 5.13 (El periodo es invariante en la clase). *Si $i \leftrightarrow j$, entonces $d(i) = d(j)$.*

Demostración. Sean $s, t \geq 0$ con $(K^s)_{ij} > 0$ y $(K^t)_{ji} > 0$. Si $(K^m)_{jj} > 0$, entonces

$$(K^{s+m+t})_{ii} \geq (K^s)_{ij}(K^m)_{jj}(K^t)_{ji} > 0,$$

luego $d(i) \mid s + m + t$. Como también $(K^{s+t})_{ii} \geq (K^s)_{ij}(K^t)_{ji} > 0$, se tiene $d(i) \mid s + t$. Por tanto $d(i) \mid m$ para todo m con $(K^m)_{jj} > 0$, lo que implica $d(i) \mid d(j)$. Por simetría $d(j) \mid d(i)$, luego $d(i) = d(j)$. $\square$

Definición 5.13 (Cadena irreducible y ergódica). *La cadena K se llama irreducible si tiene una única clase comunicante, es decir, si $i \leftrightarrow j$ para todo par $i, j \in \{1, \dots, n\}$.*

La cadena es ergódica si es irreducible y aperiódica ($d(i) = 1$ para todo i). Para cadenas ergódicas, la Proposición 5.8 garantiza que $X_t \rightarrow \pi$ para todo $X_0 \in \Delta_n$, donde π es la única distribución estacionaria.

Proposición 5.14 (Convergencia para cadenas ergódicas desde CI). Sea $K \in \mathcal{S}_n$ ergódica con distribución estacionaria $\pi \in \Delta_n^\circ$. Entonces para todo $X_0 \in \Delta_n^\circ$,

$$E_\pi(X_t) = D_{\text{KL}}(\pi \| X_t) \searrow 0 \quad (t \rightarrow \infty).$$

En particular, $X_t \rightarrow \pi$.

Demostración. Por la Proposición 5.7, la sucesión $E_\pi(X_t)$ es decreciente y acotada por abajo por 0 (Proposición 4.4), luego converge a algún $L \geq 0$. Supóngase que $L > 0$; entonces X_t no converge a π . Como Δ_n es compacto, existe una subsucesión $X_{t_k} \rightarrow X^* \neq \pi$. Por continuidad de L_K y la disipación, $E_\pi(X^*K) \leq E_\pi(X^*) = L$. Pero la ergodicidad de K implica que $(K^t)_{ij} > 0$ para t suficientemente grande, de modo que la trayectoria desde X^* se acerca a π , contradiciendo $E_\pi(X^*) = L > 0$. Por tanto $L = 0$ y $X_t \rightarrow \pi$. $\square$

Observación 5.9 (Alcance de la convergencia). La Proposición 5.14 garantiza convergencia pero no cuantifica su velocidad. La tasa de convergencia depende de la brecha espectral de K , definida como $1 - |\lambda_2|$ donde λ_2 es el segundo valor propio de K en módulo. Esa cuantificación requiere álgebra lineal espectral que queda fuera del alcance de este documento.

Observación 5.10 (No conmutatividad entre Bayes y Markov). En general, el operador bayesiano T_{Y^ℓ} y el operador de Markov L_K no conmutan. Las dos composiciones posibles son

$$T_{Y^\ell}(XK)_j = \frac{(XK)_j \ell_j}{\sum_m (XK)_m \ell_m} \quad y \quad (T_{Y^\ell}(X)K)_j = \frac{\sum_i X_i \ell_i K_{ij}}{\sum_k X_k \ell_k},$$

que son expresiones distintas porque la primera normaliza después de aplicar K , mientras que la segunda aplica K a un vector ya normalizado por ℓ . La diferencia entre ambos estados mide el efecto de intercambiar el orden de actualización informacional y transición estocástica. Determinar las condiciones exactas sobre (K, ℓ) bajo las cuales estas dos expresiones coinciden para todo $X \in \Delta_n^\circ$ queda como problema abierto dentro del marco de CI.

Observación 5.11 (Tabla de correspondencias CI $\leftrightarrow$ Bayes/Markov). El siguiente cuadro resume cómo los objetos del marco de CI se corresponden con los de los paradigmas clásicos.

Control Informacional	Bayes clásico	Markov clásico
$X \in \Delta_n^\circ$	distribución a priori	—
$X \in \Delta_n$	—	distribución en el tiempo t
$Y \in C_{\text{glob}}, 1 + Y_i = \ell_i$	verosimilitud $P(E_j H_i)$	—
$T_{Y^\ell}(X)$ (Sección C)	posterior $P(H_i E_j)$	—
$Y^K(X) \in C(X)$	—	corrección local de un paso
$T_{Y^K(X)}^{\text{loc}}(X)$ (Sección B)	—	XK , un paso de Markov
$\pi : Y^K(\pi) = 0$	—	distribución estacionaria
$E_\pi(X) = D_{\text{KL}}(\pi \ X)$ (Sección D)	distancia al posterior	energía hacia la estacionaria
$\mathcal{G}$, composición	actualizaciones secuenciales	no representa Markov globalmente

Ejemplo 5.1 (Diagnóstico médico bayesiano en CI). Sea $n = 2$, $H_1 = \{\text{enfermo}\}$, $H_2 = \{\text{sano}\}$. Prior: $X = (0,01, 0,99)$. Dato e : prueba positiva, con $\ell_1 = P(e | H_1) = 0,99$ y $\ell_2 = P(e | H_2) = 0,05$. La corrección global es $1 + Y_i^\ell = \ell_i$, y el posterior es

$$T_{Y^\ell}(X)_1 = \frac{0,01 \times 0,99}{0,01 \times 0,99 + 0,99 \times 0,05} = \frac{0,0099}{0,0099 + 0,0495} \approx 0,167.$$

5.6. Modelos continuos como estados informacionales discretos

El marco de las Secciones A–D opera exclusivamente sobre Δ_n con n finito. Sin embargo, ciertos modelos probabilísticos clásicos —como los modelos conjugados Beta-Binomial y Normal-Normal— tienen parámetros en espacios continuos. Esta subsección muestra cómo ingresar dichos modelos al marco de CI sin salir de él: el espacio continuo se convierte en un espacio de probabilidad $(\Omega, \mathcal{F}, P_0)$ concreto (Definición 1.1), la cuadrícula define una partición medible finita no degenerada (Definición 1.2), y las probabilidades de los eventos de esa partición producen el estado informacional en Δ_n° (Definición 1.4 y Proposición 1.1). La verosimilitud entra como corrección global (Definición 3.1) y la actualización es el operador T_{Y^ℓ} de la Sección C (Proposición 5.1).

Definición 5.14 (Partición paramétrica uniforme). *Sea $\Omega = (a, b) \subset \mathbb{R}$ un intervalo abierto y sea $\mathcal{F}$ la σ -álgebra de Borel en Ω . Sea P_0 una medida de probabilidad absolutamente continua sobre $(\Omega, \mathcal{F})$ con densidad $f : \Omega \rightarrow (0, \infty)$.*

Dado $n \geq 1$, sea $h := (b - a)/n$ el paso de discretización y defínase la partición paramétrica uniforme de paso h como la familia

$$\Pi_n := \{E_1, \dots, E_n\}, \quad E_i := (a + (i - 1)h, a + ih], \quad i = 1, \dots, n.$$

Esta es una partición medible finita de Ω en el sentido de la Definición 1.2. Como $f > 0$ en Ω , se tiene $P_0(E_i) > 0$ para todo i , de modo que Π_n es no degenerada.

El punto representativo del intervalo E_i es el punto medio

$$\theta_i := a + \left(i - \frac{1}{2}\right)h.$$

El estado informacional previo asociado a $(\Omega, \mathcal{F}, P_0, \Pi_n)$ es, por la Proposición 1.1,

$$X_{0,i} := P_0(E_i) = \int_{E_i} f(\theta) d\theta, \quad i = 1, \dots, n,$$

y $X_0 \in \Delta_n^\circ$.

Observación 5.12 (Relación entre $X_{0,i}$ y $f(\theta_i)$). *La definición exacta es $X_{0,i} = P_0(E_i) = \int_{E_i} f(\theta) d\theta$. Si $f \in C^2(\Omega)$, la regla del punto medio da*

$$X_{0,i} = f(\theta_i)h + O(h^3),$$

donde el error local es de orden $O(h^3)$ por intervalo. Esto motiva introducir el prior discreto por punto medio

$$\widetilde{X}_{0,i} := \frac{f(\theta_i)}{\sum_{k=1}^n f(\theta_k)}, \quad i = 1, \dots, n,$$

que pertenece a Δ_n° y aproxima $X_{0,i}$ con error $O(h^2)$ en cada coordenada normalizada. En lo que sigue se distinguirá explícitamente cuándo se usa la masa exacta $X_{0,i} = P_0(E_i)$ y cuándo la aproximación $\widetilde{X}_{0,i} \propto f(\theta_i)$.

Definición 5.15 (Verosimilitud como corrección global admisible). Sea e un dato observado y sea $\ell : (a, b) \rightarrow (0, \infty)$ una función de verosimilitud, es decir, $\ell(\theta) = P(e \mid \theta)$ para cada valor del parámetro θ . Sobre la partición Π_n , la verosimilitud del dato e bajo el evento E_i se define como

$$\ell_i := \ell(\theta_i), \quad i = 1, \dots, n.$$

Como $\ell(\theta) > 0$ para todo $\theta \in (a, b)$, se tiene $\ell_i > 0$ para todo i . Definiendo $Y^\ell \in \mathbb{R}^n$ por $1 + Y_i^\ell := \ell_i$, se obtiene $Y^\ell \in C_{\text{glob}}$ (Definición 3.1).

Observación 5.13 (Fundamento en la Sección B: cambio de medida normalizado). La corrección Y^ℓ induce un cambio de medida sobre $(\Omega, \mathcal{F}, P_0)$ en el sentido de la Proposición 2.2. La densidad de Radon-Nikodym de la medida posterior Q_{Y^ℓ} respecto de P_0 no es $\ell(\theta_i)$ directamente, sino su versión normalizada. Definiendo la constante de normalización

$$Z_n := \sum_{k=1}^n P_0(E_k) \ell(\theta_k),$$

la función

$$\tilde{h}(\omega) := \frac{\ell(\theta_i)}{Z_n}, \quad \omega \in E_i,$$

satisface $\int_\Omega \tilde{h} dP_0 = 1$ y define una medida de probabilidad $Q_{Y^\ell}(A) = \int_A \tilde{h} dP_0$. El estado informacional discreto de Q_{Y^ℓ} sobre Π_n es entonces

$$Q_{Y^\ell}(E_i) = \frac{P_0(E_i) \ell(\theta_i)}{Z_n} = T_{Y^\ell}(X_0)_i,$$

donde la última igualdad se sigue de la Proposición 2.3, y la normalización Z_n queda absorbida por el denominador de T_{Y^ℓ} .

Proposición 5.15 (Actualización bayesiana paramétrica en CI). Sea $(\Omega, \mathcal{F}, P_0, \Pi_n)$ una partición paramétrica uniforme con estado previo $X_0 \in \Delta_n^\circ$ y sea $Y^\ell \in C_{\text{glob}}$ la corrección de verosimilitud de la Definición 5.15. Entonces

$$T_{Y^\ell}(X_0)_i = \frac{P_0(E_i) \ell(\theta_i)}{\sum_{k=1}^n P_0(E_k) \ell(\theta_k)}, \quad i = 1, \dots, n,$$

y $T_{Y^\ell}(X_0) \in \Delta_n^\circ$. Este vector es la distribución posterior discreta de θ dado el dato e , obtenida aplicando la regla de Bayes discreta sobre la partición Π_n .

Además, si f y ℓ son continuas en Ω , cuando $n \rightarrow \infty$ (con $h = (b - a)/n \rightarrow 0$),

$$\sum_{k=1}^n P_0(E_k) \ell(\theta_k) \longrightarrow \int_a^b f(\theta) \ell(\theta) d\theta,$$

y la distribución discreta $T_{Y^\ell}(X_0)$ converge a la distribución posterior continua con densidad proporcional a $f(\theta)\ell(\theta)$.

Demostración. La primera parte es aplicación directa de la Proposición 5.1: dado que $X_{0,i} = P_0(E_i) > 0$ y $1 + Y_i^\ell = \ell_i > 0$, el operador global da

$$T_{Y^\ell}(X_0)_i = \frac{X_{0,i} \ell_i}{\sum_{k=1}^n X_{0,k} \ell_k} = \frac{P_0(E_i) \ell(\theta_i)}{\sum_{k=1}^n P_0(E_k) \ell(\theta_k)}.$$

La pertenencia a Δ_n° se sigue de la Proposición 3.1.

Para la convergencia: $P_0(E_k) = \int_{E_k} f(\theta) d\theta$ y $\ell(\theta_k)$ es el valor de ℓ en el punto medio de E_k . Por continuidad de $f \cdot \ell$, la suma $\sum_k P_0(E_k) \ell(\theta_k)$ es una suma de Riemann que converge a $\int_a^b f(\theta) \ell(\theta) d\theta$ cuando $h \rightarrow 0$. $\square$

Proposición 5.16 (Modelo conjugado exponencial como caso particular). *Sea $f(\theta) \propto \exp(\eta_0 \cdot T(\theta))$ un prior de la familia exponencial con parámetro natural $\eta_0 \in \mathbb{R}^k$ y estadístico suficiente $T : \Omega \rightarrow \mathbb{R}^k$. Sea $\ell(\theta) \propto \exp(\eta_\ell \cdot T(\theta))$ la verosimilitud de m observaciones, donde η_ℓ es la contribución del dato al parámetro natural.*

Usando el prior discreto por punto medio $\widetilde{X}_{0,i} \propto f(\theta_i)$ (Observación 5.12), el operador T_{Y^ℓ} produce un posterior discreto exactamente igual a

$$T_{Y^\ell}(\widetilde{X}_0)_i \propto \exp((\eta_0 + \eta_\ell) \cdot T(\theta_i)),$$

que es la evaluación de la densidad de la familia exponencial con parámetro natural actualizado $\eta_n := \eta_0 + \eta_\ell$ en los puntos medios θ_i .

Si en cambio se usan las masas exactas $X_{0,i} = P_0(E_i)$ (Proposición 5.15), la misma fórmula vale como aproximación con error $O(h^2)$ en las coordenadas normalizadas, bajo la hipótesis $f \in C^2(\Omega)$.

En ambos casos, cuando $n \rightarrow \infty$, el posterior discreto converge al posterior continuo con parámetro η_n .

Los dos casos conjugados clásicos son instancias directas:

- (I) Beta-Binomial. Prior $\text{Beta}(\alpha, \beta)$: $T(\theta) = (\log \theta, \log(1 - \theta))$, $\eta_0 = (\alpha - 1, \beta - 1)$. Verosimilitud binomial para x éxitos en m ensayos: $\eta_\ell = (x, m - x)$. Posterior:

$$T_{Y^\ell}(\widetilde{X}_0)_i \propto \theta_i^{\alpha+x-1} (1 - \theta_i)^{\beta+m-x-1},$$

evaluación de la densidad $\text{Beta}(\alpha + x, \beta + m - x)$ en θ_i .

- (II) Normal-Normal (varianza conocida σ^2). Prior $\mathcal{N}(\mu_0, \tau_0^2)$: $T(\theta) = (\theta, -\theta^2/2)$, $\eta_0 = (\mu_0/\tau_0^2, 1/\tau_0^2)$. Verosimilitud normal para m observaciones con media muestral $\bar{x}$: $\eta_\ell = (m\bar{x}/\sigma^2, m/\sigma^2)$. Posterior:

$$T_{Y^\ell}(\widetilde{X}_0)_i \propto \exp\left(-\frac{(\theta_i - \mu_n)^2}{2\tau_n^2}\right),$$

evaluación de la densidad $\mathcal{N}(\mu_n, \tau_n^2)$ en θ_i , con

$$\frac{1}{\tau_n^2} = \frac{1}{\tau_0^2} + \frac{m}{\sigma^2}, \quad \mu_n = \tau_n^2 \left(\frac{\mu_0}{\tau_0^2} + \frac{m\bar{x}}{\sigma^2} \right).$$

Demostración. Con el prior por punto medio, $\widetilde{X}_{0,i} \propto f(\theta_i) \propto \exp(\eta_0 \cdot T(\theta_i))$ exactamente, sin error de aproximación. La verosimilitud evaluada es $\ell_i = \ell(\theta_i) \propto \exp(\eta_\ell \cdot T(\theta_i))$. Aplicando T_{Y^ℓ} y cancelando constantes independientes de i por invariancia de escala (Proposición 3.2):

$$T_{Y^\ell}(\widetilde{X}_0)_i \propto \exp(\eta_0 \cdot T(\theta_i)) \cdot \exp(\eta_\ell \cdot T(\theta_i)) = \exp((\eta_0 + \eta_\ell) \cdot T(\theta_i)).$$

Con las masas exactas $X_{0,i} = P_0(E_i) = f(\theta_i)h + O(h^3)$, el factor h es constante en i y se cancela; el término $O(h^3)$ introduce un error $O(h^2)$ en las coordenadas normalizadas. Los casos (i) y (ii) se obtienen sustituyendo los estadísticos suficientes y parámetros naturales correspondientes; el factor $\binom{m}{x}$ en el caso binomial es constante en i y se cancela por invariancia de escala. La convergencia cuando $n \rightarrow \infty$ se sigue de la Proposición 5.15. $\square$

Observación 5.14 (Universalidad de la actualización en CI). *La Proposición 5.16 muestra que la regla de actualización conjugada —la suma de parámetros naturales $\eta_n = \eta_0 + \eta_\ell$ — es consecuencia directa de la ley de composición multiplicativa del operador T_{Y^ℓ} (Proposición 3.2): el producto de exponenciales en el numerador de $T_{Y^\ell}(X_0)$ corresponde exactamente a la suma de parámetros naturales. La estructura de CI no impone un modelo particular; cualquier par prior-verosimilitud de la familia exponencial produce un posterior en la misma familia, y su discretización sobre Π_n es un estado admisible en Δ_n° .*

Ejemplo 5.2 (Distribución estacionaria de una cadena de Markov en CI). *Sea $n = 2$ con matriz de transición*

$$K = \begin{pmatrix} 0,7 & 0,3 \\ 0,4 & 0,6 \end{pmatrix}.$$

La distribución estacionaria satisface $\pi K = \pi$ y $\pi_1 + \pi_2 = 1$:

$$\pi_1 = 0,7\pi_1 + 0,4\pi_2, \quad \pi_2 = 0,3\pi_1 + 0,6\pi_2.$$

Resolviendo: $0,3\pi_1 = 0,4\pi_2$, con $\pi_1 + \pi_2 = 1$, se obtiene $\pi = (4/7, 3/7)$. En CI, π es el único punto donde $Y^K(\pi) = 0$, es decir, el único punto fijo del operador local. La trayectoria desde cualquier $X_0 \in \Delta_2^\circ$ satisface $E_\pi(X_t) \searrow 0$ por la Proposición 5.7.

6. Sección E — Bloque variacional de alcanzabilidad

6.1. Objetivo del bloque

El objetivo de este bloque es reformular la pregunta

¿Es P alcanzable desde X_0 en t pasos bajo acciones admisibles $(\mathcal{K}_\varepsilon, \mathcal{U}_R)$?

como un problema geométrico y variacional sobre el interior del simplex de probabilidad. La base estructural se toma del marco validado en ?, la geometría afín del simplex y sus arcos elementales se toman de ?, y el formalismo del statistical bundle, la acción y las ecuaciones de Euler–Lagrange se toman de ?. El punto de partida informacional es el funcional E_P introducido en la Sección D (Definición 4.1), cuyo gradiente Fisher y dinámica asociada ya fueron establecidos allí (Proposiciones 4.1 y 4.2). Antes de pasar a una formulación variacional, examinaremos si la

clase markoviana admisible resulta demasiado amplia y, por tanto, trivializa la pregunta discreta de alcanzabilidad; si eso ocurre, introduciremos una subclase no degenerada para el estudio efectivo. La interpretación local del costo se apoya además en la geometría dual afín y en el teorema de Chentsov, que justifican el uso de la métrica de Fisher como referencia intrínseca de comparación (??).

Observación 6.1 (Procedencia de los enunciados). *Las marcas (Sección E) señalan construcciones propias de esta sección; las marcas (Prolnv_1) identifican resultados ya validados en el manuscrito base; y las marcas \fuentecite{\dots}\dots indican respaldo bibliográfico explícito.*

6.2. Hipótesis de trabajo

Fijemos $n \geq 2$, un objetivo $P \in \Delta_n^\circ$, un estado inicial $X_0 \in \Delta_n^\circ$ y parámetros $\varepsilon > 0$, $R > 0$, $\delta \in (0, 1)$. En adelante, todo paso discreto se estudiará bajo las restricciones refinadas introducidas más abajo.

Definición 6.1 (Matrices estocásticas por filas (Sección E)). *Definimos*

$$\mathcal{S}_n := \left\{ K \in \mathbb{R}^{n \times n} : K_{ij} \geq 0, \sum_{j=1}^n K_{ij} = 1 \text{ para todo } i \right\}.$$

Los elementos de $\mathcal{S}_n$ serán las matrices de transición admisibles para la parte markoviana del problema.

Definición 6.2 (Acciones admisibles (Sección E)). *Definimos*

$$\mathcal{K}_\varepsilon := \left\{ K \in \mathcal{S}_n : K_{ij} \geq \varepsilon \text{ para todo } i, j \right\}, \quad \mathcal{U}_R := \left\{ v \in \mathbb{R}^n : \|v\|_\infty \leq R \right\}.$$

Las acciones de Markov admisibles son los $K \in \mathcal{K}_\varepsilon$ y las acciones bayesianas admisibles son las evidencias L tales que $\log L \in \mathcal{U}_R$. Esta clase marca el punto de partida preliminar; la clase de trabajo no degenerada se introducirá más adelante.

Lema 6.1 (Degeneración de la clase markoviana actual (Sección E)). *Sea $Y \in \Delta_n^\circ$ tal que $Y_i \geq \varepsilon$ para todo i . Definimos la matriz constante por filas*

$$K_{ij}^Y := Y_j, \quad 1 \leq i, j \leq n.$$

Entonces $K^Y \in \mathcal{K}_\varepsilon$ y, para todo $X \in \Delta_n^\circ$, se tiene

$$L_{K^Y}(X) = XK^Y = Y.$$

En particular, $\mathcal{K}_\varepsilon$ contiene matrices de rango uno.

Demostración. Para cada i ,

$$\sum_{j=1}^n K_{ij}^Y = \sum_{j=1}^n Y_j = 1,$$

y, por hipótesis, $K_{ij}^Y = Y_j \geq \varepsilon$. Luego $K^Y \in \mathcal{K}_\varepsilon$.

Si $X \in \Delta_n^\circ$, entonces para cada j ,

$$(L_{K^Y}(X))_j = \sum_{i=1}^n X_i K_{ij}^Y = \sum_{i=1}^n X_i Y_j = Y_j \sum_{i=1}^n X_i = Y_j.$$

Por tanto, $L_{K^Y}(X) = Y$. □

Corolario 6.1 (Alcanzabilidad markoviana en un paso (Sección E)). Si $P \in \Delta_{n,\varepsilon}$, entonces P es alcanzable desde cualquier $X_0 \in \Delta_n^\circ$ en un solo paso mediante una acción de Markov admisible.

Demostración. Aplicar el lema anterior con $Y = P$. □

Observación 6.2 (Necesidad de no degeneración (Sección E)). La definición actual de $\mathcal{K}_\varepsilon$ no basta, por sí sola, para sostener una teoría discreta no trivial de alcanzabilidad. Para obtener una pregunta genuina de control será necesario imponer alguna restricción adicional, por ejemplo una condición de proximidad a la identidad, una cota espectral uniforme o una hipótesis de irreducibilidad más fuerte.

Definición 6.3 (Clase markoviana no degenerada (Sección E)). Definimos

$$\mathcal{K}_{\varepsilon,\delta}^{\text{nd}} := \left\{ K \in \mathcal{S}_n : K_{ij} \geq \varepsilon \text{ para todo } i, j, \max_{1 \leq i \leq n} \sum_{j=1}^n |K_{ij} - \delta_{ij}| \leq \delta \right\},$$

donde δ_{ij} denota la delta de Kronecker. Esta clase excluye el colapso de rango uno y fuerza cada paso markoviano a permanecer a distancia controlada de la identidad.

Proposición 6.1 (Paso markoviano acotado (Sección E)). Si $K \in \mathcal{K}_{\varepsilon,\delta}^{\text{nd}}$, entonces para todo $X \in \Delta_n$ se tiene

$$\|L_K(X) - X\|_1 \leq \delta.$$

En particular, ninguna acción de Markov en esta clase puede enviar arbitrariamente un estado a otro en un solo paso.

Demostración. Como $L_K(X) = XK$, se tiene

$$L_K(X) - X = X(K - I).$$

Luego,

$$\|L_K(X) - X\|_1 \leq \sum_{i=1}^n X_i \sum_{j=1}^n |K_{ij} - \delta_{ij}|.$$

Por la definición de $\mathcal{K}_{\varepsilon,\delta}^{\text{nd}}$,

$$\sum_{j=1}^n |K_{ij} - \delta_{ij}| \leq \delta \quad \forall i,$$

y, como $\sum_i X_i = 1$,

$$\|L_K(X) - X\|_1 \leq \delta.$$

□

Definición 6.4 (Núcleo markoviano de suavizado (Sección E)). Fijado $\varepsilon \in (0, 1/n)$, definimos la matriz

$$K_\varepsilon^{\text{sm}} := (k_{ij})_{i,j=1}^n, \quad k_{ij} := \begin{cases} 1 - (n-1)\varepsilon, & i = j, \\ \varepsilon, & i \neq j. \end{cases}$$

Este núcleo es estocástico por filas, tiene todas sus entradas al menos iguales a ε y representa una suavización uniforme de proximidad controlada a la identidad.

Proposición 6.2 (Propiedades del núcleo de suavizado (Sección E)). Si $0 < \varepsilon < 1/n$ y $\delta \geq 2(n-1)\varepsilon$, entonces $K_\varepsilon^{\text{sm}} \in \mathcal{K}_{\varepsilon, \delta}^{\text{nd}}$. Además, para todo $X \in \Delta_n$,

$$L_{K_\varepsilon^{\text{sm}}}(X) = (1 - n\varepsilon)X + \varepsilon(1, \dots, 1).$$

En particular, $L_{K_\varepsilon^{\text{sm}}}(X) \in \Delta_n^\circ$ y cada componente queda uniformemente separada de cero por una cota que depende solo de ε .

Demostración. Para todo i ,

$$\sum_{j=1}^n k_{ij} = (1 - (n-1)\varepsilon) + (n-1)\varepsilon = 1.$$

Luego $K_\varepsilon^{\text{sm}} \in \mathcal{S}_n$ y $K_{ij} \geq \varepsilon$ para todo i, j . Además, si $X \in \Delta_n$, entonces para cada j ,

$$(L_{K_\varepsilon^{\text{sm}}}(X))_j = \sum_{i=1}^n X_i k_{ij} = (1 - (n-1)\varepsilon)X_j + \varepsilon \sum_{i \neq j} X_i = (1 - n\varepsilon)X_j + \varepsilon.$$

En particular,

$$\sum_{j=1}^n (L_{K_\varepsilon^{\text{sm}}}(X))_j = 1 \quad \text{y} \quad (L_{K_\varepsilon^{\text{sm}}}(X))_j \geq \varepsilon.$$

Si $\delta \geq 2(n-1)\varepsilon$, entonces

$$\sum_{j=1}^n |k_{ij} - \delta_{ij}| = 2(n-1)\varepsilon \leq \delta,$$

y por tanto $K_\varepsilon^{\text{sm}} \in \mathcal{K}_{\varepsilon, \delta}^{\text{nd}}$. □

Definición 6.5 (Familia one-step refinada (Sección E)). Asociamos a estas restricciones la familia de pasos compuestos

$$\mathcal{A}_{\varepsilon, R, \delta}^{\text{nd}} := \left\{ T_Y \circ L_K : K \in \mathcal{K}_{\varepsilon, \delta}^{\text{nd}}, Y \in C_{\text{glob}}, \|Y\|_\infty \leq e^R - 1 \right\},$$

donde $L_K(X) := XK$ y T_Y es el operador informacional global de Y . Equivalentemente, si $L := 1 + Y$, cada paso tiene la forma

$$X_{t+1} = T_Y(X_t K_t) = B_L(X_t K_t).$$

Esta es la familia que se usará en adelante para la pregunta de alcanzabilidad no trivial.

Definición 6.6 (Trayectoria discreta admisible (Sección E)). Sea $T \in \mathbb{N}$. Una sucesión $X_0, \dots, X_T \in \Delta_n^\circ$ se llama trayectoria discreta admisible si existe una sucesión $A_0, \dots, A_{T-1}$ con $A_t \in \mathcal{A}_{\varepsilon, R, \delta}^{\text{nd}}$ tal que

$$X_{t+1} = A_t(X_t), \quad t = 0, \dots, T-1.$$

Definición 6.7 (Símplex truncado (Sección E)). Si $\eta > 0$, definimos

$$\Delta_{n, \eta} := \left\{ x \in \Delta_n^\circ : x_i \geq \eta \text{ para todo } i \right\}.$$

Lema 6.2 (Carta bayesiana local (Sección E)). *Fijado $X \in \Delta_n^\circ$, consideramos la aplicación*

$$\Phi_X : \mathcal{U}_R \rightarrow \Delta_n^\circ, \quad \Phi_X(v) := B_{e^v}(X).$$

Entonces Φ_X es de clase C^∞ , satisface $\Phi_X(0) = X$ y su diferencial en el origen es

$$D\Phi_X(0)(h)_i = X_i \left(h_i - \sum_{j=1}^n X_j h_j \right), \quad h \in \mathbb{R}^n.$$

En particular, $\ker D\Phi_X(0) = \text{span}\{(1, \dots, 1)\}$ y $\text{Im } D\Phi_X(0) = T_X \Delta_n^\circ$ (véase Definición 4.2).

Demostración. Escribimos

$$\Phi_X(v)_i = \frac{X_i e^{v_i}}{Z(v)}, \quad Z(v) := \sum_{j=1}^n X_j e^{v_j}.$$

Como $Z(v) > 0$, Φ_X es de clase C^∞ . Además, $Z(0) = 1$, luego $\Phi_X(0) = X$.

Para $h \in \mathbb{R}^n$,

$$D\Phi_X(0)(h)_i = \left. \frac{d}{ds} \right|_{s=0} \frac{X_i e^{s h_i}}{\sum_{j=1}^n X_j e^{s h_j}} = X_i \left(h_i - \sum_{j=1}^n X_j h_j \right).$$

Si $h = (1, \dots, 1)$, entonces $D\Phi_X(0)(h) = 0$. Recíprocamente, si $D\Phi_X(0)(h) = 0$, entonces $h_i = \sum_j X_j h_j$ para todo i , y por tanto $h \in \text{span}\{(1, \dots, 1)\}$. Luego

$$\ker D\Phi_X(0) = \text{span}\{(1, \dots, 1)\}.$$

Además,

$$\sum_{i=1}^n D\Phi_X(0)(h)_i = \sum_{i=1}^n X_i h_i - \sum_{j=1}^n X_j h_j \sum_{i=1}^n X_i = 0,$$

por lo que $\text{Im } D\Phi_X(0) \subset T_X \Delta_n^\circ$. Como ambos espacios tienen dimensión $n - 1$, la inclusión es igualdad. $\square$

Corolario 6.2 (Inversión local de la carta bayesiana (Sección E)). *Sea*

$$H_X := \left\{ h \in \mathbb{R}^n : \sum_{j=1}^n X_j h_j = 0 \right\}.$$

La restricción $\Phi_X|_{H_X}$ es un difeomorfismo local de clase C^∞ entre un entorno de $0 \in H_X$ y un entorno de X en Δ_n° . En particular, todo estado suficientemente cercano a X se escribe de manera única como $B_{e^v}(X)$ con $v \in H_X$ pequeño.

Demostración. Sea

$$H_X = \left\{ h \in \mathbb{R}^n : \sum_{j=1}^n X_j h_j = 0 \right\}.$$

Si $h \in H_X$, entonces

$$D\Phi_X(0)(h)_i = X_i h_i.$$

Por tanto, $D\Phi_X(0)|_{H_X}$ es inyectiva. Como

$$\dim H_X = n - 1 = \dim T_X \Delta_n^\circ,$$

es un isomorfismo lineal. El teorema de la función inversa aplica a $\Phi_X|_{H_X}$, y la conclusión sigue. $\square$

Proposición 6.3 (Control multiplicativo bajo evidencia acotada (Sección E)). Sea $L \in \mathbb{R}_{>0}^n$ tal que $\log L \in \mathcal{U}_R$. Entonces, para todo $X \in \Delta_n^\circ$ y todo $i = 1, \dots, n$,

$$e^{-2R}X_i \leq B_L(X)_i \leq e^{2R}X_i.$$

En particular,

$$B_L(X) \in \Delta_{n, \eta_R(X)}, \quad \eta_R(X) := e^{-2R} \min_{1 \leq i \leq n} X_i.$$

Demostración. De $\log L \in \mathcal{U}_R$ se sigue

$$e^{-R} \leq L_i \leq e^R, \quad i = 1, \dots, n.$$

Si $c := \sum_{j=1}^n X_j L_j$, entonces

$$e^{-R} \leq c \leq e^R.$$

Por definicion,

$$B_L(X)_i = \frac{X_i L_i}{c}.$$

Luego,

$$\frac{e^{-R}}{e^R} X_i \leq B_L(X)_i \leq \frac{e^R}{e^{-R}} X_i,$$

esto es,

$$e^{-2R}X_i \leq B_L(X)_i \leq e^{2R}X_i.$$

La cota inferior implica

$$B_L(X)_i \geq e^{-2R} \min_{1 \leq j \leq n} X_j = \eta_R(X).$$

□

Proposición 6.4 (Identificación con la corrección multiplicativa (ProInv_I; ?)). Sea $L \in \mathbb{R}_{>0}^n$ y defínase $Y := L - 1$. Entonces, para todo $X \in \Delta_n^\circ$,

$$B_L(X) = T_Y(X),$$

es decir, la actualización bayesiana usada aquí coincide con la corrección multiplicativa global introducida en ? bajo el cambio de variable $L = 1 + Y$.

Demostración. La fórmula de T_Y establecida en la Definición 3.2 de la Sección C es

$$T_Y(X)_i = \frac{X_i(1 + Y_i)}{\sum_{j=1}^n X_j(1 + Y_j)}.$$

Bajo el cambio de variable $L := 1 + Y$, esta expresión coincide exactamente con $B_L(X)_i = \frac{X_i L_i}{\sum_{j=1}^n X_j L_j}$. □

Proposición 6.5 (Cota del campo de corrección (Sección E)). Si $\log L \in \mathcal{U}_R$ y $Y := L - 1$, entonces $\|Y\|_\infty \leq e^R - 1$. En particular, la corrección multiplicativa global T_Y usada aquí actúa con amplitud uniformemente acotada por R .

Demostración. De $\log L \in \mathcal{U}_R$ se sigue

$$e^{-R} \leq L_i \leq e^R, \quad i = 1, \dots, n.$$

Si $Y := L - 1$, entonces

$$|Y_i| = |L_i - 1| \leq e^R - 1.$$

Luego

$$\|Y\|_\infty \leq e^R - 1.$$

□

Proposición 6.6 (Cota del paso compuesto (Sección E)). *Sea $X \in \Delta_n^\circ$, $K \in \mathcal{K}_{\varepsilon, \delta}^{\text{nd}}$ y $L \in \mathbb{R}_{>0}^n$ con $\log L \in \mathcal{U}_R$. Entonces*

$$\|B_L(XK) - X\|_1 \leq \delta + e^{2R} - 1.$$

Si además $X \in \Delta_{n, \eta}$ para algún $\eta > 0$, entonces

$$g_X(B_L(XK) - X, B_L(XK) - X) \leq \eta^{-1}(\delta + e^{2R} - 1)^2.$$

Demostración. Sea $Y := XK$. Por la proposición de paso markoviano acotado,

$$\|Y - X\|_1 \leq \delta.$$

Además, si $c := \sum_{j=1}^n Y_j L_j$, entonces

$$e^{-R} \leq c \leq e^R, \quad e^{-R} \leq L_i \leq e^R.$$

Por tanto,

$$e^{-2R} \leq \frac{L_i}{c} \leq e^{2R}, \quad i = 1, \dots, n.$$

Luego

$$|B_L(Y)_i - Y_i| = Y_i \left| \frac{L_i}{c} - 1 \right| \leq Y_i (e^{2R} - 1),$$

y al sumar en i se obtiene

$$\|B_L(Y) - Y\|_1 \leq e^{2R} - 1.$$

Finalmente,

$$\|B_L(XK) - X\|_1 \leq \|B_L(Y) - Y\|_1 + \|Y - X\|_1 \leq \delta + e^{2R} - 1.$$

Si además $X \in \Delta_{n, \eta}$, entonces para $u := B_L(XK) - X$,

$$g_X(u, u) = \sum_{i=1}^n \frac{u_i^2}{X_i} \leq \eta^{-1} \sum_{i=1}^n u_i^2 \leq \eta^{-1} \left(\sum_{i=1}^n |u_i| \right)^2 = \eta^{-1} \|u\|_1^2.$$

□

Observación 6.3 (Comparabilidad de la métrica de Fisher). *La definición del costo elemental fija el punto base en X ; por ello la evaluación en g_X es la adecuada. En subconjuntos compactos $\Delta_{n, \eta}$, las métricas de Fisher son uniformemente equivalentes, de modo que medir en el extremo inicial o en el extremo final produce cotas comparables hasta una constante uniforme.*

Definición 6.8 (Costo elemental discreto (Sección E)). Sea $X \in \Delta_n^\circ$, $K \in \mathcal{K}_{\varepsilon, \delta}^{\text{nd}}$ y $L \in \mathbb{R}_{>0}^n$ con $\log L \in \mathcal{U}_R$. Definimos el costo elemental del paso compuesto $X \mapsto B_L(XK)$ por

$$\mathfrak{c}_{P,\lambda}(X, K, L) := \frac{1}{2} g_X(B_L(XK) - X, B_L(XK) - X) + \lambda E_P(B_L(XK)).$$

Aquí g_X es la métrica de Fisher de la Definición 4.3 y E_P es el funcional de la Definición 4.1. Si $(X_t, K_t, L_t)_{t=0}^{T-1}$ es una trayectoria discreta admisible, su costo total es

$$\mathfrak{A}_{P,\lambda} := \sum_{t=0}^{T-1} \mathfrak{c}_{P,\lambda}(X_t, K_t, L_t).$$

Observación 6.4 (Lagrangiano como relajacion continua (Sección E)). El funcional $\mathfrak{A}_P$ se interpreta aquí como la relajacion formal de $\mathfrak{A}_{P,\lambda}$ cuando el mallado temporal se refina y los incrementos discretos son de primer orden. En este bloque no se afirma una teoria completa de Γ -convergencia; solo se fija el funcional continuo que servira como blanco variacional.

Proposición 6.7 (Persistencia en el interior (Sección E)). Sea $T \in \mathbb{N}$ y sea $X_0, \dots, X_T$ una trayectoria discreta admisible. Entonces existe

$$\eta_* := e^{-2R} \min\left\{\varepsilon, \min_{1 \leq i \leq n} (X_0)_i\right\} > 0$$

tal que $X_t \in \Delta_{n,\eta_*}$ para todo $t = 0, \dots, T$. En particular, la imagen de la trayectoria queda contenida en un subconjunto compacto de Δ_n° , con cota uniforme independiente de T .

Demostración. Escribamos

$$X_{t+1} = B_{L_t}(X_t K_t).$$

Para cada i ,

$$(X_t K_t)_i = \sum_{j=1}^n (X_t)_j (K_t)_{ji} \geq \varepsilon \sum_{j=1}^n (X_t)_j = \varepsilon.$$

Por la proposición de control multiplicativo,

$$(X_{t+1})_i \geq e^{-2R} (X_t K_t)_i \geq e^{-2R} \varepsilon.$$

Como $X_0 \in \Delta_n^\circ$, se tiene también $(X_0)_i \geq \min_j (X_0)_j$. En consecuencia, si

$$\eta_* := e^{-2R} \min\left\{\varepsilon, \min_{1 \leq j \leq n} (X_0)_j\right\},$$

entonces $X_t \in \Delta_{n,\eta_*}$ para todo $t = 0, \dots, T$. □

Definición 6.9 (Arcos geométricos elementales (ref1; ?)). Para $p, q \in \Delta_n^\circ$, definimos el arco de mezcla y el arco exponencial por

$$m_{p,q}(s) := (1-s)p + sq, \quad e_{p,q}(s)_i := \frac{p_i^{1-s} q_i^s}{\sum_{j=1}^n p_j^{1-s} q_j^s}, \quad s \in [0, 1].$$

Proposición 6.8 (Regularidad de los arcos (ref1; ?)). *Para cualesquiera $p, q \in \Delta_n^\circ$, las aplicaciones $m_{p,q}$ y $e_{p,q}$ son curvas C^∞ en $[0, 1]$ con valores en Δ_n° , y satisfacen*

$$m_{p,q}(0) = e_{p,q}(0) = p, \quad m_{p,q}(1) = e_{p,q}(1) = q.$$

Demostración. El arco de mezcla

$$m_{p,q}(s) = (1-s)p + sq$$

es afín en s ; por tanto, es C^∞ . Para el arco exponencial, si

$$D(s) := \sum_{j=1}^n p_j^{1-s} q_j^s,$$

entonces $D(s) > 0$ y $D \in C^\infty([0, 1])$. Cada componente

$$e_{p,q}(s)_i = \frac{p_i^{1-s} q_i^s}{D(s)}$$

es cociente de funciones C^∞ con denominador positivo; luego $e_{p,q} \in C^\infty([0, 1]; \Delta_n^\circ)$. Además,

$$m_{p,q}(0) = e_{p,q}(0) = p, \quad m_{p,q}(1) = e_{p,q}(1) = q.$$

□

Observación 6.5 (Interpolación continua auxiliar (Sección E)). *Toda trayectoria discreta admisible $X_0, \dots, X_T$ admite una interpolación continua por concatenación de arcos de mezcla o de arcos exponenciales. Esta interpolación se usa solo como representante geométrico de la sucesión discreta; no se afirma ninguna propiedad minimizante para la acción.*

Definición 6.10 (Función potencial de referencia (ProInv_I; ?)). *Para $P \in \Delta_n^\circ$, definimos*

$$E_P(X) := D_{\text{KL}}(P \| X) = \sum_{i=1}^n P_i \log \left(\frac{P_i}{X_i} \right), \quad X \in \Delta_n^\circ.$$

Proposición 6.9 (Propiedades del potencial KL (ProInv_I; ?)). *La función $E_P : \Delta_n^\circ \rightarrow \mathbb{R}$ es de clase C^∞ , convexa en toda carta afín del símplex, y posee un único minimizador global, dado por $X = P$. Además, su gradiente respecto de la métrica de Fisher satisface*

$$\text{grad}_g E_P(X) = X - P, \quad X \in \Delta_n^\circ.$$

Demostración. Se tiene

$$E_P(X) = \sum_{i=1}^n P_i \log P_i - \sum_{i=1}^n P_i \log X_i.$$

Por tanto $E_P \in C^\infty(\Delta_n^\circ)$. Para $u \in T_X \Delta_n^\circ$, $\sum_i u_i = 0$, y

$$DE_P(X)[u] = - \sum_{i=1}^n \frac{P_i}{X_i} u_i.$$

Si $g_X(u, v) = \sum_i u_i v_i / X_i$, entonces

$$g_X(X - P, u) = \sum_{i=1}^n \frac{X_i - P_i}{X_i} u_i = \sum_{i=1}^n u_i - \sum_{i=1}^n \frac{P_i}{X_i} u_i = - \sum_{i=1}^n \frac{P_i}{X_i} u_i.$$

Luego

$$\text{grad}_g E_P(X) = X - P.$$

Además,

$$D^2 E_P(X)[u, u] = \sum_{i=1}^n \frac{P_i}{X_i^2} u_i^2 > 0 \quad (u \neq 0, \sum_i u_i = 0),$$

por lo que E_P es estrictamente convexa en cada carta afín. Finalmente,

$$E_P(X) = D_{\text{KL}}(P \| X) \geq 0, \quad E_P(X) = 0 \iff X = P,$$

y por tanto P es el único minimizador global. $\square$

Proposición 6.10 (Cuadraticidad local del potencial (Sección E; ?)). *El diferencial de E_P se anula en P y el hessiano de E_P en P coincide con la métrica de Fisher. En particular, en coordenadas tangentes centradas en P ,*

$$E_P(P + \xi) = \frac{1}{2} g_P(\xi, \xi) + o(\|\xi\|^2) \quad (\xi \rightarrow 0, \sum_i \xi_i = 0).$$

Demostración. Por la proposición anterior, $DE_P(P) = 0$. Además, para $\xi \in T_P \Delta_n^\circ$,

$$D^2 E_P(P)[\xi, \xi] = \sum_{i=1}^n \frac{P_i}{P_i^2} \xi_i^2 = \sum_{i=1}^n \frac{\xi_i^2}{P_i} = g_P(\xi, \xi).$$

El desarrollo de Taylor en una carta afín centrada en P da

$$E_P(P + \xi) = E_P(P) + DE_P(P)[\xi] + \frac{1}{2} D^2 E_P(P)[\xi, \xi] + o(\|\xi\|^2) = \frac{1}{2} g_P(\xi, \xi) + o(\|\xi\|^2).$$

$\square$

Definición 6.11 (Statistical bundle finito (ref2; ?)). *Denotamos por*

$$S\Delta_n^\circ := \{(q, w) \in \Delta_n^\circ \times \mathbb{R}^n : \sum_{i=1}^n w_i = 0\}$$

el statistical bundle finito. En cada fibra $T_q \Delta_n^\circ$ se considera la forma bilineal de Fisher

$$g_q(u, v) := \sum_{i=1}^n \frac{u_i v_i}{q_i}.$$

Definición 6.12 (Lagrangiano de alcanzabilidad (ref2; ?)). *Fijado $\lambda > 0$, definimos el Lagrangiano*

$$\mathcal{L}_P(q, w) := \frac{1}{2} g_q(w, w) + \lambda E_P(q), \quad (q, w) \in S\Delta_n^\circ.$$

Si $q : [0, T] \rightarrow \Delta_n^\circ$ es una curva de clase C^1 , su acción es

$$\mathcal{A}_P(q) := \int_0^T \mathcal{L}_P(q(t), \dot{q}(t)) dt.$$

Proposición 6.11 (Levantamiento al statistical bundle (ref2; ?)). Si $q : [0, T] \rightarrow \Delta_n^\circ$ es de clase C^2 , entonces

$$\gamma(t) := (q(t), \dot{q}(t))$$

define una curva de clase C^1 en $S\Delta_n^\circ$. En particular, la velocidad y la aceleración de q quedan bien definidas en el marco afín del statistical bundle descrito en ?.

Demostración. Si $q \in C^2([0, T]; \Delta_n^\circ)$, entonces $\dot{q} \in C^1([0, T]; \mathbb{R}^n)$. Como

$$\sum_{i=1}^n q_i(t) = 1,$$

al derivar se obtiene

$$\sum_{i=1}^n \dot{q}_i(t) = 0.$$

Por tanto,

$$\gamma(t) := (q(t), \dot{q}(t)) \in S\Delta_n^\circ \quad \text{para todo } t \in [0, T],$$

y $\gamma \in C^1([0, T]; S\Delta_n^\circ)$. □

Teorema 6.1 (Existencia de minimizador para el problema relajado (Sección E)). Sean $X_0, P \in \Delta_n^\circ$ y $T > 0$. Consideremos la clase de curvas

$$\mathcal{C}_{\eta_T}(X_0, P; T) := \left\{ q \in H^1([0, T]; \Delta_n^\circ) : q(0) = X_0, q(T) = P, q([0, T]) \subset \Delta_{n, \eta_T} \right\}.$$

Entonces la acción $\mathcal{A}_P$ es acotada inferiormente en $\mathcal{C}_{\eta_T}(X_0, P; T)$ y, bajo la coercividad del término cinético, admite al menos un minimizador en dicha clase.

Demostración. Sea $(q^m)_{m \in \mathbb{N}} \subset \mathcal{C}_{\eta_T}(X_0, P; T)$ una sucesión minimizante. Como $q^m([0, T]) \subset \Delta_{n, \eta_T}$ y Δ_{n, η_T} es compacto, el término potencial $E_P(q^m)$ es uniformemente acotado inferiormente. La coercividad del término cinético implica acotación de $(\dot{q}^m)$ en $L^2([0, T])$; por tanto, (q^m) es acotada en $H^1([0, T])$.

Por reflexividad, existe una subsucesión, todavía denotada q^m , y una curva $q^* \in H^1([0, T])$ tales que

$$q^m \rightharpoonup q^* \text{ en } H^1, \quad q^m \rightarrow q^* \text{ en } C^0([0, T]).$$

Luego $q^*(0) = X_0$, $q^*(T) = P$ y $q^*([0, T]) \subset \Delta_{n, \eta_T}$. Por semicontinuidad inferior del término cinético y continuidad de E_P respecto de la convergencia uniforme,

$$\mathcal{A}_P(q^*) \leq \liminf_{m \rightarrow \infty} \mathcal{A}_P(q^m) = \inf_{q \in \mathcal{C}_{\eta_T}(X_0, P; T)} \mathcal{A}_P(q).$$

Por consiguiente, q^* es minimizador. □

Proposición 6.12 (Ecuaciones de Euler–Lagrange (ref2; ?)). Si $q \in \mathcal{C}_{\eta_T}(X_0, P; T)$ es un minimizador de $\mathcal{A}_P$ y q es de clase C^2 , entonces satisface la ecuación de Euler–Lagrange

$$\frac{d}{dt} \left(\partial_w \mathcal{L}_P(q(t), \dot{q}(t)) \right) - \partial_q \mathcal{L}_P(q(t), \dot{q}(t)) = 0$$

en cualquier carta del statistical bundle.

Demostración. Sea $\varphi \in C_c^\infty((0, T); \mathbb{R}^n)$ tal que $\sum_{i=1}^n \varphi_i = 0$. Para $q^\epsilon := q + \epsilon\varphi$,

$$0 = \frac{d}{d\epsilon} \Big|_{\epsilon=0} \mathcal{A}_P(q^\epsilon) = \int_0^T \sum_{i=1}^n \left(\frac{\dot{q}_i}{q_i} \dot{\varphi}_i - \frac{1}{2} \frac{\dot{q}_i^2}{q_i^2} \varphi_i - \lambda \frac{P_i}{q_i} \varphi_i \right) dt.$$

Integrando por partes y usando $\varphi(0) = \varphi(T) = 0$, queda

$$\int_0^T \sum_{i=1}^n \left(-\frac{d}{dt} \left(\frac{\dot{q}_i}{q_i} \right) - \frac{1}{2} \frac{\dot{q}_i^2}{q_i^2} - \lambda \frac{P_i}{q_i} \right) \varphi_i dt = 0.$$

El anulador del subespacio $\{\varphi : \sum_i \varphi_i = 0\}$ es $\text{span}\{(1, \dots, 1)\}$; por tanto existe $\mu(t)$ tal que

$$\frac{d}{dt} \left(\partial_w \mathcal{L}_P(q(t), \dot{q}(t)) \right) - \partial_q \mathcal{L}_P(q(t), \dot{q}(t)) = 0$$

en cualquier carta del statistical bundle. □

Corolario 6.3 (Caso puramente cinético (ref1+ref2; ??)). *Si $\lambda = 0$, entonces las trayectorias críticas de $\mathcal{A}_P$ son geodésicas de la geometría afín del símplex. En las cartas exponenciales y de mezcla de ?, estas trayectorias son precisamente las curvas de aceleración nula.*

Demostración. Si $\lambda = 0$, entonces

$$\mathcal{L}_P(q, w) = \frac{1}{2} g_q(w, w).$$

Las curvas críticas de la energía cinética en una variedad riemanniana satisfacen la ecuación geodésica. En las cartas de mezcla y exponenciales de ?, dichas geodésicas son exactamente las curvas de aceleración nula. Luego las trayectorias críticas de $\mathcal{A}_P$ son geodésicas de la geometría afín del símplex. □

Teorema 6.2 (Discretización admisible del minimizador (Sección E)). *Sea $q^* \in \mathcal{C}_{\eta_T}(X_0, P; T)$ un minimizador de $\mathcal{A}_P$ de clase C^2 . Fijemos el núcleo markoviano de suavizado K_ϵ^{sm} de la Definición anterior, con $0 < \epsilon < 1/n$ y $\delta \geq 2(n-1)\epsilon$.*

Entonces existe una partición $0 = t_0 < t_1 < \dots < t_m = T$ suficientemente fina y existen constantes $h_0 > 0$ y $R_0 > 0$ tales que, si $h := \max_k (t_{k+1} - t_k) \leq h_0$ y definimos

$$z_k := q^*(t_k) K_\epsilon^{\text{sm}}, \quad L_{k,i} := \frac{q_i^*(t_{k+1})}{(z_k)_i}, \quad i = 1, \dots, n,$$

entonces $L_k = (L_{k,1}, \dots, L_{k,n}) \in \mathbb{R}_{>0}^n$, $\log L_k \in \mathcal{U}_{R_0}$ y

$$q^*(t_{k+1}) = B_{L_k}(z_k) = B_{L_k}(q^*(t_k) K_\epsilon^{\text{sm}}), \quad k = 0, \dots, m-1.$$

En particular, para todo $R \geq R_0$ la sucesión $q^(t_0), \dots, q^*(t_m)$ es una trayectoria discreta admisible bajo $\mathcal{A}_{\epsilon, R, \delta}^{\text{nd}}$, realizada mediante el paso compuesto canónico*

$$X_{t+1} = B_{L_t}(X_t K_\epsilon^{\text{sm}}).$$

Demostración. Sea $q^* \in \mathcal{C}_{\eta_T}(X_0, P; T)$. Fijemos una partición $0 = t_0 < t_1 < \dots < t_m = T$ y pongamos

$$z_k := q^*(t_k)K_\varepsilon^{\text{sm}}, \quad L_{k,i} := \frac{q_i^*(t_{k+1})}{(z_k)_i}.$$

Como $q^*(t_k) \in \Delta_{n,\eta_T}$ y cada entrada de $K_\varepsilon^{\text{sm}}$ es al menos ε ,

$$(z_k)_i = \sum_{j=1}^n q_j^*(t_k)(K_\varepsilon^{\text{sm}})_{ji} \geq \varepsilon.$$

Además, $q_i^*(t_{k+1}) \in [\eta_T, 1]$, luego

$$\eta_T \leq L_{k,i} \leq \frac{1}{\varepsilon}.$$

Por consiguiente,

$$\log L_k \in \mathcal{U}_{R_0}, \quad R_0 := \max\{-\log \eta_T, \log(1/\varepsilon)\}.$$

Ahora,

$$\sum_{j=1}^n (z_k)_j L_{k,j} = \sum_{j=1}^n q_j^*(t_{k+1}) = 1,$$

y por tanto

$$B_{L_k}(z_k)_i = \frac{(z_k)_i L_{k,i}}{\sum_{j=1}^n (z_k)_j L_{k,j}} = q_i^*(t_{k+1}).$$

De aquí

$$q^*(t_{k+1}) = B_{L_k}(q^*(t_k)K_\varepsilon^{\text{sm}})$$

para todo k . Si $R \geq R_0$, entonces cada paso pertenece a $\mathcal{A}_{\varepsilon,R,\delta}^{\text{nd}}$. □

Proposición 6.13 (Euler–Lagrange en coordenadas baricentricas (Sección E)). *Sea q una curva crítica de $\mathcal{A}_P$ con $\sum_{i=1}^n q_i(t) = 1$. Entonces existe una función escalar $\mu(t)$ tal que, para cada $i = 1, \dots, n$,*

$$\frac{d}{dt} \left(\frac{\dot{q}_i(t)}{q_i(t)} \right) + \frac{1}{2} \frac{\dot{q}_i(t)^2}{q_i(t)^2} + \lambda \frac{P_i}{q_i(t)} = \mu(t),$$

equivalentemente,

$$\ddot{q}_i(t) - \frac{1}{2} \frac{\dot{q}_i(t)^2}{q_i(t)} + \lambda P_i - \mu(t) q_i(t) = 0.$$

La función $\mu(t)$ es el multiplicador de Lagrange asociado a la restricción $\sum_i q_i = 1$.

Demostración. Consideremos el funcional aumentado

$$\tilde{\mathcal{L}}_P(q, \dot{q}, \mu) := \frac{1}{2} \sum_{i=1}^n \frac{\dot{q}_i^2}{q_i} + \lambda \sum_{i=1}^n P_i \log \left(\frac{P_i}{q_i} \right) - \mu(t) \left(\sum_{i=1}^n q_i - 1 \right).$$

Entonces

$$\partial_{\dot{q}_i} \tilde{\mathcal{L}}_P = \frac{\dot{q}_i}{q_i}, \quad \partial_{q_i} \tilde{\mathcal{L}}_P = -\frac{1}{2} \frac{\dot{q}_i^2}{q_i^2} - \lambda \frac{P_i}{q_i} - \mu(t).$$

La ecuación de Euler–Lagrange da

$$\frac{d}{dt} \left(\frac{\dot{q}_i}{q_i} \right) + \frac{1}{2} \frac{\dot{q}_i^2}{q_i^2} + \lambda \frac{P_i}{q_i} = \mu(t), \quad i = 1, \dots, n.$$

Multiplicando por q_i y usando

$$q_i \frac{d}{dt} \left(\frac{\dot{q}_i}{q_i} \right) = \ddot{q}_i - \frac{\dot{q}_i^2}{q_i},$$

se obtiene

$$\ddot{q}_i - \frac{1}{2} \frac{\dot{q}_i^2}{q_i} + \lambda P_i - \mu(t) q_i = 0.$$

□

Corolario 6.4 (Límite estacionario formal (Sección E)). *Consideremos el funcional reescalado $\mathcal{L}_{P,\eta}(q, w) := \frac{\eta}{2} g_q(w, w) + \lambda E_P(q)$. Al pasar formalmente al límite $\eta \downarrow 0$, las trayectorias críticas quedan forzadas a satisfacer*

$$\text{grad}_g E_P(q) = 0,$$

y por tanto

$$q = P.$$

Este paso no produce por sí mismo un flujo de primer orden; sólo produce la condición estacionaria del potencial.

Demostración. La ecuación variacional asociada a $\mathcal{L}_{P,\eta}$ contiene el término inercial multiplicado por η y el término de potencial $\lambda \text{grad}_g E_P(q)$. Al pasar formalmente al límite $\eta \downarrow 0$, desaparece la contribución inercial y queda

$$\text{grad}_g E_P(q) = 0.$$

Por la proposición sobre el potencial KL,

$$\text{grad}_g E_P(q) = q - P.$$

Luego $q = P$.

□

Observación 6.6 (Flujo heredado de la Sección D). *El flujo $\dot{X} = P - X$ y su convergencia a P son consecuencia directa de la Proposición 4.1 y la Proposición 4.2 de la Sección D. Este resultado no se rededuce aquí; se adopta como punto de partida del análisis variacional.*

6.3. Observaciones geométricas finales

Observación 6.7 (Dualidad e/m del paso compuesto (ref3; ?)). *El paso libre $X_t K_\varepsilon^{\text{sm}}$ y la corrección bayesiana B_{L_t} se interpretan, respectivamente, como una componente m -afín y una componente e -afín del proceso compuesto. Bajo esta lectura, la función de costo separa el transporte libre y la corrección informacional, y el caso $\lambda = 0$ del Corolario anterior corresponde al régimen puramente geodésico del simplex dually flat.*

Observación 6.8 (Fisher como métrica natural (ref3; ??)). *La selección de la métrica de Fisher en el funcional continuo no es arbitraria: por el teorema de Chentsov, esta es la métrica intrínseca compatible con las transformaciones markovianas finitas. En consecuencia, el puente discreto-continuo debe formularse en términos de Fisher/KL y no mediante una métrica composicional auxiliar.*

Problema abierto 6.1 (Criterio variacional de alcanzabilidad (Sección E)). *Determinar condiciones necesarias y suficientes para que, dados $X_0, P \in \Delta_n^\circ$ y $T \in \mathbb{N}$, exista una trayectoria discreta admisible de longitud T que conecte X_0 con P bajo las acciones refinadas $(\mathcal{K}_{\varepsilon, \delta}^{\text{nd}}, \mathcal{U}_R)$, y comparar dicho criterio con la existencia de minimizadores de la acción relajada $\mathcal{A}_P$.*

7. Conclusiones y perspectivas

En este trabajo se desarrolló un marco interno para el estudio de transformaciones entre distribuciones de probabilidad discretas sobre el símplex. En particular, se introdujo el concepto de correcciones multiplicativas y su estructura asociada, distinguiendo entre correcciones locales dependientes del estado y correcciones globales definidas de manera uniforme. A partir de ello, se construyeron operadores informacionales que preservan el símplex y cuya ley de composición corresponde a un producto coordinado de factores positivos.

Asimismo, se estableció una conexión con la geometría de información mediante la métrica de Fisher y la divergencia de Kullback–Leibler, mostrando que la dinámica inducida por el gradiente conduce a un flujo explícito que converge hacia una distribución de referencia. Esto proporciona una interpretación dinámica del proceso de corrección como una relajación informacional.

En continuidad con este desarrollo, el manuscrito unificado podría orientarse hacia diversas extensiones estructurales del marco descrito. En particular, resulta natural explorar la relación entre los operadores introducidos y operadores de tipo Markov, con el objetivo de analizar si estos últimos pueden interpretarse como una subfamilia dentro del conjunto de transformaciones multiplicativas. De manera análoga, podría estudiarse la existencia de una representación multiplicativa de operadores de Markov y la posible emergencia de una estructura de tipo grupoide.

Por otra parte, una dirección relevante consiste en incorporar el enfoque del análisis de datos composicionales de Aitchison, en el cual el símplex se dota de una geometría basada en coordenadas log-ratio. En este contexto, podría investigarse si las correcciones multiplicativas del marco descrito admiten una representación lineal en dichas coordenadas, lo que permitiría reinterpretar las transformaciones en términos de estructuras vectoriales asociadas y analizar nociones como ortogonalidad y proyección.

Finalmente, también podría considerarse la conexión con problemas de inferencia estadística. En particular, sería de interés analizar si ciertos procedimientos, como la actualización bayesiana, pueden interpretarse dentro de este esquema como correcciones óptimas, así como explorar posibles vínculos con herramientas del análisis multivariado composicional, incluyendo matrices de covarianza en coordenadas log-ratio, métodos tipo PCA y técnicas de agrupamiento. Estas líneas constituyen posibles direcciones de desarrollo y requerirán un análisis más detallado en etapas posteriores.